La mejora continua en la producción quesera

Análisis de datos industriales

Juan Riera

20 de marzo de 2026

Tabla de contenidos

1. Introducción **1**
- 1.1. Por qué aprender Python y R, además de la hoja de cálculo . . . 1
- 1.2. Recursos adicionales . . . 2
- 1.3. Nota para los equipos docentes . . . 2
- 1.4. Sobre este libro . . . 4

I. Herramientas y técnicas básicas **5**

2. El análisis de datos de producción en el entorno industrial. **7**
- 2.1. El método científico y la variabilidad . . . 8
- 2.2. El pensamiento estadístico como filosofía de trabajo . . . 8
- 2.3. Los datos industriales . . . 9
- 2.4. La calidad de los datos como condición previa al análisis . . . 11
- 2.5. Resumen del capítulo . . . 12

3. Herramientas para el análisis. La reproducibilidad. **13**
- 3.1. Introducción . . . 13
- 3.2. La hoja de cálculo . . . 13
- 3.3. Python y R: las herramientas principales . . . 16
- 3.4. Otras herramientas del ecosistema . . . 16
- 3.5. El concepto de reproducibilidad . . . 17
- 3.6. Scripts frente a hoja de cálculo: ventajas para la reproducibilidad . . . 18
- 3.7. Resumen del capítulo . . . 18

4. Conceptos fundamentales, organización de datos y flujo de trabajo **21**
- 4.1. Introducción . . . 21
- 4.2. Conceptos básicos: datos, variables y casos . . . 22
- 4.3. El flujo de trabajo . . . 24
- 4.4. Etapas de un flujo de trabajo estructurado . . . 24
- 4.5. Los datos ordenados o *tidy data* . . . 26
- 4.6. Ficheros planos y ficheros CSV . . . 28
- 4.7. Práctica . . . 30
- 4.8. Para resolver . . . 30
- 4.9. Resumen del capítulo . . . 30

5. La exploración de los datos mediante gráficos. **31**
- 5.1. El diagrama de tallo y hojas (*stem and leaf plot* o *stemplot*) . . . 32
- 5.2. Distribuciones de frecuencias . . . 35
- 5.3. R base . . . 37
- 5.4. R con dplyr . . . 37
- 5.5. R base . . . 37

5.6. R con dplyr . . . 38
5.7. Diagrama de barras . . . 39
5.8. Histograma . . . 40
5.9. La forma de los datos . . . 43
5.10. Diagrama de caja o *boxplot* . . . 45
5.11. Alternativas al boxplot . . . 51
5.12. Gráficos de densidad . . . 52
5.13. Gráficos de dispersión . . . 54
5.14. Gráficos de series temporales . . . 56
5.15. Algunas sugerencias para la creación de gráficos . . . 58
5.16. Resumen del capítulo . . . 60

6. Medidas centrales y medidas de dispersión: la media y la varianza. 63
6.1. Introducción . . . 63
6.2. Recursos utilizados . . . 64
6.3. La media aritmética: un ejemplo de cálculo. . . . 64
6.4. Las medidas de dispersión: la varianza y la desviación típica . . . 70
6.5. Las limitaciones de la media y la desviación típica . . . 74
6.6. Cálculo manual de la media y la desviación típica . . . 77
6.7. Cálculo de estadísticos básicos en Python y R . . . 78
6.8. Resumen del capítulo . . . 78

7. Distribuciones de probabilidad y la distribución normal 81
7.1. De la frecuencia relativa a la probabilidad . . . 81
7.2. Distribuciones discretas y continuas . . . 82
7.3. Las formas más frecuentes en datos industriales . . . 83
7.4. La distribución normal . . . 84
7.5. Cálculo de probabilidades con Python y R . . . 86
7.6. Comprobación de normalidad: el QQ-plot . . . 87
7.7. Resumen del capítulo . . . 88

8. La relación entre dos variables: correlación y regresion 89
8.1. Más allá de una variable: la relación entre dos variables . . . 89
8.2. El coeficiente de correlación de Pearson . . . 90
8.3. La línea de regresión . . . 91
8.4. Correlación no implica causalidad . . . 92
8.5. Correlaciones en los datos de pingüinos . . . 95
8.6. Resumen del capítulo . . . 95

9. El control estadístico de procesos 97
9.1. El origen del control estadístico de procesos . . . 97
9.2. Causas comunes y causas especiales . . . 98
9.3. Variabilidad a corto plazo y variabilidad a largo plazo . . . 100
9.4. El gráfico de control: la herramienta de Shewhart . . . 101
9.5. Caso práctico: control del proceso de llenado de yogures . . . 102
9.6. La capacidad del proceso . . . 104
9.7. Actuar correctamente: la regla de oro del SPC . . . 109
9.8. Resumen del capítulo . . . 109

10. Introducción al diseño de experimentos **111**
10.1. El problema del ensayo y error: por qué "un factor a la vez" no es suficiente . . . 111
10.2. Los conceptos básicos . . . 112
10.3. El diseño factorial 2^2 . . . 113
10.4. El caso práctico: temperatura y dosis de cuajo . . . 113
10.5. Los gráficos de efectos principales . . . 113
10.6. El gráfico de interacciones . . . 114
10.7. Los puntos centrales . . . 116
10.8. Herramientas para el diseño de experimentos . . . 116
10.9. Del diseño de dos factores a diseños más complejos . . . 117
10.10El diseño de experimentos en la era de la inteligencia artificial . . . 118
10.11Resumen del capítulo . . . 119

11. Comunicación de resultados **121**
11.1. El análisis que nadie lee no existe . . . 121
11.2. La audiencia determina el mensaje . . . 121
11.3. Los principios de Tufte: menos es más . . . 122
11.4. Los gráficos a evitar . . . 123
11.5. ¿Qué gráfico usar? Recursos de referencia . . . 123
11.6. Ejemplos comparativos: el gráfico incorrecto y el gráfico correcto . . . 124
11.7. El color como información, no como decoración . . . 125
11.8. De los gráficos del libro a la comunicación real . . . 126
11.9. Organizar una presentación de resultados . . . 128
11.10Informes reproducibles: Quarto y el código abierto . . . 129
11.11Recursos para seguir aprendiendo . . . 130
11.12Resumen del capítulo . . . 131

II. Aplicaciones en producción quesera **133**

12. Análisis exploratorio de una fabricación de queso camembert. **135**
12.1. Flujo de trabajo . . . 136
12.2. Importar los datos . . . 136
12.3. Verificar los datos . . . 137
12.4. Análisis variable a variable . . . 138
12.5. Análisis de otras variables . . . 145
12.6. Conclusiones y plan de acción . . . 148
12.7. Resumen del capítulo . . . 150
12.8. Ejercicios propuestos . . . 150
12.9. Práctica en Google Colab . . . 151

13. Los costes de materia: el precio de la leche **153**
13.1. El pago de la leche por calidad en España . . . 153
13.2. Conceptos clave del pago por calidad . . . 153
13.3. Aplicación práctica: ejemplo de cálculo . . . 154
13.4. Cálculo del precio de la leche mediante la hoja de cálculo. . . . 156
13.5. Construcción del precio de la materia grasa y la proteína a partir del precio de la leche . . . 158
13.6. Resumen del capítulo . . . 161

14. El balance de materia **163**
14.1. El proceso de elaboración de queso. 163
14.2. Etapas en el proceso de fabricación de queso. 164
14.3. Las pérdidas de materia en quesería 166
14.4. Análisis de un caso 167
14.5. Balance de materia con la hoja de cálculo 168
14.6. Diseñar un plan de acción para la reducción de pérdidas 173
14.7. Otros casos más complejos: mezclas de leche, estandarizaciones diferentes, ventas de materia y otras situaciones 175
14.8. Resumen del capítulo 175

15. El rendimiento quesero **177**
15.1. Un ejemplo de cálculo de rendimientos 178
15.2. El estándar técnico de fabricación 180
15.3. Construcción de un estándar técnico de fabricación 181
15.4. El estándar técnico de fabricación en la hoja de cálculo 185
15.5. La importancia de la estandarización de la leche 186
15.6. El análisis de las desviaciones de rendimiento 187
15.7. Análisis de una fabricación 188
15.8. Resumen del capítulo 197

III. Otras aplicaciones **199**

16. El análisis del sistema de medición **201**
16.1. ¿Qué es una medida? 201
16.2. Las fuentes de variación en el laboratorio 202
16.3. Veracidad y precisión: la norma ISO 5725-1:2023 203
16.4. Repetibilidad y reproducibilidad 205
16.5. Caso práctico: evaluación de analistas en el método Gerber 205
16.6. Seguimiento temporal del sistema de medición 208
16.7. Resumen del capítulo 210

IV. La metodología para la mejora continua **211**

17. La variabilidad industrial **213**
17.1. Qué es la variabilidad industrial 213
17.2. Consecuencias económicas y de calidad: el coste de no medir 214
17.3. Cómo hemos medido la variabilidad a lo largo del libro: un recorrido 215
17.4. Cómo reducir la variabilidad: herramientas, prioridades y objetivos realistas . . . 216
17.5. Cómo hacer el seguimiento: indicadores, revisiones y tendencias 217
17.6. La variabilidad como oportunidad 217
17.7. Resumen del capítulo 218

18. La mejora continua y el análisis de datos **219**
18.1. Qué es la mejora continua y por qué importa en la industria quesera 219
18.2. Definir el problema: el paso más importante 220
18.3. Estrategia de resolución de problemas 220
18.4. El ciclo DMAIC: el marco de Six Sigma 221

18.5. Las 7 herramientas clásicas de la calidad 222
18.6. Lean Manufacturing: eliminar el desperdicio 223
18.7. Six Sigma: reducir la variabilidad con rigor estadístico 223
18.8. El gráfico como herramienta de decisión 224
18.9. Casos de discusión en equipo 224
18.10Resumen del capítulo y cierre del libro 227

Apéndices **229**

A. Glosario de términos **229**

B. Configuración del entorno de trabajo **239**
B.1. Escenario 1: Sin instalación (recomendado) 239
B.2. Escenario 2: Instalación en local 240
B.3. Recursos para aprender Python y R 241
B.4. Cómo usar la inteligencia artificial para entender el código 241

C. La media aritmética como centro de gravedad de un grupo de datos **243**
C.1. Ejemplo 244
C.2. Paso a paso 244
C.3. Ejemplo práctico 245
C.4. Media ponderada 245
C.5. Centro de gravedad como media ponderada 246
C.6. Media aritmética y centro de gravedad con masas idénticas 247
C.7. Conclusión 248
C.8. Importancia del concepto de la media como centro de gravedad, y su comparación con la mediana. 248

Referencias **251**

Bibliografía recomendada **253**

1. Introducción

La industria alimentaria genera cada vez más datos: sensores, líneas automatizadas, sistemas de trazabilidad. Transformar esos datos en información útil para la toma de decisiones es ya una competencia esencial para cualquier técnico de planta, tanto en el trabajo diario como en la presentación de resultados ante la Dirección.

Este libro aborda las herramientas y métodos del análisis de datos en la producción industrial. La hoja de cálculo es el eje central, complementada con una introducción progresiva a los lenguajes **Python** y **R**. El enfoque es práctico: se hace hincapié en los métodos gráficos y en el análisis exploratorio, reduciendo al mínimo la estadística formal. Los capítulos de herramientas cubren desde la estadística descriptiva y las distribuciones de probabilidad hasta la correlación y regresión, el control estadístico de procesos y una introducción al diseño de experimentos. La segunda parte aplica estas herramientas a casos reales de la producción quesera: balance de materia, rendimientos, análisis del sistema de medición y cumplimiento del RD 1801/2008 sobre contenido efectivo de envases. El libro cierra con dos capítulos de síntesis — la variabilidad industrial y la mejora continua — que integran todas las herramientas aprendidas en un marco de trabajo orientado a la acción.

Una idea recorre todo el libro: entender *en qué consiste* un estadístico es más importante que saber *cómo se calcula*. Se busca desarrollar el juicio analítico del estudiante, no memorizar fórmulas. Un buen ejemplo es la media aritmética: veremos que su valor equivale al centro de gravedad de los datos —como el punto de equilibrio de una palanca— y eso explica de forma intuitiva por qué los valores extremos la distorsionan, y cuándo conviene usar otros estadísticos como la mediana. Este tipo de razonamiento práctico, apoyado en analogías físicas concretas, es el que se utiliza a lo largo de todo el libro.

1.1. Por qué aprender Python y R, además de la hoja de cálculo

La hoja de cálculo sigue siendo imprescindible en la empresa, y en este libro se trata con detalle. Pero los lenguajes de programación tienen una ventaja práctica que no puede ignorarse: el código documenta cada paso del análisis, lo que permite verificarlo, repetirlo y compartirlo. Esto es la **reproducibilidad** —concepto que se desarrolla en el capítulo 3—, y es cada vez más valorada tanto en la industria como en las auditorías de calidad.

Hay además una razón muy concreta para el sector alimentario: las normas de calidad y seguridad alimentaria —IFS, BRC, ISO 22000— exigen que los datos de proceso estén documentados y sean verificables. Un flujo de trabajo basado en código cumple ese requisito de forma natural, y quien sepa trabajar así tendrá una ventaja real en cualquier auditoría.

Otras razones de peso:

- **Python** es el lenguaje de referencia en inteligencia artificial y el más extendido en la industria. Su conocimiento, aunque sea básico, representa un valor diferencial en cualquier currículum técnico.

- **R** es el lenguaje de referencia en análisis estadístico y de datos, con uno de los mayores índices de crecimiento entre los lenguajes de programación.
- Ambos son gratuitos y de código abierto. En este libro se usa **Google Colab**, que permite ejecutar scripts Python en el navegador sin instalar nada.

Este libro no pretende formar programadores. El código se usa como sucesión de órdenes sencillas en scripts cortos, al servicio de la comprensión del análisis. La programación en Excel —macros, Visual Basic— queda fuera del alcance.

1.2. Recursos adicionales

Este libro no proporciona una formación de base en Excel, Python o R, aunque el código utilizado se explica con detalle y se indica la forma en la que se puede utilizar los diferentes modelos de IA para explicar y ayudar a comprender el código. El apéndice B detalla algunos recursos para este aprendizaje.

Para quienes deseen ampliar su formación, plataformas como Datacamp, edX, Udemy y Coursera ofrecen cursos gratuitos de Python, R y estadística aplicada. La editorial **OpenStax** (openstax.org, Universidad Rice, EE. UU.) publica recursos educativos abiertos de alta calidad, algunos en español, que pueden complementar el estudio:

- *Workplace Software and Skills*
- *Principles of Data Science*
- *Introduction to Python Programming*
- *Introducción a la estadística empresarial*
- *Introductory Business Statistics 2e*

Todos los datos de los ejemplos están disponibles en hojas de cálculo y ficheros CSV, accesibles mediante enlaces directos en el texto desde el repositorio GitHub del libro. Al final se incluyen referencias y la bibliografía completa.

1.3. Nota para los equipos docentes

Esta sección recoge argumentos y referencias pensados para apoyar la inclusión de estas materias en los ciclos formativos de la rama alimentaria, tanto en la programación didáctica como en la justificación ante equipos directivos o claustros.

1.3.1. Demanda del mercado laboral

El último *Informe sobre el futuro del empleo* del Foro Económico Mundial (WEF, junio de 2025) sitúa el **pensamiento analítico** como la principal habilidad básica demandada por los empleadores, e identifica el **análisis de datos** y la **inteligencia artificial** como las dos competencias con mayor crecimiento en los últimos dos años:

> «El pensamiento analítico sigue siendo la principal habilidad básica para los empleadores: siete de cada diez empresas lo consideran esencial. […] La capacidad de resolución de problemas y la resiliencia personal son críticas para el éxito.»
>
> — WEF, *Future of Jobs Report* 2025

Python ocupa el primer puesto en el índice TIOBE de lenguajes de programación, y R figura entre los diez primeros con uno de los mayores índices de crecimiento. El Principado de Asturias ha establecido el desarrollo de competencias en inteligencia artificial como línea prioritaria para la FP, y varias empresas de la región ya están implantando experiencias en esa dirección.

1.3.2. Digitalización industrial y trazabilidad

La transformación digital de la industria alimentaria —Industria 4.0, sistemas MES (*Manufacturing Execution Systems*), sensores conectados— está generando volúmenes de datos de proceso que las empresas necesitan analizar para mejorar su competitividad. Los técnicos que salgan de la FP se incorporarán a plantas donde esta realidad ya es cotidiana.

Por otro lado, el Reglamento (CE) 178/2002 y las normas de certificación del sector —IFS, BRC, ISO 22000— exigen trazabilidad documental completa y datos de proceso verificables. Un técnico que trabaje con flujos de análisis reproducibles y documentados en código responde a esa exigencia de forma natural, y aporta una garantía adicional de rigor frente a los errores habituales de las hojas de cálculo no controladas.

1.3.3. El problema de los errores en hojas de cálculo

La literatura académica sobre fiabilidad de hojas de cálculo es inequívoca: estudios sistemáticos estiman que entre el 20 % y el 90 % de las hojas de uso profesional contienen errores, la mayoría silenciosos y difíciles de detectar [1], [2]. En un entorno donde una decisión basada en datos erróneos puede afectar a la seguridad del producto o a la conformidad con una auditoría, este no es un argumento menor.

El código en Python o R, al ser revisable paso a paso y ejecutable de forma reproducible, reduce estructuralmente ese riesgo. No se trata de abandonar la hoja de cálculo, sino de complementarla con herramientas que aporten trazabilidad y control al proceso de análisis.

1.3.4. Orientación didáctica

Algunas sugerencias para el uso de este libro en el aula:

- Los capítulos de hoja de cálculo y los de Python/R son en gran medida independientes. Es posible trabajar solo con Excel/Calc en un primer curso e introducir el código en un segundo, o alternar ambos a lo largo del mismo módulo.
- Google Colab no requiere instalación ni cuenta de pago. Basta con una cuenta Google estándar, lo que elimina barreras técnicas en el aula.
- Los informes automatizados con Quarto o Colab (código + texto + resultados en un único documento) pueden usarse como formato de entrega de prácticas, facilitando la corrección y la evaluación entre pares.

- Los recursos de OpenStax mencionados anteriormente están disponibles en abierto e incluyen materiales para el docente (guías, bancos de ejercicios). El Gobierno de España también ofrece cursos de R dentro de su iniciativa de datos abiertos (datos.gob.es).

Todos los conjuntos de datos usados en los ejemplos están disponibles en el repositorio GitHub del libro con licencia abierta, y pueden reutilizarse libremente para diseñar nuevos ejercicios o adaptar los existentes.

1.4. Sobre este libro

Este libro se ha realizado utilizando RStudio Desktop[3] y Positron[4], y compilado con Quarto[5], un conjunto de herramientas gratuitas y libres de Posit. En la redacción y corrección de algunas partes del contenido se ha utilizado Claude Sonnet 4.6[6], de Anthropic

Parte I.

Herramientas y técnicas básicas

2. El análisis de datos de producción en el entorno industrial.



Figura 2.1.: Un grupo de trabajo en planta ante un panel de variables indicadoras

Objetivos de aprendizaje

Al terminar este capítulo, el alumno debe ser capaz de:

- Explicar qué es el método científico y por qué es la base del trabajo técnico riguroso en la industria.
- Describir el concepto de variabilidad y distinguir entre variación normal y variación que indica un problema real en un proceso.
- Enunciar los tres principios del pensamiento estadístico y aplicarlos al análisis de situaciones industriales concretas.
- Identificar y diferenciar los tres tipos de estudio según el origen de los datos —retrospectivo, observacional y experimental— y reconocer las ventajas y limitaciones de cada uno.
- Valorar la calidad de los datos como condición previa a cualquier análisis, y reconocer las principales fuentes de error en los datos históricos.

Los conceptos clave introducidos en este capítulo son: **variabilidad**, **pensamiento estadístico**, **método científico**, **ciclo PDCA**, **datos estructurados y no estructurados**, **estudio retrospectivo**, **estudio observacional**, **experimento diseñado**, y **calidad de los datos**.

2.1. El método científico y la variabilidad

En el trabajo industrial, los problemas rara vez tienen una causa única ni una solución inmediata. La forma más eficaz de abordarlos es mediante el **método científico**: observar lo que está ocurriendo, formular una hipótesis sobre sus causas, diseñar pruebas para verificarla, analizar los resultados y extraer conclusiones. Este ciclo —observación, hipótesis, experimentación, conclusión— no es exclusivo de la investigación académica; es el fundamento del trabajo técnico riguroso en cualquier industria.

Lo que hace útil al método científico en el entorno industrial es que obliga a basar las decisiones en datos reales y no en intuiciones o en la experiencia acumulada de forma no sistemática. La experiencia es valiosa, pero puede engañar: un proceso que "siempre ha funcionado así" puede estar ocultando problemas que solo se hacen visibles cuando se analizan los datos con rigor.

El concepto central que conecta el método científico con el análisis de datos industriales es la **variabilidad**. En cualquier proceso industrial, las sucesivas observaciones de una misma variable no dan exactamente el mismo resultado: el peso de una pieza varía ligeramente de una unidad a otra, el pH de una cuba no es idéntico en cada fabricación, el rendimiento quesero fluctúa de un día a otro. Esta variación no es un fallo ni una anomalía: es inherente a cualquier proceso real. Lo importante es saber distinguir cuándo la variación es normal —es decir, atribuible a causas comunes y aleatorias— y cuándo indica un problema real que requiere intervención.

> **!** Importante
>
> El objetivo principal de la **mejora industrial** es la **reducción de la variabilidad**.

La estadística proporciona las herramientas para analizar esa variabilidad: identificar sus fuentes, cuantificar su magnitud, determinar qué factores tienen mayor impacto y decidir sobre cuáles actuar. Pero las herramientas estadísticas solo tienen sentido dentro de un contexto: los datos son números dentro de un proceso, y para interpretarlos correctamente es imprescindible el conocimiento tecnológico de ese proceso. En un análisis de la producción de un queso, los valores de pH, temperatura o humedad significan poco sin comprender cómo interactúan en la fabricación; la estadística describe, pero es el conocimiento del proceso el que explica.

2.2. El pensamiento estadístico como filosofía de trabajo

El pensamiento estadístico va más allá del uso de herramientas concretas: es una forma de entender y abordar los procesos industriales. Se apoya en tres principios fundamentales:

- Todo proceso industrial está compuesto por procesos interconectados.
- La variabilidad existe y es inherente a esos procesos.
- Entender y reducir la variabilidad es la clave de la mejora y el éxito.

Aplicar estos principios en el trabajo diario significa tomar decisiones basadas en datos en lugar de en suposiciones, cuantificar la incertidumbre en lugar de ignorarla, y comunicar los resultados de forma clara y fundamentada. No se trata de aplicar fórmulas mecánicamente, sino de desarrollar un juicio analítico que permita distinguir lo relevante de lo accesorio, y la causa real del efecto aparente.

En la práctica, el pensamiento estadístico se materializa en ciclos de mejora continua: cada análisis genera conocimiento sobre el proceso, ese conocimiento orienta las acciones de mejora, y los resultados de esas acciones se convierten en nuevos datos que realimentan el ciclo. Las metodologías más extendidas en la industria alimentaria —*Lean Manufacturing*, *Six Sigma*— están construidas sobre este principio: la mejora no es un evento puntual sino un proceso continuo de aprendizaje organizacional basado en evidencia.

! El pensamiento estadístico en la toma de decisiones industriales

En el entorno industrial, el pensamiento estadístico es esencial para:

- **Tomar decisiones basadas en datos**, evitando conclusiones basadas en intuiciones o suposiciones.
- **Evaluar riesgos**, cuantificando la incertidumbre y permitiendo tomar decisiones que los minimicen.
- **Mejorar el conocimiento de los procesos** para una toma de decisiones más eficaz.
- **Comunicar resultados** de manera clara, precisa y verificable.

2.3. Los datos industriales

En el entorno industrial los datos pueden clasificarse atendiendo a dos criterios: su estructura y su origen.

2.3.1. Clasificación según la estructura

Datos estructurados son los organizados en un formato definido —tablas, hojas de cálculo, archivos CSV— que facilita su análisis y consulta. Son los más habituales en el control de producción: lecturas de sensores, registros de fabricación, datos de control de calidad, información de inventario.

Datos no estructurados no tienen un formato predefinido: textos, imágenes, audio, vídeo. Su análisis requiere técnicas más avanzadas, como el procesamiento de lenguaje natural o la visión artificial. En el entorno industrial aparecen como registros de mantenimiento, informes de incidentes, imágenes de inspección visual o grabaciones de maquinaria.

Datos semiestructurados tienen cierta organización pero con mayor flexibilidad que los estructurados. Los archivos XML o JSON y los registros de eventos son ejemplos habituales.

En el contexto de la Industria 4.0, la cantidad y variedad de datos industriales crece de forma exponencial, con una incorporación creciente de datos no estructurados procedentes de sensores, cámaras y sistemas conectados.

2.3.2. Clasificación según el origen

La forma en que se obtienen los datos determina en gran medida qué tipo de conclusiones pueden extraerse de ellos. Esta distinción es fundamental para interpretar correctamente cualquier análisis.

Estudios retrospectivos o históricos

Un **estudio retrospectivo** utiliza datos recogidos en el pasado durante un período determinado. Su objetivo puede ser investigar relaciones entre variables, explorar la calidad de la información disponible, construir un modelo que describa el proceso tal como es actualmente, o detectar si el proceso se ha desviado de su comportamiento habitual. Los modelos construidos a partir de datos históricos se denominan **modelos empíricos**, porque se basan en los propios datos del proceso y no en una formulación teórica.

La principal ventaja de los estudios retrospectivos es la disponibilidad inmediata de una gran cantidad de datos ya recogidos. Sin embargo, presentan limitaciones importantes que conviene tener presentes:

- Puede ser imposible determinar si las condiciones en que se obtuvieron los datos históricos son comparables con la situación actual del proceso.
- Es frecuente que falten variables clave que no se recogieron en su momento, o que se recogieran de forma defectuosa.
- La fiabilidad y validez de los datos históricos no siempre puede verificarse, especialmente si provienen de fuentes diversas o de períodos con procedimientos de registro diferentes.
- Las notas explicativas sobre valores anómalos suelen ser insuficientes o inexistentes, y los recuerdos de quienes participaron en esos procesos se pierden o distorsionan con el tiempo.
- Los datos históricos se recogieron con una finalidad determinada, y pueden no ser adecuados para los objetivos del análisis actual.

Por estas razones, los estudios retrospectivos suelen requerir una fase previa de preparación y depuración de datos que puede ser larga y laboriosa. Se estima que en muchos proyectos de análisis de datos, esta fase puede ocupar hasta el 60 % del tiempo total. Las herramientas de análisis son de gran ayuda en esta fase, aunque en muchas ocasiones será necesario un trabajo manual de recolección a partir de papel, hojas de cálculo diversas y otras fuentes. Este trabajo, aunque tedioso, tiene un valor añadido: mejora el conocimiento de cómo se originan y almacenan los datos del proceso, lo que siempre es útil para mejorar los procedimientos de captura futuros.

Estudios observacionales

Un **estudio observacional** observa el proceso durante un período de operación en condiciones normales de rutina, interfiriendo lo mínimo posible en él. El objetivo es recoger información relevante sin alterar el proceso, lo que proporciona datos que reflejan fielmente las condiciones reales de trabajo.

Si se planifican con cuidado, los estudios observacionales ofrecen datos fiables, precisos y completos para documentar un proceso. Su limitación principal es que el rango de variación de las variables observadas durante el período de estudio puede no cubrir todas las situaciones posibles —en particular, las condiciones extraordinarias o los valores extremos—, lo que restringe las conclusiones que pueden extraerse sobre las relaciones entre variables.

Experimentos diseñados

Los **experimentos diseñados** son la forma más rigurosa de obtener información sobre un proceso. En ellos, el técnico o ingeniero introduce cambios deliberados en las variables que controla —denominadas **factores**— observa el resultado y determina qué variables son responsables de los cambios observados.

La diferencia fundamental respecto a los estudios históricos y observacionales es que en los experimentos diseñados las combinaciones de factores se aplican de forma aleatoria sobre las unidades experimentales. Esta aleatorización es lo que permite establecer con precisión las relaciones de causa y efecto, algo que no es posible con los otros dos tipos de estudio, donde las variables no están bajo el control del analista.

Los experimentos diseñados requieren más planificación y recursos que los estudios retrospectivos u observacionales, pero proporcionan conclusiones mucho más sólidas y directamente accionables para la mejora del proceso.

2.4. La calidad de los datos como condición previa al análisis

El ciclo de mejora continua descrito en la sección anterior —conocido en la industria como ciclo **PDCA** (*Plan-Do-Check-Act* o Planificar-Hacer-Verificar-Actuar), también llamado **ciclo de Deming**— está en la base de las metodologías de mejora más extendidas en el sector alimentario, desde la gestión de la calidad ISO hasta el *Six Sigma* o el *Lean Manufacturing*. Su lógica es simple: planificar una acción de mejora, ejecutarla, verificar sus resultados mediante datos, y actuar en consecuencia para consolidar la mejora o reiniciar el ciclo. Los datos son el elemento que hace funcionar este ciclo: sin datos fiables, no hay verificación posible, y sin verificación el ciclo se rompe.

Esto conduce a una condición previa que con frecuencia se subestima: **la calidad de los datos**. Un análisis es tan bueno como los datos en que se basa. Datos incorrectos, incompletos o mal recogidos producen conclusiones incorrectas, independientemente de la sofisticación del método estadístico utilizado. En el ámbito anglosajón de la ciencia de datos esto se resume con la expresión *garbage in, garbage out* —basura entra, basura sale—, que describe con precisión el problema: ninguna herramienta de análisis, por potente que sea, puede compensar la mala calidad de los datos de partida.

> **!** Importante
>
> La calidad del análisis depende directamente de la calidad de los datos. Antes de analizar, conviene siempre verificar que los datos son fiables, completos y pertinentes para el objetivo del estudio.

Esta advertencia es especialmente relevante en el trabajo con datos históricos, como se ha visto en la sección anterior, pero se aplica a cualquier tipo de estudio. Por esa razón, la organización, la depuración y la verificación de los datos antes del análisis es un paso metodológico imprescindible, y no un trámite previo que pueda obviarse. El capítulo 4 desarrolla con detalle los principios y herramientas para organizar correctamente los datos antes de analizarlos.

2.5. Resumen del capítulo

Este capítulo ha presentado los fundamentos conceptuales del análisis de datos en el entorno industrial. El punto de partida es el **método científico**: una forma sistemática de resolver problemas que obliga a basar las decisiones en datos y no en intuiciones. El concepto central que articula todo el capítulo es la **variabilidad**: todo proceso industrial varía, y el objetivo de la mejora es entender y reducir esa variación.

El **pensamiento estadístico** es la filosofía de trabajo que integra estos principios en el día a día industrial. Se materializa en el **ciclo PDCA** —planificar, hacer, verificar, actuar—, que es la base de las metodologías de mejora continua más extendidas en el sector alimentario.

Los datos industriales pueden clasificarse por su estructura —estructurados, no estructurados y semiestructurados— y por su origen. Esta segunda clasificación es especialmente relevante para el análisis: los **estudios retrospectivos** trabajan con datos históricos y ofrecen abundancia de información pero con limitaciones de fiabilidad; los **estudios observacionales** recogen datos en condiciones reales de operación sin intervenir en el proceso; y los **experimentos diseñados** son la forma más rigurosa de establecer relaciones de causa y efecto, al introducir cambios controlados y aleatorizar las condiciones.

Finalmente, cualquier análisis parte de una condición previa ineludible: la **calidad de los datos**. Datos incorrectos o incompletos producen conclusiones incorrectas independientemente del método utilizado. La organización y depuración de los datos antes del análisis, que se desarrolla en el capítulo 4, es un paso metodológico tan importante como el análisis mismo.

3. Herramientas para el análisis. La reproducibilidad.

Objetivos de aprendizaje

Al terminar este capítulo, el alumno debe ser capaz de:

- Identificar las principales herramientas disponibles para el análisis de datos industriales y explicar las razones por las que se eligen Python y R como herramientas principales en este libro.
- Describir los usos habituales de la hoja de cálculo en el entorno industrial y reconocer sus limitaciones para el análisis reproducible.
- Explicar el concepto de reproducibilidad y distinguirlo del de repetibilidad, y argumentar por qué es relevante en el análisis de datos industriales.
- Comparar el uso de scripts frente al uso de hojas de cálculo desde el punto de vista de la transparencia, la trazabilidad y la reproducibilidad del análisis.

Los conceptos clave introducidos en este capítulo son: **hoja de cálculo**, **lenguaje de programación**, **script**, **reproducibilidad**, **repetibilidad**, **flujo de trabajo reproducible**, **datos rectangulares**.

3.1. Introducción

En el capítulo anterior vimos que el análisis de datos industriales requiere rigor metodológico y datos de calidad. En este capítulo abordamos las herramientas con las que vamos a trabajar a lo largo del libro: la hoja de cálculo Microsoft Excel y los lenguajes de programación **Python** y **R**. Veremos también por qué la elección de la herramienta no es indiferente cuando se trata de garantizar que un análisis sea verificable y reproducible, un requisito cada vez más exigido tanto en el ámbito industrial como en el académico.

3.2. La hoja de cálculo

La hoja de cálculo es una herramienta presente hoy en todos los ámbitos de trabajo y educativos. Desde la aparición de VisiCalc en 1978, ha contribuido a la gestión de miles de empresas y se ha utilizado de manera general en el análisis de datos. En la década de los años 80, Lotus 1-2-3 fue la aplicación más utilizada en los ordenadores IBM-PC y compatibles; con la llegada de Microsoft Windows a finales de esa década, Microsoft Excel se convirtió en la hoja de cálculo dominante, posición que mantiene hasta hoy.



Figura 3.1.: VisiCalc, primera hoja de cálculo para el ordenador *Apple II* (1979)

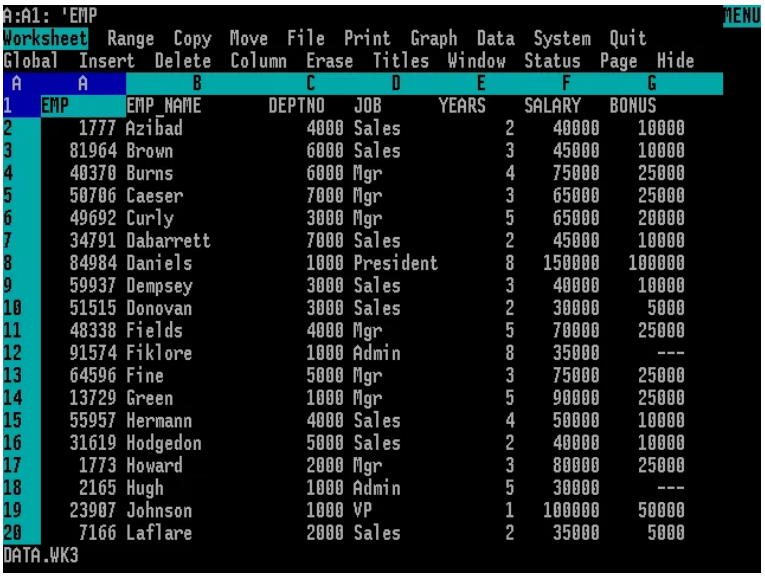


Figura 3.2.: Hoja de cálculo Lotus 1-2-3 para MS-DOS (1983)

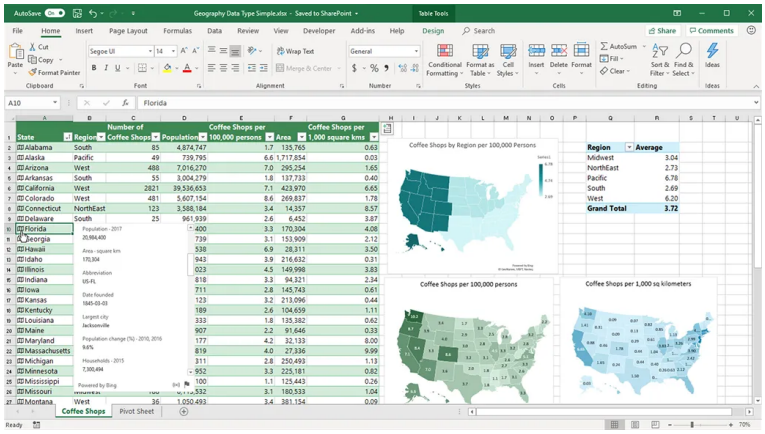


Figura 3.3.: Microsoft Excel (2023)

3.2.1. Usos de la hoja de cálculo en el análisis industrial

La hoja de cálculo es especialmente útil para:

- La introducción, edición y almacenamiento de datos.
- El filtrado y la corrección de errores básicos.
- La manipulación de datos mediante tablas dinámicas.
- La preparación de gráficos para la presentación de resultados.

En este libro trabajaremos exclusivamente con lo que llamaremos **datos rectangulares**: grupos de valores asociados a una o más variables y a varias observaciones, organizados en tablas. Es la forma más habitual de almacenar datos industriales, y la base del principio de los **datos arreglados** (*tidy data*) que se desarrolla en el capítulo siguiente.

La tendencia actual en la industria es recoger los datos de forma automática o mediante sistemas informatizados, lo que elimina el papel y reduce los errores de transcripción. En todos los casos, es imprescindible que los sistemas de información puedan exportar sus datos a ficheros de texto plano o CSV, de modo que puedan importarse tanto en Excel como en Python o R.

3.2.2. Limitaciones de la hoja de cálculo

A pesar de su utilidad y su enorme difusión, la hoja de cálculo presenta limitaciones importantes cuando se usa como herramienta principal de análisis:

- Los cálculos se realizan mediante fórmulas embebidas en las celdas, que son difíciles de rastrear y verificar por terceros, lo que compromete la transparencia del análisis.
- Los gráficos disponibles son relativamente limitados en comparación con los que ofrecen los lenguajes de programación.
- No está diseñada específicamente para el análisis estadístico, y puede mostrar inexactitudes en algunos métodos, como la regresión lineal.
- La falta de transparencia dificulta la auditoría de los análisis, un requisito cada vez más frecuente en entornos de calidad certificada.

Por estas razones, en este libro usaremos Excel principalmente para el almacenamiento de datos y el análisis básico, y Python o R para el análisis gráfico y estadístico más detallado.

3.3. Python y R: las herramientas principales

Python es actualmente el lenguaje de programación más utilizado en el mundo y el de referencia en inteligencia artificial y ciencia de datos. Para el análisis de datos industriales ofrece una combinación de simplicidad, potencia y un ecosistema de bibliotecas muy completo:

- `pandas` para la manipulación de datos tabulares: registros de producción, análisis de lotes, control de calidad.
- `matplotlib` y `seaborn` para la generación de gráficos de alta calidad: tendencias, distribuciones, correlaciones.
- `numpy` para cálculos numéricos precisos sobre arrays de datos.

R es el lenguaje de referencia en estadística y análisis de datos. Dispone de algunas de las bibliotecas gráficas más potentes disponibles —en particular `ggplot2`— y cubre toda la gama de métodos estadísticos, desde la estadística descriptiva básica hasta los modelos más avanzados. Es el lenguaje más utilizado en investigación estadística y en análisis de datos en ciencias de la salud, biología y, en general, en cualquier disciplina con fuerte componente cuantitativo.

Ambos lenguajes son **gratuitos y de código abierto**, cuentan con comunidades de usuarios enormes y están respaldados por una documentación extensa. A lo largo del libro, los ejemplos de código se presentan en pestañas alternativas Python/R, de modo que el lector puede seguir el lenguaje de su elección.

3.4. Otras herramientas del ecosistema

Más allá de Python, R y Excel, existen otras herramientas relevantes en el análisis de datos y la estadística industrial que conviene conocer, aunque no se desarrollen en este libro.

Matlab es un entorno de cálculo numérico muy potente, ampliamente utilizado en ingeniería y en aplicaciones científicas que requieren alto rendimiento computacional. Su sintaxis está orientada al álgebra matricial y es especialmente adecuado para simulación, procesamiento de señales y control de sistemas. Su principal limitación para nuestros objetivos es su coste elevado: se trata de software propietario con licencias de precio significativo.

Minitab es un software estadístico diseñado específicamente para la calidad industrial y la mejora de procesos. Es muy utilizado en entornos *Six Sigma* y en certificaciones de calidad por su facilidad de uso y sus herramientas específicas para el control estadístico de procesos. Como Matlab, es software propietario y su coste puede ser un obstáculo para su uso en formación.

Julia es un lenguaje de programación más reciente, diseñado para el cálculo numérico de alto rendimiento. Ofrece velocidades comparables a lenguajes compilados como C, con una sintaxis cercana a Python y R. Está ganando popularidad en la comunidad científica, especialmente en aplicaciones donde el rendimiento computacional es crítico. Sin embargo, su ecosistema para el análisis de datos es todavía menos maduro que el de Python y R, y su uso en formación es aún limitado.

Google Sheets y **LibreOffice Calc** son alternativas gratuitas a Microsoft Excel, casi totalmente compatibles, que pueden usarse cuando no se dispone de licencia de Office.

La elección de Python y R como herramientas principales de este libro responde, por tanto, a tres criterios combinados: son gratuitas y de código abierto, tienen el ecosistema más rico y

maduro para el análisis de datos y la estadística, y son las que mejor responden al requisito de reproducibilidad que se desarrolla en la sección siguiente.

3.5. El concepto de reproducibilidad

La **reproducibilidad** de un análisis o experimento es la capacidad de obtener los mismos resultados al replicarlo utilizando los mismos datos, la misma metodología y, en su caso, el mismo código informático. En otras palabras, un análisis es reproducible cuando otra persona —o el propio autor en un momento posterior— puede verificar los resultados y llegar a las mismas conclusiones partiendo de los datos originales.

Conviene distinguir la reproducibilidad de un concepto relacionado pero diferente: la **repetibilidad** o **replicabilidad**, que se refiere a la capacidad de obtener resultados consistentes al replicar un estudio con un conjunto *distinto* de datos, pero obtenidos siguiendo el mismo diseño. La repetibilidad responde a la pregunta "¿se confirman estos resultados con nuevos datos?"; la reproducibilidad responde a "¿puede otra persona verificar este análisis con los mismos datos?".

El químico irlandés **Robert Boyle**, en el siglo XVII, fue uno de los primeros en subrayar la importancia de la reproducibilidad en la ciencia. Sostenía que el conocimiento científico debía basarse en hechos experimentales que pudieran volverse creíbles para la comunidad científica precisamente por su reproducibilidad. La bomba de aire de Boyle dio lugar a una de las primeras disputas documentadas sobre la reproducibilidad de un fenómeno científico.

3.5.1. La crisis de reproducibilidad

En las últimas décadas ha crecido la preocupación por la falta de reproducibilidad en resultados científicos publicados [7], [8], [9], [10]. Muchos estudios no pueden reproducirse porque los datos originales no están disponibles, el código de análisis no se ha conservado o documentado, o los procedimientos no se describen con suficiente detalle. Esta situación, conocida como **crisis de reproducibilidad**, afecta a disciplinas tan diversas como la psicología, la biomedicina o la economía, y ha llevado a un cambio en las exigencias de publicación y auditoría en muchos campos.

En el entorno industrial, las consecuencias de un análisis no reproducible pueden ser igualmente serias: una decisión tomada sobre la base de un análisis que no puede verificarse ni auditarse es una decisión con un riesgo oculto.

3.5.2. Reproducibilidad en metrología

En metrología, el término tiene un significado más específico: la reproducibilidad es la capacidad de un instrumento de dar el mismo resultado en mediciones diferentes realizadas en las mismas condiciones a lo largo de períodos prolongados de tiempo. Esta acepción, que se desarrollará con más detalle en el capítulo dedicado al análisis del sistema de medición, es distinta de la reproducibilidad del análisis de datos, aunque comparten el mismo principio de fondo: la confianza en los resultados depende de su consistencia y verificabilidad.

3.6. Scripts frente a hoja de cálculo: ventajas para la reproducibilidad

La diferencia fundamental entre trabajar con scripts y trabajar con hojas de cálculo, desde el punto de vista de la reproducibilidad, es la **transparencia**. En un script, cada operación realizada sobre los datos está escrita de forma explícita y secuencial: cualquier persona que lea el código puede seguir exactamente qué se ha hecho, en qué orden y con qué parámetros. En una hoja de cálculo, las operaciones están embebidas en fórmulas dispersas por las celdas, a menudo sin documentación, y el flujo del análisis no es visible de forma directa.

Las ventajas concretas de los scripts para la reproducibilidad son:

- **Trazabilidad completa**: el código documenta cada paso del análisis, desde la carga de los datos hasta la generación de los gráficos y los resultados finales.
- **Verificabilidad**: cualquier persona con acceso al código y a los datos originales puede reproducir el análisis y comprobar los resultados.
- **Reutilización**: un script bien documentado puede adaptarse fácilmente a nuevos conjuntos de datos o a variaciones del análisis.
- **Control de versiones**: el código puede gestionarse con herramientas como Git, que registran el historial completo de cambios realizados sobre los archivos, permiten recuperar versiones anteriores y facilitan la colaboración entre varios analistas sin riesgo de sobrescribir el trabajo ajeno. Git es una herramienta cada vez más presente en entornos industriales y técnicos, y su conocimiento es un valor añadido en cualquier perfil profesional orientado a los datos.

Conviene distinguir dos formas de trabajar con scripts. El **análisis interactivo** —en entornos como Google Colab o RStudio— es exploratorio y provisional: el analista prueba, ajusta y descarta opciones hasta encontrar el enfoque adecuado. El **informe automatizado** es el resultado final documentado: combina en un único documento el código, los comentarios del autor y los resultados del análisis, generado de forma reproducible cada vez que se ejecuta. Herramientas como Quarto o Google Colab permiten producir este tipo de documentos en Python o R, lo que facilita tanto la auditoría del análisis como su presentación y comunicación. La combinación de scripts bien documentados y datos correctamente organizados constituye la base de un **flujo de trabajo reproducible**, concepto que se desarrolla en detalle en el capítulo siguiente.

> **!** Importante
>
> Utilizar código en lugar de clics de ratón no es solo una cuestión de eficiencia: es la forma más fiable de garantizar que un análisis sea transparente, verificable y reproducible.

3.7. Resumen del capítulo

Este capítulo ha presentado las herramientas de análisis que se utilizarán a lo largo del libro y ha introducido el concepto de reproducibilidad como criterio fundamental para elegir entre ellas.

La **hoja de cálculo** —Microsoft Excel principalmente— es la herramienta dominante en la empresa y resulta muy útil para el almacenamiento, la edición y el análisis básico de datos. Sin embargo, sus limitaciones en transparencia y trazabilidad la hacen insuficiente como herramienta única de análisis cuando se requiere rigor y verificabilidad.

Python y **R** son los lenguajes de programación elegidos como herramientas principales: gratuitos, de código abierto, con ecosistemas maduros para el análisis de datos y la estadística, y con una comunidad de usuarios amplia y activa. Otras herramientas —Matlab, Minitab, Julia— tienen sus nichos de aplicación, pero su coste o su menor madurez las hacen menos adecuadas para los objetivos de este libro.

La **reproducibilidad** es la capacidad de verificar y replicar un análisis utilizando los mismos datos y el mismo código. Es un requisito cada vez más exigido en la industria y en la investigación, y ha cobrado relevancia ante la llamada crisis de reproducibilidad que afecta a múltiples disciplinas. La **repetibilidad**, concepto relacionado, se refiere en cambio a la consistencia de los resultados al usar nuevos datos con el mismo diseño.

Los **scripts** ofrecen ventajas decisivas frente a la hoja de cálculo en reproducibilidad: documentan cada paso del análisis, son verificables por terceros y pueden reutilizarse y gestionarse con herramientas de control de versiones. Los **informes automatizados** con Quarto o Colab llevan este principio un paso más allá, integrando código, comentarios y resultados en un único documento auditable. La combinación de ambos, sobre datos bien organizados, constituye la base de un flujo de trabajo reproducible, concepto que se desarrolla en el capítulo siguiente.

4. Conceptos fundamentales, organización de datos y flujo de trabajo

Objetivos de aprendizaje

Al terminar este capítulo, el alumno debe ser capaz de:

- Definir y distinguir los conceptos de población, muestra, parámetro y estadístico, y aplicarlos a situaciones de análisis industrial concretas.
- Identificar y clasificar los tipos de variables —cualitativas y cuantitativas— y asignar nombres válidos a variables según las convenciones establecidas.
- Describir las etapas de un flujo de trabajo estructurado de análisis de datos y explicar por qué es importante seguirlo.
- Reconocer y corregir estructuras incorrectas de almacenamiento de datos en hojas de cálculo, aplicando los principios de los datos ordenados (*tidy data*).
- Crear, exportar e importar ficheros CSV desde Excel, y comprender su papel en el intercambio de datos entre herramientas.

Los conceptos clave introducidos en este capítulo son: **población**, **muestra**, **parámetro**, **estadístico**, **variable cualitativa**, **variable cuantitativa**, **caso**, **flujo de trabajo**, **datos ordenados** (*tidy data*), **fichero plano**, **fichero CSV**, **DataFrame**.

4.1. Introducción

En el capítulo anterior vimos que trabajar con scripts en lugar de hojas de cálculo es la base de un análisis reproducible. Pero la reproducibilidad no depende solo de la herramienta: depende también de cómo están organizados los datos. Un script impecable aplicado sobre datos mal estructurados produce resultados incorrectos o ininterpretables. Este capítulo aborda precisamente eso: cómo organizar los datos de forma que sean útiles para el análisis, y cómo estructurar el proceso de trabajo para que sea ordenado, eficiente y reproducible.

Antes de entrar en el flujo de trabajo y la organización de los datos, es necesario establecer un vocabulario común. Las definiciones que siguen son la base conceptual sobre la que se apoya todo el análisis de datos.

4.2. Conceptos básicos: datos, variables y casos

4.2.1. Variables y casos

A los objetos descritos en un conjunto de datos los llamamos **casos**. Cuando esos objetos son personas, podemos llamarlos **individuos**; en el entorno industrial, donde los casos suelen ser fabricaciones, lotes, muestras o mediciones, utilizamos la nomenclatura genérica de caso.

Una **variable** es una característica de un caso que puede ser medida u observada, y que puede tomar diferentes valores en diferentes casos. Por ejemplo, el pH de una muestra de leche, la temperatura de una cuba de cuajado o el peso de un envase son variables. El conjunto de variables medidas sobre cada caso constituye la información que vamos a analizar.

4.2.2. Tipos de variables

No todas las variables son del mismo tipo, y esa diferencia es importante porque determina qué operaciones pueden realizarse con ellas y qué gráficos son apropiados para representarlas.

Variables cualitativas o categóricas		Variables cuantitativas o métricas	
Nominales	**Ordinales**	**Discretas**	**Continuas**
Valores en categorías arbitrarias Sin unidades	Valores en categorías ordenadas Sin unidades	Valores enteros en escala numérica Unidades contadas	Valores continuos en escala numérica Unidades medidas

Una **variable cualitativa** o **categórica** clasifica los casos en categorías: el tipo de queso, la línea de producción, el turno de trabajo. Con estas variables no tiene sentido hacer operaciones aritméticas directamente, aunque sí podemos contarlas y calcular frecuencias.

Una **variable cuantitativa** o **métrica** toma valores numéricos con los que sí tiene sentido operar: sumar, calcular medias, calcular desviaciones. El peso, el pH, la temperatura o el rendimiento quesero son variables cuantitativas.

> ⚠ ¿Cualitativo significa “de calidad”?
>
> El término *cualitativo* proviene de *cualidad*, no de *calidad*, y hace referencia a las características o propiedades de un objeto sin implicar juicio de valor. En estadística describe variables que representan categorías o atributos. La frase, usada a veces, “este envase es muy cualitativo” es por tanto incorrecta; lo correcto es “este envase es de gran calidad”.

4.2.3. Población y muestra

Una **población** es el conjunto completo de casos que queremos estudiar. En muchas ocasiones la población es demasiado grande para analizarla completamente, por lo que extraemos una **muestra**: un subconjunto seleccionado para el estudio. El proceso de obtener una muestra se llama **muestreo**.

Para que los resultados obtenidos a partir de la muestra sean válidos para la población, la muestra debe ser **representativa**, es decir, debe reflejar adecuadamente las características de la población. Esto se consigue mediante el **muestreo aleatorio**: cada caso de la población debe tener la misma probabilidad de ser seleccionado.

> **i** Ejemplo: muestreo en una cámara de maduración
>
> Imagina que debes analizar el extracto seco de una producción de quesos en maduración. Dado que la cámara está llena y es difícil acceder a su interior, decides tomar tu muestra de los quesos más accesibles, situados cerca de la puerta y a la altura de la vista.
> Esta forma de muestrear no es correcta: al seleccionar solo los quesos más accesibles introduces un *sesgo*. Las condiciones de humedad, temperatura y circulación de aire pueden variar dentro de la cámara, afectando el extracto seco según la ubicación. Para obtener resultados fiables, todos los quesos deben tener la misma probabilidad de ser seleccionados.
> La **población** en este caso es el conjunto total de quesos en maduración dentro de la cámara.

En muchas aplicaciones industriales, definimos la población como *todos los resultados que podríamos haber obtenido* en las mismas condiciones. A este conjunto lo llamamos **población conceptual**. Por ejemplo, al medir el pH de varias muestras de leche, la población es el conjunto de todos los valores posibles que podríamos haber obtenido. Muchos problemas de ingeniería y tecnología se refieren a poblaciones conceptuales.

4.2.4. Parámetro y estadístico

Un **parámetro** es una característica de una población —su media, su variabilidad, su proporción de defectos—. Como la población completa raramente es accesible, estimamos el valor del parámetro a partir de la muestra, calculando un **estadístico muestral**. El estadístico es un número que resume una propiedad de la muestra y constituye nuestra mejor estimación del parámetro poblacional correspondiente.

> **!** Importante
>
> En la mayoría de las situaciones reales, nuestros datos provienen de una **muestra** obtenida de una **población**. Los estadísticos que calculamos estiman parámetros poblacionales, y esa estimación siempre lleva asociada una incertidumbre.

4.2.5. Reglas para nombrar variables

Nombrar bien las variables es más importante de lo que parece: un nombre claro y consistente evita errores, facilita la lectura del código y permite el intercambio de datos entre herramientas. Las reglas que seguiremos son:

1. Los nombres deben empezar siempre por una letra, nunca por un número o un signo especial.
2. Solo se usarán letras minúsculas, números y el signo de subrayado `_`.
3. No se usarán espacios, acentos, `ñ` (salvo casos justificados), guiones ni paréntesis.
4. Las palabras se separarán con el signo de subrayado: `temp_cuajo`, no `temperaturaDelCuajo`.

5. Los nombres serán lo más cortos posible sin perder claridad: `ph_leche_rec` es preferible a `pH_de_la_leche_en_recepcion`.

No válido	Válido	Motivo
`peso en gramos`	`peso_g`	Espacios no permitidos
`pH_Leche_Recepción`	`ph_leche_rec`	Mayúsculas y acento
`extracto_seco_total_salida_salmuera`	`est_sal`	Demasiado largo
`1er_control`	`control_1`	Empieza por número

En Python y R usaremos el signo de subrayado como separador, que es la convención estándar en ambos lenguajes (*snake_case*).

4.3. El flujo de trabajo

Un **flujo de trabajo** en análisis de datos es un proceso sistemático y estructurado que guía la manipulación, exploración y análisis de los datos desde su recolección hasta la comunicación de los resultados. Es la hoja de ruta que asegura que cada paso se realice de forma ordenada, eficiente y reproducible.

Hadley Wickham [11] —uno de los autores más influyentes en la ciencia de datos moderna— ha propuesto un modelo de flujo de trabajo que se ha convertido en referencia en la disciplina (disponible en español en [12]):

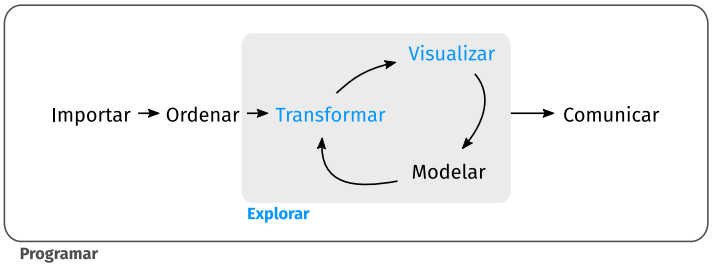


Figura 4.1.: Flujo de trabajo propuesto por Wickham para el análisis de datos

Este modelo integra todas las actividades del análisis: importación y limpieza de datos, transformación, exploración, modelado y comunicación de resultados, dentro de un marco de programación reproducible.

4.4. Etapas de un flujo de trabajo estructurado

4.4.1. Recolección de datos

La primera etapa es obtener los datos desde sus fuentes: archivos CSV, bases de datos, sistemas de captura automática, hojas de cálculo. La calidad del análisis depende directamente de la calidad de los datos recogidos, como se señaló en el capítulo anterior.

4.4.2. Inspección de los datos

Una vez disponibles los datos, se examinan para entender su estructura y contenido: tipos de variables, presencia de valores faltantes o duplicados, rango de los valores, posibles inconsistencias. Esta fase es imprescindible antes de cualquier análisis.

4.4.3. Limpieza de los datos

La limpieza incluye el tratamiento de valores faltantes, la eliminación de duplicados, la corrección de inconsistencias y la conversión de los datos al formato adecuado para el análisis. Es, con diferencia, la fase más larga y laboriosa de cualquier proyecto de datos: se estima que un analista dedica entre el 60 % y el 80 % de su tiempo total a preparar y depurar los datos, y solo el resto al análisis propiamente dicho. Esta proporción sorprende a quienes se acercan por primera vez al análisis de datos, pero refleja una realidad bien documentada: los datos reales raramente llegan limpios, completos y listos para el análisis, independientemente de si provienen de registros históricos, de sistemas automáticos o de mediciones de laboratorio.

Por su extensión y su dependencia del contexto —las técnicas de limpieza varían según el tipo de dato y el problema concreto— esta etapa no se desarrolla de forma abstracta en un único capítulo, sino de forma práctica a lo largo del libro, aplicada a los conjuntos de datos de cada ejemplo. Lo que sí conviene interiorizar desde ahora es su importancia: ninguna herramienta de análisis, por potente que sea, puede compensar datos mal preparados. Como se señaló en el capítulo anterior, *garbage in, garbage out*.

4.4.4. Transformación de los datos

Los datos se restructuran en formato **ordenado o arreglado** (*tidy*), que se desarrolla en la sección siguiente, y se calculan las variables derivadas necesarias para el análisis.

4.4.5. Análisis exploratorio de datos (EDA)

El análisis exploratorio busca entender los patrones y relaciones en los datos mediante estadísticas descriptivas y visualizaciones: medias, medianas, dispersiones, gráficos de distribución y de relación entre variables. Es la fase central de este libro.

4.4.6. Modelado

Dependiendo del objetivo, se pueden aplicar modelos estadísticos para extraer información más profunda: regresión, análisis de tendencias, control estadístico de procesos. El modelado va más allá del alcance introductorio de este libro, pero el flujo de trabajo que aquí se aprende es el mismo que se usaría en análisis más avanzados.

4.4.7. Comunicación de resultados

La última etapa es presentar los resultados de forma clara y efectiva: tablas, gráficos, informes. Un análisis que no se comunica bien no tiene impacto, independientemente de su calidad técnica.

Seguir este flujo de trabajo de forma sistemática garantiza la reproducibilidad del análisis, reduce los errores, facilita la colaboración y permite adaptar el trabajo cuando cambian los datos o los objetivos. La ausencia de un flujo estructurado, en cambio, conduce con frecuencia a errores difíciles de detectar, a análisis que no pueden verificarse y a trabajo que no puede reutilizarse ni compartirse.

4.5. Los datos ordenados o *tidy data*

4.5.1. El problema: datos mal estructurados

El error más frecuente al almacenar datos en una hoja de cálculo es tratarla como un bloc de notas: anotar de forma libre, colocar varias tablas en la misma hoja, usar pestañas distintas para cada mes o cada año, o mezclar datos y resultados en el mismo espacio. Este tipo de estructura puede resultar cómoda para quien la crea, pero es prácticamente inanalizable por cualquier programa de análisis.

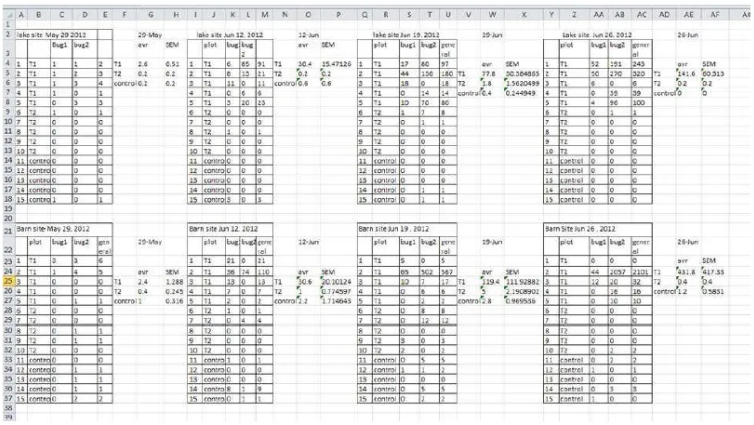
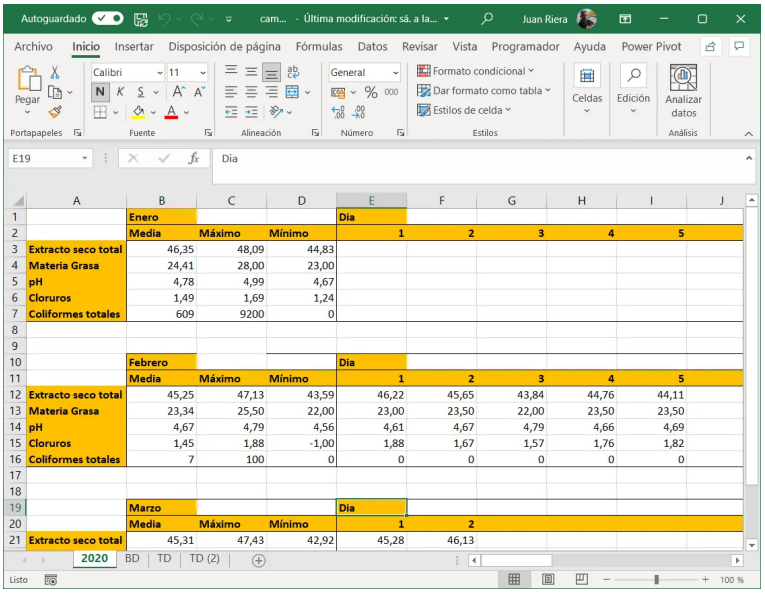


Figura 4.2.: Hoja Excel desordenada: ¡no hagas esto!

Una variante igualmente problemática es el uso de pestañas para separar períodos de tiempo —una pestaña por mes, una por año—. Si los datos corresponden a las mismas variables medidas en fechas distintas, la solución correcta no es usar pestañas sino añadir una variable de fecha que permita filtrar y seleccionar los datos según el período de interés, manteniendo toda la información en una única tabla coherente.



	A	B	C	D	E	F	G	H	I	J
1		**Enero**			**Dia**					
2		**Media**	**Máximo**	**Mínimo**	**1**	**2**	**3**	**4**	**5**	
3	**Extracto seco total**	46,35	48,09	44,83						
4	**Materia Grasa**	24,41	28,00	23,00						
5	**pH**	4,78	4,99	4,67						
6	**Cloruros**	1,49	1,69	1,24						
7	**Coliformes totales**	609	9200	0						
8										
9										
10		**Febrero**			**Dia**					
11		**Media**	**Máximo**	**Mínimo**	**1**	**2**	**3**	**4**	**5**	
12	**Extracto seco total**	45,25	47,13	43,59	46,22	45,65	43,84	44,76	44,11	
13	**Materia Grasa**	23,34	25,50	22,00	23,00	23,50	22,00	23,50	23,50	
14	**pH**	4,67	4,79	4,56	4,61	4,67	4,79	4,66	4,69	
15	**Cloruros**	1,45	1,88	-1,00	1,88	1,67	1,57	1,76	1,82	
16	**Coliformes totales**	7	100	0	0	0	0	0	0	
17										
18										
19		**Marzo**			**Dia**					
20		**Media**	**Máximo**	**Mínimo**	**1**	**2**				
21	**Extracto seco total**	45,31	47,43	42,92	45,28	46,13				

Figura 4.3.: Hoja Excel con estructura de pestañas: no es la forma óptima para el análisis

4.5.2. La solución: tres reglas simples

De la misma manera que la gramática estructura un escrito según reglas comunes, los **datos ordenados** (*tidy data*) siguen tres reglas que garantizan una estructura homogénea y analizable [11]:

- **Cada variable ocupa una columna.**
- **Cada observación ocupa una fila.**
- **Cada valor ocupa una celda.**

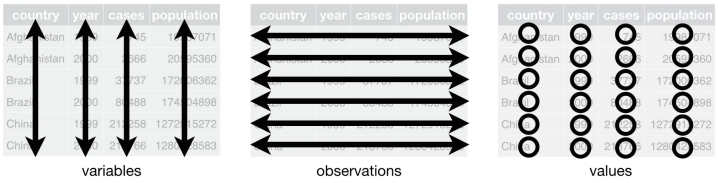
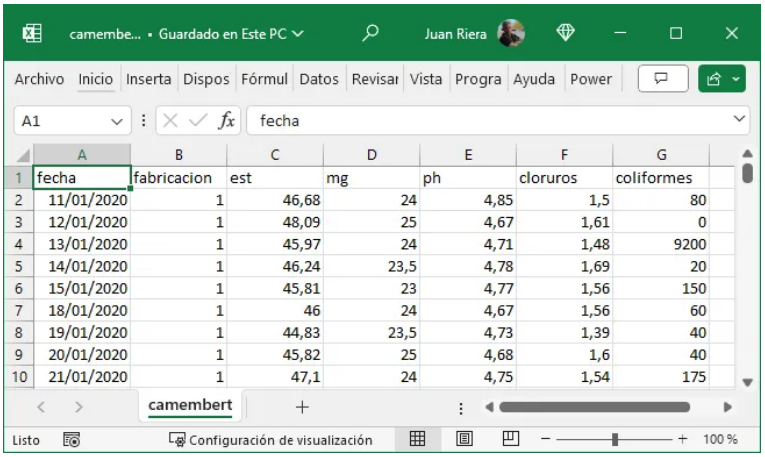


Figura 4.4.: Las tres reglas de los datos ordenados. Fuente: [11]

Estas tres reglas son interdependientes: no es posible cumplir solo dos de las tres. Cuando se respetan, la tabla resultante tiene una estructura rectangular homogénea que puede importarse directamente en Python, R o Excel y analizarse sin necesidad de transformaciones previas.



	A	B	C	D	E	F	G
1	fecha	fabricacion	est	mg	ph	cloruros	coliformes
2	11/01/2020	1	46,68	24	4,85	1,5	80
3	12/01/2020	1	48,09	25	4,67	1,61	0
4	13/01/2020	1	45,97	24	4,71	1,48	9200
5	14/01/2020	1	46,24	23,5	4,78	1,69	20
6	15/01/2020	1	45,81	23	4,77	1,56	150
7	18/01/2020	1	46	24	4,67	1,56	60
8	19/01/2020	1	44,83	23,5	4,73	1,39	40
9	20/01/2020	1	45,82	25	4,68	1,6	40
10	21/01/2020	1	47,1	24	4,75	1,54	175

Figura 4.5.: Ejemplo de hoja Excel con estructura de datos ordenados

4.6. Ficheros planos y ficheros CSV

4.6.1. Qué son

Un **fichero plano** es un archivo de texto sin formato donde los datos están separados por espacios o tabulaciones. Muchos equipos de laboratorio y básculas de proceso generan este tipo de archivos, que pueden importarse directamente en Excel, Python o R.

Un **fichero CSV** (*Comma-Separated Values*) es un tipo de fichero plano en el que los valores están separados por un carácter especial denominado **separador**. Existen dos variantes habituales:

- Separador coma `,` con punto decimal `.` — estándar en EE.UU. y Reino Unido.
- Separador punto y coma `;` con coma decimal `,` — estándar en España y Europa continental.

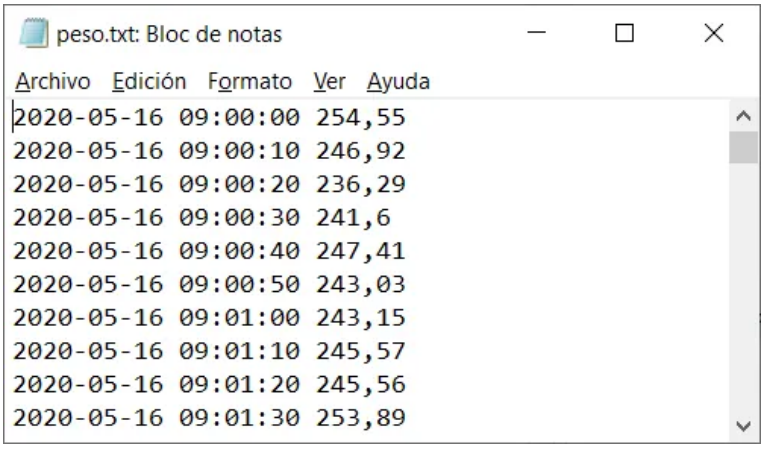


Figura 4.6.: Fichero plano separado por espacios

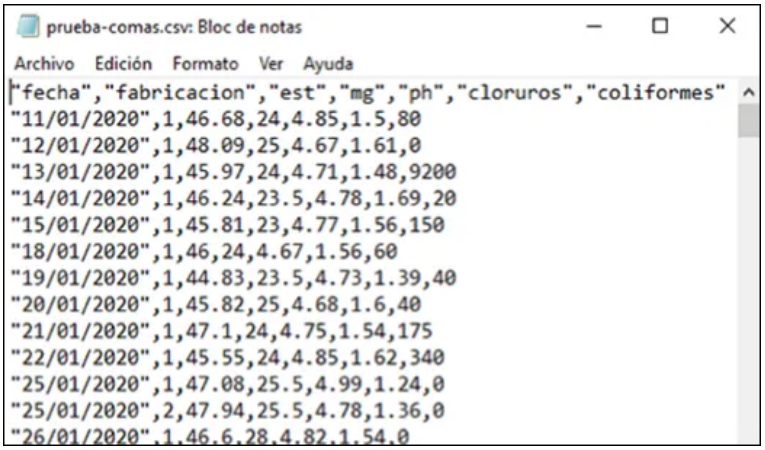


Figura 4.7.: Fichero CSV separado por comas (EE.UU., Reino Unido)

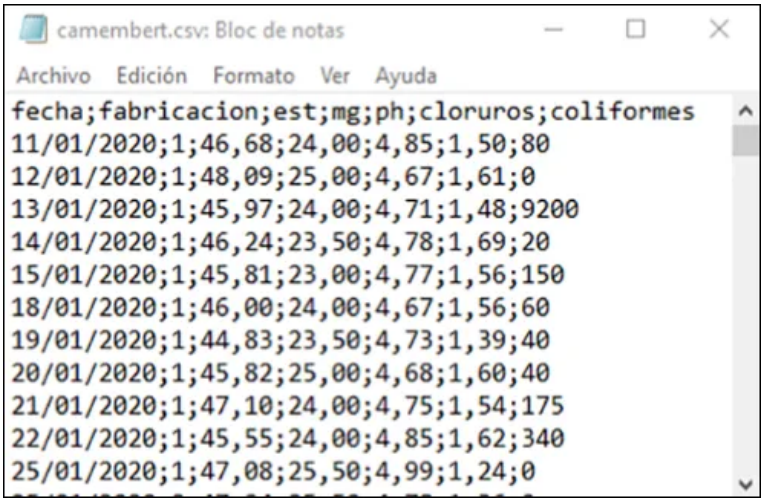


Figura 4.8.: Fichero CSV separado por punto y coma (Europa, España)

La primera fila del fichero suele contener los nombres de las columnas. Los programas de importación se ocupan de la conversión de formatos en la mayoría de los casos.

El fichero CSV es el formato de intercambio de datos más universal: todos los programas de análisis —Excel, Python, R— pueden leerlo y generarlo. Por esa razón es el formato recomendado para almacenar y compartir datos en este libro.

4.6.2. Exportar un fichero CSV desde Excel

Una vez que los datos están correctamente organizados en Excel, podemos exportarlos a CSV para usarlos en Python o R:

1. Abre el fichero en Excel.
2. Selecciona **Archivo > Guardar como**.
3. Elige el formato **CSV (delimitado por comas) (*.csv)**.
4. Guarda el archivo.

Alternativamente, tanto Python como R pueden leer directamente ficheros Excel sin necesidad de exportar a CSV, utilizando las funciones adecuadas de sus respectivas bibliotecas (`pandas` en Python, `readxl` en R). En el capítulo siguiente veremos cómo realizar esta importación.

Cuando los datos se importan en Python o R, se almacenan en una estructura denominada **DataFrame** o **cuadro de datos**, equivalente a la tabla rectangular de Excel, y sobre la que se realizarán todas las operaciones de análisis.

4.7. Práctica

- En Excel, crea una tabla de datos con al menos tres variables y cinco observaciones, siguiendo las reglas de datos ordenados y la convención de nombres de variables. Guárdala en formato CSV y vuelve a abrirla para verificar que el formato se ha conservado correctamente.
- Practica el uso de **Datos** > **Filtro** en Excel para seleccionar observaciones según distintos criterios.

4.8. Para resolver

Escribe cinco ejemplos de nombres de variables relacionados con medidas analíticas o de proceso en quesería —como la temperatura de la leche en recepción o el pH al finalizar la cuajada— y verifica si son válidos según las reglas establecidas. Para los que no sean válidos, propón una alternativa correcta.

4.9. Resumen del capítulo

Este capítulo ha establecido los fundamentos conceptuales y prácticos para organizar los datos antes de analizarlos.

Los conceptos básicos del análisis de datos son: la **variable** —característica medible de un caso—, el **caso** —unidad de observación—, y la distinción entre variables **cualitativas** —que clasifican en categorías— y **cuantitativas** —que toman valores numéricos con los que se puede operar—. La **población** es el conjunto completo de casos de interés; la **muestra** es el subconjunto que analizamos. Un **parámetro** describe a la población; un **estadístico** lo estima a partir de la muestra.

El **flujo de trabajo** es la secuencia ordenada de pasos desde la recolección de los datos hasta la comunicación de los resultados: recolección, inspección, limpieza, transformación, análisis exploratorio, modelado y comunicación. Seguir este flujo de forma sistemática garantiza la reproducibilidad, reduce los errores y facilita la colaboración.

Los **datos ordenados** (*tidy data*) siguen tres reglas: cada variable en una columna, cada observación en una fila, cada valor en una celda. Esta estructura rectangular es la única que permite el análisis directo con cualquier herramienta, y evita los errores frecuentes de las hojas de cálculo mal estructuradas.

Los **ficheros CSV** son el formato de intercambio de datos más universal, legible por Excel, Python y R. Al importarlos en Python o R, los datos se almacenan en un **DataFrame**, estructura equivalente a la tabla de Excel sobre la que se realizarán los análisis.

5. La exploración de los datos mediante gráficos.

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Construir e interpretar un diagrama de tallo y hojas (stemplot) a partir de un conjunto de datos pequeño, tanto manualmente como con Python y R.
- Elaborar tablas de distribución de frecuencias con frecuencias absolutas, relativas y acumuladas en Excel, Python y R.
- Crear e interpretar diagramas de barras para variables discretas en Excel.
- Construir histogramas para variables continuas en Excel, Python y R, y seleccionar la amplitud de intervalo adecuada según el conjunto de datos.
- Identificar e interpretar la forma de una distribución de datos (simétrica, asimétrica, bimodal) a partir de un histograma.
- Describir la distribución de un conjunto de datos mediante el diagrama de caja (boxplot), identificando la mediana, los cuartiles, el rango intercuartil y los valores atípicos (outliers), y relacionar la forma del boxplot con la forma de la distribución.
- Utilizar alternativas al boxplot (beeswarm, stripplot, violin plot) para visualizar distribuciones con mayor detalle.
- Construir gráficos de densidad con Python y R y utilizarlos para comparar distribuciones entre grupos.
- Crear e interpretar gráficos de dispersión para analizar relaciones entre dos variables numéricas, tanto en Excel como en Python y R.
- Construir gráficos de series temporales e identificar tendencias, estacionalidad y anomalías, utilizando las funciones de remuestreo y ventanas móviles de pandas en Python y los equivalentes en R.
- Elegir el tipo de gráfico más adecuado según el objetivo del análisis y el tipo de variable.

Los conceptos clave introducidos en este capítulo son: **stemplot, distribución de frecuencias, frecuencia absoluta, frecuencia relativa, frecuencia acumulada, diagrama de barras, histograma, intervalo (bin), forma de los datos, distribución simétrica, distribución asimétrica, distribución bimodal, diagrama de caja (boxplot), cuartil, mediana, rango intercuartil (IQR), valor atípico (outlier), beeswarm, violin plot, gráfico de densidad, gráfico de dispersión, correlación, serie temporal, estacionalidad, tendencia, remuestreo, media móvil, matplotlib, seaborn, ggplot2, pandas**.

Una imagen vale más que mil palabras, y en el análisis de datos, la visualización es fundamental para entender patrones, distribuciones y relaciones en nuestros datos.

En este capítulo estudiaremos cómo describir conjuntos de datos de forma visual, utilizando varios tipos de gráficos distintos:

5. La exploración de los datos mediante gráficos.

- *Stemplot*
- Histograma
- Diagrama de caja o *boxplot*
- Gráfico de dispersión
- Gráfico de series temporales

Veremos la relación visual entre un histograma y un diagrama de caja, y aprenderemos también a construir tablas de frecuencias en Excel, en Python y en R. Finalmente, veremos algunos otros tipos de gráficos que son útiles para aplicaciones concretas, como los gráficos de densidad.

> **Librerías necesarias en este capítulo**
>
> A lo largo de este capítulo se utilizan las siguientes librerías:
>
> - Python: `pip install palmerpenguins`
> - R: `install.packages(c("palmerpenguins", "ggbeeswarm", "patchwork"))`
>
> La mayoría forman parte de una instalación estándar de Python o R; `palmerpenguins`, `ggbeeswarm` y `patchwork` deben instalarse la primera vez.

5.1. El diagrama de tallo y hojas (*stem and leaf plot* o *stemplot*)

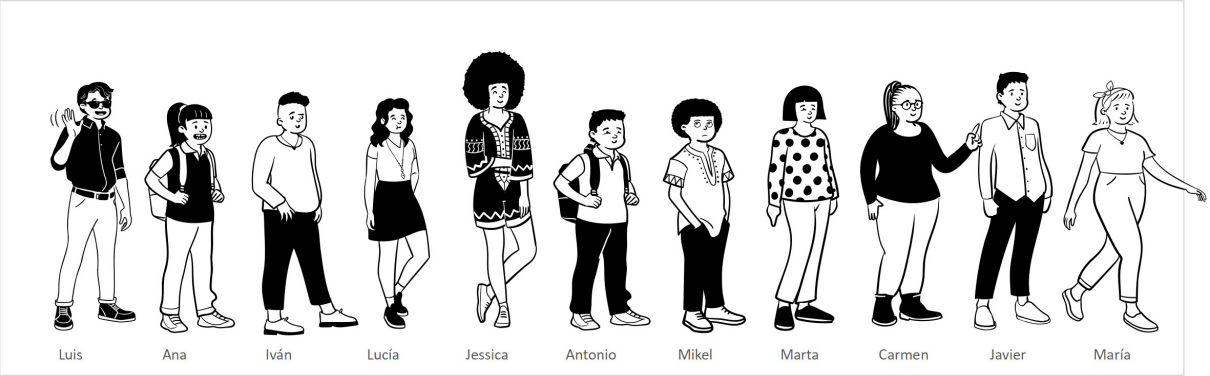
El diagrama de tallo y hojas, también conocido como *stemplot*, es una herramienta gráfica utilizada en estadística para representar la distribución de un conjunto de datos. Es especialmente útil para conjuntos de datos pequeños y proporciona una forma rápida y efectiva de visualizar la forma de los datos y su dispersión. El *stemplot* recibe este nombre porque el dibujo que resulta se asemeja a un tallo el que le salen las hojas que son los datos individuales.

Los componentes de un *stemplot* son:

- **Tallo**: Representa el grupo principal de los valores de los datos. Generalmente, se usa la parte más significativa del número. Por ejemplo, en el número 43, el tallo podría ser 4.
- **Hojas**: Representan los dígitos finales o menos significativos de los valores de los datos. Siguiendo el ejemplo anterior, la hoja sería 3.

Construcción del diagrama en la hoja de cálculo

Supongamos que queremos medir la altura de un grupo de alumnos de nuestra clase. Éste es nuestro grupo:



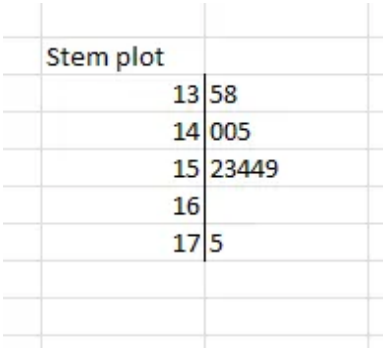
Realizamos la medida de altura de cada persona y registramos los valores en una hoja de cálculo, siguiendo las buenas prácticas que hemos visto al estudiar los *datos ordenados*.

	A	B	C	D
1	nombre	altura_cm		
2	Luis	153		
3	Ana	135		
4	Iván	140		
5	Lucía	140		
6	Jessica	175		
7	Antonio	138		
8	Mikel	145		
9	Marta	154		
10	Carmen	152		
11	Javier	159		
12	María	154		
13				
14				
15				

Vamos a utilizar los datos de medidas de altura de nuestro grupo de alumnos. Quitamos el último dígito a la derecha de nuestros valores y colocamos verticalmente los valores resultantes ordenándolos de menor a mayor, y evitando las repeticiones. Para evitar errores en la escala, debemos incluir los valores intermedios aunque no haya ninguno en nuestros datos (en el ejemplo, el valor 16 que correspondería a los 160). Esto forma el "tallo" de nuestro diagrama:

Stem plot
13
14
15
16
17

A continuación añadimos las "hojas" en la celda a la derecha, que consisten en los valores que hemos "cortado" de nuestro árbol, uno al lado de otro, incluyendo esta vez los valores repetidos, en orden de menor a mayor. Por ejemplo, para el valor 135, descartamos 13 y utlizamos 5; para el valor 138, descartamos 13 y utilizamos 8, y así sucesivamente para todos los valores.



Stem plot	
13	58
14	005
15	23449
16	
17	5

Construcción del diagrama en Python y R

R permite realizar el *stemplot* mediante la función *stem*() de forma automática. Python no incluye entre sus métodos básicos una función para hacer un *stemplot*, aunque sí la tiene en la librería `stemgraphic`; importamos de esta librería sólo la función `stem_text()`

> Importante: Explicación del código
>
> En este capítulo veremos varios ejemplos de código R y Python.
> Para un explicación detallada del código, copia el código R o Python y pégalo en Gemini o en ChatGPT (o Copilot). A continuación. da esta instrucción a la IA (puedes copiar y pegar el párrafo):
>
> > Actúa como un tutor de programación. Explica este código instrucción a instrucción de forma detallada y sencilla, indicando qué hace cada línea y por qué es necesaria. Usa analogías con Excel o tareas manuales para que sea más fácil de entender.

5.1.1. Interpretación del diagrama de tallo y hojas

- **Tallo**: Los números a la izquierda del símbolo `|` representan los valores base (o tallos), en este caso, las decenas de las alturas.
- **Hojas**: Los números a la derecha del símbolo `|` representan los dígitos adicionales (o hojas). Por ejemplo, en la línea `13 | 58`, el tallo es `13` (130), y las hojas son `5` y `8`, que corresponden a los datos `135` y `138`.

El diagrama nos dice que los valores en torno a 150 cm son los más frecuentes, y que hay un valor alto (175) que se separa un poco del resto.

5.1.2. Resumen

El *stemplot* es muy sencillo de hacer y nos da una visión rápida y compacta de la *distribución* de nuestros valores, así como de la posible existencia de valores que se separan del conjunto. Estos valores alejados, que se conocen en inglés como *outliers*, tienen mucha importancia en el analisis e interpretación de los datos, como veremos más adelante.

La ventaja principal del *stemplot* es que mantiene los valores originales de las observaciones, y puede hacerse fácilmente con bolígrafo y papel, sin necesidad de más herramientas.

Su principal inconveniente es la elaboración manual (aunque lenguajes como R tienen funciones que lo contruyen de forma automática), y por lo tanto, la dificultad de aplicarlo a volumenes de datos medios o grandes. El uso generalizado de los ordenadores ha hecho que actualmente esta herramienta tenga muy poco uso, y se utilicen en su lugar otras más gráficas y de construcción automática, como el **histograma**.

5.2. Distribuciones de frecuencias

Una **distribución de frecuencias** es una tabla que muestra la frecuencia con la que ocurren los valores diferentes en un conjunto de datos. Esta herramienta es fundamental en la estadística descriptiva y permite resumir y visualizar cómo se distribuyen los datos de manera clara y comprensible. A partir de una tabla de frecuencias se pueden construir diagramas de barra o histogramas para visualizar la tabla de forma gráfica.

Para construir una distribución de frecuencias, agrupamos nuestros valores por intervalos, y contamos el número de observaciones que aparecen en cada intervalo. Los componentes de una distribución de frecuencias son:

- las **categorías o clases** son los intervalos o valores específicos de los datos que se están analizando. Cada categoría representa un rango de valores en caso de datos continuos, o valores específicos en caso de datos discretos.
- la **frecuencia absoluta** es un *recuento simple* de cuántas veces aparece cada valor en un conjunto de datos.
- la **frecuencia relativa** nos muestra la *proporción* de cada valor frente al total. Puede expresarse como fracción (entre 0 y 1) o como porcentaje (respecto a 100), y se calcula como:

$$\text{Frecuencia Relativa} = \frac{\text{Frecuencia Absoluta}}{\text{Número Total de Observaciones}}$$

- la **frecuencia acumulada** nos dice cuántas observaciones están por debajo de un cierto valor.
- la **frecuencia relativa acumulada** es la proporción de valores que están por debajo de un cierto valor

5.2.1. Construcción de una tabla de frecuencias paso a paso en Excel

Para crear una tabla de frecuencias de la variable `altura_cm` mediante una tabla dinámica en Excel, sigue estos pasos:

1. Selecciona los Datos

5. La exploración de los datos mediante gráficos.

1. Abre tu archivo de Excel y selecciona toda la tabla que incluye los encabezados (`nombre` y `altura_cm`).

2. Inserta una tabla dinámica

1. Ve a la pestaña **Insertar** en la barra de herramientas de Excel.
2. Haz clic en **Tabla Dinámica**.
3. En el cuadro de diálogo que aparece, asegúrate de que el rango de datos seleccionado es correcto y elige dónde deseas colocar la tabla dinámica (en una nueva hoja de cálculo o en la hoja actual).

3. Añade la frecuencia absoluta

1. En el panel de campos de la tabla dinámica, arrastra el campo `altura_cm` a la sección **Filas**.
2. Arrastra nuevamente el campo `altura_cm` a la sección **Valores**.

4. Ajusta la configuración de valores

1. Haz clic en el campo `altura_cm` en la sección **Valores**.
2. Selecciona **Configuración de campo de valor**.
3. En el cuadro de diálogo que aparece, asegúrate de que esté seleccionada la opción **Recuento**
4. Acepta todo hasta volver a Excel.

5. Añade la frecuencia relativa

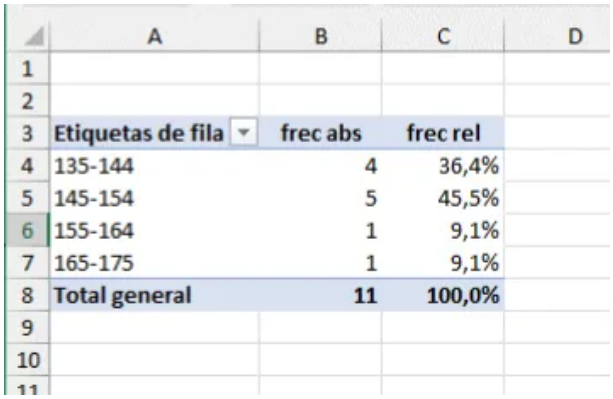
1. En el panel de campos de la tabla dinámica, arrastra de nuevo el campo `altura_cm` a la sección **Valores**. Ahora la variable aparecerá como `altura_cm2`.

6. Ajusta de nuevo la configuración de valores

1. Haz clic en el campo `altura_cm2` en la sección **Valores**.
2. Selecciona **Configuración de campo de valor**.
3. En el cuadro de diálogo que aparece, asegúrate de que esté seleccionada la opción **Recuento**.
4. En ese mismo cuadro, haz click en el botón **Formato de número**, selecciona **Número** y **2 decimales**, y acepta.
5. En ese mismo cuadro, selecciona la pestaña que dice **Mostrar valores como**
6. En el menú desplegable, escoge la opción **% del total de columnas**.
7. Acepta todo hasta volver a Excel.

7. Ordena y formatea

1. Puedes ordenar las alturas en orden ascendente o descendente haciendo clic en la flecha junto a `altura_cm` en la tabla dinámica.
2. También puedes cambiar el formato de la tabla dinámica para que sea más fácil de leer.
3. Puedes renombrar los encabezados de la tabla para que sea más fácil de leer, rotulando las columnas, por ejemplo, como `frec_abs`y `frec_rel`, o cualquier otro encabezado que te resulte claro y útil.



	A	B	C	D
1				
2				
3	Etiquetas de fila	frec abs	frec rel	
4	135-144	4	36,4%	
5	145-154	5	45,5%	
6	155-164	1	9,1%	
7	165-175	1	9,1%	
8	Total general	11	100,0%	
9				
10				

5.2.2. Construcción de una tabla de frecuencias mediante Python o R

5.3. R base

```
altura_cm
135 138 140 145 152 153 154 159 175
  1   1   2   1   1   1   2   1   1
```

5.4. R con dplyr

```
# A tibble: 9 x 2
  altura frecuencia
   <dbl>      <int>
1    140          2
2    154          2
3    135          1
4    138          1
5    145          1
6    152          1
7    153          1
8    159          1
9    175          1
```

Con un poco más de código podemos hacer la tabla agrupando los valores en clases de amplitud 10, con las frecuencias absolutas y relativas. Es un poco más complicado, tómate tu tiempo para entender cada paso de las instrucciones.

5.5. R base

```
  Intervalo Frecuencia Frec_acum Frec_rel_pct Frec_rel_acum_pct
1 [130,140)          2         2        18.18             18.18
2 [140,150)          3         5        27.27             45.45
3 [150,160)          5        10        45.45             90.90
```

```
4 [160,170)          0        10         0.00             90.90
5 [170,180)          1        11         9.09             99.99
6 [180,190)          0        11         0.00             99.99
```

5.6. R con dplyr

```
# A tibble: 6 x 5
  intervalo Frecuencia Frec_acum_pct Frec_rel_pct Frec_rel_acum_pct
  <fct>          <int>         <int>        <dbl>              <dbl>
1 [130,140)          2             2        18.2               18.2
2 [140,150)          3             5        27.3               45.4
3 [150,160)          5            10        45.4               90.9
4 [160,170)          0            10         0                 90.9
5 [170,180)          1            11         9.09              100.0
6 [180,190)          0            11         0                 100.0
```

Como ves en el resultado, a veces se utilizan los símbolos `(` y `[` para definir los intervalos, tal como se hace en matemáticas.

- Intervalo **abierto**: El símbolo `(` se utiliza para denotar un intervalo abierto. El límite correspondiente **no** está incluido en el intervalo.
- Intervalo **cerrado o semiabierto**: El símbolo `[` se utiliza para denotar un intervalo cerrado o semiabierto. El límite correspondiente **sí** está incluido en el intervalo.

Ejemplos:

- (a, b) representa todos los números reales **mayores** que a y **menores** que b (excluye los valores a y b).
- $[a, b]$ representa todos los números reales **mayores o iguales** que a y **menores o iguales** que b (incluye a y b).
- $[a, b)$ representa todos los números reales **mayores o iguales** que a y **menores** que b (incluye a, pero excluye b)
- $(a, b]$ representa todos los números reales **mayores** que a y **menores o iguales** que b (excluye a, pero incluye b).

Si comparamos los dos métodos que hemos utilizado para construir la tabla de frecuencias, vemos que:

- en Excel los pasos que hemos dado no están registrados y a la vista, y, por lo tanto, no son fácilmente revisables
- en Python y R, todos los pasos y opciones que hemos utilizado están a la vista en el código del script

Si otra persona quisiera modificar la tabla, le sería fácil editar el código y relanzar el script, mientras que en Excel no sería fácil asegurarse de todos y cada uno de los pasos y clicks de ratón que hemos dado para construir y formatear la tabla.

Esta es una de las principales razones de la conveniencia del aprendizaje de `Python` incluso para las actividades más sencillas.

5.6.1. Ejercicio propuesto

En la tabla de frecuencias anterior, calcular **frecuencia absoluta acumulada** y **frecuencia relativa acumulada** en Excel, e incluirlas en la tabla como dos columnas adicionales. La **frecuencia relativa acumulada** nos permitirá crear **diagramas de Pareto**, muy útiles en los procesos de mejora de calidad.

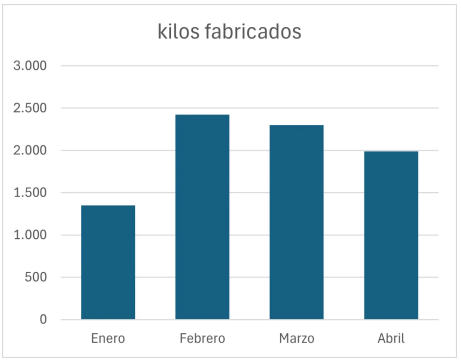
5.7. Diagrama de barras

Cuando nuestra variable es *discreta*, podemos representar las frecuencias de cada valor de forma gráfica utilizando un diagrama de barras. Este diagrama utiliza barras rectangulares para representar la frecuencia de cada categoría.

Este gráfico es muy utilizado para representar, por ejemplo, resultados de encuestas, como el número de votos que han obtenido los diferentes partidos políticos en unas elecciones, o tablas discretas, como los kilos fabricados por meses en una fábrica.

	A	B
1		kilos fabricados
2	Enero	1.350
3	Febrero	2.425
4	Marzo	2.300
5	Abril	1.987
6		
7		

(a) Tabla de frecuencias

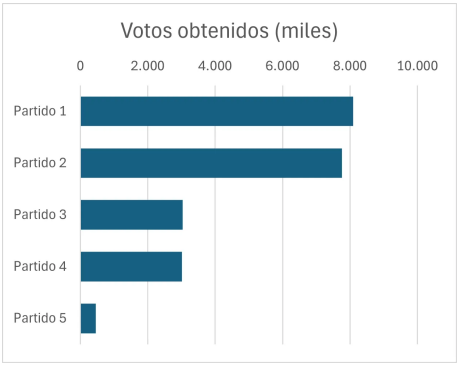


(b) Diagrama de barras

Figura 5.1.: Representación mediante diagrama de barras de una variable discreta: fabricación mensual en kg.

	A	B	C
1		Votos obtenidos (miles)	
2	Partido 1	8.092	
3	Partido 2	7.761	
4	Partido 3	3.033	
5	Partido 4	3.014	
6	Partido 5	463	
7			

(a) Tabla de frecuencias



(b) Diagrama de barras

Figura 5.2.: Representación mediante diagrama de barras de una variable discreta: resultado de una encuesta.

5.8. Histograma

Para visualizar las variables continuas se utiliza el **histograma**, que es un diagrama que utiliza las barras rectangulares para hacer un gráfico de la distribución de valores continuos, previamente agrupados en intervalos (*bins* en inglés), tal como se ha hecho en la tabla de frecuencias.

Componentes de un histograma

1. **Eje horizontal (X)**: Representa los intervalos de valores de la variable. Cada intervalo abarca un rango específico de valores.
2. **Eje vertical (Y)**: Muestra la frecuencia o el número de veces que los valores caen dentro de cada intervalo.
3. **Barras**: Cada barra en el histograma representa un intervalo. La altura de la barra indica la frecuencia de los valores dentro de ese intervalo.

Cómo interpretar un histograma

- Si las barras son altas en un intervalo específico, significa que muchos valores del conjunto de datos caen dentro de ese rango.
- Un histograma puede ayudar a identificar patrones, como si los datos están distribuidos de manera simétrica, sesgada, o si hay picos y valles significativos.

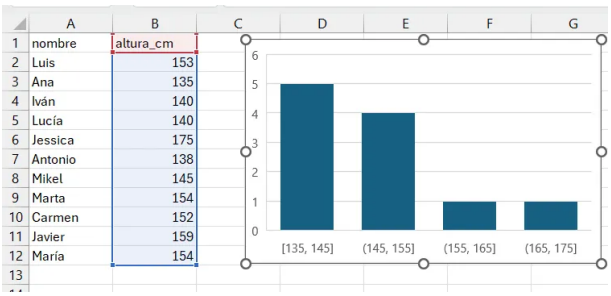
5.8.1. Construcción de un histograma en Excel

Usaremos el ejemplo de la altura en cm. de un grupo de alumnos.

Podemos utilizar dos métodos para hacer un histograma en Excel

Método 1: histograma directo

- Seleccionamos el rango de datos. Podemos hacerlo mediante un click en el encabezado de la columna de la variable `altura_cm`, en este caso, la columna `B`.
- En la opción de menú `Insertar`, seleccionamos el icono `Seleccionar gráficos de estadística`
- Seleccionamos `Histograma`



Excel calcula automáticamente la amplitud de los intervalos y el número de columnas; estas opciones pueden modificarse seleccionando con el botón derecho del ratón el elemento a modificar. En este caso, utilizamos estas opciones:

- Eliminamos título del gráfico
- Modificamos anchura de las barras seleccionando `Dar formato a serie de datos`, `Opciones de serie`, `Ancho del rango`= 50 %
- Modificamos los intervalos seleccionando el eje X: `Dar formato al eje`, `Opciones de eje`, `Ancho del rango` = 10

La descripción de los intervalos utiliza los mismos símbolos que hemos visto en las tablas de frecuencias de `Python`.

En el momento de escribir este manual, Excel no permite hacer histogramas múltiples ni agrupados por otra variable, por lo que para diseños más complejos, no hay más remedio que recurrir a otras opciones como las tablas dinámicas de Excel o, mejor aún, `Python` o `R`.

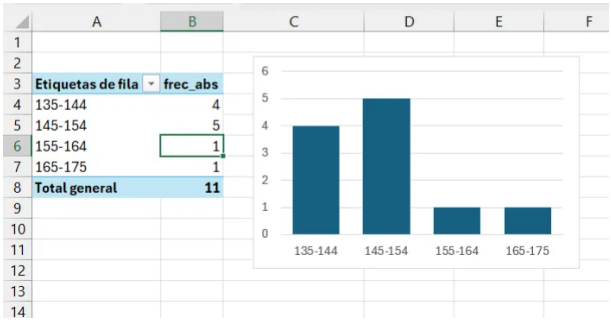
Método 2: utilizar una tabla dinámica

La tabla dinámica que hemos construido en Excel ha convertido nuestra variable continua, `altura_cm`, en una tabla de valores discretos, al agrupar los valores en intervalos. En Excel podemos representar las frecuencias absolutas de nuestra tabla gráficamente, insertando un gráfico de barras a partir de la tabla:

- Con el cursor dentro de la tabla, seleccionamos la opción de menú `Insertar`
- Insertamos un gráfico de barras

Opcionalmente, aplicamos las siguientes opciones de formato:

- Hacemos click sobre uno de los botones del gráfico dinámico con el boton derecho del ratón, y seleccionamos la opción ocultar todos los botones del gráfico.
- Eliminamos el título del gráfico
- Abrimos el formato de la serie de datos, e introducimos en la opción `Ancho del rango` el valor 50 % para ensanchar las barras.



Al utiizar la tabla dinámica para construir el gráfico, Excel utiliza las categorías de la tabla dinámica. Dado que estas categorías (los intervalos que ha formado la tabla dinámica) son discretas, Excel utiliza el resultado de la tabla dinámica para hacer el gráfico con un diagrama de barras. No es posible insertar un histograma a partir de una tabla dinámica.

5.8.2. Histograma en Python y R

En Python, las librerías `matplotlib` y `seaborn` son las herramientas estándar para crear gráficos.

- **matplotlib.pyplot (alias `plt`):** Es la base, una librería de bajo nivel que da un control muy granular sobre cada aspecto del gráfico.
- **seaborn (alias `sns`):** Construye sobre `matplotlib`, ofreciendo una interfaz de alto nivel para crear gráficos estadísticos complejos y estéticamente agradables con menos código. Es ideal para explorar distribuciones, relaciones entre variables y comparaciones entre grupos.

Siempre importamos ambas, ya que `seaborn` a menudo usa funciones de `matplotlib` para mostrar y personalizar los gráficos (como `plt.title()` para el título o `plt.show()` para mostrar el gráfico).

En **R**, usaremos las funciones de base y la librería `ggplot2`.

Las funciones de histograma de Python y R permiten construir el histograma directamente sin necesidad de hacer previamente una tabla de frecuencias (en realidad, la tabla de frecuencias se calcula internamente). Es mucho más sencillo utilizar estas funciones, ya que el código se simplifica mucho.

Vemos que los gráficos no son idénticos a pesar de provenir de los mismos datos, porque la construcción de los intervalos subyacente y el aspecto de las barras pueden ser ligeramente diferentes. Esto no debe preocuparnos, porque el aspecto general de la distribución de los datos es el mismo.

En la fase de exploración nos importa más entender estas propiedades de los datos (aspecto, forma de la distribución) que la precisión en la construcción del gráfico.

Comenzamos con el histograma de nuestros datos de altura:

Con solo 11 observaciones el histograma es poco informativo. Cuando tenemos más datos, el histograma muestra con mucha más claridad la forma de la distribución. Usaremos a partir de ahora el dataset `penguins`, que contiene medidas de 344 pingüinos de tres especies del archipiélago Palmer (Antártida).

> **Nota**
>
> Para usar el dataset `penguins` es necesario instalar la librería correspondiente la primera vez:
>
> - En Python: `pip install palmerpenguins`
> - En R: `install.packages("palmerpenguins")`

Con 344 observaciones el histograma muestra una forma mucho más clara. En la sección siguiente aprenderemos a interpretar esta forma.

5.9. La forma de los datos

¿Por qué es importante conocer la forma de los datos? Porque la forma nos dice si los datos son homogéneos o si hay grupos distintos mezclados, y eso cambia completamente la interpretación. Imaginemos que medimos la altura de los alumnos de un aula y obtenemos el histograma que ya conocemos: una distribución centrada en torno a 150 cm, aproximadamente simétrica. Ahora imaginemos que en esa misma aula hay tres alumnos de 16 años mezclados con alumnos de 12 años: el histograma mostraría dos grupos claramente separados, y la forma nos estaría diciendo que no estamos ante una población homogénea sino ante dos grupos distintos. Si no miramos la forma y nos quedamos solo con un número resumen, perderíamos esa información fundamental.

Lo mismo ocurre en la industria: si mezclamos en una tabla de datos la producción de dos líneas con ajustes diferentes, o de dos turnos con operarios distintos, o de dos épocas del año con materias primas diferentes, el histograma nos lo mostrará. La forma de los datos es la primera señal de que algo merece una investigación más profunda, antes de hacer ningún cálculo. En el capítulo 8 veremos un caso real de fabricación de queso camembert en el que la forma de los datos nos dará la primera pista sobre una desviación estacional que solo se explica cuando analizamos los datos en el tiempo.

5.9.1. Distribución simétrica

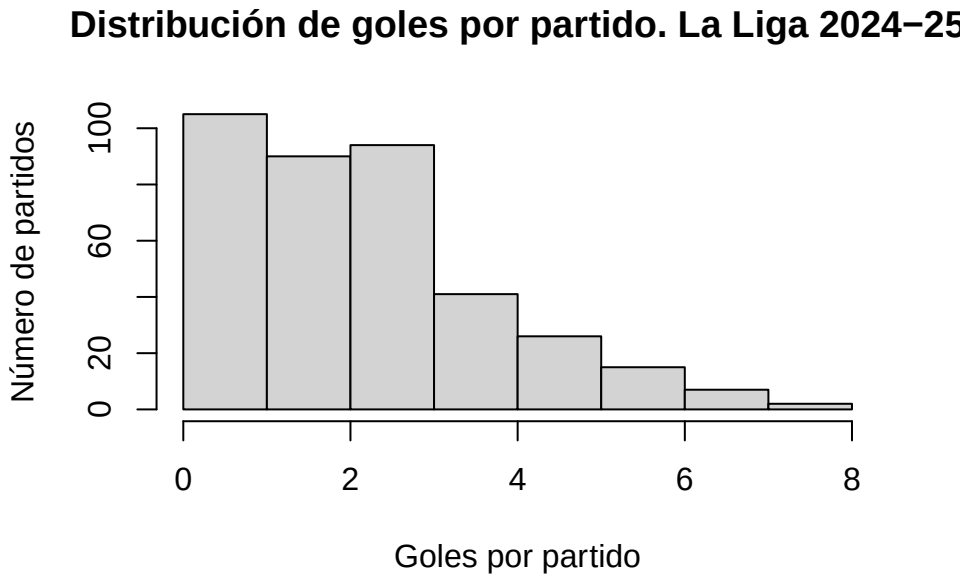
Cuando la mayoría de los valores se concentran en el centro y las frecuencias disminuyen de forma equilibrada hacia ambos lados, decimos que la distribución es **simétrica**. Es el caso más frecuente en medidas de procesos industriales controlados: pesos, temperaturas, extractos secos. El histograma de la longitud de aleta de los pingüinos que acabamos de ver es un buen ejemplo de distribución aproximadamente simétrica.

Esta forma recuerda a una campana, y es la que en estadística se conoce como **distribución normal** o **campana de Gauss**. Volveremos sobre este concepto en el capítulo 7, cuando estudiemos la media y la desviación típica.

5.9.2. Distribución asimétrica

No todas las distribuciones son simétricas. Cuando la mayoría de los valores se concentran en un extremo y la frecuencia disminuye lentamente hacia el otro, decimos que la distribución es **asimétrica**. Un ejemplo muy claro es la distribución de goles por partido en La Liga. El dataset `laliga_resultados2425.csv` contiene los resultados de los 380 partidos de la temporada 2024-25 de la Primera División de fútbol española, con el marcador de cada equipo al final del partido. Se ha elegido este conjunto de datos por su familiaridad para cualquier alumno español y porque la distribución de goles por partido es un ejemplo clásico de asimetría positiva: la mayoría de los partidos terminan con pocos goles, pero ocasionalmente aparecen resultados muy abultados que forman una cola hacia la derecha.

Los resultados proceden de los registros oficiales de LaLiga.

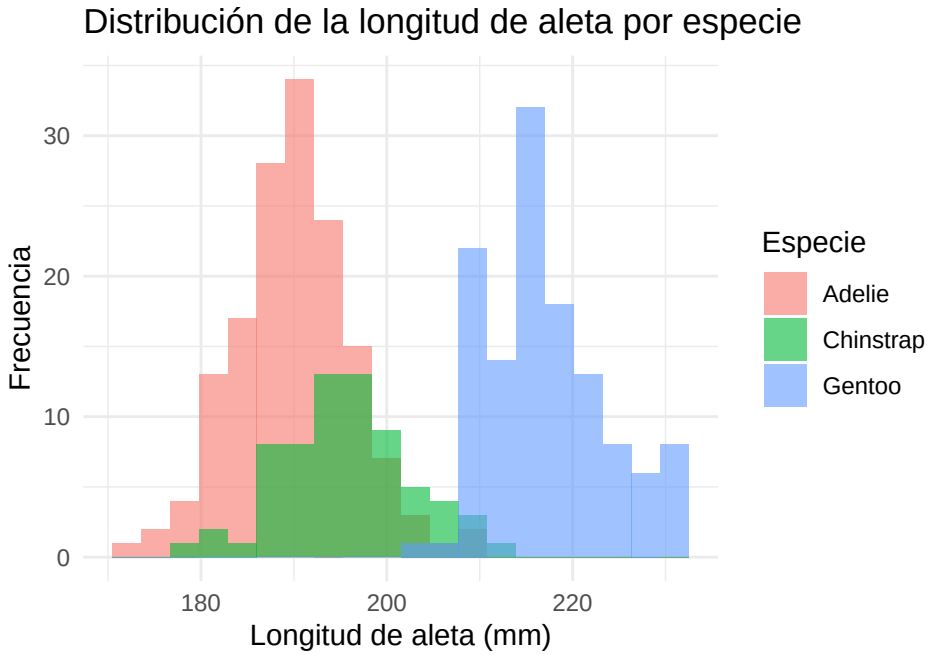


La mayoría de los partidos terminan con pocos goles, y los partidos con muchos goles son cada vez más raros. La distribución tiene una cola larga hacia la derecha: esto es lo que se conoce como **asimetría positiva** o **sesgo positivo**. El valor más frecuente (la **moda**) es más bajo que el valor central, y hay algunos partidos con resultados muy abultados que forman esa cola. En la industria alimentaria encontraremos distribuciones asimétricas positivas con frecuencia en variables como los recuentos de bacterias o los tiempos de avería de una máquina, donde la mayoría de los valores son bajos pero ocasionalmente aparecen valores muy altos.

> **Nota**
>
> Cuando la cola es hacia la derecha (valores altos poco frecuentes) hablamos de **asimetría positiva**. Cuando la cola es hacia la izquierda (valores bajos poco frecuentes) hablamos de **asimetría negativa**. En la práctica industrial, la asimetría positiva es mucho más frecuente que la negativa.

5.9.3. Distribución bimodal

En ocasiones el histograma muestra **dos picos** claramente diferenciados en lugar de uno. Esto se conoce como **distribución bimodal** y suele indicar que los datos provienen de dos grupos distintos que se han mezclado. Si volvemos al histograma de la longitud de aleta de los pingüinos y coloreamos por especie, vemos que lo que parecía una distribución aproximadamente simétrica es en realidad la mezcla de dos grupos:



Cuando en un proceso industrial aparece una distribución bimodal, es casi siempre una señal de que hay dos condiciones de proceso distintas mezcladas en los datos: dos máquinas, dos turnos, dos proveedores de materia prima o dos épocas del año con comportamientos diferentes. Identificar y separar esos grupos es uno de los primeros pasos del análisis.

5.9.4. Valores extremos y su efecto en la forma

Ya hemos visto en la sección del stemplot que algunos valores se separan claramente del resto. Estos valores, que llamamos **valores atípicos** o ***outliers***, afectan a la forma del histograma añadiendo barras aisladas en los extremos. Son importantes porque pueden indicar errores en la toma de datos, condiciones excepcionales del proceso, o simplemente la variabilidad natural de algunos fenómenos.

> **Nota**
>
> La presencia de valores extremos es uno de los motivos por los que la exploración gráfica siempre debe preceder al cálculo de estadísticos. Como veremos en el capítulo 7, los valores extremos tienen una influencia desproporcionada sobre la media y la desviación típica, y pueden llevar a conclusiones erróneas si no se han detectado previamente.

En el capítulo siguiente veremos cómo la forma de los datos se refleja también en el diagrama de caja, y cómo la elección del estadístico más adecuado depende precisamente de esta forma.

5.10. Diagrama de caja o *boxplot*

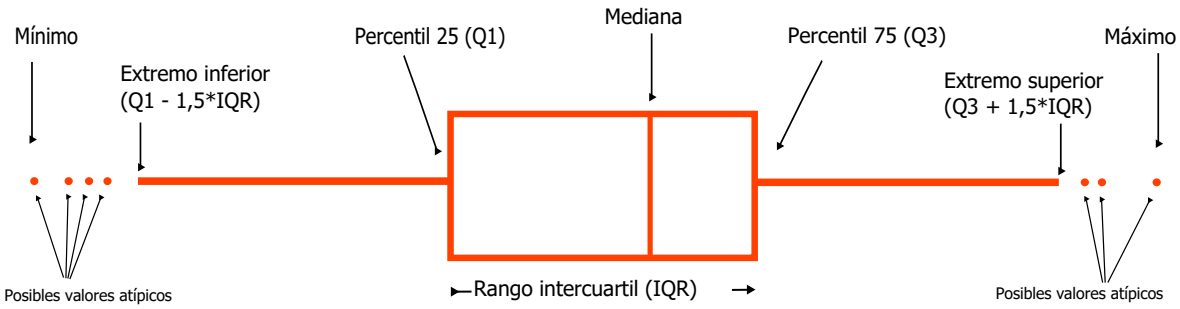
Este gráfico fue creado por el estadístico John Tukey en 1977, y es una herramienta fundamental en la exploración de datos. Se basa en el conjunto de **cuartiles**: si dividimos un grupo de datos **ordenados** en cuatro partes iguales mediante **tres** puntos de corte, llamamos **primer cuartil**

o $Q1$ al valor que se sitúa en el 25 %, **segundo cuartil** o $Q2$ al valor que se sitúa en el centro (50 %), y **tercer cuartil** o $Q3$ al punto que se sitúa en el 75 % de los datos. A estos tres valores añadimos el **mínimo** y el **máximo**, y tenemos un conjunto de **cinco números** que nos permiten describir la forma de la distribución con cierta precisión. El segundo cuartil ($Q2$), que corresponde al 50 % de los datos, se conoce habitualmente como **mediana**. El valor resultante de restar $Q3 - Q1$ es lo que se conoce como **rango intercuartil** o IQR, y es una medida de la dispersión de la distribución.

El **diagrama de caja**, también conocido como *boxplot*, es un gráfico que permite resumir las características principales de un conjunto de datos utilizando estos cinco números. Sus ventajas son:

- Muestra la mediana y los cuartiles (Q1 y Q3) de los datos.
- Permite identificar la simetría de la distribución: si la mediana no está en el centro, la distribución no es simétrica.
- Permite detectar posibles valores atípicos, representando los *outliers* que están lejos del resto de los datos (un valor es atípico si está más allá de $(Q3 + 1{,}5 \cdot IQR)$ o $(Q1 - 1{,}5 \cdot IQR)$).

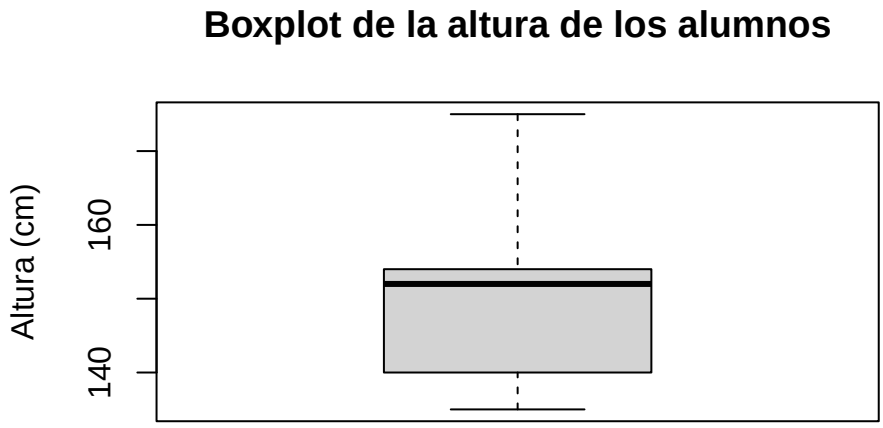
La construcción de un diagrama de caja es como sigue:



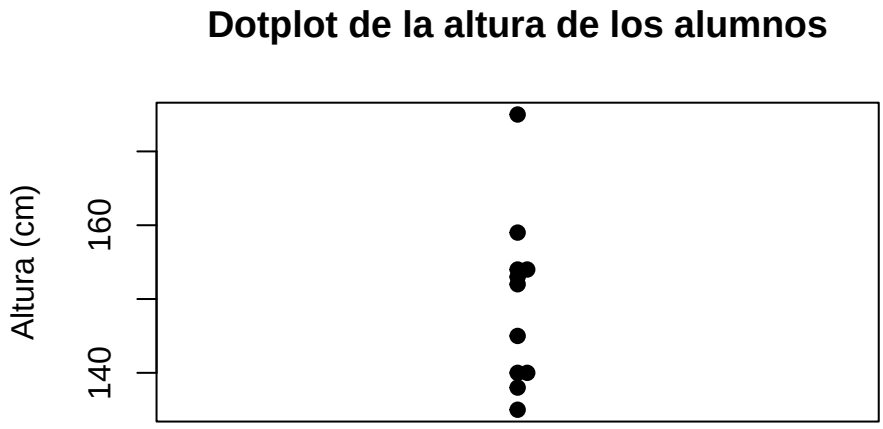
Microsoft Excel no dispone de un diseño de gráficos de caja que sea práctico, por lo que recurriremos siempre a `Python` o `R` para realizarlos.

5.10.1. El boxplot con pocos datos

Empecemos con nuestros datos de altura. Con solo 11 observaciones, el boxplot nos da un resumen numérico correcto, pero oculta la estructura real de los datos:



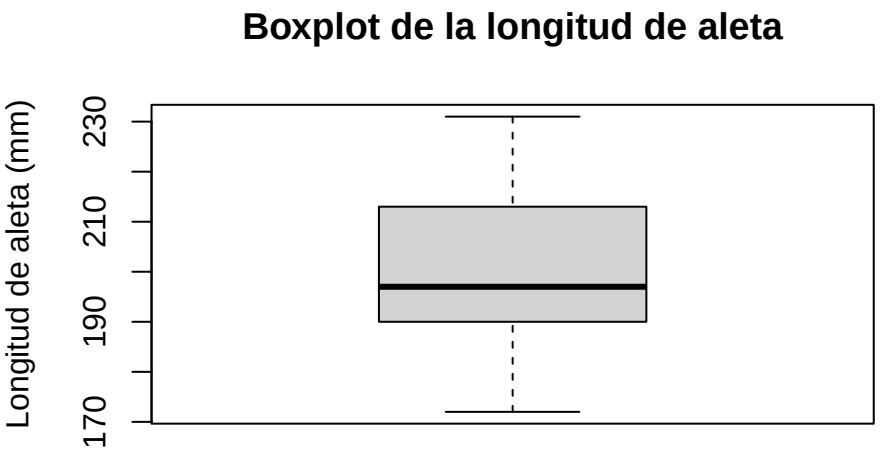
El boxplot nos indica que hay un valor alto que se separa del resto (175 cm), y que la distribución es ligeramente asimétrica. Pero con solo 11 valores, ¿podemos fiarnos de este resumen? La caja representa el 50 % central de los datos, pero ese 50 % son apenas 5 o 6 alumnos. En estos casos es mucho más informativo mostrar los puntos individuales directamente, usando un dotplot:



Con el dotplot vemos exactamente cuántos alumnos hay en cada valor y dónde se concentran, información que el boxplot comprimía en una caja. La regla práctica es sencilla: **con pocos datos, el dotplot es más informativo que el boxplot**; el boxplot cobra todo su sentido cuando tenemos muchas observaciones.

5.10.2. El boxplot con más datos: penguins

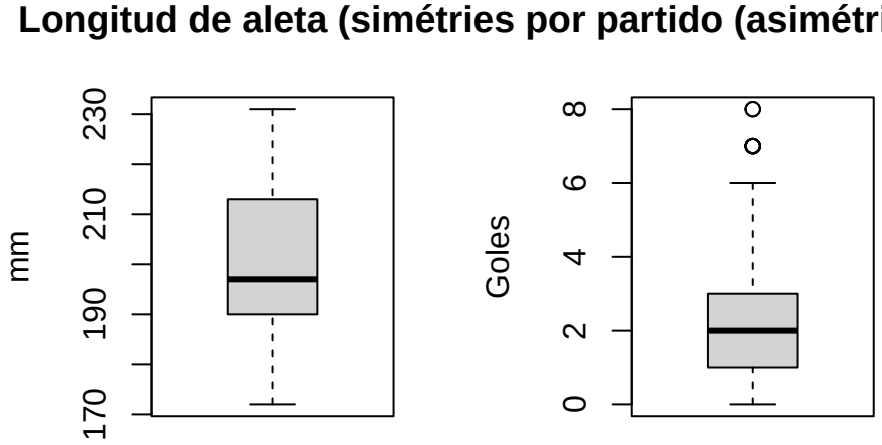
Con un dataset más grande el boxplot muestra toda su utilidad. Usaremos la longitud de aleta del dataset `penguins`. Este *dataset* fue recopilado por la bióloga Kristen Gorman junto al equipo de la estación de investigación Palmer, en la Antártida, entre 2007 y 2009, y publicado en un estudio sobre dimorfismo sexual en pingüinos del género Pygoscelis [13]. Posteriormente, Allison Horst, Alison Hill y Kristen Gorman lo empaquetaron como dataset de referencia para la enseñanza de estadística y visualización de datos, como alternativa al histórico dataset iris de Ronald Fisher. Contiene medidas morfológicas (longitud y profundidad del pico, longitud de aleta y peso corporal) de 344 pingüinos de tres especies (Adelie, Chinstrap y Gentoo) recogidas en tres islas del archipiélago Palmer. Su tamaño moderado, la presencia de valores ausentes reales, la existencia de grupos naturales con solapamiento parcial y la riqueza de relaciones entre variables lo han convertido en uno de los datasets estándar tanto en Python como en R.



5.10.3. La forma de los datos en el boxplot

La forma que vimos en el histograma se refleja directamente en el boxplot. En una distribución simétrica, la mediana está centrada dentro de la caja y los dos bigotes tienen una longitud similar. En una distribución asimétrica, la mediana se desplaza hacia uno de los extremos de la caja y los bigotes tienen longitudes desiguales.

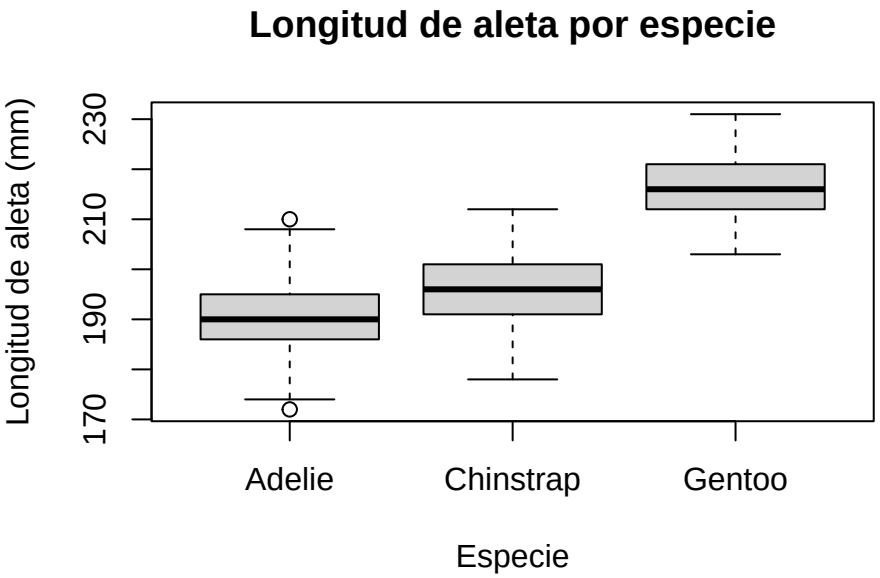
Comparemos el boxplot de la longitud de aleta de penguins (distribución aproximadamente simétrica) con el boxplot de los goles por partido en La Liga (distribución asimétrica positiva):



En el boxplot de los goles vemos claramente la asimetría positiva: la mediana está desplazada hacia la parte inferior de la caja, el bigote superior es mucho más largo que el inferior, y hay varios valores atípicos en la parte alta. En el capítulo 8 veremos cómo esta misma lectura del boxplot nos ayudará a interpretar la variabilidad estacional del extracto seco en la fabricación de queso camembert.

5.10.4. El boxplot por grupos

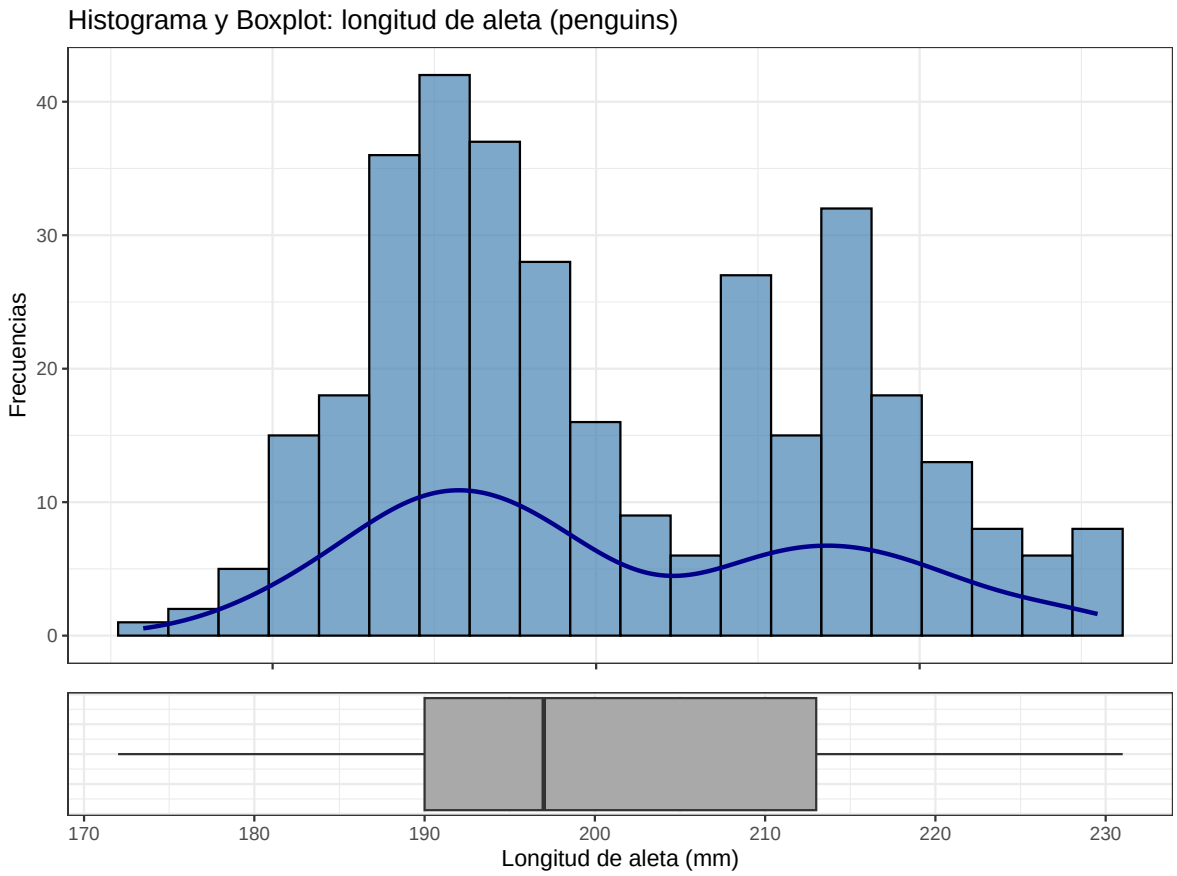
Una de las aplicaciones más útiles del boxplot es la comparación de distribuciones entre grupos. Para ello simplemente indicamos a Python o R qué variable queremos usar como agrupación. Usamos penguins para comparar la longitud de aleta por especie:



Cuando la caja de un grupo se sitúa claramente por encima o por debajo de la caja de otro grupo, las diferencias entre ellos son visualmente significativas. En este caso, los pingüinos *Gentoo* tienen aletas notablemente más largas que los *Adelie* y los *Chinstrap*. En el capítulo 8 usaremos este mismo tipo de gráfico para comparar la composición del queso camembert mes a mes a lo largo del año.

5.10.5. Relación entre el *boxplot* y el histograma

Resulta muy útil comprender visualmente la relación entre el *boxplot* y el histograma para entender la distribución de los datos. La caja del boxplot se corresponde con el 50 % central de los datos, y la línea media representa la mediana. En el gráfico siguiente mostramos ambas representaciones de forma simultánea para la longitud de aleta de penguins:



5.11. Alternativas al boxplot

Beeswarm

El *boxplot* es muy útil para resumir grandes cantidades de información, pero cuando el número de puntos es bajo puede resultarnos más útil la visualización mediante gráficos que muestren los puntos individuales. Entre estas visualizaciones, el gráfico tipo *beeswarm* puede utilizarse en Python mediante la función `swarmplot()` de `seaborn`, o en R mediante la librería `ggbeeswarm`.

El *beeswarm* nos da una distribución aproximada de los valores individuales, colocándolos de forma que se eviten solapamientos.

Stripplot o dotplot

El *stripplot* muestra los puntos en distribución vertical sobre las categorías; para evitar que los puntos con la misma coordenada se solapen, utilizamos la opción *jitter*, que introduce un pequeño ruido aleatorio horizontal.



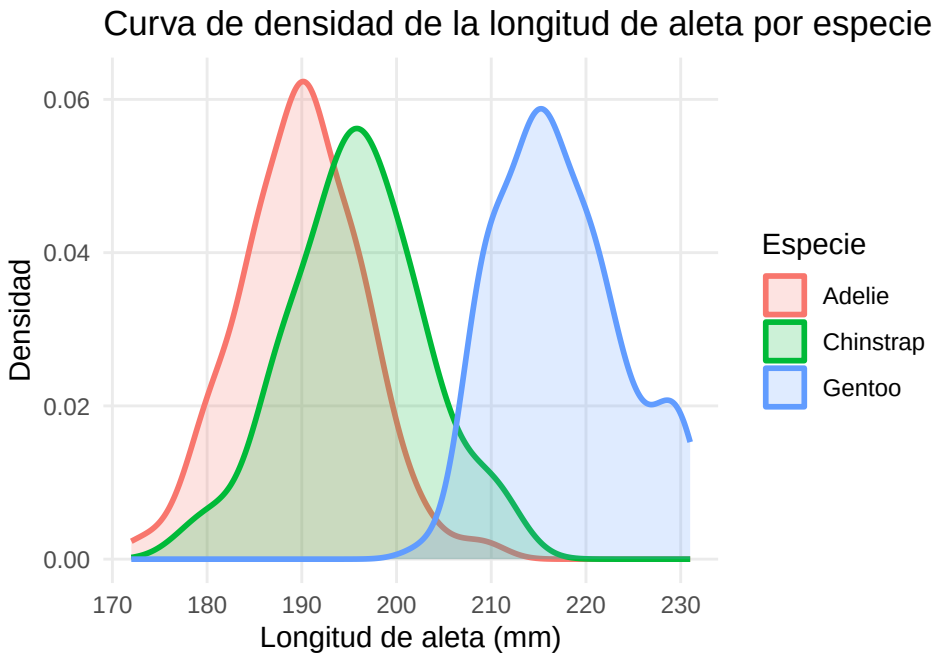
Estos diagramas pueden superponerse al *boxplot*, lo que nos permite completar la visualización de los puntos y la interpretación que hace el *boxplot* de su distribución.

5.12. Gráficos de densidad

Un gráfico de densidad es una representación visual suavizada de la distribución de un conjunto de datos. A diferencia de los histogramas, que dividen los datos en intervalos y cuentan las frecuencias, los gráficos de densidad utilizan técnicas estadísticas no paramétricas para estimar la función de densidad de probabilidad.

Excel no permite la representación de los gráficos de densidad; en `Python` utilizamos `seaborn` y en `R` utilizamos `ggplot2`.

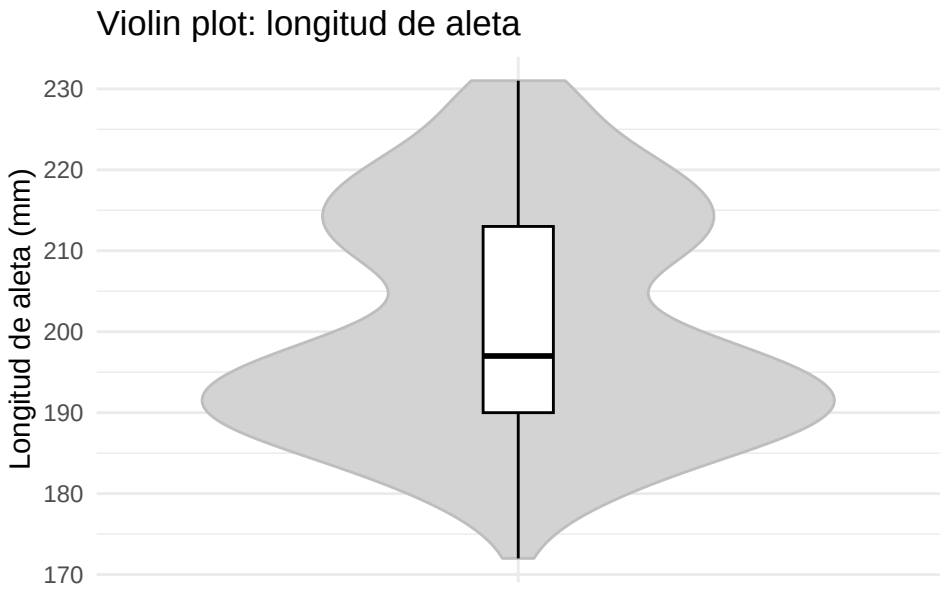
Los gráficos de densidad son especialmente útiles cuando estamos comparando diferentes grupos de datos entre sí. En este caso comparamos la longitud de aleta de los pingüinos por especie:



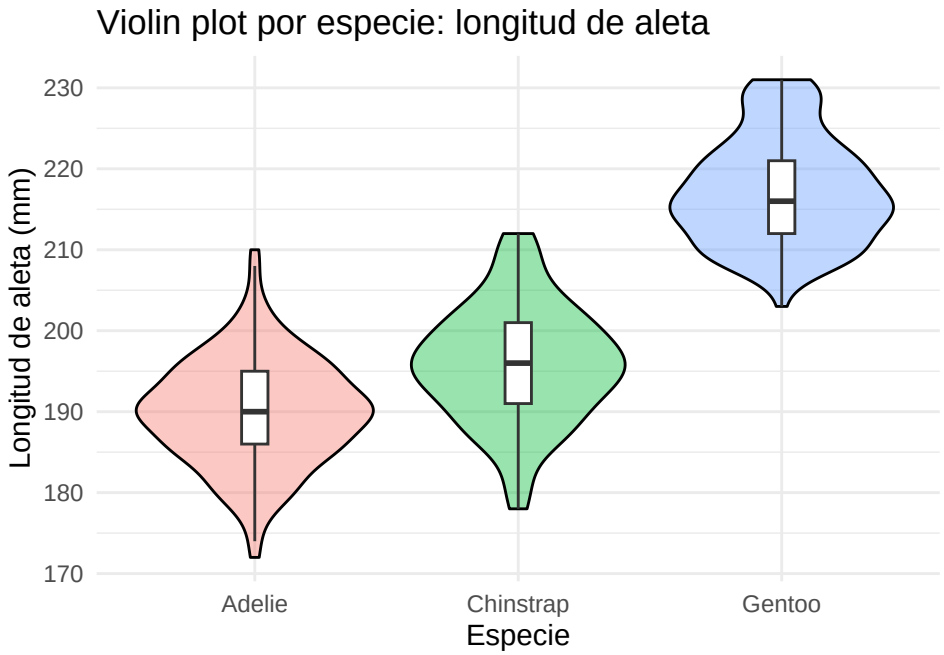
Los gráficos de densidad confirman la bimodalidad que observamos en el histograma: las especies *Adelie* y *Chinstrap* tienen distribuciones solapadas con aletas más cortas, mientras que *Gentoo* tiene aletas claramente más largas.

5.12.1. Otra alternativa al *boxplot*: el *violin plot*

El *violin plot* es una alternativa al *boxplot* que tiene la ventaja de mostrar la *densidad* de la distribución superpuesta al *boxplot*, lo que permite visualizar con más claridad la distribución de los datos:



Tanto el *violin plot* como el *boxplot* se usan muy a menudo para comparar distribuciones de datos. El violin plot múltiple por especie muestra con claridad las diferencias que ya observamos en los gráficos de densidad:



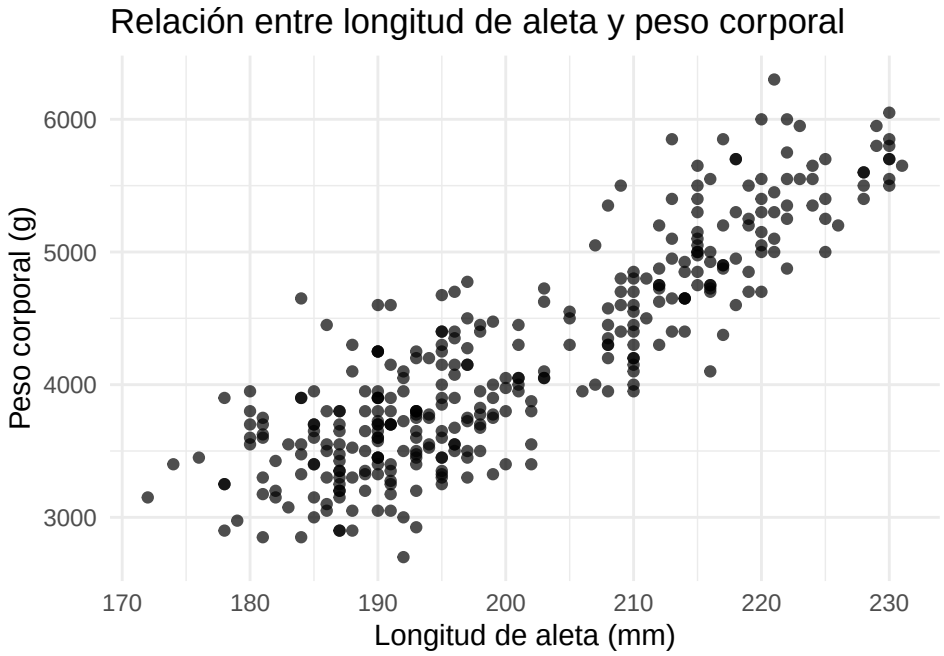
5.13. Gráficos de dispersión

Un gráfico de dispersión, también conocido como diagrama de dispersión o *scatter plot*, es una representación gráfica que utiliza puntos para mostrar la relación entre dos variables numéricas. Cada punto en el gráfico representa una observación del conjunto de datos y se coloca en el plano cartesiano de acuerdo con sus valores en las dos variables que se están comparando.

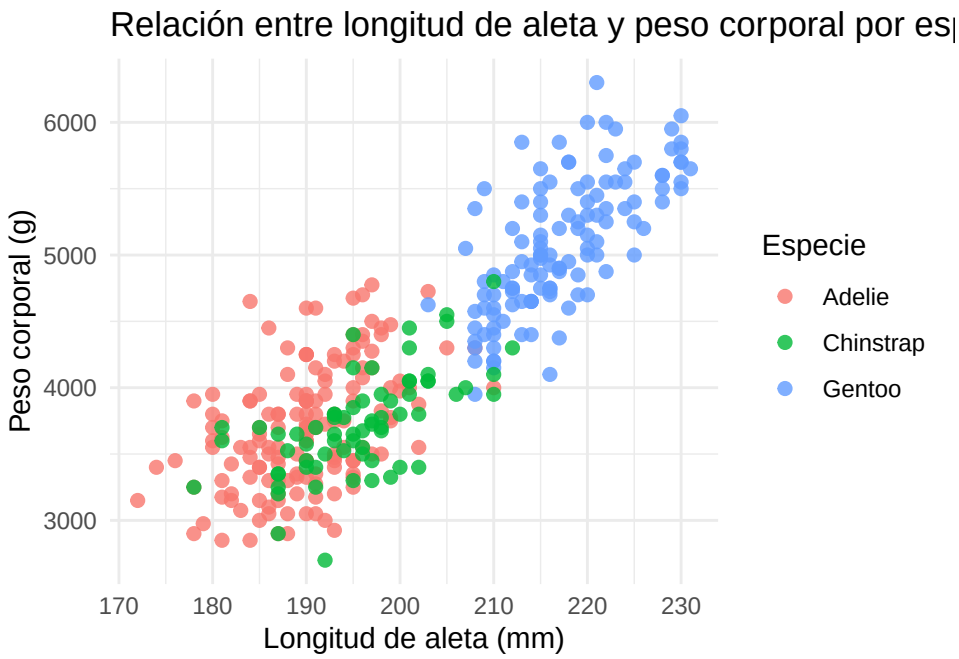
Los gráficos de dispersión son útiles para identificar varios aspectos de la relación entre las dos variables:

- Si los puntos tienden a agruparse a lo largo de una línea recta ascendente, esto indica una **correlación positiva** (a medida que una variable aumenta, la otra también lo hace).
- Si los puntos se agrupan a lo largo de una línea descendente, esto indica una **correlación negativa** (a medida que una variable aumenta, la otra disminuye).
- Si los puntos forman una curva en lugar de una línea recta, esto sugiere una **relación no lineal** entre las variables.
- La dispersión de los puntos puede indicar la variabilidad de los datos. Puntos que están muy lejos del patrón general pueden ser valores atípicos.

Representamos la longitud de aleta y el peso corporal de los pingüinos del dataset `penguins`:



Tanto Python como R nos permiten separar el diagrama de dispersión en función de una tercera variable, en este caso la especie:



Los gráficos de dispersión multiserie no son nativos en Microsoft Excel, pero pueden hacerse con algo de trabajo manual, un poco más complejo que el procedimiento en **Python** o **R** (ver el procedimiento aquí y aquí, y un vídeo con el procedimiento detallado aquí).

Como vemos, los gráficos de dispersión son una herramienta esencial en el análisis exploratorio de datos, ya que permiten visualizar relaciones y patrones, identificar correlaciones y detectar posibles anomalías.

5.14. Gráficos de series temporales

Hasta ahora hemos utilizado gráficos y tablas que describen la estructura y forma de una variable, o las relaciones entre dos variables. Hay otros gráficos que tienen en cuenta la forma en la que esos datos cambian con el tiempo. En este caso, será necesario que hayamos recogido en una variable de nuestra tabla los intervalos de tiempo en los que se han producido nuestros valores.

Algunos ejemplos:

- proceso de llenado de envases de queso crema: se llena una tarrina cada 15 segundos. Nuestros datos deben recoger el tiempo y el peso.
- el registro diario de temperatura en una cámara de maduración.
- el seguimiento mensual de la temperatura media exterior en una zona geográfica.

En un gráfico de series temporales:

- el eje horizontal (X) representa el tiempo. Los puntos de tiempo pueden ser minutos, horas, días, meses, años, etc.
- el eje vertical (Y) representa los valores de la variable que se está estudiando.
- los valores se conectan mediante una línea que muestra cómo cambia la variable a lo largo del tiempo.
- normalmente no suelen representarse los puntos individuales para facilitar la legibilidad del gráfico.

Cuando representamos valores en el tiempo, nunca usaremos el diagrama de barras, sino el gráfico de líneas.

Usaremos el dataset de **temperatura media mensual de Oviedo entre 2020 y 2024**, que está en el fichero `oviedo_temperatura.csv`. Este *dataset* contiene la temperatura media mensual registrada en Oviedo entre 2020 y 2024, con un total de 60 observaciones. Los datos proceden de los registros de AEMET (Agencia Estatal de Meteorología) y se han utilizado por su proximidad geográfica y por ilustrar con claridad dos patrones habituales en las series temporales industriales: la estacionalidad regular (el ciclo anual de temperaturas) y la tendencia a largo plazo, en este caso un ligero incremento de las temperaturas medias a lo largo del período.

5.14.1. Cómo hacer los gráficos de series temporales en Excel

Para hacer el gráfico en Excel, seleccionamos la columna `temperatura` e insertamos un gráfico de líneas. A continuación, con el cursor sobre el gráfico, pulsamos el botón derecho y seleccionamos la opción `Seleccionar datos`. Una vez abierto el cuadro de opciones, editamos las etiquetas del eje X y seleccionamos el rango de la variable `fecha` desde la fila 2 hasta la última. Aceptamos, y a continuación editamos el formato del eje Y para ajustar la escala a los valores de temperatura.

5.14.2. Gráficos de series temporales en `Python` utilizando `pandas`

En los procesos industriales, el manejo de datos que cambian con el tiempo (**series temporales**) es fundamental. Hablamos de registrar **temperaturas** en un proceso de cocción, el **pH** de una fermentación a lo largo de las horas o días, o la **evolución de inventarios** de productos perecederos.

Para abordar este análisis de manera **eficiente y sencilla**, la biblioteca `pandas` de Python es la herramienta de referencia. Esto nos ofrece una serie de ventajas clave:

1. **Fácil Indexación Temporal:** Pandas permite que la fecha y hora sean el "índice" principal de los datos, simplificando el filtrado y la selección por rangos.
2. **Remuestreo (Resampling) Sencillo:** Pandas permite cambiar la frecuencia de los datos con una única función, lo que es vital para suavizar el "ruido" y ver la tendencia real del proceso.
3. **Ventanas Móviles (`rolling`):** Permite calcular promedios móviles o desviaciones estándar sobre un periodo de tiempo definido, crucial para el control de calidad.

5.14.3. Construyendo la serie temporal con `pandas`

Creamos el índice temporal y representamos la serie:

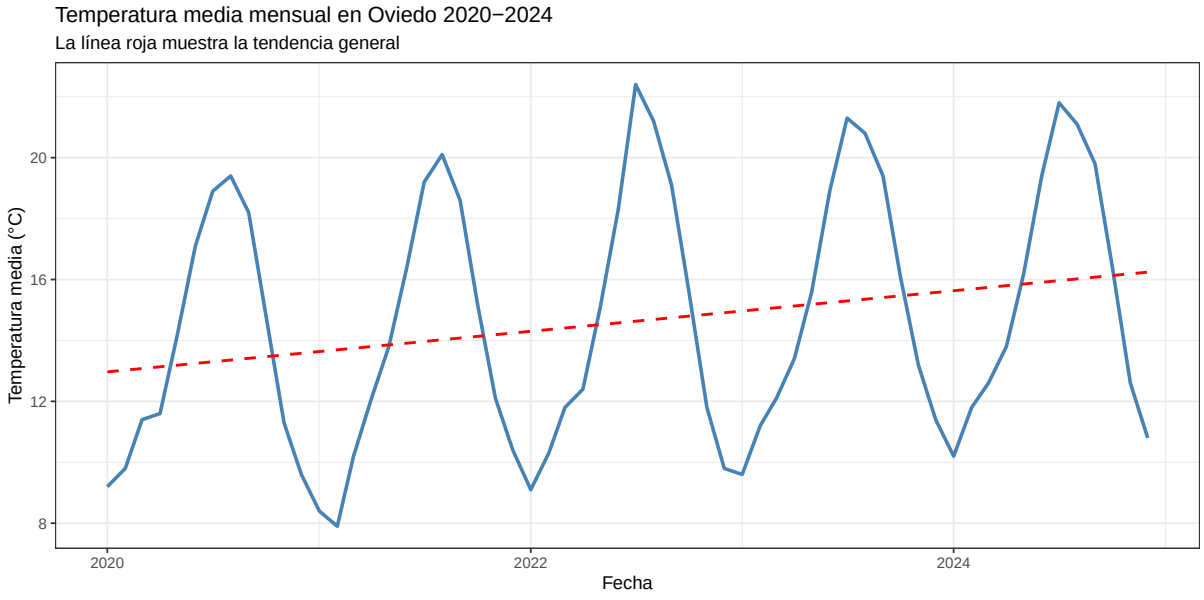
El gráfico muestra con claridad la **estacionalidad** anual: temperaturas bajas en invierno y altas en verano, con un patrón que se repite cada año. Además, si observamos con atención, podemos apreciar una ligera **tendencia creciente** a lo largo del período, que refleja el calentamiento registrado en los últimos años. Los gráficos de series temporales son capaces de mostrar simultáneamente estos dos patrones: la variación estacional a corto plazo y la tendencia a largo plazo.

Podemos calcular y representar la media anual para visualizar mejor la tendencia:

Y podemos hacer zoom en un período concreto para analizar con más detalle:

> **Sugerencia**
>
> Se recomienda copiar el código y pegarlo en ChatGPT o Gemini para explicarlo en detalle. Utiliza el texto de la nota de aviso que dimos al principio del capítulo para pedir que explique el código.

A continuación, el gráfico realizado con R.



5.14.4. Resumen

Los gráficos de series temporales son la herramienta fundamental para el seguimiento y control de los procesos industriales. Permiten identificar tendencias a largo plazo, detectar estacionalidad (variaciones ligadas al ciclo productivo o a la época del año) y localizar anomalías puntuales que pueden indicar incidencias en el proceso o errores en la toma de datos. En la industria alimentaria, donde variables como temperatura, pH, extracto seco o rendimiento se registran de forma continua o periódica, la representación temporal es con frecuencia el primer paso del análisis antes de aplicar cualquier otra herramienta estadística.

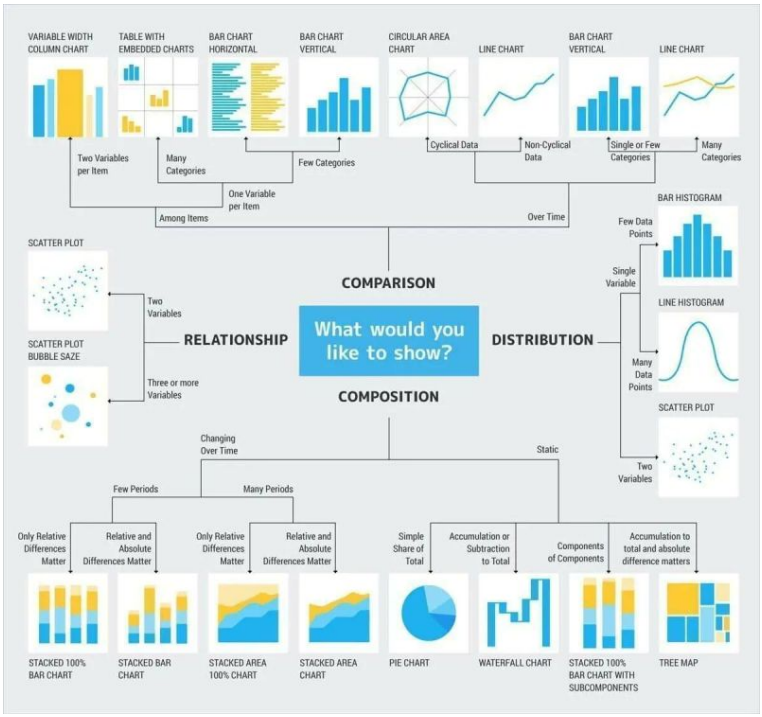
5.15. Algunas sugerencias para la creación de gráficos

Algunos sitios tienen ejemplos de gráficos que puede resultar útil revisar:

- Galería de `matplotlib`, gran cantidad de ejemplos en Python
- Galería de `seaborn`, una extensa galería de gráficos hechos con esta librería Python
- Python Graph Gallery, otra extensa galería de gráficos en Python
- The R Graph Gallery, una galería de gráficos hechos con R
- R-charts es una galería de gráficos R creada por un español, José Carlos Soage.
- ggplot2: Elegant Graphics for Data Analysis para profundizar en ggplot2, el libro de referencia de Hadley Wickham, de acceso libre en web
- R for Data Science, cap. Visualización, introducción práctica a ggplot2 en contexto de análisis de datos
- Tidyplots utiliza la librería `tidyplots` en R para realizar de forma sencilla gran cantidad de gráficos, simplificando la sintaxis de ggplot2.

Una de las guías más conocidas y seguidas para la creación de gráficos es el vocabulario visual del Financial Times, disponible en https://ft-interactive.github.io/visual-vocabulary/

También esta guía proporciona información sobre el uso adecuado de cada tipo de gráfico, facilitando la elección según el objetivo perseguido


What would you like to show?
COMPARISON
RELATIONSHIP
DISTRIBUTION
COMPOSITION
VARIABLE WIDTH COLUMN CHART
TABLE WITH EMBEDDED CHARTS
BAR CHART HORIZONTAL
BAR CHART VERTICAL
CIRCULAR AREA CHART
LINE CHART
BAR CHART VERTICAL
LINE CHART
Two Variables per Item
Many Categories
Few Categories
One Variable per Item
Among Items
Cyclical Data
Non-Cyclical Data
Over Time
Single or Few Categories
Many Categories
BAR HISTOGRAM
Few Data Points
Single Variable
LINE HISTOGRAM
Many Data Points
SCATTER PLOT
Two Variables
SCATTER PLOT
Two Variables
SCATTER PLOT BUBBLE SAZE
Three or more Variables
Changing Over Time
Static
Few Periods
Many Periods
Only Relative Differences Matter
Relative and Absolute Differences Matter
Only Relative Differences Matter
Relative and Absolute Differences Matter
Simple Share of Total
Accumulation or Subtraction to Total
Components of Components
Accumulation to total and absolute difference matters
STACKED 100% BAR CHART
STACKED BAR CHART
STACKED AREA 100% CHART
STACKED AREA CHART
PIE CHART
WATERFALL CHART
STACKED 100% BAR CHART WITH SUBCOMPONENTS
TREE MAP



5.16. Resumen del capítulo

La visualización gráfica es la herramienta más directa para explorar un conjunto de datos antes de aplicar cualquier análisis estadístico. El stemplot permite obtener una visión rápida de la distribución de datos pequeños manteniendo los valores originales, aunque su uso ha quedado desplazado por herramientas gráficas más potentes. Las tablas de distribución de frecuencias organizan los datos en intervalos y permiten calcular frecuencias absolutas, relativas y acumuladas; pueden construirse en Excel mediante tablas dinámicas, o en Python y R mediante código reproducible y auditable.

El histograma es el gráfico estándar para representar la distribución de variables continuas. La forma del histograma nos informa sobre la naturaleza de los datos: una distribución simétrica indica homogeneidad, una distribución asimétrica señala que los valores extremos son frecuentes en uno de los lados, y una distribución bimodal revela la presencia de dos grupos distintos mezclados en los datos. El diagrama de barras se reserva para variables discretas o categóricas. El boxplot resume la distribución mediante cinco números (mínimo, Q1, mediana, Q3, máximo), refleja la forma de la distribución a través de la posición de la mediana y la longitud de los bigotes, y señala automáticamente los valores atípicos; con pocos datos es preferible usar el

dotplot, que muestra los valores individuales. Para conjuntos de datos mayores pueden utilizarse alternativas como el beeswarm, el stripplot o el violin plot, que combinan el resumen estadístico con la visualización de los puntos individuales.

Los gráficos de densidad, disponibles en Python mediante seaborn y en R mediante ggplot2, ofrecen una representación suavizada de la distribución y resultan especialmente útiles para comparar grupos. Los gráficos de dispersión permiten visualizar la relación entre dos variables numéricas e identificar correlaciones, relaciones no lineales y valores atípicos; Python y R facilitan la segmentación por una tercera variable, lo que en Excel requiere un trabajo manual adicional. Los gráficos de series temporales representan la evolución de una variable en el tiempo y permiten identificar simultáneamente la estacionalidad y la tendencia a largo plazo; pandas en Python proporciona funciones de remuestreo que simplifican este análisis, con equivalentes en R mediante dplyr y lubridate. El capítulo concluye con referencias a galerías de ejemplos en Python y R y a guías de selección del tipo de gráfico según el objetivo del análisis.

6. Medidas centrales y medidas de dispersión: la media y la varianza.

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Calcular la media aritmética de un conjunto de datos e interpretar su significado como valor central de la distribución.
- Explicar por qué la media por sí sola es insuficiente para describir un conjunto de datos, mediante ejemplos con la misma media y distribuciones distintas.
- Deducir el concepto de varianza a partir del problema de las diferencias que se anulan, y relacionarlo con la fórmula de la distancia entre dos puntos.
- Calcular la varianza y la desviación típica de un conjunto de datos en Excel, e interpretar su significado como medida de dispersión.
- Distinguir entre estadísticos paramétricos (media, desviación típica) y no paramétricos (mediana, rango intercuartil), e identificar en qué condiciones es más adecuado el uso de cada uno.
- Reconocer la influencia de los valores atípicos sobre la media y la desviación típica, y relacionar este comportamiento con la elección del estadístico más apropiado.
- Relacionar los estadísticos paramétricos con la distribución normal y los no paramétricos con el diagrama de caja estudiado en el capítulo anterior.

Conceptos clave: **media aritmética, valor central, dispersión, varianza, desviación típica, estadístico paramétrico, estadístico no paramétrico, mediana, rango intercuartil, valor atípico (outlier), distribución normal, campana de Gauss, robustez**

6.1. Introducción

Al estudiar el diagrama de caja (*boxplot*) hemos visto que este gráfico se describe mediante los **cinco números**, que son:

- mínimo y máximo,
- primer y tercer cuartil (25 % y 75 %), y
- segundo cuartil (50 %).

De estos valores, el segundo cuartil, que se corresponde con la mitad de los valores, representa una estimación del centro de la distribución, y por eso lo llamamos **mediana**. La distancia entre el primer y tercer cuartil es lo que se conoce como **rango intercuartil** (se suele representar por sus siglas en inglés, **IQR**), y nos da una indicación de la **dispersión**: cuanto mayor mayor es

la dispersión de nuestros valores, más alejados estarán del centro, y por lo tanto habrá mayor distancia entre el primer y el tercer cuartil.

Una de las mayores ventajas de la mediana y del rango intercuartil es que son estadísticos robustos, es decir, tiene una alta robustez a los valores atípicos. Como en el cálculo del rango intercuartil no se tienen en cuenta los valores extremos, su valor variará muy poco si aparecen nuevas observaciones atípicas (outliers). Como sus valores no dependen de la distribución de los datos, a estos estadísticos se los conoce como **no paramétricos**.

Existen otras estadísticos, llamados **paramétricos**, que, en determinadas condiciones, tienen ventajas frente a los no paramétricos. Los principales son la **media aritmética**, o simplemente, **media**, y la **varianza**.

6.2. Recursos utilizados

En este ejercicio usaremos diversos datos y gráficas realizados en Excel. Para facilitar el análisis, puede descargarse esta hoja Excel, con muchas tablas y gráficos, en el enlace a continuación.

Descargar hoja Excel

6.3. La media aritmética: un ejemplo de cálculo.

6.3.1. Definición

La media aritmética de un conjunto de valores es el valor central que se obtiene al dividir la suma de todos los valores por la cantidad de valores. Es una medida de tendencia central que proporciona un punto de referencia para el conjunto de datos.

6.3.2. Deducción de la Fórmula:

Supongamos que tenemos un conjunto de n valores numéricos: $x_1, x_2, x_3, \ldots, x_n$.

1. **Suma de Todos los Valores**: Primero, sumamos todos los valores del conjunto. Matemáticamente, esto se expresa como:

$$S = x_1 + x_2 + x_3 + \cdots + x_n$$

2. **Cantidad de Valores**: Luego, contamos cuántos valores hay en el conjunto. Este número es n.

3. **División de la Suma por la Cantidad de Valores**: Finalmente, dividimos la suma total S por la cantidad de valores n para obtener la media aritmética:

$$\text{Media Aritmética} = \frac{S}{n}$$

4. **Expresión General**: Sustituyendo la suma S en la fórmula, tenemos:

$$\text{Media Aritmética} = \frac{x_1 + x_2 + x_3 + \cdots + x_n}{n}$$

6.3.3. Ejemplo:

Supongamos que tenemos los siguientes valores: $5, 7, 9$.

1. **Suma de los Valores**:
$$S = 5 + 7 + 9 = 21$$

2. **Cantidad de Valores**:
$$n = 3$$

3. **Cálculo de la Media Aritmética**:
$$\text{Media Aritmética} = \frac{21}{3} = 7$$

Entonces, la media aritmética de los valores $5, 7, 9$ es 7.

La media de una muestra se representa habitualmente mediante el símbolo

$$\bar{x}$$

y, de una manera más formal, su valor se obtiene mediante la fórmula siguiente:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

El signo $\sum$ se conoce como *sumatorio*, e indica que ese término consiste en la suma de los x valores desde el primero hasta el valor n. Expresado mediante una formulación matemática,

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

lo quiere quiere decir: *"la suma de todos los valores observados dividido entre el número de estos valores"*.

La **media** es lo que conocemos como un *valor central*, ya que representa el centro de nuestro conjunto de números. Como es el centro de nuestro conjunto de datos, la suma de las distancias de todos los valores a este valor central es *cero*. Más adelante veremos la importancia de este hecho, al hablar de la dispersión y las formas de cálculo de la misma. Como hemos visto, la media de una **muestra** se representa como $\bar{x}$, mientras que la media de una **población** se representa con la letra griega *mu*: μ. En ambos casos, el cálculo se realiza de forma idéntica.

Volvamos a nuestro ejemplo de la altura de un grupo de alumnos, para realizar los cálculos según el modelo que hemos descrito. En nuestro caso, la *altura media* de nuestros alumnos (la *media* de nuestro conjunto de números) se calcula como:

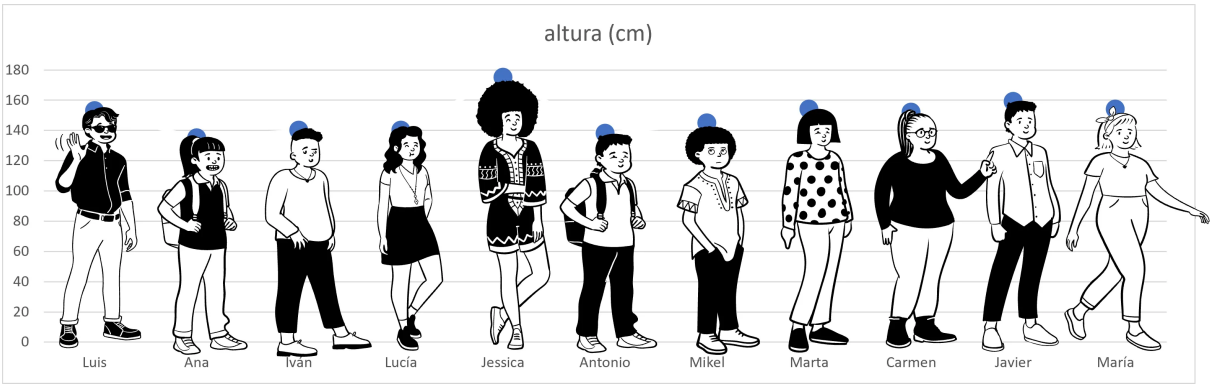
$$\bar{x} = \frac{153 + 135 + 140 + 140 + 175 + 138 + 145 + 154 + 152 + 159 + 154}{11} = 149,54$$

Utilicemos una hoja de cálculo para guardar nuestros valores.

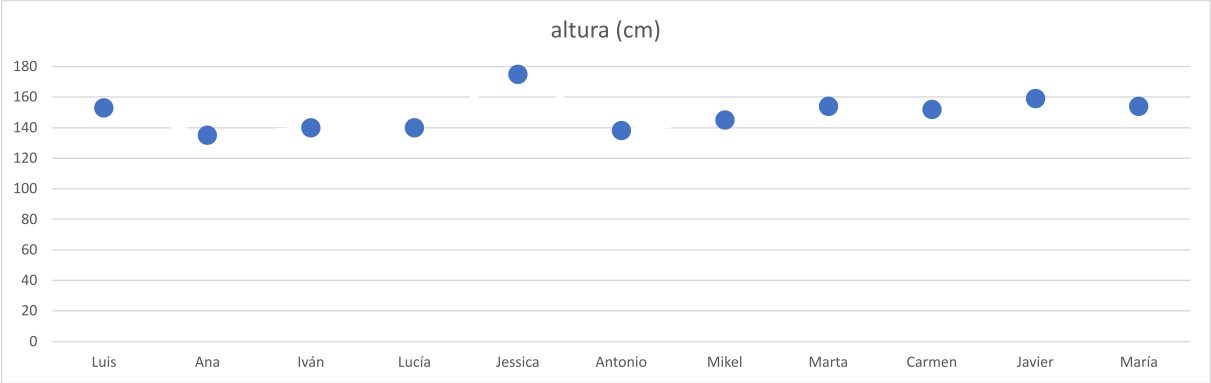
	A	B	C	D
1	nombre	altura_cm		
2	Luis	153		
3	Ana	135		
4	Iván	140		
5	Lucía	140		
6	Jessica	175		
7	Antonio	138		
8	Mikel	145		
9	Marta	154		
10	Carmen	152		
11	Javier	159		
12	María	154		
13				
14				
15				

La fórmula para obtener la media en la hoja de cálculo, por ejemplo en la versión en español de *Microsoft Excel*, es `=PROMEDIO(...)`, donde los puntos suspensivos deben sustituirse por el rango a calcular. En nuestro ejemplo, introduciríamos la fórmula en la celda `B13`como `=PROMEDIO(B2..B12)` (Para más detalles, verificar la hoja Excel adjunta).

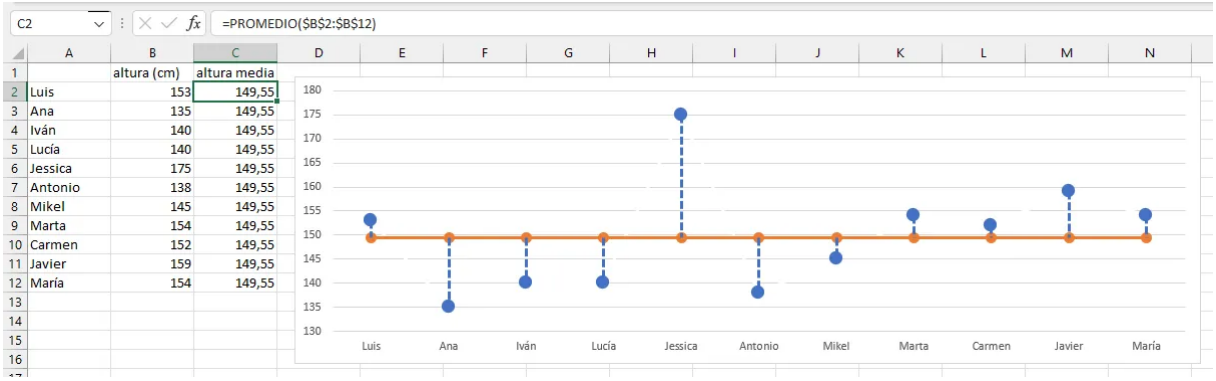
Para representar más cómodamente nuestros valores, dibujamos un punto a la altura de cada alumno,



y eliminamos del gráfico los dibujos de nuestros alumnos; así hemos convertido nuestro dibujo en un *diagrama de puntos*:



Para representar la media, aunque la media es un valor único, necesitamos añadir una columna a la derecha de nuestros datos, que rotulamos en la fila 1, celda C como `altura media`, e introducimos en cada una de las celdas desde `C2`hasta `C12`la fórmula del promedio, con el valor de nuestro rango de datos (Verificar hoja de cálculo). A continuación, designamos nuestro rango de datos para hacer un gráfico de puntos, y hacemos un *zoom* en los valores de manera que el eje Y se escale mejor entre los valores mínimo y máximo. Por último, hacemos unos ajustes en el formato para dibujar las líneas verticales que nos representan la distancia de cada valor a la media.



Si verificamos el eje Y , veremos que en este gráfico hemos ajustado la escala respecto al gráfico anterior, situando el mínimo en 130. Esto permite visualizar las diferencias con mucha más claridad. Hemos representado la media $\bar{x}$ como una línea, y hemos dibujado unas líneas que unen cada valor individual con la media, que se sitúa en el valor $149,55$, tal como calculamos más arriba.

Hemos representado la media como una serie de puntos unidos por una línea amarilla. Representamos en azul nuestros valores, uniendo cada valor con la línea media mediante una línea de puntos vertical. A partir de ahora, por conveniencia, eliminaremos los puntos en la linea media, dejando sólo la línea.

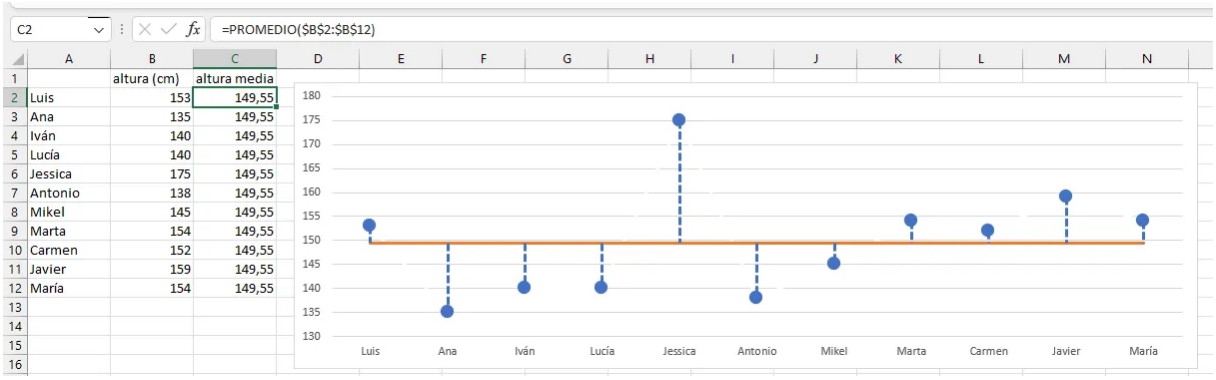


Figura 6.1.: Hoja de cálculo con los valores y el gráfico de puntos

Esta línea azul de puntos representa la *distancia* de cada valor a la media. Usaremos esta distancia para calcular una **distancia media**, que será una medida de la dispersión de nuestros valores.

Hemos visto que para describir un conjunto de números, en nuestro ejemplo, las medidas de la altura de un grupo de estudiantes, existe un valor, la *media* de este conjunto, que nos describe el centro de los valores. En nuestro ejemplo, si nuestro grupo tuviese un solo niño, éste tendría $149,55$ *cm* de altura.

¿Es suficiente con este valor para describir el conjunto de valores? Vamos a ver que no: diferentes conjuntos de valores pueden proporcionar el mismo *valor medio*, y sin embargo los grupos pueden ser muy diferentes.

Veamos un caso extremo. Comparemos dos grupos, uno formado por individuos iguales y otro formado por diez individuos iguales y uno distinto. Para ello usaremos nuestra hoja de cálculo:

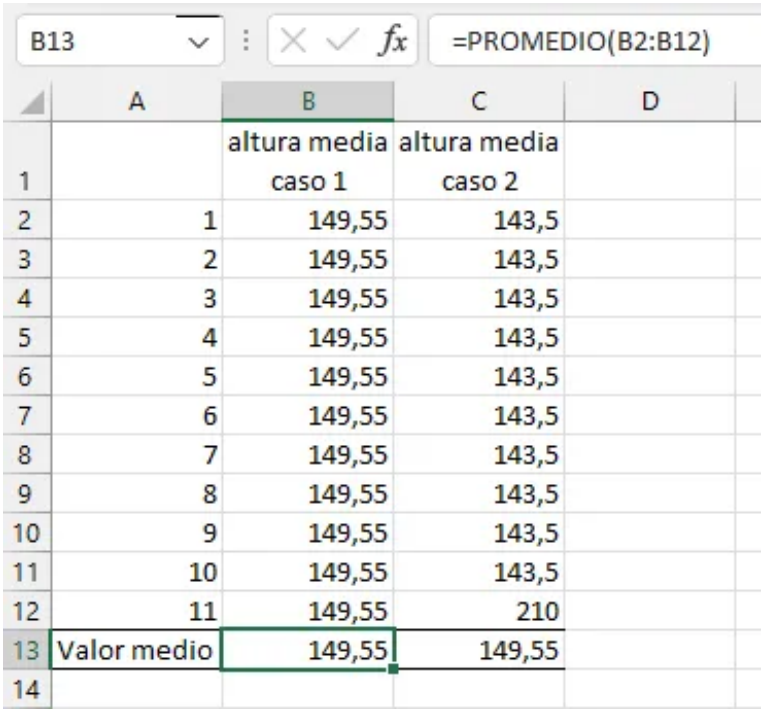


Figura 6.2.: Dos grupos de valores con la misma media

¿Podemos describir adecuadamente los valores de la altura de cada uno de los grupos utilizando el valor medio? Parece evidente que no, ya que a partir de diferentes valores de altura estamos obteniendo el mismo valor medio. Sin embargo, uno de los grupos *es más alto* que el otro, si no fuera por un sólo individuo que aparentemente distorsiona el cálculo. Podríamos incluir nuestro grupo original, y veremos que los tres grupos son diferentes, aunque su valor medio es idéntico.

D13 | =PROMEDIO(D2:D12)

	A	B	C	D
1		altura media caso 1	altura media caso 2	altura (datos originales)
2	1	149,55	143,5	153
3	2	149,55	143,5	135
4	3	149,55	143,5	140
5	4	149,55	143,5	140
6	5	149,55	143,5	175
7	6	149,55	143,5	138
8	7	149,55	143,5	145
9	8	149,55	143,5	154
10	9	149,55	143,5	152
11	10	149,55	143,5	159
12	11	149,55	210	154
13	Valor medio	149,55	149,55	149,55

Figura 6.3.: Tres grupos de valores con la misma media

Si nos ayudamos de un gráfico equivalente al que hemos utilizado antes, vemos estas diferencias con claridad:

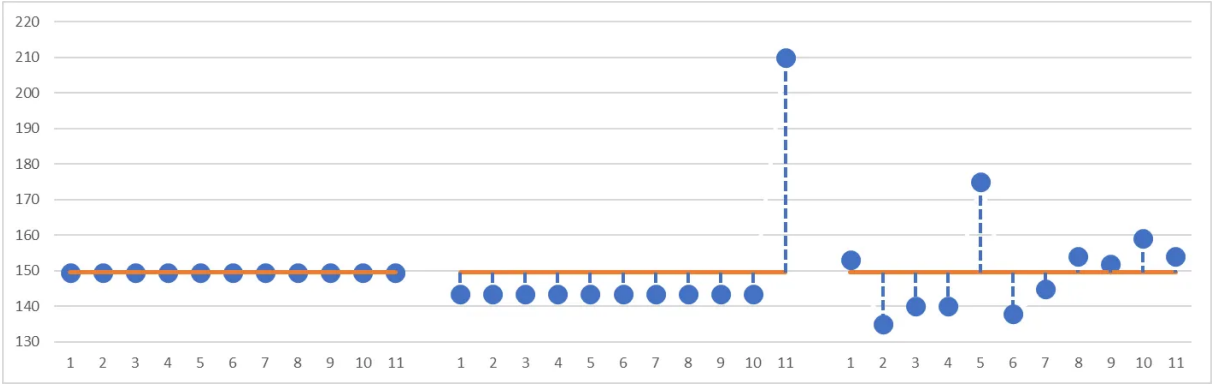


Figura 6.4.: Gráfico de tres grupos de valores

Aunque el valor medio de estos tres grupos de datos es idéntico, parece claro que los tres grupos son muy distintos en su composición, y por lo tanto la *media* no es suficiente para describir con suficiente precisión cada uno de los grupos. Necesitamos un valor adicional, que nos indique de

qué forma los valores se alejan del valor medio. Para ello, vamos a introducir un concepto nuevo: la *medida de la dispersión*.

6.4. Las medidas de dispersión: la varianza y la desviación típica

Como hemos visto en el apartado anterior, diferentes conjuntos de datos pueden tener el mismo valor medio y sin embargo ser muy diferentes. En la última gráfica que hemos visto, el primer grupo se caracteriza por tener todos sus valores idénticos; el segundo tiene todos sus valores idénticos menos uno, que está muy apartado del resto, y el tercero tiene todos sus valores diferentes.

Ahora que conocemos cómo calcular un valor resumen de un conjunto de datos, podríamos utilizar una medida semejante para describir de qué forma en cada caso los valores se separan de la media. Podríamos utilizar una *distancia media*: calculamos las diferencias entre cada valor y la media, y hacemos su promedio: esto debería darnos una indicación de la magnitud de la separación de los valores en cada uno de los tres grupos.

Usemos la hoja de cálculo para ello:

D14 =PROMEDIO(D2:D12)

	A	B	C	D	E	F	G	H	I	J	K	L
1		altura media caso 1	media del grupo	diferencia		altura media caso 2	media del grupo	diferencia		altura (datos originales)	media del grupo	diferencia
2	1	149,5454545	149,55	0,00		143,5	149,55	-6,05		153	149,55	3,45
3	2	149,5454545	149,55	0,00		143,5	149,55	-6,05		135	149,55	-14,55
4	3	149,5454545	149,55	0,00		143,5	149,55	-6,05		140	149,55	-9,55
5	4	149,5454545	149,55	0,00		143,5	149,55	-6,05		140	149,55	-9,55
6	5	149,5454545	149,55	0,00		143,5	149,55	-6,05		175	149,55	25,45
7	6	149,5454545	149,55	0,00		143,5	149,55	-6,05		138	149,55	-11,55
8	7	149,5454545	149,55	0,00		143,5	149,55	-6,05		145	149,55	-4,55
9	8	149,5454545	149,55	0,00		143,5	149,55	-6,05		154	149,55	4,45
10	9	149,5454545	149,55	0,00		143,5	149,55	-6,05		152	149,55	2,45
11	10	149,5454545	149,55	0,00		143,5	149,55	-6,05		159	149,55	9,45
12	11	149,5454545	149,55	0,00		210	149,55	60,45		154	149,55	4,45
13												
14			Promedio	0,00			Promedio	0,00			Promedio	0,00

Figura 6.5.: Tres grupos de valores en la hoja de cálculo

Algo parece que no está funcionando aquí: el promedio de las diferencias es cero en los tres casos; no podemos usar este cálculo para calcular la dispersión. Pero esto es esperable: ya que la media es un valor central, como hemos visto antes, la suma de las diferencias de todos los valores respecto de su media debe ser forzosamente cero, y esto es lo que estamos obteniendo.

Para encontrar una solución, vamos a recurrir al viejo teorema de Pitágoras, que si recuerdas, nos dice que, en un triángulo rectángulo, el cuadrado de la hipotenusa es igual a la suma de los cuadrados de los catetos (una explicación gráfica muy divertida en el anexo …):

$$h^2 = a^2 + b^2$$

Esta fórmula es la base del cálculo de la distancia entre dos puntos:

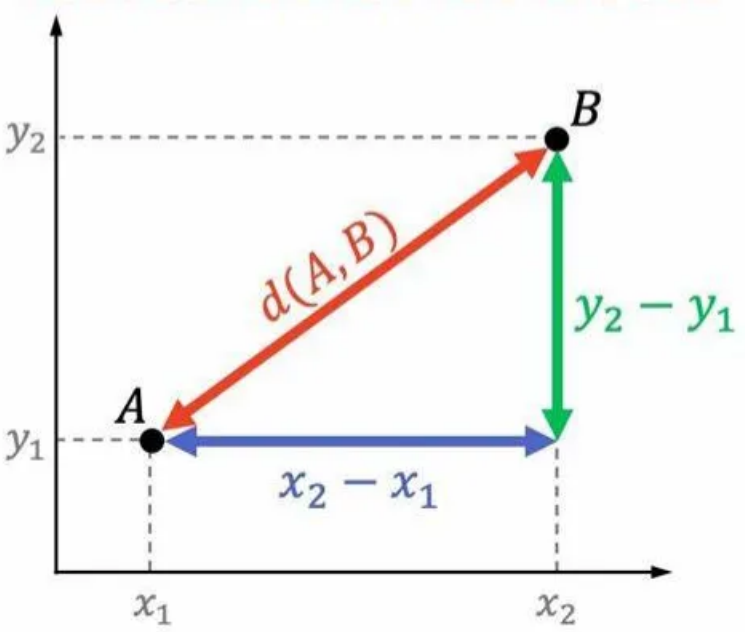


Figura 6.6.: Distancia entre dos puntos

$$d(A,B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Podemos adaptar esta fórmula al cálculo de nuestra distancia media. Como estamos calculando la distancia en una dimensión, sólo necesitamos la coordenada X. Si tenemos en cuenta un solo punto, esta distancia d sería:

$$(d \textit{ del valor } 1 \textit{ a la media})^2 = (x_1 - \bar{x})^2$$

¡El hecho de elevar al cuadrado las diferencias nos da la solución! Las diferencias negativas ya no son un problema porque sabemos que al elevar un numero negativo al cuadrado, el resultado es positivo; de esta manera conseguimos que las diferencias no se anulen.

> **Nota**
>
> Esta analogía con la distancia geométrica nos ayuda a entender por qué se eleva al cuadrado, aunque la justificación formal de la varianza tiene un desarrollo matemático más preciso que va más allá del alcance de este libro."

Ahora sí podemos calcular una distancia media $\bar{d}$ entre el conjunto de puntos y su media, calculando el promedio de las diferencias elevadas al cuadrado:

$$(\bar{d} \textit{ de los } n \textit{ valores a la media})^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2}{n}$$

y utilizando la notación que hemos aprendido antes,

$$(\bar{d} \textit{ de los } n \textit{ valores a la media})^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Al igual que en el cálculo de la distancia entre dos puntos, sólo tenemos que extraer la raíz cuadrada de este valor para obtener la distancia media, que es el parámetro que estábamos buscando.

La distancia media

$$(\bar{d} \text{ de los } n \text{ valores a la media})^2$$

se conoce en estadística como **varianza**, y su raíz cuadrada es lo que se conoce como **desviación típica**. La varianza de una población se representa en estadística con el signo de la letra griega *sigma* minúscula elevada al cuadrado, σ^2, y la desviación típica, mediante la letra σ. En el caso de una muestra, la varianza se representa como s_x^2, y la desviación típica, como s_x.

Es importante resaltar que la desviación típica *es una medida de la distancia media de los valores de una población a su media*, y por lo tanto tiene dimensión, la misma que las medidas originales. La varianza, al estar elevada al cuadrado, no tiene una dimensión, o, mejor dicho, tiene la de la medida al cuadrado.

Con estos nuevos hallazgos, recalculamos nuestra hoja de cálculo:

M15 =RAIZ(M13)

	A	B	C	D	E	F	G	H	I	J	K	L	M
1		altura media caso 1	media del grupo	diferencia	diferencia ^2	altura media caso 2	media del grupo	diferencia	diferencia^2	altura (datos originales)	media del grupo	diferencia	diferencia^2
2	1	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	153,00	149,55	3,45	11,93
3	2	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	135,00	149,55	-14,55	211,57
4	3	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	140,00	149,55	-9,55	91,12
5	4	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	140,00	149,55	-9,55	91,12
6	5	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	175,00	149,55	25,45	647,93
7	6	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	138,00	149,55	-11,55	133,30
8	7	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	145,00	149,55	-4,55	20,66
9	8	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	154,00	149,55	4,45	19,84
10	9	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	152,00	149,55	2,45	6,02
11	10	149,55	149,55	0,00	0,00	143,50	149,55	-6,05	36,55	159,00	149,55	9,45	89,39
12	11	149,55	149,55	0,00	0,00	210,00	149,55	60,45	3654,75	154,00	149,55	4,45	19,84
13	Promedio	149,55		0,00	0,00	149,55		0,00	365,48	149,55		0,00	122,07
14	Varianza	0,00				365,48				122,07			
15	Desviación típica	0,00				19,12			19,12	11,05			11,05
16													

Figura 6.7.: Tres grupos de valores en la hoja de cálculo, con la misma media y distinta desviación típica

Vamos a analizar con detalle esta tabla.

En la columna `J` tenemos nuestra población original de 11 alumnos, con las alturas que hemos medido. En la columna `B` hemos supuesto que todos los alumnos fuesen iguales, con la misma altura del valor medio de los datos originales. En la columna `F` hemos simulado otro grupo, con todos los valores iguales excepto uno, y con la misma media que los otros dos grupos.

A la derecha de cada columna de medias, tenemos la columna de diferencias (columnas `D`, `H` y `L`), y en la fila `13`, nuestro primer intento de calcular una dispersión media; intento fallido, puesto que obteníamos el valor 0 para los tres grupos.

En la siguiente columna a la derecha, para los tres grupos (columnas `E`, `I`y `M`), hemos elevado al cuadrado la distancia de cada valor a la media, siguiendo los hallazgos que nos ha proporcionado el teorema de Pitágoras y la fórmula de la distancia entre dos puntos. En la fila `13` de estas columnas, calculamos el promedio de la distancia a la media al cuadrado: esta vez el resultado ya no es cero, sino que obtenemos el valor de la **varianza**, de acuerdo con la fórmula que hemos deducido más arriba. En la fila `14` (columnas B, `F` y `J`)utilizamos la fórmula de la hoja de cálculo para la **varianza poblacional** (más detalles posteriormente), y vemos que coincide exactamente

con el promedio de las diferencias al cuadrado, tal como debe ser, ya que en eso consiste la fórmula que hemos deducido.

Por último, en la fila `15`calculamos la desviación típica de ambas formas, con la fórmula de la hoja de cálculo para la **desviación típica poblacional** (columnas `B`, `F`y `J`), que Excel llama **desviación estándar**, y como la raíz cuadrada del promedio calculado antes (columnas `E`, `I`y `M`). De nuevo, ambos valores coinciden exactamente, como esperamos.

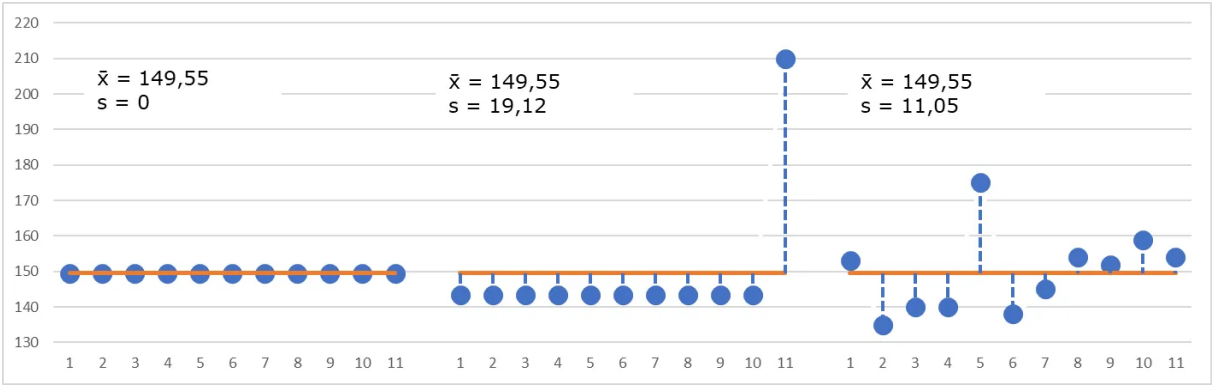


Figura 6.8.: Gráfico con tres conjuntos de datos con la misma media y diferente desviación típica

Ahora sí tenemos una forma más completa de describir nuestro conjunto de valores. Aunque el valor medio es el mismo en los tres casos, la *dispersión* de los valores es muy distinta.

¿Son suficientes estos dos parámetros que hemos calculado para describir un conjunto de datos? La respuesta a esta pregunta es sí y no. La explicación es que, más allá de los valores numéricos que hemos obtenido, la visualización gráfica de los valores nos debe hacer reflexionar.

En el primer grupo, todos los valores son iguales a la media. La variación es cero. Son valores que hemos simulado en nuestra hoja de cálculo, pero difícilmente en el mundo real encontraremos una población en la que todos sus valores, en este caso, la altura de un grupo de alumnos, sean idénticos.

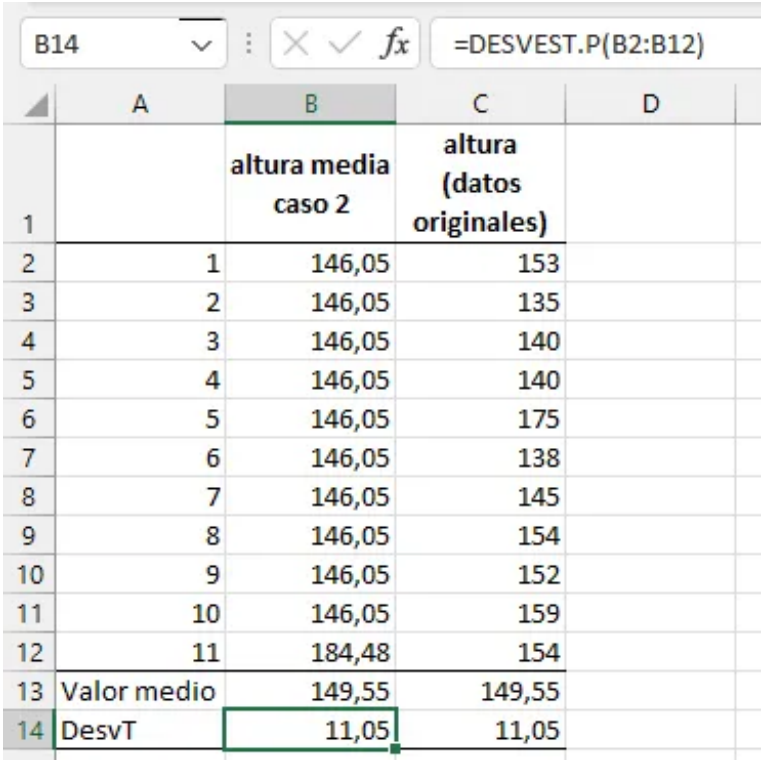
En el segundo grupo, todos los valores son idénticos, salvo uno, que se distancia mucho. ¿Debemos aceptar esto como bueno? En realidad, ¿es cierto que el valor medio de este grupo sea el mismo que el del primero? Para responder a esta pregunta debemos recurrir a nuestra experiencia, la estadística no nos da *fórmulas mágicas*. Pero, con un poco de sentido común, parece que el caso extremo que aparece en este grupo no es coherente con el resto de valores. Es lo que se llama un *valor anormal* o *extraño* (en inglés, *outlier*), y debe hacernos reflexionar sobre si el valor es correcto y realmente pertenece a esta población, o es un error de medida. O, simplemente, un valor que corresponde a otro grupo y que por error hemos situado en éste. La decisión de eliminar o no un valor anormal es una de las decisiones más complejas en estadística, que pueden tener una influencia enorme en la interpretación de los datos, y por lo tanto, hay que hacer con sumo cuidado. En este caso, extremo y artificial, el valor anormal debería ser eliminado, ya que, en realidad, todos los valores restantes son idénticos y más bajos que los del grupo 1. No tiene sentido lógico decir que sus medias son idénticas.

En el tercer grupo todos los valores son diferentes, y no podemos decir nada especial sobre sus valores individuales. Hay un valor que se destaca del resto, pero ¿podemos afirmar que es anormal? Seguramente, no con seguridad. De nuevo la experiencia debe indicarnos cómo proceder, aunque en este caso no tendría sentido eliminar este valor. En la situación real, todos conocemos

a niños que han *pegado el estirón* antes que sus compañeros, y en algunos casos, pueden llegar a ser mucho más altos (o más bajos, si han tenido un retraso en este *estirón*) La experiencia nos dice que no es seguro que este valor sea realmente anormal, y por lo tanto, deberíamos conservarlo.

6.5. Las limitaciones de la media y la desviación típica

En ocasiones nos enfrentamos a conjuntos de datos con valores de media y desviación típica idénticos o muy parecidos, pero que en realidad son muy diferentes. Veamos un ejemplo, semejante a los que hemos visto hasta ahora.



	A	B	C	D
1		altura media caso 2	altura (datos originales)	
2	1	146,05	153	
3	2	146,05	135	
4	3	146,05	140	
5	4	146,05	140	
6	5	146,05	175	
7	6	146,05	138	
8	7	146,05	145	
9	8	146,05	154	
10	9	146,05	152	
11	10	146,05	159	
12	11	184,48	154	
13	Valor medio	149,55	149,55	
14	DesvT	11,05	11,05	

Figura 6.9.: Hoja de cálculo con dos conjuntos de datos diferentes, con la misma media y desviación típica

En este caso, vemos que tanto la media como la desviación típica son idénticos, y sin embargo los datos son muy diferentes, tal como nos muestra el gráfico de dispersión que hemos estado utilizando:

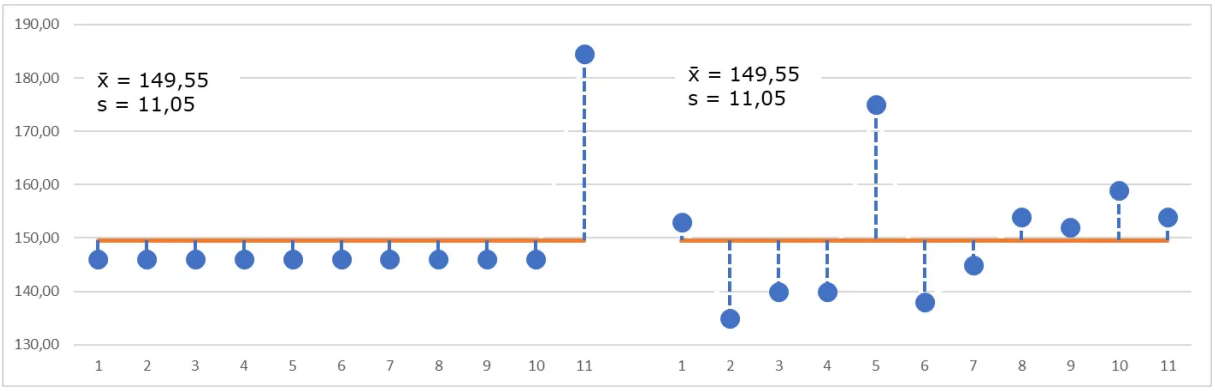
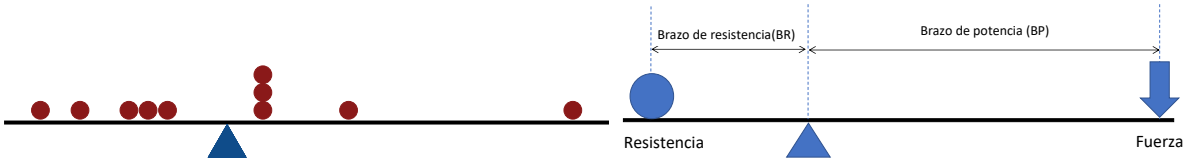


Figura 6.10.: Gráfico con dos conjuntos de datos diferentes, con la misma media y desviación típica

La existencia de valores anormales o extremos muestra una de las debilidades de la media y la desviación típica como descriptores de un conjunto de datos: **ambos son muy sensibles a los casos extremos**.

Una forma intuitiva de entender por qué ocurre esto es imaginar una **barra rígida apoyada sobre un fulcro**, como una balanza o un balancín. Cada valor del conjunto es un peso colocado sobre la barra a una distancia proporcional a su magnitud. La media es exactamente el punto de apoyo en el que la barra quedaría en equilibrio perfecto: la suma de los momentos a la izquierda iguala la suma de los momentos a la derecha.



(a) La media como punto de equilibrio (b) Palanca de primer grado

Figura 6.11.: Comparación gráfica del significado de la media en un diagrama de puntos (*dotplot*) con una palanca de primer grado, con el fulcro como punto de equilibrio.

Un valor muy alejado del centro actúa como un **peso situado lejos del fulcro**: su efecto sobre el equilibrio es desproporcionado respecto a su tamaño. Un único valor extremo puede desplazar el punto de equilibrio —la media— de forma mucho más acusada que varios valores moderados.

Por eso, **deberíamos usar la media y la desviación típica preferiblemente cuando estamos razonablemente seguros de que los datos tienen una forma aproximadamente simétrica y equilibrada**, como la famosa **campana de Gauss** (distribución normal), que podemos relacionar con el boxplot, tal como vemos en el gráfico a continuación,

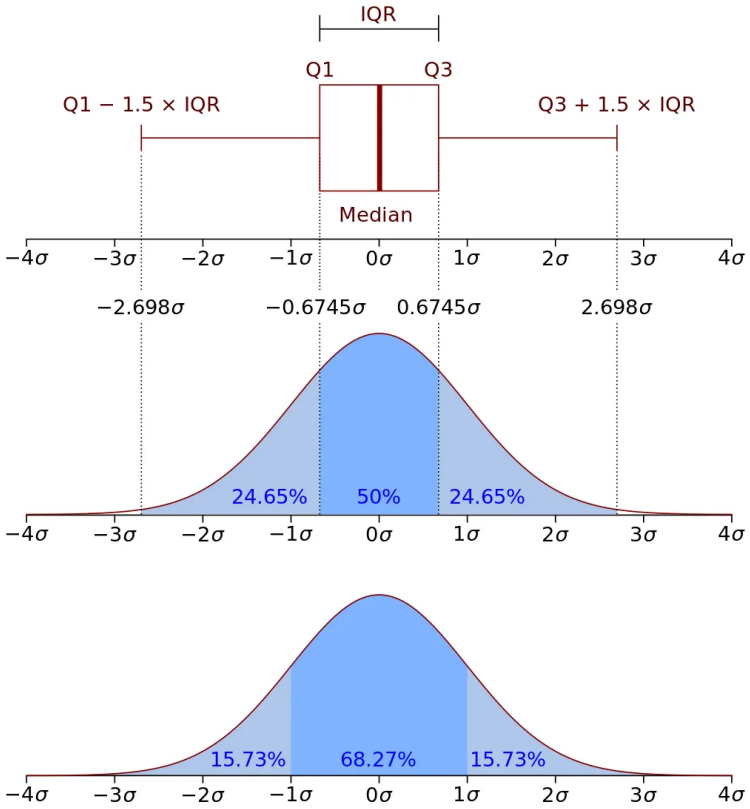


Figura 6.12.: Campana de Gauss y boxplot mostrando las relaciones entre los elementos no paramétricos del boxplot y los elementos paramétricos de la distribución normal

En otros casos, especialmente cuando hay valores muy altos o muy bajos, **la mediana y el rango intercuartílico** (que ya vimos en el boxplot) son **estadísticos más robustos**, es decir, **más resistentes a los extremos y más seguros para describir el conjunto de datos**.

Esta diferencia entre estadísticos sensibles y robustos es clave para elegir bien qué medidas usar según el tipo de datos.

6.5.1. Ventajas e inconvenientes de las medidas paramétricas frente a las no paramétricas

La media aritmética es el estadístico central más utilizado: representa el valor en torno al cual se distribuye el conjunto de datos y se calcula como la suma de todos los valores dividida entre su número. Sin embargo, la media por sí sola no es suficiente para describir un conjunto de datos, ya que grupos muy distintos pueden compartir el mismo valor medio. Para completar la descripción es necesario medir la dispersión, es decir, cuánto se alejan los valores individuales de ese centro. La varianza mide esa distancia elevando al cuadrado las diferencias entre cada valor y la media, lo que evita que las diferencias positivas y negativas se anulen; la desviación típica es su raíz cuadrada y recupera las unidades originales de la medida.

Estos estadísticos paramétricos son muy potentes cuando los datos tienen una distribución aproximadamente simétrica, pero son sensibles a los valores extremos. En esos casos, la mediana y el rango intercuartil, ya vistos en el boxplot del capítulo 6, resultan más robustos y seguros. En

la práctica, ambos tipos de estadísticos se usan de forma complementaria. En el capítulo siguiente aplicaremos todos estos conceptos al análisis de una fabricación real de queso camembert.

6.6. Cálculo manual de la media y la desviación típica

Los cálculos que hemos realizado en este capítulo con la hoja de cálculo pueden reproducirse con pocas líneas de código en Python y R. Antes de ver el código, repasemos el cálculo paso a paso con nuestros datos de altura de los alumnos.

Paso 1 — Media aritmética:

$$\bar{x} = \frac{153 + 135 + 140 + 140 + 175 + 138 + 145 + 154 + 152 + 159 + 154}{11} = 149{,}55$$

Paso 2 — Diferencias a la media:

$$\begin{aligned} x_i - \bar{x}: \quad & (153 - 149{,}55),\ (135 - 149{,}55),\ (140 - 149{,}55),\ \ldots \\ & = 3{,}45,\ -14{,}55,\ -9{,}55,\ -9{,}55,\ 25{,}45,\ -11{,}55,\ -4{,}55,\ 4{,}45,\ 2{,}45,\ 9{,}45,\ 4{,}45 \end{aligned}$$

Paso 3 — Diferencias al cuadrado:

$$(x_i - \bar{x})^2: \quad 11{,}90,\ 211{,}70,\ 91{,}20,\ 91{,}20,\ 647{,}70,\ 133{,}40,\ 20{,}70,\ 19{,}80,\ 6{,}00,\ 89{,}30,\ 19{,}80$$

Paso 4 — Suma de cuadrados (SC):

$$\begin{aligned} SC &= \sum_{i=1}^{n} (x_i - \bar{x})^2 \\ &= 11{,}90 + 211{,}70 + 91{,}20 + 91{,}20 + 647{,}70 + 133{,}40 + 20{,}70 + 19{,}80 + 6{,}00 + 89{,}30 + 19{,}80 \\ &= 1342{,}70 \end{aligned}$$

> **Nota**
>
> La **suma de cuadrados** (SC) es una cantidad que aparecerá de forma recurrente en el análisis estadístico. Mide la variación total de un conjunto de datos respecto a su media. En el análisis de la varianza (**ANOVA**), que permite comparar si las medias de varios grupos son significativamente distintas, la SC total se descompone en partes atribuibles a diferentes causas: la variación entre grupos y la variación dentro de cada grupo. Entender qué es la SC en este capítulo facilita enormemente la comprensión del ANOVA cuando se aborde más adelante.

Paso 5 — Varianza y desviación típica poblacional:

$$s^2 = \frac{SC}{n} = \frac{1342{,}70}{11} = 122{,}06 \qquad s = \sqrt{122{,}06} = 11{,}05$$

Paso 6 — Desviación típica muestral:

$$s = \sqrt{\frac{SC}{n-1}} = \sqrt{\frac{1342{,}70}{10}} = \sqrt{134{,}27} = 11{,}59$$

> **Corrección de Bessel**
>
> Cuando trabajamos con una **muestra** en lugar de con la población completa, dividir entre n tiende a subestimar la dispersión real de la población. Para corregir este sesgo, se divide entre $n-1$ en lugar de n. Esta corrección se conoce como **corrección de Bessel**, y el valor resultante es la **desviación típica muestral**. En la práctica industrial, donde casi siempre trabajamos con muestras, es el valor que se usa por defecto, y es también el que calculan Excel, Python y R con sus funciones estándar.

6.7. Cálculo de estadísticos básicos en Python y R

```
[1] 149.5455
```

```
[1] 152
```

```
[1] 11.58761
```

```
[1] 134.2727
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  135.0   140.0   152.0   149.5   154.0   175.0
```

Una nota importante: tanto Python como R calculan por defecto la desviación típica muestral, dividiendo entre n−1 en lugar de n. La diferencia es pequeña cuando el número de datos es grande, pero conviene tenerlo en cuenta.

6.8. Resumen del capítulo

La media aritmética es el estadístico central más utilizado: representa el valor en torno al cual se distribuye el conjunto de datos y se calcula como la suma de todos los valores dividida entre su número. Sin embargo, la media por sí sola no es suficiente para describir un conjunto de datos, ya que grupos muy distintos pueden compartir el mismo valor medio.

Para completar la descripción es necesario medir la dispersión, es decir, cuánto se alejan los valores individuales de ese centro. La varianza mide esa distancia elevando al cuadrado las diferencias entre cada valor y la media, lo que evita que las diferencias positivas y negativas se anulen; la desviación típica es su raíz cuadrada y recupera las unidades originales de la medida.

Estos estadísticos paramétricos son muy potentes cuando los datos tienen una distribución aproximadamente simétrica, pero son sensibles a los valores extremos. En esos casos, la mediana

y el rango intercuartil, ya vistos en el boxplot del capítulo 6, resultan más robustos y seguros. En la práctica, ambos tipos de estadísticos se usan de forma complementaria.

En el capítulo siguiente aplicaremos todos estos conceptos al análisis de una fabricación real de queso camembert.

7. Distribuciones de probabilidad y la distribución normal

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Interpretar un histograma como representación de una distribución de probabilidad empírica.
- Reconocer las formas características de las distribuciones más frecuentes en datos industriales y relacionarlas con el proceso que las genera.
- Describir la distribución normal mediante sus parámetros (μ y σ) y aplicar la regla 68-95-99,7.
- Calcular probabilidades a partir de la distribución normal usando Python y R.
- Interpretar un gráfico QQ-plot para evaluar visualmente si un conjunto de datos sigue una distribución normal.

Conceptos clave: **distribución de probabilidad, frecuencia relativa, distribución normal, parámetros, media, desviación típica, tipificación, puntuación Z, QQ-plot, asimetría, distribución discreta, distribución continua**.

Sobre el código de este capítulo

A lo largo del capítulo encontrarás bloques de código Python y R que generan los gráficos. Cuando el código es largo o utiliza funciones avanzadas de formato y visualización, aparece **oculto por defecto**: puedes mostrarlo haciendo clic en "Mostrar código".
No es necesario entender cada línea para seguir el razonamiento del capítulo. Si tienes curiosidad sobre qué hace un bloque de código concreto, cópialo y pégalo en un asistente de inteligencia artificial como Gemini, ChatGPT o Claude y pregúntale: *"Explícame este código línea a línea, en lenguaje sencillo"*.

7.1. De la frecuencia relativa a la probabilidad

En los capítulos anteriores hemos usado el histograma para describir la distribución de los valores de una variable. Cada barra del histograma representa cuántos valores caen en un intervalo determinado. Si en lugar de contar valores contamos su proporción respecto al total, obtenemos las **frecuencias relativas**, que ya conocemos del capítulo 6.

Hay un paso conceptual sencillo desde las frecuencias relativas hasta la probabilidad: la frecuencia relativa de un intervalo es la **probabilidad** de que un valor tomado al azar de ese conjunto caiga en ese intervalo.

Por ejemplo, si en los datos de La Liga el 28 % de los partidos terminan con 2 goles en total, podemos decir que la probabilidad de que un partido elegido al azar acabe con 2 goles es del 28 %, o 0,28.

> **Probabilidad y frecuencia relativa**
>
> La probabilidad de un evento es la proporción de veces que ese evento ocurre en un gran número de repeticiones. Cuando disponemos de datos reales, la frecuencia relativa observada es nuestra mejor estimación de esa probabilidad. Cuantos más datos tengamos, más fiable es esa estimación.

Para precisar la distinción entre los dos conceptos, la tabla siguiente resume sus diferencias:

	Frecuencia relativa	Probabilidad
Qué es	Proporción observada en un conjunto de datos reales	Medida teórica basada en un modelo o supuesto
Cómo se obtiene	Contando: $\frac{\text{veces que ocurre el evento}}{\text{total de observaciones}}$	Razonando: $\frac{\text{casos favorables}}{\text{casos posibles}}$
Ejemplo	En 380 partidos de La Liga, 106 acabaron con 2 goles: frecuencia relativa = 0,279	En una moneda perfectamente equilibrada, P(cara) = 0,5
Carácter	Empírico: depende de los datos disponibles	Teórico: no requiere datos observados
Relación	Con muchos datos, la frecuencia relativa se acerca a la probabilidad teórica	

En el análisis de datos industriales trabajamos casi siempre con frecuencias relativas: no conocemos la probabilidad teórica de que un queso salga fuera de especificación, pero podemos estimarla a partir de los datos históricos del proceso.

Esta conexión tiene una consecuencia práctica importante: el **área bajo la curva** de un histograma (o de una distribución teórica) entre dos valores es la probabilidad de que una observación caiga entre esos dos valores. Es la misma idea que la suma de frecuencias relativas acumuladas que vimos en el capítulo 6, pero expresada como área.

7.2. Distribuciones discretas y continuas

Antes de describir las formas más habituales, conviene distinguir dos tipos de variables:

Las **variables discretas** solo pueden tomar valores enteros: número de goles en un partido, número de colonias bacterianas en una placa, número de envases defectuosos en un lote. No tiene sentido hablar de 2,7 goles. Las distribuciones de variables discretas tienen barras separadas porque los valores posibles están separados.

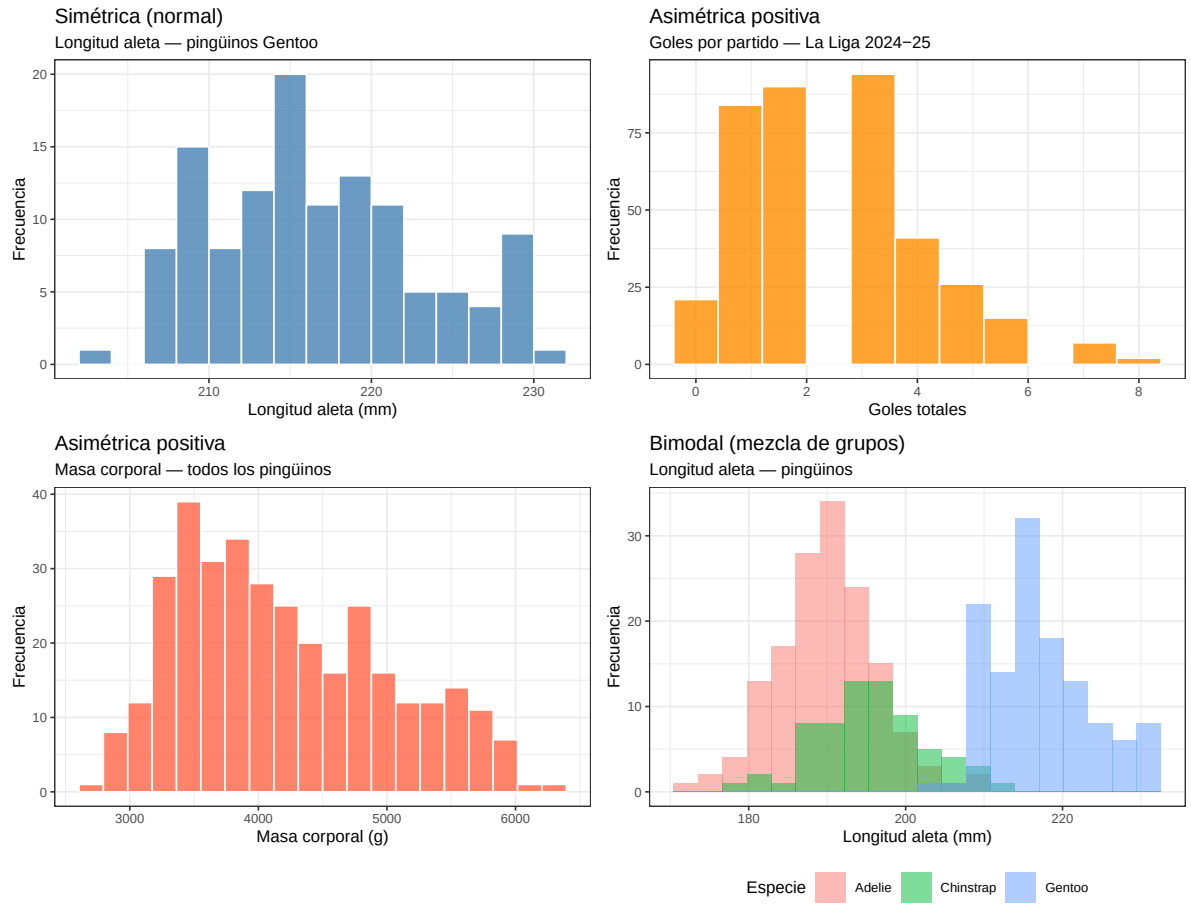
Las **variables continuas** pueden tomar cualquier valor dentro de un rango: la materia grasa de un queso, el pH, el peso de un envase. Entre 23,5 % y 23,6 % de grasa hay infinitos valores posibles. Las distribuciones de variables continuas se representan con una curva continua.

En la práctica industrial, la mayoría de las variables de proceso y calidad son continuas, y la distribución normal —que veremos en detalle— es una distribución continua.

7.3. Las formas más frecuentes en datos industriales

Los datos que encontramos en la industria alimentaria no siempre tienen la misma forma. Reconocer la forma de una distribución es el primer paso para interpretarla correctamente y elegir las herramientas estadísticas adecuadas.

Veamos las cuatro formas más frecuentes usando datos que ya conocemos del libro:



Cada una de estas formas tiene una explicación en el proceso que genera los datos:

- **Simétrica:** los valores se distribuyen de forma equilibrada alrededor de un valor central. Es la forma que se asocia con procesos bajo control estadístico, donde las pequeñas variaciones aleatorias se compensan entre sí. La longitud de aleta de los pingüinos Gentoo es un buen ejemplo de esta forma.
- **Asimétrica positiva:** la mayoría de los valores son bajos pero hay una cola hacia valores altos. Es típica de recuentos de eventos poco frecuentes, como los goles por partido: la mayoría de los partidos tienen pocos goles, pero alguno tiene muchos.

- **Asimétrica positiva extrema:** versión extrema de la anterior. Los coliformes son el ejemplo perfecto: la mayoría de las muestras tienen recuentos bajos o nulos, pero episodios de contaminación producen valores muy altos. La transformación logarítmica hace visible la distribución real.
- **Bimodal:** dos grupos superpuestos con características distintas. En los pingüinos, la mezcla de especies con diferente tamaño produce dos modas. En datos de proceso, una distribución bimodal suele indicar que hay dos máquinas, dos operarios o dos materias primas mezcladas en el mismo dataset.

7.4. La distribución normal

La distribución normal, también llamada **campana de Gauss**, es la más importante en estadística aplicada. No porque sea la única, sino porque muchas variables de proceso industrial se aproximan a ella cuando el proceso está bajo control, y porque es la base del cálculo de probabilidades en el control de calidad.

Su forma es característica: simétrica, con un único máximo en el centro, y colas que se extienden hacia ambos lados sin llegar nunca a cero. Está completamente definida por dos parámetros:

- **La media μ:** determina dónde está centrada la distribución. Desplazar μ mueve toda la curva hacia la derecha o la izquierda sin cambiar su forma.
- **La desviación típica σ:** determina cuán ancha o estrecha es la curva. Una σ pequeña produce una curva alta y estrecha (proceso preciso); una σ grande produce una curva baja y ancha (proceso con mucha variabilidad).

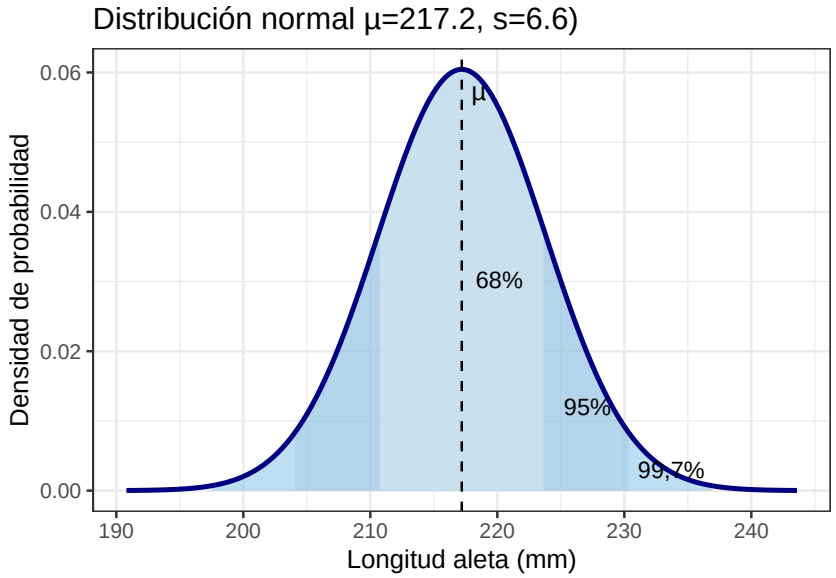
7.4.1. La regla 68-95-99,7

Una propiedad fundamental de la distribución normal es que la proporción de valores dentro de cada rango alrededor de la media es siempre la misma, independientemente de los valores concretos de μ y σ:

- El **68 %** de los valores cae dentro de $\mu \pm 1\sigma$
- El **95 %** de los valores cae dentro de $\mu \pm 2\sigma$
- El **99,7 %** de los valores cae dentro de $\mu \pm 3\sigma$

Esta regla tiene consecuencias prácticas inmediatas: si sabemos que un proceso sigue una distribución normal con media μ y desviación típica σ, podemos calcular qué proporción de unidades estará fuera de cualquier límite especificado.

Visualicemos la regla con datos simulados:



La regla 68-95-99,7 y el boxplot

¿Recuerdas el boxplot del capítulo 6? En una distribución normal, los bigotes del boxplot (que se extienden hasta 1,5 veces el rango intercuartílico) capturan aproximadamente el 99,3 % de los valores. Los puntos fuera de los bigotes corresponden aproximadamente al 0,7 % de las observaciones, que es la región de las colas más allá de $\pm 2{,}7\sigma$.

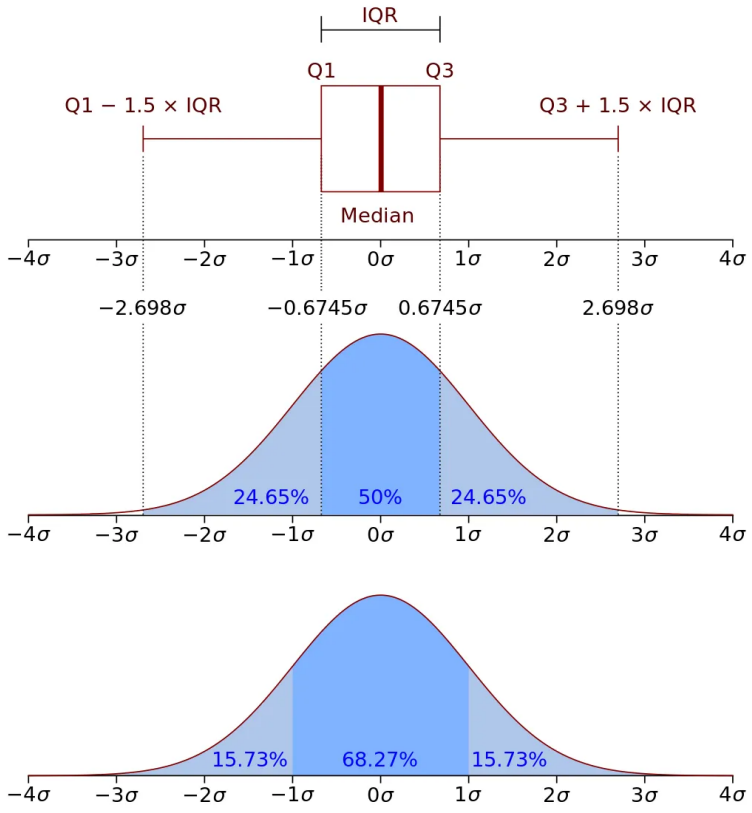


Figura 7.1.: Relación entre la campana de Gauss y el boxplot

7.4.2. Tipificación y puntuación Z

Una propiedad muy útil de la distribución normal es que cualquier distribución normal, independientemente de sus valores de μ y σ, puede transformarse en una distribución normal estándar con media 0 y desviación típica 1. Esta transformación se llama **tipificación** y el valor resultante se llama **puntuación Z** o **valor Z**:

$$Z = \frac{x - \mu}{\sigma}$$

La puntuación Z indica cuántas desviaciones típicas separan un valor concreto de la media. Un valor con $Z = 2$ está 2 desviaciones típicas por encima de la media; un valor con $Z = -1,5$ está 1,5 desviaciones típicas por debajo.

La utilidad práctica de la tipificación es que permite calcular probabilidades para cualquier distribución normal usando una única tabla o función, sin importar las unidades ni los valores concretos de μ y σ. Veremos su aplicación práctica en el capítulo siguiente, cuando calculemos la proporción de envases que incumple el contenido efectivo reglamentario.

7.5. Cálculo de probabilidades con Python y R

Python y R calculan directamente la probabilidad de que un valor sea menor que un valor dado en cualquier distribución normal. No es necesario usar tablas.

La función que necesitamos es la **función de distribución acumulada** (*cumulative distribution function*, CDF): dado un valor x, nos devuelve la probabilidad de que una observación sea menor o igual que x, es decir, el área bajo la curva a la izquierda de ese punto.

Como ejemplo, calculamos algunas probabilidades para la longitud de aleta de los pingüinos Gentoo (aproximadamente normal con media 217,2 mm y desviación típica 6,6 mm):

```
P(MG < 22%) = 0.0000 = 0.00%
```

```
P(MG > 25%) = 1.0000 = 100.00%
```

```
P(22%% < MG < 25%%) = 0.0000 = 0.00%
```

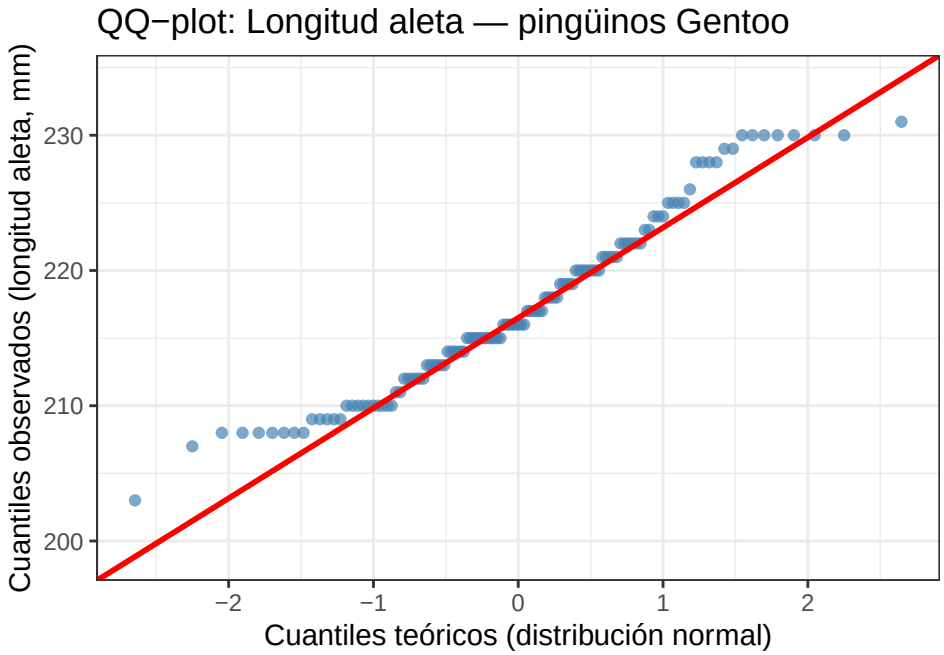
La función `norm.cdf` en Python y `pnorm` en R calculan el área bajo la curva a la izquierda del valor indicado. Para probabilidades hacia la derecha (valores superiores a x) basta con restar a 1. Para probabilidades en un intervalo, se restan las dos CDF de los extremos.

7.6. Comprobación de normalidad: el QQ-plot

Antes de aplicar cualquier cálculo basado en la distribución normal, es conveniente comprobar si los datos se ajustan razonablemente bien a esa distribución. El gráfico más sencillo y más informativo para esta comprobación es el **QQ-plot** (*quantile-quantile plot*).

La idea es simple: si los datos siguen una distribución normal, sus cuantiles empíricos (los valores observados ordenados de menor a mayor) deberían coincidir con los cuantiles teóricos de una distribución normal. El QQ-plot representa estos dos conjuntos de cuantiles uno frente al otro: si los puntos siguen una línea recta, los datos son aproximadamente normales; si se desvían de la línea, hay indicios de no normalidad.

Aplicamos el QQ-plot a la longitud de aleta de los pingüinos Gentoo, que acabamos de ver que sigue una distribución aproximadamente normal:



La mayoría de los puntos siguen la línea roja con bastante fidelidad, lo que confirma que la longitud de aleta de los pingüinos Gentoo sigue una distribución aproximadamente normal. Los puntos en los extremos se ajustan bien a la línea, sin separaciones llamativas, lo que indica que no hay valores atípicos importantes ni asimetría pronunciada.

i Cómo interpretar un QQ-plot

- **Puntos sobre la línea recta:** los datos se ajustan bien a la distribución normal.
- **Cola superior por encima de la línea:** hay valores altos más extremos de lo esperado (cola derecha más pesada, asimetría positiva).
- **Cola inferior por debajo de la línea:** hay valores bajos más extremos de lo esperado (cola izquierda más pesada, asimetría negativa).
- **Forma en S:** la distribución tiene colas más ligeras que la normal (más concentrada en el centro).
- **Punto aislado en un extremo:** un outlier.

7.7. Resumen del capítulo

Este capítulo ha establecido el puente entre las frecuencias relativas del histograma y el concepto de probabilidad: la proporción de valores en un intervalo es la probabilidad de que una observación caiga en ese intervalo. A partir de esta idea, la distribución normal aparece como el modelo teórico que describe el comportamiento de muchas variables industriales bajo control.

Los cuatro tipos de distribución ilustrados con datos del libro —simétrica, asimétrica positiva, asimétrica positiva extrema y bimodal— permiten al alumno reconocer en sus propios datos la forma que subyace al proceso que los genera. La distribución normal se ha descrito en profundidad mediante sus parámetros μ y σ, la regla 68-95-99,7 y el cálculo de probabilidades con Python y R. El QQ-plot proporciona una herramienta visual sencilla para verificar si la hipótesis de normalidad es razonable antes de aplicar estos cálculos. En capítulos posteriores aplicaremos estas mismas herramientas a variables de proceso real como la materia grasa del queso o el peso de envases de yogur.

En el capítulo dedicado al contenido efectivo de envases aplicaremos estos conceptos a un problema real de control de calidad: el análisis del llenado de yogures según el RD 1801/2008.

8. La relación entre dos variables: correlación y regresion

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Interpretar un gráfico de dispersión para identificar visualmente si existe relación entre dos variables y describir su dirección e intensidad.
- Explicar el concepto de correlación y usar el coeficiente de Pearson como medida numérica de la intensidad de la relación lineal.
- Distinguir entre correlación y causalidad, y reconocer ejemplos de correlación espuria.
- Interpretar una línea de regresión como resumen de la tendencia en un gráfico de dispersión.
- Aplicar estos conceptos a datos reales de fabricación de queso.

Conceptos clave: **correlación, coeficiente de Pearson, causalidad, correlación espuria, regresión lineal, línea de tendencia**.

Sobre el código de este capítulo

Los bloques de código que generan gráficos complejos aparecen **ocultos por defecto**. Puedes mostrarlos haciendo clic en "Mostrar código". Si quieres entender qué hace un bloque, cópialo y pégalo en un asistente de IA como Gemini, ChatGPT o Claude y pregúntale: *"Explícame este código línea a línea, en lenguaje sencillo"*.

8.1. Más allá de una variable: la relación entre dos variables

En los capítulos anteriores hemos descrito las variables una a una: su distribución, su media, su dispersión. Pero en la práctica industrial, muchas de las preguntas más importantes son sobre la relación entre variables: ¿influye la composición de la leche en el rendimiento quesero? ¿Tiene relación el pH con el extracto seco? ¿Están correlacionadas la materia grasa y la humedad del queso?

El gráfico de dispersión, que ya usamos en el capítulo de análisis del camembert, es la herramienta visual fundamental para explorar estas relaciones. Cada punto representa una observación con sus dos valores, y la forma de la nube de puntos nos dice si hay relación y de qué tipo.

8.2. El coeficiente de correlación de Pearson

La inspección visual del gráfico de dispersión nos da una idea cualitativa de la relación entre dos variables, pero necesitamos también una medida numérica que nos permita compararla y comunicarla con precisión. El **coeficiente de correlación de Pearson** (r) es esa medida.

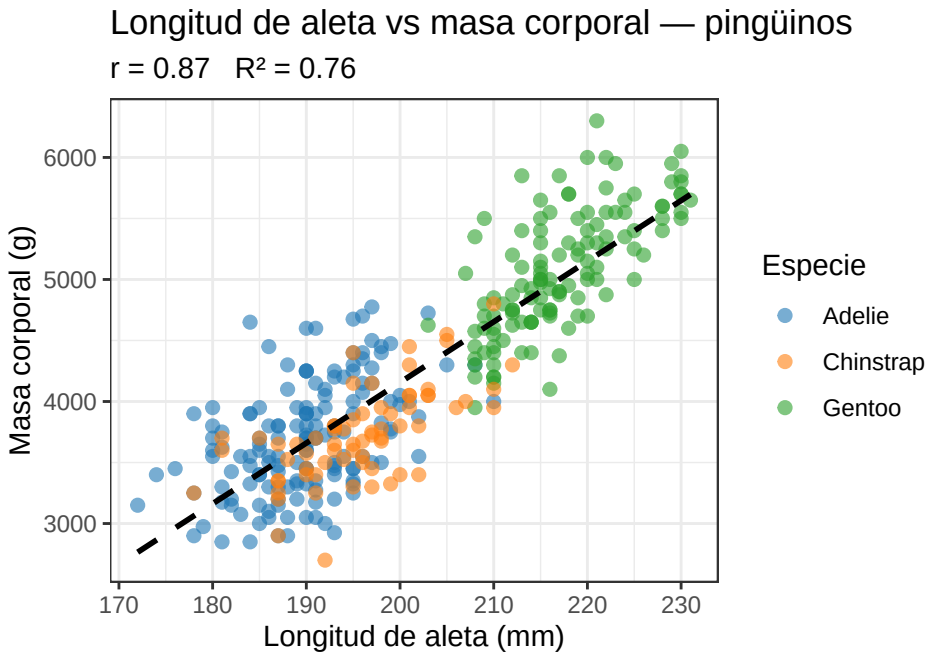
r toma valores entre -1 y $+1$:

- $r = +1$: correlación positiva perfecta. Cuando una variable sube, la otra sube proporcionalmente siempre.
- $r = -1$: correlación negativa perfecta. Cuando una variable sube, la otra baja proporcionalmente siempre.
- $r = 0$: no hay relación lineal entre las variables.
- Valores intermedios indican correlaciones parciales: cuanto más cerca de ± 1, más intensa la relación.

Como referencia práctica, en datos industriales:

Valor de $\lvert r \rvert$	Interpretación habitual
0,00 — 0,20	Correlación muy débil o nula
0,20 — 0,40	Correlación débil
0,40 — 0,60	Correlación moderada
0,60 — 0,80	Correlación fuerte
0,80 — 1,00	Correlación muy fuerte

Veamos un ejemplo concreto con los pingüinos. La longitud de la aleta y la masa corporal deberían estar relacionadas: los pingüinos más grandes tienen aletas más largas. Calculamos r y visualizamos la relación con la línea de regresión:



El gráfico muestra una relación positiva clara: los pingüinos con aletas más largas son más pesados. Ahora que tenemos el gráfico delante, podemos entender mejor qué significan r y R^2:

> **i** ¿Qué mide exactamente r? El coeficiente de correlación y el coeficiente de determinación
>
> El **coeficiente de correlación de Pearson** (r) mide la **intensidad y la dirección de la relación lineal** entre dos variables. Va de -1 a $+1$: valores cercanos a ± 1 indican una relación fuerte; valores cercanos a 0 indican ausencia de relación lineal.
> El **coeficiente de determinación** (R^2) es simplemente el cuadrado de r. Va de 0 a 1 y se interpreta como la **proporción de la variación de una variable que queda explicada por la otra**.
> En el gráfico anterior, $r \approx 0{,}87$ y $R^2 \approx 0{,}76$. Esto significa que si tuviéramos que adivinar la masa corporal de un pingüino sin saber nada más, nuestra mejor apuesta sería la media de todos los pingüinos. Pero si además sabemos la longitud de su aleta, podemos hacer una predicción mucho mejor usando la línea de regresión. El $R^2 = 0{,}76$ nos dice que conocer la longitud de la aleta reduce en un 76 % el error que cometeríamos si adivinásemos solo con la media. Ese 76 % es la "variación explicada" por la longitud de la aleta; el 24 % restante se debe a otros factores como la especie, el sexo o la condición corporal individual.
> Excel muestra R^2 cuando se añade una línea de tendencia a un gráfico de dispersión. Es habitual ver ambos valores en informes técnicos: r para describir la relación y R^2 para cuantificar su poder explicativo.
> Una advertencia: una correlación baja no significa necesariamente que no hay relación entre las variables. Puede haber una relación curvilínea perfecta con $r = 0$. Por eso siempre hay que mirar el gráfico de dispersión junto con el valor de r.

8.3. La línea de regresión

La línea discontinua en el gráfico anterior es la **línea de regresión** o **línea de tendencia**. Representa la mejor aproximación lineal a la relación entre las dos variables: para cualquier longitud de aleta, la línea nos da el valor medio esperado de la masa corporal.

La ecuación de la línea tiene la forma:

$$\hat{y} = a + b \cdot x$$

donde $\hat{y}$ es el valor predicho de la variable dependiente (masa corporal), x es el valor de la variable independiente (longitud de aleta), b es la pendiente (cuánto sube la masa corporal por cada milímetro adicional de aleta) y a es la intersección con el eje Y.

La línea se calcula por el método de los **mínimos cuadrados**: se busca la línea que minimiza la suma de los cuadrados de las distancias verticales entre cada punto y la línea. Este criterio garantiza que la línea pase lo más cerca posible de todos los puntos simultáneamente.

> **i** La regresión en Excel
>
> Excel permite añadir una línea de tendencia a cualquier gráfico de dispersión con clic derecho → "Agregar línea de tendencia". En las opciones se puede mostrar la ecuación de la línea y el coeficiente R^2 (que es el cuadrado del coeficiente de Pearson y mide la proporción

de variación de y explicada por x). Es una forma rápida de obtener la regresión sin código.

8.4. Correlación no implica causalidad

El coeficiente de correlación mide la intensidad de la asociación estadística entre dos variables, pero no dice nada sobre si una variable *causa* a la otra. Dos variables pueden estar correlacionadas por tres razones distintas:

1. **Causalidad directa:** x causa y. Por ejemplo, una mayor concentración de cuajo produce una coagulación más rápida.
2. **Causa común:** una tercera variable z influye en ambas. Por ejemplo, la temperatura ambiente afecta tanto al extracto seco como a la velocidad de acidificación, creando una correlación entre estas dos aunque no se causen entre sí.
3. **Coincidencia:** es una correlación espuria, sin ninguna relación causal real.

El tercer caso es más frecuente de lo que parece, especialmente cuando se analizan series temporales largas donde muchas variables crecen o decrecen juntas simplemente porque el tiempo avanza.

8.4.1. Ejemplos de correlación espuria

Tyler Vigen ha recopilado en su página web tylervigen.com/spurious-correlations miles de correlaciones estadísticamente fuertes entre variables que no tienen ninguna relación causal posible. Dos ejemplos especialmente ilustrativos:

El primero tiene una conexión temática directa con este libro: el consumo de margarina per cápita correlaciona muy fuertemente con el número de divorcios en el estado de Maine (Estados Unidos). Ambas variables han crecido en paralelo durante décadas, pero nadie diría que comer más margarina lleva a divorciarse más.

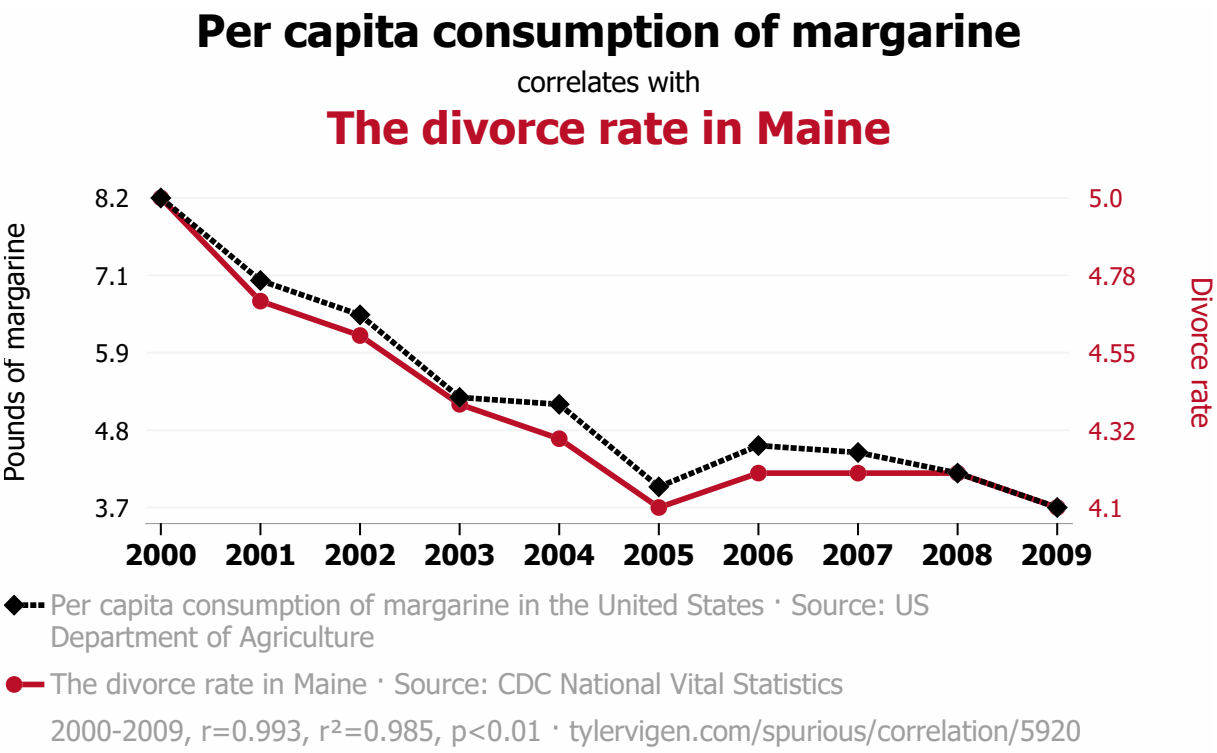
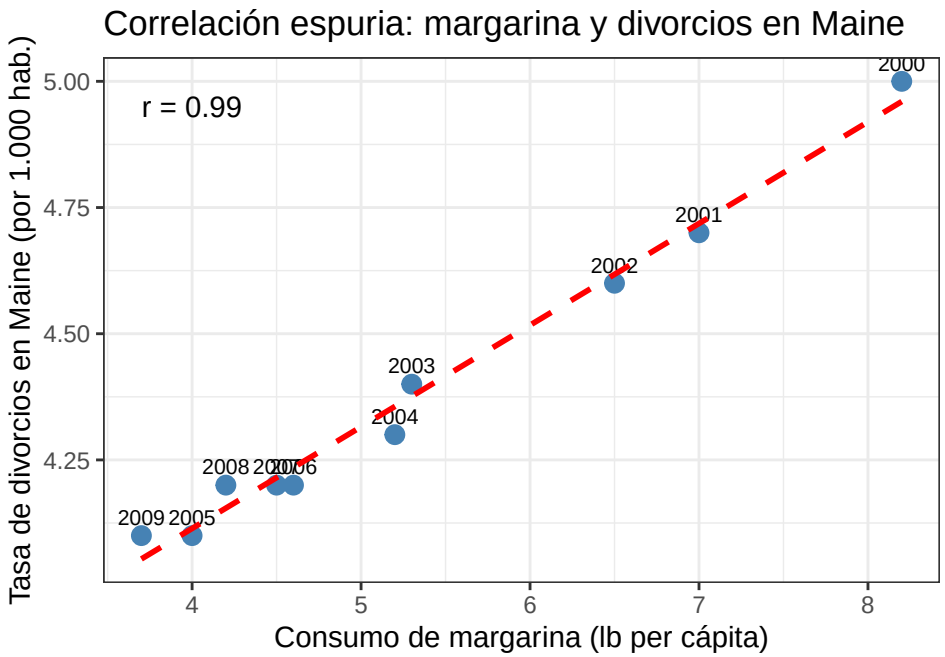


Figura 8.1.: Correlación espuria entre consumo de margarina y tasa de divorcios en Maine (E.E.U.U.)

Fuente: Tyler Vigen, Spurious Correlations (tylervigen.com). Licencia Creative Commons Attribution.

El gráfico de dispersión de los mismos datos muestra la nube de puntos, la línea de regresión y el valor de r:



El segundo es el consumo de queso en E.E.U.U., que correlaciona con el número de patentes concedidas en el país. La causa es simplemente que ambas series tienen tendencias temporales similares en el período analizado.

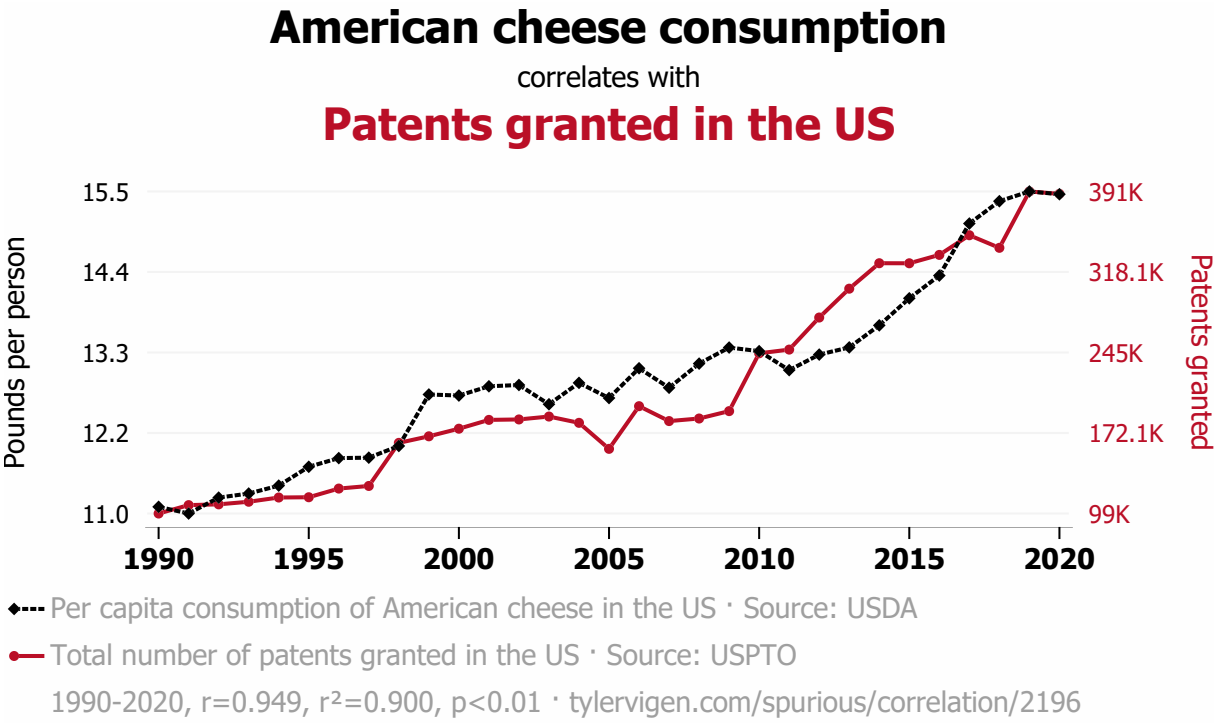
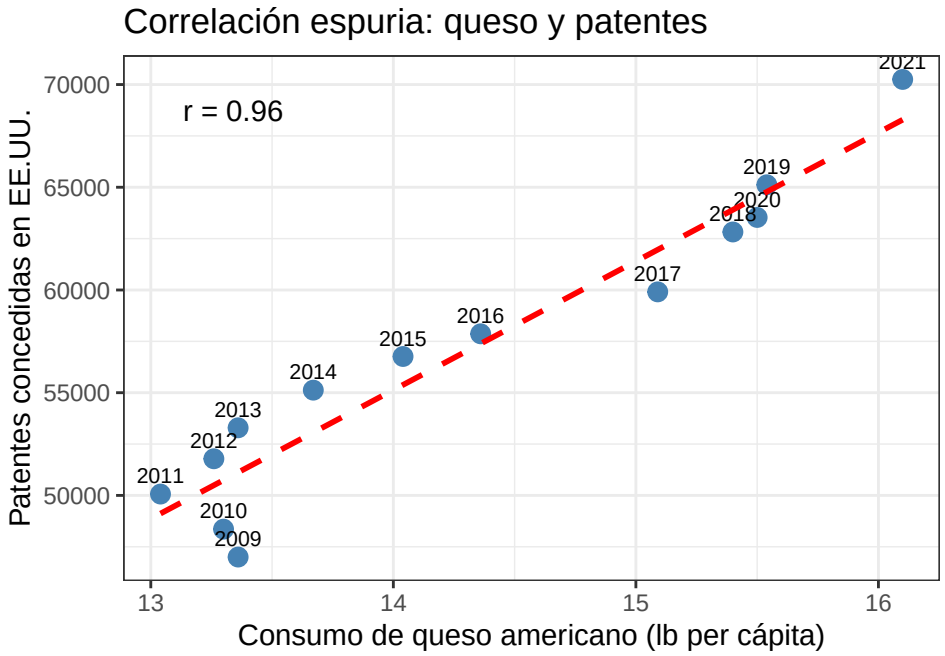


Figura 8.2.: Correlación espuria entre consumo de queso y número de patentes concedidas en E.E.U.U.

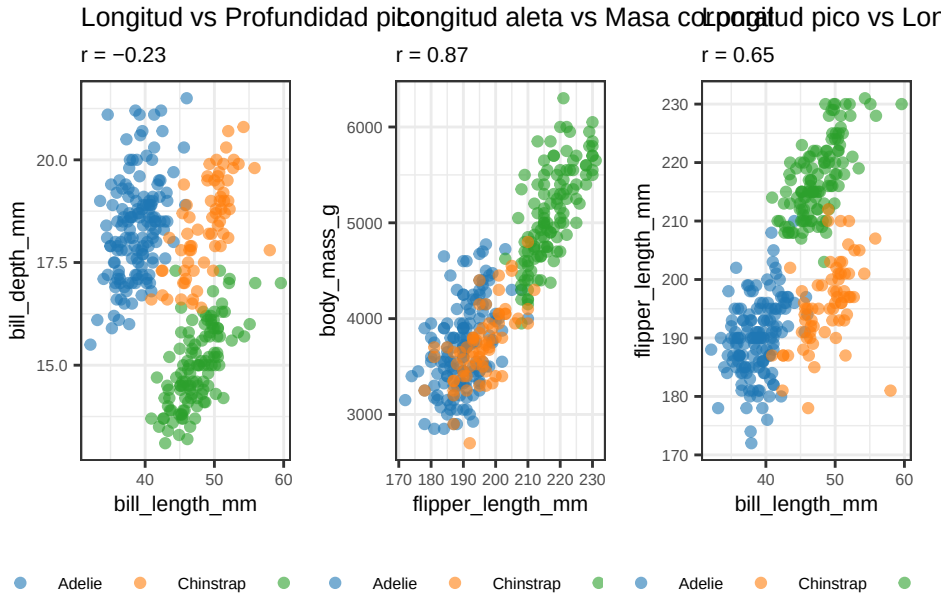
Fuente: Tyler Vigen, Spurious Correlations (tylervigen.com). Licencia Creative Commons Attribution.



Estos ejemplos ilustran una regla fundamental del análisis de datos: **una correlación, por fuerte que sea, no prueba causalidad**. Para establecer una relación causal se necesita un diseño experimental controlado, no solo datos observacionales.

8.5. Correlaciones en los datos de pingüinos

Para consolidar los conceptos, exploramos las correlaciones en el dataset de pingüinos, que tiene varias variables numéricas con relaciones interesantes:



El panel de tres gráficos muestra situaciones muy distintas. La relación entre longitud de aleta y masa corporal es la más fuerte y clara: los pingüinos más grandes tienen aletas más largas. La relación entre dimensiones del pico es más compleja: el coeficiente global puede ser bajo o incluso negativo porque las tres especies tienen patrones diferentes que se mezclan en la nube de puntos. Este es un ejemplo de cómo el coloreado por grupos puede revelar estructura que el coeficiente global oculta.

8.6. Resumen del capítulo

Este capítulo ha extendido el análisis exploratorio más allá de las variables individuales para explorar las relaciones entre pares de variables. El gráfico de dispersión proporciona la visión cualitativa; el coeficiente de correlación de Pearson la cuantifica en un único número entre -1 y $+1$. La línea de regresión resume la tendencia lineal y permite hacer predicciones dentro del rango de los datos.

El mensaje más importante del capítulo es la distinción entre correlación y causalidad: una correlación fuerte, incluso con $r > 0,95$, no prueba que una variable cause a la otra. Los ejemplos espurios de Vigen ilustran con humor que cualquier búsqueda sistemática de correlaciones en bases de datos grandes encontrará asociaciones sin ningún sentido causal. La única forma de

establecer causalidad es a través del diseño experimental controlado, que introduciremos en el capítulo dedicado a la introducción al diseño experimental.

9. El control estadístico de procesos

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Distinguir entre variabilidad por causas comunes y variabilidad por causas especiales, e identificar ejemplos de cada tipo en un proceso industrial.
- Diferenciar la variabilidad a corto plazo de la variabilidad a largo plazo y reconocer sus causas típicas.
- Explicar qué significa que un proceso está "bajo control estadístico" y qué consecuencias tiene para la toma de decisiones.
- Interpretar un gráfico de control X-barra/S: límites de control, línea central, señales de alarma.
- Aplicar las reglas básicas de detección de causas especiales en un gráfico de control.
- Entender el concepto de capacidad de proceso y los índices C_p y C_{pk}.
- Usar `qicharts2` en R para construir gráficos de control a partir de datos reales de proceso.

Conceptos clave: **control estadístico de procesos, causas comunes, causas especiales, variabilidad a corto y largo plazo, gráfico de control, límites de control, X-barra, rango, reglas de Western Electric, capacidad de proceso,** C_p**,** C_{pk}**.**

Sobre el código de este capítulo

Los gráficos de control de este capítulo se generan exclusivamente con R, usando la librería `qicharts2`. Es uno de los casos en que R dispone de herramientas específicas mucho más adecuadas que Python para esta tarea.

9.1. El origen del control estadístico de procesos

A finales de los años 1920, el ingeniero Walter Shewhart, trabajando en los laboratorios Bell de AT&T, se enfrentaba a un problema práctico: los teléfonos que fabricaban tenían una variabilidad de calidad que nadie sabía cómo interpretar. ¿Cuándo era necesario intervenir en el proceso y cuándo era mejor dejarlo en marcha? Intervenir innecesariamente introducía más variabilidad, no menos.

Shewhart formuló una distinción que cambió la forma de entender la calidad industrial: no toda la variabilidad es igual. Hay una variabilidad que es inherente al proceso — inevitable, predecible, consecuencia de la suma de muchas causas pequeñas — y hay otra variabilidad que es señal de que algo ha cambiado y que requiere investigación.

Esta distinción, y la herramienta que Shewhart desarrolló para detectarla — el gráfico de control —, siguen siendo hoy el fundamento del control estadístico de procesos (SPC, del inglés *Statistical Process Control*).

9.2. Causas comunes y causas especiales

9.2.1. La variabilidad por causas comunes

Las **causas comunes** son todas aquellas fuentes de variación que están siempre presentes en el proceso, que afectan a todos los resultados de forma continua y que son inherentes al sistema tal como está diseñado. Su efecto individual es pequeño, pero su suma produce la variabilidad de fondo del proceso.

En un proceso de llenado de yogures, las causas comunes incluyen: pequeñas fluctuaciones de presión en la línea de llenado, variaciones mínimas en la viscosidad del producto, pequeñas diferencias en la temperatura del producto, vibraciones del equipo. Ninguna de estas causas produce por sí sola una desviación importante, pero juntas explican por qué dos envases consecutivos no pesan exactamente lo mismo.

En un laboratorio de análisis de leche, las causas comunes incluyen: la variabilidad natural de la técnica analítica, pequeñas diferencias entre repeticiones del mismo analista, fluctuaciones del instrumento dentro de su rango normal de operación.

La variabilidad por causas comunes produce una distribución aproximadamente normal y predecible. Un proceso que solo tiene causas comunes se dice que está *bajo control estadístico*: sus resultados son aleatorios dentro de un rango definido y calculable.

> **Causas comunes y el sistema**
>
> Las causas comunes son responsabilidad del **sistema**, no del operario. Eliminarlas requiere cambiar el diseño del proceso, los equipos, los materiales o el método. Un operario que trabaja correctamente dentro de un sistema con mucha variabilidad no puede reducir esa variabilidad por sí solo.
> Esto tiene implicaciones importantes para la gestión: culpar al operario de la variabilidad causada por el sistema es un error que Deming identificó como uno de los principales obstáculos para la mejora de la calidad. La ausencia de procedimientos escritos, la falta de formación o la inexistencia de instrucciones de trabajo en el puesto son causas comunes del sistema — no del operario — y solo la dirección puede corregirlas. Este es uno de los principios fundamentales de Lean Manufacturing: estandarizar antes de mejorar.

9.2.2. La variabilidad por causas especiales

Las **causas especiales** son eventos discretos, identificables y no siempre presentes que producen una variación adicional sobre la variabilidad de fondo. Su aparición es una señal de que algo ha cambiado en el proceso.

En el proceso de llenado de yogures, las causas especiales incluyen: un cambio brusco de presión en la línea, el desgaste progresivo de una válvula dosificadora, un ajuste incorrecto del operario, un cambio de lote de materia prima con propiedades diferentes.

En el laboratorio, las causas especiales incluyen: un analista que ha desarrollado un hábito incorrecto de lectura, un instrumento que necesita calibración, una muestra contaminada o mal conservada. Como veremos en el capítulo dedicado al análisis del sistema de medición, el sesgo sistemático de un analista es un ejemplo clásico de causa especial identificable y corregible.

La variabilidad por causas especiales produce patrones no aleatorios en los datos: tendencias, saltos bruscos, ciclos, puntos fuera de los límites esperados. Estos patrones son detectables y su detección es el objetivo del gráfico de control.

> **i** Causas especiales y el operario
>
> Las causas especiales son responsabilidad del **operario o del equipo de proceso**. Cuando aparece una causa especial, la acción correcta es investigarla, identificarla y eliminarla. No requiere rediseñar el sistema — requiere encontrar qué cambió y corregirlo.
> La distinción entre causas comunes (sistema) y causas especiales (proceso) es fundamental para actuar correctamente: intervenir en el sistema cuando hay una causa especial, o tratar de corregir el proceso cuando el problema es del sistema, son errores que empeoran la situación.

9.2.3. Ejemplos en la industria quesera y alimentaria

Situación	Tipo de causa	Acción correcta
El extracto seco varía ±0,5 % de forma aleatoria entre fabricaciones	Común	Revisar el proceso de estandarización y los equipos
El extracto seco sube de forma sostenida durante tres semanas de verano	Especial	Investigar cambio estacional, ajuste del operario
El pH varía ±0,05 unidades de forma aleatoria	Común	Revisar la precisión del método analítico
Un análisis de pH da 4,35 cuando el rango habitual es 4,5-4,9	Especial	Verificar la muestra, repetir el análisis
Los recuentos de coliformes fluctúan con mediana 10 ufc/g	Común	Revisar las condiciones generales de higiene
Los coliformes alcanzan 20.200 ufc/g en agosto	Especial	Investigar la fabricación concreta y las condiciones de ese día
El peso de envases varía ±2 g de forma aleatoria	Común	Revisar la precisión de la dosificadora
El peso medio cae 5 g en una hora	Especial	Verificar presión, temperatura y ajustes del operario

9.2.4. La conexión con la distribución normal

Cuando un proceso opera solo con causas comunes, sus resultados se distribuyen de forma aproximadamente normal alrededor de la media del proceso. Cuando aparece una causa especial, la distribución ya no es normal ni predecible: puede aparecer un sesgo, una cola asimétrica, o incluso una distribución bimodal. Estos patrones son exactamente lo que los gráficos de control están diseñados para detectar.

9.3. Variabilidad a corto plazo y variabilidad a largo plazo

Además de la distinción entre causas comunes y especiales, es útil distinguir entre la variabilidad que se manifiesta en períodos cortos de tiempo y la que solo se hace visible a lo largo de semanas, meses o años.

9.3.1. Variabilidad a corto plazo

Es la variabilidad que se observa dentro de un turno o entre turnos consecutivos. Es la que captura el gráfico de control diario. Sus causas son generalmente visibles y trazables: un ajuste incorrecto, un cambio de turno, una variación de temperatura ambiental durante el día.

9.3.2. Variabilidad a largo plazo

Es la variabilidad que solo se hace visible cuando se analizan datos de semanas o meses. Sus causas son más difíciles de identificar precisamente porque su efecto es gradual e imperceptible en el día a día:

En la industria quesera: - Deriva gradual de la composición de la leche a lo largo de la lactación (más grasa en otoño-invierno, más proteína en primavera) - Cambio imperceptible en el tiempo de acidificación por acostumbramiento o mutación del cultivo iniciador - Desgaste progresivo de equipos de corte de cuajada que produce granos cada vez más grandes - Deriva en los procedimientos de estandarización que el operario ha ido ajustando informalmente sin documentar - Colmatación progresiva del electrodo de los pHmetros por mantenimiento y limpieza insuficientes: las medidas de pH van perdiendo fiabilidad de forma tan gradual que el error pasa desapercibido durante semanas o meses, hasta que la desviación es ya demasiado grande para ignorarla. Es una de las causas de variabilidad analítica más frecuentes en quesería y una de las menos vigiladas

En la industria alimentaria en general: - Cambio gradual en las características de un proveedor de envases que afecta al sellado - Deriva estacional en la humedad ambiental que afecta al secado de productos - Acumulación de depósitos en intercambiadores de calor que reduce progresivamente la eficiencia

En la industria en general: - Desgaste de herramientas de corte en mecanizado que produce dimensiones progresivamente fuera de tolerancia - Degradación de catalizadores en procesos químicos - Deriva de calibración de instrumentos de medida

> **La variabilidad a largo plazo y los procedimientos**
>
> Una de las causas más frecuentes e insidiosas de la variabilidad a largo plazo es la **deriva en los procedimientos**: los operarios van introduciendo pequeños ajustes informales que no quedan documentados y que con el tiempo se convierten en la forma habitual de trabajar, desviándose del procedimiento original sin que nadie lo haya decidido explícitamente.
> Lean Manufacturing pone especial énfasis en la **estandarización y auditoría de procedimientos** precisamente para combatir esta deriva. Un procedimiento que no se audita regularmente tiende a evolucionar espontáneamente, no siempre en la dirección correcta. Los gráficos de control a largo plazo son una herramienta de auditoría del proceso: si la media del proceso o su dispersión cambian gradualmente a lo largo de meses, es señal de que algo en el sistema ha derivado.

9.4. El gráfico de control: la herramienta de Shewhart

Un **gráfico de control** es una representación temporal de los resultados del proceso con tres líneas horizontales:

- **La línea central (CL):** la media del proceso en condiciones de referencia
- **El límite de control superior (UCL):** la media más 3 desviaciones típicas
- **El límite de control inferior (LCL):** la media menos 3 desviaciones típicas

Shewhart eligió ± 3 como límites por razones prácticas: con una distribución normal, el 99,7 % de los valores caen dentro de ese rango. Un punto fuera de los límites es tan improbable por azar (probabilidad $< 0{,}3\,\%$) que su aparición es casi siempre señal de una causa especial.

> **Límites de control vs. especificaciones**
>
> Los límites de control **no son** las especificaciones del producto ni los límites legales. Son límites estadísticos calculados a partir del comportamiento real del proceso. Un proceso puede estar bajo control estadístico y aun así producir producto fuera de especificación, si su variabilidad natural es demasiado grande. Esta es la conexión con el concepto de capacidad de proceso, que veremos más adelante en este capítulo y en detalle en el capítulo dedicado al RD 1801/2008.

9.4.1. El gráfico X-barra/S y el muestreo

En la práctica industrial, los datos no se toman de forma continua sino mediante **muestreo**: a intervalos regulares de tiempo se toma un pequeño grupo de unidades consecutivas, se miden y se registran. Para cada subgrupo se calculan:

- **La media del subgrupo ($\bar{X}$):** representa el nivel del proceso en ese momento
- **La desviación típica del subgrupo (S):** mide la dispersión de los valores dentro del subgrupo y es más robusta que el rango cuando el tamaño del subgrupo es pequeño

El intervalo de muestreo es una decisión de diseño importante. Un intervalo corto (cada 5 minutos) permite detectar problemas rápidamente pero genera mucho trabajo de toma de datos. Un intervalo largo (cada hora) es más manejable pero puede perder señales importantes. En la

práctica industrial se busca un equilibrio entre la frecuencia necesaria para tomar decisiones a tiempo y el coste del muestreo.

En nuestro caso práctico, simularemos un muestreo de **5 envases cada 3 minutos**, lo que da 160 subgrupos a lo largo del turno de 8 horas — suficiente para ver las derivas con claridad sin emborronar el gráfico.

> **i** Muestreo automático vs. muestreo manual
>
> Un muestreo cada 3 minutos solo es realista con un **sistema de control de peso automático en línea**, integrado en la propia línea de llenado. Estos sistemas pesan cada envase o toman muestras automáticas a intervalos programados y registran los datos sin intervención del operario.
> En un sistema de **muestreo manual**, donde el operario tiene que detener la línea, pesar los envases, anotar los resultados y calcular la media del subgrupo, un intervalo inferior a 5-10 minutos no es realista: no hay tiempo material para hacerlo correctamente. Un operario presionado por un intervalo demasiado corto acabará tomando atajos — pesando menos envases, anotando de memoria, saltando muestras — lo que invalida el gráfico de control.
> El diseño del sistema de muestreo debe ser compatible con la carga de trabajo real del operario. Un gráfico de control basado en datos mal tomados es peor que no tener gráfico: da una falsa sensación de control.

9.4.2. Las reglas de detección

Además de los puntos fuera de los límites de control, hay patrones en la secuencia de puntos que también indican la presencia de causas especiales. Las **reglas de Western Electric** son el conjunto más utilizado:

- **Regla 1:** un punto fuera de los límites ± 3
- **Regla 2:** dos de tres puntos consecutivos más allá de ± 2 en el mismo lado
- **Regla 3:** cuatro de cinco puntos consecutivos más allá de ± 1 en el mismo lado
- **Regla 4:** ocho puntos consecutivos en el mismo lado de la línea central

Cada regla detecta un tipo diferente de señal: la regla 1 detecta cambios bruscos, las reglas 2 y 3 detectan tendencias moderadas, la regla 4 detecta desplazamientos sostenidos de la media.

9.5. Caso práctico: control del proceso de llenado de yogures

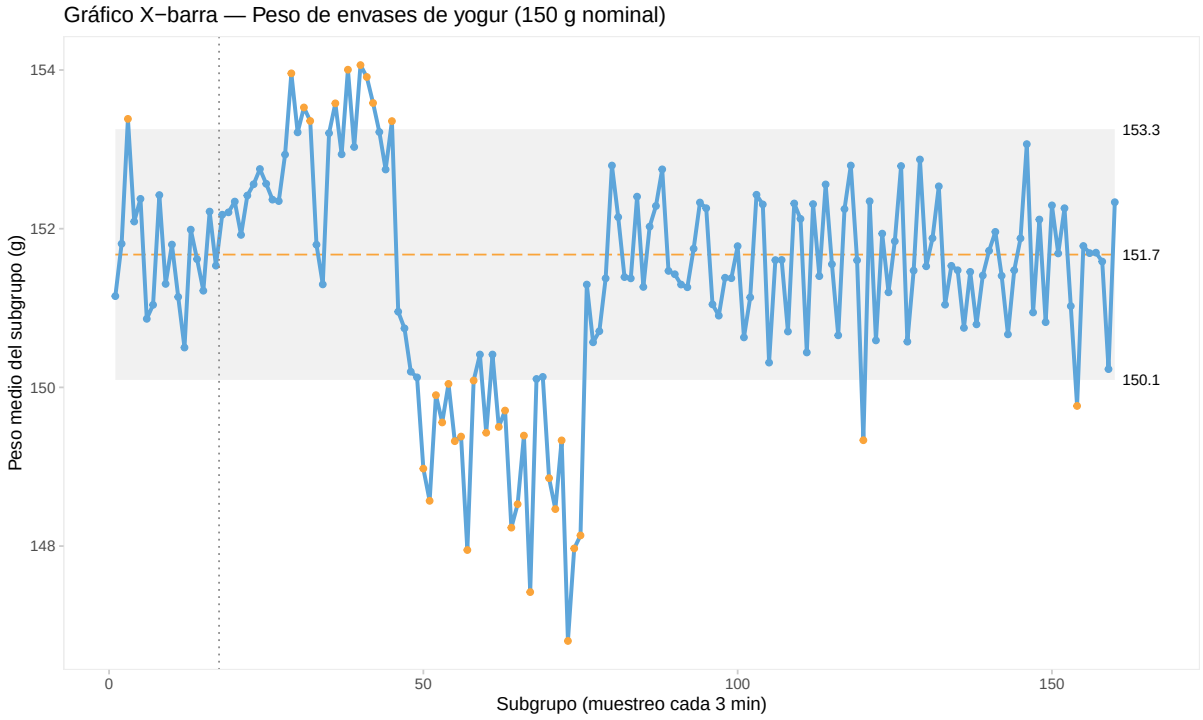
Usamos el dataset `llenado_yogures_muestra.csv` que contiene los resultados de un muestreo de 5 envases cada 3 minutos durante un turno de 8 horas (160 subgrupos, 800 envases en total). El turno incluye varias derivas simuladas que el gráfico de control debería detectar.

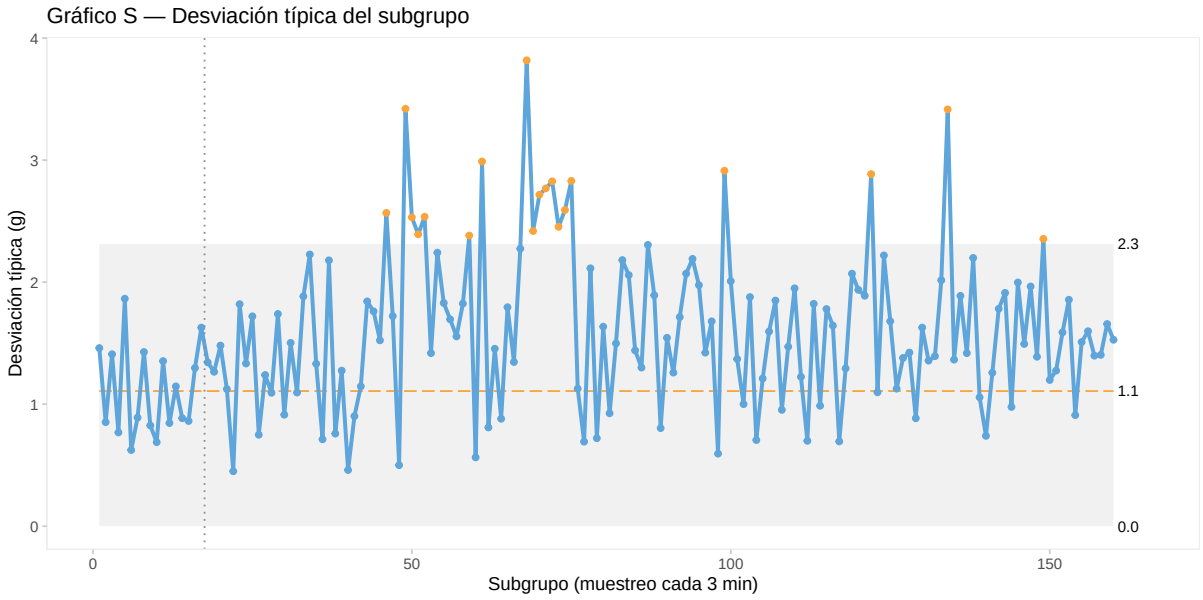
9.5.1. Fase I: establecer los límites de control

Usamos los primeros 17 subgrupos (proceso estable al inicio del turno, hasta las 08:51) como período de referencia para calcular los límites:

```
Subgrupos: 160
```

```
Envases por subgrupo: 5
```





9.5.2. Interpretación de los gráficos

El gráfico X-barra muestra con claridad las tres derivas simuladas:

Deriva ascendente (subgrupos ~17-42): la media del proceso sube progresivamente desde aproximadamente 151,5 g hasta 153 g. Los puntos empiezan a aparecer sistemáticamente por encima de la línea central, activando primero las reglas 3 y 4 y luego la regla 1. En un proceso real, esta señal indicaría que la dosificadora está entregando más producto de lo previsto —

posiblemente por desgaste de la válvula o por un aumento de temperatura que reduce la viscosidad del yogur.

Salto brusco a la baja (subgrupos ~42-50): la media cae bruscamente por debajo del límite de control inferior. Esta señal corresponde al ajuste incorrecto del operario: al detectar la deriva ascendente, corrigió en exceso. Los saltos bruscos de este tipo son consecuencia habitual de ajustes manuales no documentados.

Aumento de dispersión (subgrupos ~50-75): el gráfico S muestra un aumento progresivo de la desviación típica mientras que el X-barra muestra la media ligeramente baja pero sin tendencia clara. Este patrón — dispersión creciente sin cambio de media — es característico del desgaste de equipos: la dosificadora empieza a ser inconsistente, llenando algunos envases de más y otros de menos.

Restauración tras mantenimiento (subgrupos ~75 en adelante): tanto la media como el rango vuelven al rango de referencia.

> **i** `qcc`: una alternativa más potente
>
> La librería `qicharts2` es moderna, integrada con ggplot2 y muy fácil de usar para casos estándar. Para análisis más avanzados — descomposición detallada de la varianza, índices de capacidad de proceso, gráficos CUSUM para detectar derivas lentas — la librería `qcc` ofrece más funcionalidades.
> `qcc` es la librería de referencia académica para SPC en R, utilizada en el libro *Quality Control with R* de Emilio L. Cano, Javier M. Moguerza y Mariano Prieto Corcoba (Springer, 2015), con código disponible en qualitycontrolwithr.com.

9.6. La capacidad del proceso

Saber que un proceso está bajo control estadístico no es suficiente: también necesitamos saber si ese proceso es capaz de cumplir las especificaciones. Un proceso puede ser perfectamente estable y predecible, y aun así producir demasiado producto fuera de los límites aceptables si su variabilidad natural es demasiado grande.

La **capacidad del proceso** mide la relación entre la variabilidad natural del proceso y los límites de especificación. Se cuantifica mediante dos índices:

9.6.1. El índice C_p

$$C_p = \frac{LSE - LIE}{6\sigma}$$

donde LSE es el límite superior de especificación, LIE es el límite inferior de especificación y σ es la desviación típica del proceso. El denominador 6σ representa la amplitud total de la variabilidad natural (± 3 a cada lado de la media).

Un $C_p = 1$ significa que la variabilidad natural del proceso ocupa exactamente el espacio entre los dos límites de especificación. Un $C_p > 1$ indica que el proceso tiene más "holgura" que la

mínima necesaria. En la práctica industrial se exige habitualmente $C_p \geq 1{,}33$ o incluso $C_p \geq 1{,}67$ para procesos críticos.

El problema de C_p es que no tiene en cuenta si la media del proceso está centrada entre los límites. Un proceso puede tener $C_p > 1$ y estar produciendo muchos defectos si su media está desplazada hacia uno de los límites.

9.6.2. El índice C_{pk}

$$C_{pk} = \text{mín}\left(\frac{LSE - \mu}{3\sigma},\ \frac{\mu - LIE}{3\sigma}\right)$$

C_{pk} toma el mínimo de las dos distancias — de la media al límite superior y de la media al límite inferior — y la expresa en unidades de 3 . A diferencia de C_p, sí tiene en cuenta el centrado de la media.

Si el proceso está perfectamente centrado, $C_{pk} = C_p$. Si la media está desplazada, $C_{pk} < C_p$. Un C_{pk} bajo con un C_p alto indica que el problema no es la variabilidad sino el centrado del proceso.

9.6.3. Aplicación al proceso de llenado de yogures

Para el proceso de llenado de yogures en el período estable (Fase I), con $\mu \approx 151{,}5$ g y $\sigma \approx 1{,}3$ g, y usando como límites de especificación los del RD 1801/2008 (T2 = 141 g como límite inferior; no hay límite superior legal):

$$C_{pk} = \frac{\mu - LIE}{3\sigma} = \frac{151{,}5 - 141}{3 \times 1{,}3} = \frac{10{,}5}{3{,}9} \approx 2{,}7$$

Un $C_{pk} = 2{,}7$ indica un proceso muy capaz respecto al límite T2. Pero si la variabilidad aumenta a $\sigma = 3$ g (como en el período de dispersión creciente):

$$C_{pk} = \frac{151{,}5 - 141}{3 \times 3} = \frac{10{,}5}{9} \approx 1{,}2$$

El proceso sigue siendo capaz ($C_{pk} > 1$) pero con mucho menos margen. Y si la media baja a 149 g (período tras el ajuste incorrecto):

$$C_{pk} = \frac{149 - 141}{3 \times 3} = \frac{8}{9} \approx 0{,}9$$

Un $C_{pk} < 1$ indica que el proceso está produciendo producto por debajo de T2, lo que el RD 1801/2008 prohíbe. El análisis de capacidad conecta directamente con el análisis económico de la sobredosificación que veremos en el capítulo dedicado al RD 1801/2008.

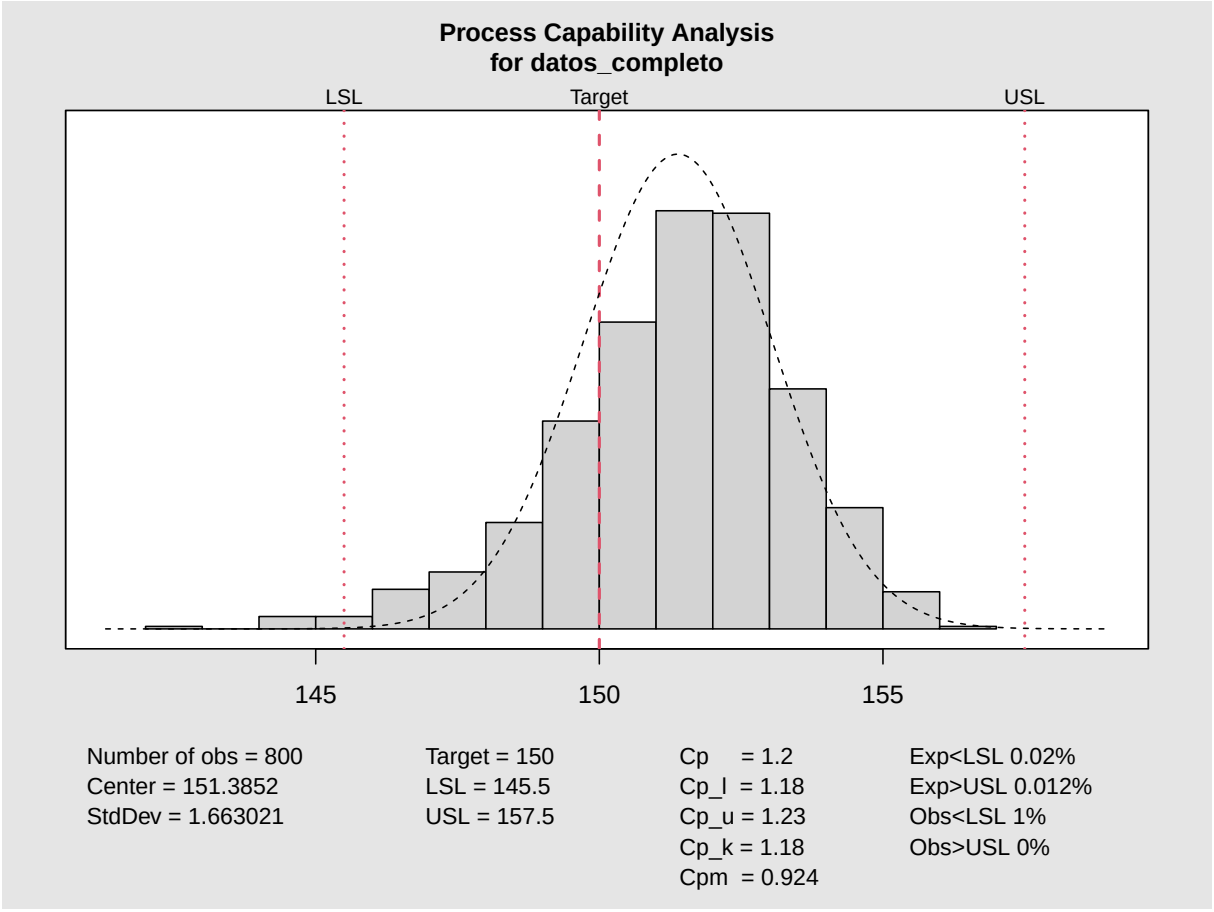
9.6.4. El gráfico de capacidad

Los índices de capacidad son más fáciles de interpretar cuando se visualizan en un gráfico que muestra simultáneamente la distribución del proceso y los límites de especificación. Usamos la librería `qcc` para generarlo.

Como límite inferior de especificación (LSL) usamos **T1 = 145,5 g**, el límite por debajo del cual un envase se considera defectuoso según el RD 1801/2008. Como límite superior usamos 157,5 g, valor simétrico respecto al peso nominal de 150 g, que aunque no existe como límite legal nos permite visualizar el centrado del proceso. El análisis detallado de los límites T1 y T2, el porcentaje máximo permitido de envases defectuosos y el análisis económico de la sobredosificación se desarrollan en el capítulo dedicado al RD 1801/2008.

Gráfico 1: capacidad del turno completo (incluyendo derivas)

En la situación real, los 800 envases muestreados durante el turno han salido al mercado — no había sistema de detección en tiempo real que los eliminara. El gráfico muestra la capacidad del proceso tal como ocurrió, con todas las derivas incluidas:




```
Process Capability Analysis

Call:
process.capability(object = q_completo, spec.limits = c(145.5,     157.5), target = 150)
```

```
Number of obs = 800          Target = 150
       Center = 151.4           LSL = 145.5
       StdDev = 1.663           USL = 157.5

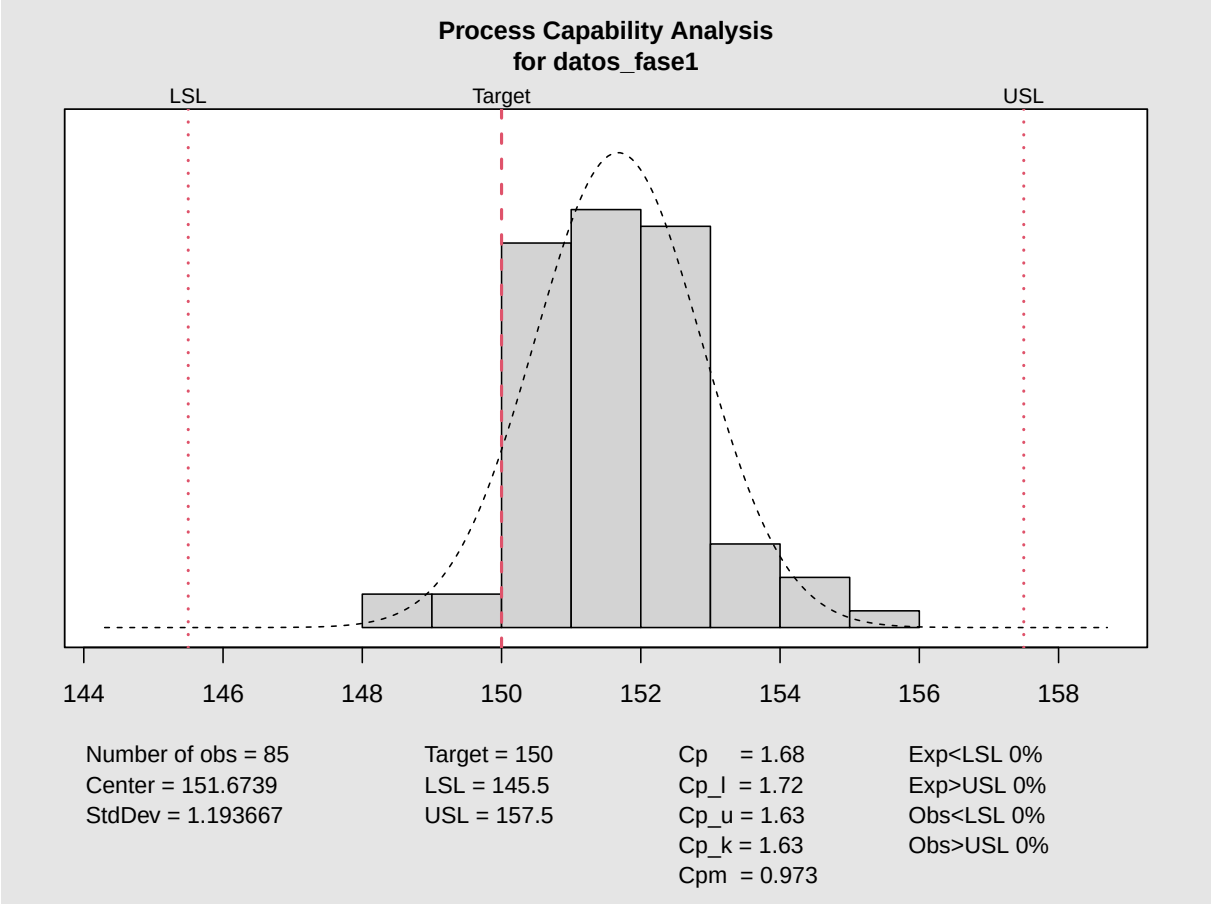
Capability indices:

       Value    2.5%   97.5%
Cp    1.2026  1.1437  1.2616
Cp_l  1.1796  1.1274  1.2319
Cp_u  1.2256  1.1716  1.2797
Cp_k  1.1796  1.1174  1.2419
Cpm   0.9241  0.8703  0.9778

Exp<LSL 0.02%    Obs<LSL 1%
Exp>USL 0.012%   Obs>USL 0%
```

Gráfico 2: capacidad del proceso en Fase I (solo proceso estable)

Ahora repetimos el análisis usando únicamente los primeros 17 subgrupos, cuando el proceso estaba bajo control estadístico sin causas especiales activas. Esta es la capacidad potencial del proceso si se eliminan las derivas:



```
Process Capability Analysis

Call:
process.capability(object = q_fase1, spec.limits = c(145.5, 157.5),     target = 150)

Number of obs = 85           Target = 150
       Center = 151.7           LSL = 145.5
       StdDev = 1.194           USL = 157.5

Capability indices:

       Value    2.5%  97.5%
Cp    1.6755  1.4224  1.928
Cp_l  1.7241  1.4973  1.951
Cp_u  1.6270  1.4121  1.842
Cp_k  1.6270  1.3709  1.883
Cpm   0.9728  0.7847  1.161

Exp<LSL 0%   Obs<LSL 0%
Exp>USL 0%   Obs>USL 0%
```

La comparación entre los dos gráficos muestra con claridad el efecto de las derivas sobre la capacidad del proceso. En el turno completo, la distribución es más ancha y menos centrada, lo que se traduce en índices C_p y C_{pk} más bajos y en un mayor porcentaje de envases fuera de especificación. En la Fase I, la distribución es más estrecha y mejor centrada, con índices notablemente mejores.

La diferencia entre los dos escenarios es precisamente el argumento económico de la mejora: eliminar las causas especiales que producen las derivas no solo mejora la calidad del producto sino que reduce la sobredosificación necesaria para cumplir la legislación. Este análisis se desarrolla en detalle en el capítulo dedicado al RD 1801/2008.

Establecer límites técnicos a partir de la capacidad

Un error frecuente en la industria es fijar límites técnicos de proceso ("no más de X defectos por turno") sin haber evaluado previamente la capacidad del proceso. Si el proceso tiene una variabilidad natural que produce inevitablemente un 5 % de defectos, fijar el límite en 1 % es irrealista — no importa cuánto se esfuercen los operarios.
El enfoque correcto es:

1. Medir la capacidad real del proceso (C_{pk})
2. Calcular el porcentaje de defectos que esa capacidad produce inevitablemente
3. Fijar los límites técnicos en función de esa capacidad real
4. Trabajar en la reducción de la variabilidad para mejorar la capacidad y reducir progresivamente los límites

Este es el vínculo entre el control estadístico de procesos y la mejora continua: el gráfico de control detecta las causas especiales, los índices de capacidad cuantifican la variabilidad de fondo, y la mejora continua trabaja en reducir esa variabilidad estructural. Lo veremos en profundidad en el capítulo dedicado a la mejora continua y el análisis de datos.

9.7. Actuar correctamente: la regla de oro del SPC

El gráfico de control no es solo una herramienta de detección — es también una guía de actuación:

- **Si el proceso está bajo control:** no intervenir. Los ajustes innecesarios introducen variabilidad adicional. Esta es una de las lecciones contraintuitivas del SPC: a veces la mejor acción es no hacer nada.
- **Si el gráfico muestra una señal:** investigar la causa especial, identificarla y eliminarla. No ajustar el proceso a ciegas — primero entender qué ocurrió.

El turno de yogures ilustra el coste de no seguir esta regla: el operario que ajustó la dosificadora al detectar la deriva ascendente introdujo un salto brusco que fue peor que la propia deriva. Si hubiera esperado a confirmar la señal con las reglas de Western Electric, el ajuste habría sido más preciso.

9.8. Resumen del capítulo

El control estadístico de procesos parte de una distinción fundamental: no toda la variabilidad es igual. La variabilidad por causas comunes es inherente al sistema y solo puede reducirse cambiando el sistema. La variabilidad por causas especiales es señal de que algo ha cambiado y debe investigarse. A esta distinción se añade la diferencia entre variabilidad a corto plazo — visible en el gráfico de control diario — y variabilidad a largo plazo, causada por derivas graduales en la composición de materias primas, el desgaste de equipos o la deriva imperceptible de los procedimientos.

El gráfico de control X-barra/S detecta ambos tipos de señal. Los índices de capacidad C_p y C_{pk} cuantifican si la variabilidad natural del proceso es compatible con las especificaciones. Estos dos conceptos — control y capacidad — son los pilares del SPC y la base sobre la que se construye la mejora continua.

10. Introducción al diseño de experimentos

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Explicar por qué el enfoque OFAT (un factor a la vez) es insuficiente y puede llevar a conclusiones incorrectas.
- Identificar los elementos de un experimento diseñado: factores, niveles, respuesta, réplicas y aleatorización.
- Interpretar un gráfico de efectos principales y un gráfico de interacciones.
- Reconocer una interacción entre factores y explicar su importancia práctica.
- Proponer un diseño factorial 2^2 para un problema concreto de proceso quesero.

Conceptos clave: **diseño de experimentos, factor, nivel, respuesta, diseño factorial, efecto principal, interacción, OFAT, réplica, aleatorización**.

10.1. El problema del ensayo y error: por qué "un factor a la vez" no es suficiente

En la industria es habitual enfrentarse a preguntas del tipo: ¿a qué temperatura debo cuajar para obtener mejor retención de materia prima? ¿Qué dosis de cuajo es la óptima? ¿Cambia el resultado si modifico los dos a la vez?

La respuesta intuitiva es probar una cosa cada vez: primero cambio la temperatura y veo qué pasa, luego cambio la dosis y veo qué pasa. Este enfoque se conoce como **OFAT** (*One Factor At a Time*, un factor a la vez) y es, con diferencia, el más extendido en la práctica industrial. Su aparente sencillez lo hace atractivo: parece lógico, ordenado y fácil de interpretar.

El problema es que el enfoque OFAT es incorrecto en la mayoría de los casos industriales reales. Tiene dos defectos fundamentales:

Primero, no detecta las interacciones entre factores. Una interacción ocurre cuando el efecto de un factor depende del nivel al que se encuentra el otro. Por ejemplo: puede que subir la temperatura mejore la retención de materia prima cuando la dosis de cuajo es baja, pero no cuando es alta. Si solo cambiamos un factor a la vez, fijaremos el otro en un nivel arbitrario y nunca sabremos si la conclusión que obtenemos es válida para otros niveles del factor fijo. Podemos llegar a recomendar "usa temperatura alta" cuando la respuesta correcta es "usa temperatura alta solo si usas dosis baja de cuajo".

Segundo, es menos eficiente que el diseño factorial. Para estudiar dos factores con tres réplicas, el OFAT requiere al menos 12 experimentos pero solo obtiene información sobre cada factor de forma independiente. Un diseño factorial 2^2 con tres réplicas también usa 12

experimentos, pero obtiene información sobre los dos factores y su interacción simultáneamente, con mayor precisión estadística.

El **diseño de experimentos** (DoE, del inglés *Design of Experiments*) es la metodología que permite estudiar varios factores simultáneamente de forma eficiente, detectar interacciones y obtener conclusiones estadísticamente sólidas con el mínimo número de experimentos necesarios.

10.2. Los conceptos básicos

10.2.1. Factor y niveles

Un **factor** es una variable que controlamos deliberadamente durante el experimento. Los **niveles** son los valores que ese factor toma en el experimento. Usamos habitualmente dos niveles por factor — un nivel bajo y un nivel alto — lo que se denomina diseño de dos niveles.

En nuestro caso:

- **Factor A — Temperatura de cuajado:** nivel bajo = 30°C, nivel alto = 34°C
- **Factor B — Dosis de cuajo:** nivel bajo = 20 ml/100L, nivel alto = 30 ml/100L

10.2.2. La variable respuesta

La **respuesta** es la variable que medimos para evaluar el efecto de los factores. En nuestro experimento, la respuesta es el **porcentaje de retención de materia prima en el extracto seco magro (ESM) del queso**: la proporción de la materia prima de la leche que queda retenida en el queso, expresada en porcentaje. En condiciones normales de proceso, este indicador oscila entre el 92 % y el 98 %.

10.2.3. Las réplicas

Una **réplica** es la repetición completa de una combinación de tratamiento. Las réplicas son imprescindibles porque permiten estimar la variabilidad experimental — la variación que existe incluso cuando hacemos exactamente lo mismo dos veces — y distinguirla del efecto real de los factores. Sin réplicas no podemos saber si una diferencia entre dos tratamientos es real o es simplemente ruido experimental.

10.2.4. La aleatorización

El orden en que se realizan los experimentos debe ser **aleatorio**. Si fabricamos primero todas las combinaciones con temperatura baja y luego todas con temperatura alta, cualquier factor que cambie con el tiempo (variación de la leche, temperatura ambiental, fatiga del operario) quedará confundido con el efecto de la temperatura. La aleatorización distribuye estos efectos de forma aleatoria entre todas las combinaciones y protege la validez de las conclusiones.

10.3. El diseño factorial 2^2

Con dos factores y dos niveles cada uno tenemos $2^2 = 4$ combinaciones posibles. Con 3 réplicas por combinación, el experimento completo requiere $4 \times 3 = 12$ fabricaciones:

Fabricación	Temperatura	Dosis de cuajo
1-3	30°C	20 ml/100L
4-6	30°C	30 ml/100L
7-9	34°C	20 ml/100L
10-12	34°C	30 ml/100L

El orden real de fabricación debe aleatorizarse. En la tabla aparecen agrupadas por combinación solo para facilitar la lectura.

> **i** ¿Por qué 3 réplicas?
>
> Con 2 réplicas por combinación tendríamos 8 fabricaciones en total — suficiente para estimar los efectos, pero con muy poca información sobre la variabilidad experimental. Con 3 réplicas (12 fabricaciones) ya tenemos una estimación razonable del error. En proyectos industriales reales, el número de réplicas se decide en función del tiempo y el coste disponibles y de la magnitud del efecto que queremos detectar.

10.4. El caso práctico: temperatura y dosis de cuajo

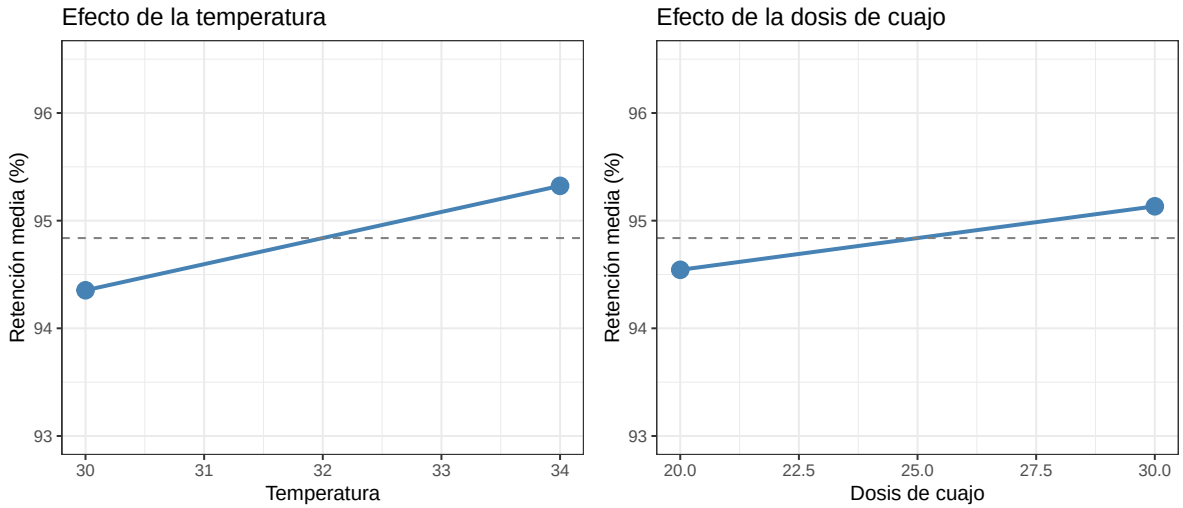
Cargamos los resultados del experimento:

```
# A tibble: 4 x 5
  temperatura dosis_cuajo     n media desv_tip
        <dbl>       <dbl> <int> <dbl>    <dbl>
1          30          20     3  93.8     0.12
2          30          30     3  95.0     0.31
3          34          20     3  95.3     0.31
4          34          30     3  95.3     0.17
```

La tabla de medias ya revela algo importante: a 30°C, subir la dosis de cuajo de 20 a 30 ml/100L mejora la retención en más de 1 punto (de 93,75 % a 94,96 %). Pero a 34°C, esa misma subida de dosis apenas produce mejora (de 95,34 % a 95,31 %). Esto es exactamente una interacción, y es precisamente la información que el enfoque OFAT nunca habría podido revelar.

10.5. Los gráficos de efectos principales

El **gráfico de efectos principales** muestra el efecto medio de cada factor sobre la respuesta, promediando sobre todos los niveles del otro factor:

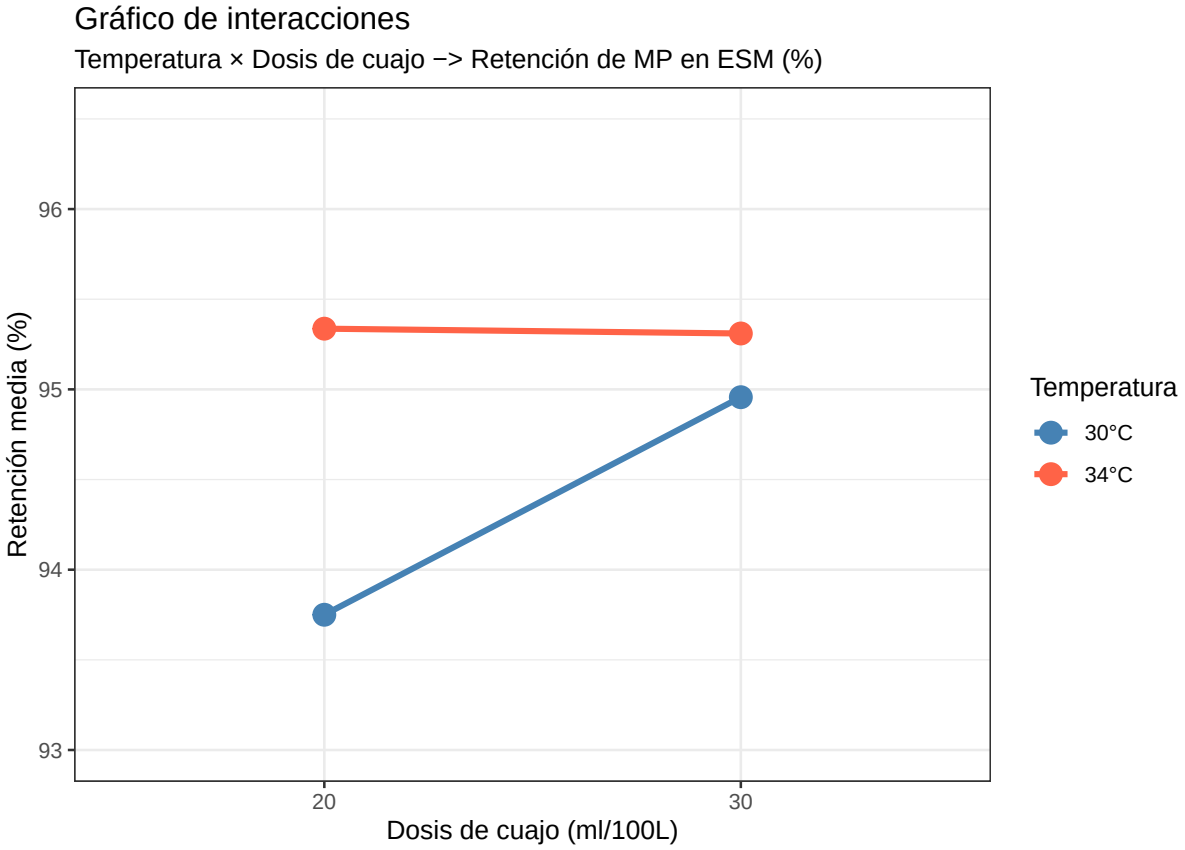


La línea discontinua horizontal es la media global del experimento. Los dos gráficos muestran que tanto la temperatura como la dosis de cuajo tienen un efecto positivo sobre la retención: subir la temperatura de 30°C a 34°C mejora la retención en promedio, y subir la dosis de 20 a 30 ml/100L también.

Sin embargo, estos son efectos **promedio** — la interacción que veremos a continuación matiza considerablemente estas conclusiones. El gráfico de efectos principales oculta el hecho de que el efecto de la dosis depende fuertemente de la temperatura.

10.6. El gráfico de interacciones

El **gráfico de interacciones** es el más informativo del análisis factorial. Representa las medias de cada combinación de tratamiento, con las líneas conectando los niveles de un factor para cada nivel del otro:



10.6.1. Cómo interpretar el gráfico de interacciones

La clave está en el **paralelismo de las líneas**:

- **Líneas paralelas** → no hay interacción. El efecto de la dosis de cuajo es el mismo independientemente de la temperatura a la que se trabaje.
- **Líneas que convergen o se cruzan** → hay interacción. El efecto de la dosis de cuajo depende de la temperatura.

En nuestro gráfico las líneas no son paralelas: a 30°C (línea azul), pasar de dosis baja a dosis alta produce una mejora notable de la retención. Pero a 34°C (línea roja), ambas dosis dan prácticamente el mismo resultado — la línea roja es casi horizontal. Las dos líneas convergen en el nivel alto de dosis.

La conclusión práctica es importante y no es trivial: si solo hubiéramos estudiado la dosis de cuajo a 30°C, habríamos concluido que conviene usar la dosis alta. Si hubiéramos hecho el experimento solo a 34°C, habríamos concluido que la dosis no importa. Ambas conclusiones son parcialmente correctas pero ninguna es completa. Solo el diseño factorial, que estudia los dos factores simultáneamente, revela la imagen completa: **la dosis alta solo aporta mejora cuando la temperatura es baja**.

Esta es exactamente la limitación del enfoque OFAT que describimos al principio del capítulo. Al fijar la temperatura en un valor y variar solo la dosis, obtenemos una respuesta que solo es válida para ese valor de temperatura. Si el nivel fijo es 30°C, la dosis parece importante; si es 34°C,

parece irrelevante. El OFAT nos da una respuesta incompleta que depende del nivel arbitrario al que fijamos el otro factor.

> **Interacción en lenguaje industrial**
>
> En la práctica, cuando un técnico responde "eso depende" a una pregunta sobre el efecto de un factor, casi siempre está describiendo una interacción. "¿Conviene usar más cuajo?" — "Depende de la temperatura a la que trabajes." Esa dependencia es una interacción, y el diseño factorial es la herramienta que la cuantifica y la hace visible. Las interacciones son muy frecuentes en procesos biológicos como la fabricación de queso, donde las condiciones de temperatura, pH, concentración de enzimas y composición de la leche interactúan constantemente.

10.7. Los puntos centrales

Una práctica habitual es añadir algunos experimentos con los factores en sus valores centrales — en nuestro caso, 32°C y 25 ml/100L. Estos **puntos centrales** tienen dos utilidades:

1. Permiten comprobar si la relación entre los factores y la respuesta es lineal o si hay curvatura (un efecto que los diseños de dos niveles no pueden detectar por sí solos).
2. Proporcionan una estimación adicional de la variabilidad experimental sin incrementar el número de combinaciones a estudiar.

Si la retención en el punto central es muy diferente de la media de las cuatro esquinas, hay curvatura y el modelo lineal no es suficiente para describir el proceso.

10.8. Herramientas para el diseño de experimentos

El análisis que hemos hecho aquí — gráficos de efectos principales e interacciones — se puede realizar con R y con cualquier software estadístico. Para proyectos más complejos con más factores, réplicas o restricciones de aleatorización, existen herramientas especializadas:

En R: las librerías `DoE.base` y `FrF2` permiten generar diseños factoriales completos y fraccionados, calcular efectos y construir los gráficos de análisis. `FrF2` es especialmente útil para diseños con muchos factores donde no es posible hacer todas las combinaciones.

En software industrial: Minitab y **JMP** son las herramientas más utilizadas en la industria para diseño de experimentos. Ambas integran el diseño del experimento, el análisis estadístico completo (incluyendo ANOVA) y los gráficos de diagnóstico en un flujo de trabajo guiado. Minitab es el estándar en muchos programas Six Sigma; JMP, desarrollado por SAS, es especialmente potente para el análisis visual interactivo. Ambas producen gráficos de efectos e interacciones similares a los que hemos construido aquí con R.

> **¿Por qué no hemos hecho ANOVA?**
>
> El análisis de varianza (ANOVA) es la herramienta estadística formal para determinar si los efectos que observamos en los gráficos son estadísticamente significativos o podrían deberse al azar. No lo hemos incluido aquí porque requiere conceptos de inferencia estadística que

van más allá del alcance de este capítulo introductorio.
Los gráficos de efectos e interacciones son suficientes para entender el concepto y para tomar decisiones orientativas en muchos casos industriales. Para proyectos formales de mejora — especialmente en contextos Six Sigma o de calificación de procesos — el ANOVA es imprescindible y el software especializado (Minitab, JMP) lo calcula automáticamente.

10.9. Del diseño de dos factores a diseños más complejos

El diseño 2^2 que hemos visto es el más sencillo posible. En la práctica, los procesos industriales tienen muchos más factores potenciales. Algunas extensiones naturales:

Más factores: un diseño 2^3 (tres factores, dos niveles) tiene 8 combinaciones; un 2 tiene 16. A partir de 4-5 factores, el número de combinaciones crece rápidamente y puede ser inviable hacer el experimento completo.

Diseños fraccionados y confundidos: cuando hay muchos factores, se puede hacer solo una fracción del diseño completo. Por ejemplo, en lugar de hacer las 32 combinaciones de un diseño 2 , se hacen solo 16 (la mitad). El precio que se paga es el **confundimiento**: algunos efectos quedan mezclados con otros y no se pueden estimar de forma independiente. En la práctica, se acepta este coste porque las interacciones de orden alto (tres o más factores a la vez) suelen ser despreciables, y confundirlas con efectos de orden bajo es un riesgo razonable.

En el mundo real, los procesos industriales tienen docenas de variables potenciales que pueden interactuar entre sí de formas complejas. Elegir qué factores estudiar, en cuántos niveles, con cuántas réplicas y con qué grado de confundimiento aceptable es una decisión que requiere experiencia y conocimiento del proceso. No existe un diseño universalmente óptimo: el mejor diseño es el que extrae la máxima información relevante con los recursos disponibles.

i Referencias para profundizar en DoE

La referencia clásica en diseño de experimentos para ingeniería industrial es **Montgomery, D.C. (2017). *Design and Analysis of Experiments* (9ª ed.). Wiley.** Es el libro de referencia en programas de ingeniería y Six Sigma, con capítulos específicos sobre diseños fraccionados, confundimiento y diseños de superficie de respuesta.
Para una introducción más accesible orientada a la práctica industrial, **Box, G.E.P., Hunter, J.S. y Hunter, W.G. (2005). *Statistics for Experimenters* (2ª ed.). Wiley** es una obra muy recomendable por su enfoque intuitivo y su orientación a la resolución de problemas reales.
Ambos libros están disponibles en las principales bibliotecas universitarias y en formatos digitales.

Diseños de superficie de respuesta: cuando se quiere optimizar el proceso — encontrar los valores óptimos de los factores, no solo comparar niveles — se usan diseños más elaborados que permiten modelar la curvatura de la respuesta.

En todos los casos, el principio es el mismo: estudiar los factores simultáneamente, aleatorizar el orden, replicar para estimar el error, y representar los resultados gráficamente antes de aplicar cualquier análisis formal.

10.10. El diseño de experimentos en la era de la inteligencia artificial

Una pregunta razonable en el contexto actual es: si puedo enviar los datos de un experimento a un modelo de inteligencia artificial como Claude, GPT o Gemini y pedirle que calcule los efectos e interacciones, ¿sigue siendo necesario aprender diseño de experimentos?

La respuesta es sí, y por razones que la IA no resuelve.

Lo que la IA puede hacer: si le proporcionas los datos de un experimento factorial — incluso con diseño confundido, si le explicas qué generadores usaste — un modelo de lenguaje puede calcular los efectos principales e interacciones, identificar cuáles son grandes y cuáles pequeños, e interpretar los resultados en lenguaje natural. Las versiones de pago de los principales modelos (Claude Pro, ChatGPT Plus, Gemini Advanced) pueden además generar el código R o Python para construir los gráficos, e incluso mostrar los gráficos directamente en la conversación. Las versiones gratuitas generalmente pueden hacer el análisis numérico y explicar los resultados, pero tienen más limitaciones para generar y ejecutar código o mostrar visualizaciones. En cualquier caso, la barrera de entrada al análisis se ha reducido enormemente respecto a hace pocos años.

Lo que no cambia: el diseño de experimentos se hace *antes* del experimento, no después. Decidir qué factores estudiar, cuántos niveles, cuántas réplicas, cómo aleatorizar y qué confundimientos son aceptables requiere conocimiento del proceso y juicio experto. Un modelo de IA puede ayudarte a generar el diseño si le describes bien el problema, pero alguien tiene que definir ese problema — y hacerlo mal puede llevar a experimentos que no responden la pregunta correcta, que son demasiado costosos, o que tienen sesgos no detectables.

Además, **los experimentos siguen costando dinero y tiempo**. En la industria, cada fabricación experimental tiene un coste real: materia prima, tiempo de línea, análisis de laboratorio. El diseño eficiente — obtener la máxima información con el mínimo de experimentos — sigue siendo igual de valioso independientemente de quién haga el análisis posterior.

Finalmente, **la interpretación requiere contexto que la IA no tiene**. Un modelo puede decir "hay una interacción significativa entre temperatura y dosis de cuajo". Pero traducir eso en una decisión concreta — ¿cambiamos el protocolo de fabricación? ¿el cambio es económicamente viable? ¿hay restricciones de proceso que lo impidan? ¿necesitamos más experimentos para confirmar? — requiere conocimiento del proceso, de la empresa y del contexto que solo el técnico que trabaja en esa planta tiene.

> **Cómo usar la IA con el diseño de experimentos**
>
> Una forma muy efectiva de combinar ambas herramientas es la siguiente: tú diseñas el experimento (qué factores, qué niveles, cuántas réplicas, cómo aleatorizar), ejecutas las fabricaciones, recoges los datos, y luego le pides a la IA que te ayude con el análisis y la interpretación. Le puedes pedir que calcule los efectos, que construya los gráficos, que explique qué significa una interacción en términos prácticos, o que sugiera qué experimentos adicionales harían falta para confirmar las conclusiones.
> Esta división del trabajo aprovecha lo mejor de cada parte: tu conocimiento del proceso para diseñar bien, y la capacidad analítica de la IA para procesar y comunicar los resultados.

10.11. Resumen del capítulo

El diseño de experimentos es la alternativa sistemática al ensayo y error. El enfoque OFAT — estudiar un factor a la vez mientras se fijan los demás — parece intuitivo pero tiene un defecto fundamental: no puede detectar interacciones entre factores. Una interacción ocurre cuando el efecto de un factor depende del nivel del otro, y en procesos biológicos como la fabricación de queso son la norma, no la excepción.

El diseño factorial 2^2 estudia dos factores simultáneamente en cuatro combinaciones, con réplicas en orden aleatorio. Los gráficos de efectos principales muestran el efecto medio de cada factor; el gráfico de interacciones — donde las líneas no paralelas son la señal clave — muestra si ese efecto es constante o depende del otro factor.

En el experimento de temperatura y dosis de cuajo, el gráfico de interacciones revela que la dosis alta mejora la retención de materia prima a 30°C pero no a 34°C. Esta conclusión no habría sido posible con el enfoque OFAT, y es exactamente el tipo de conocimiento que permite tomar decisiones de proceso mejor fundamentadas.

11. Comunicación de resultados

Del análisis a la acción: cómo presentar datos para que se entiendan y se usen

> **Objetivos de aprendizaje**
>
> Al finalizar este capítulo, el alumno será capaz de:
>
> - Elegir el tipo de gráfico adecuado en función del mensaje que quiere comunicar.
> - Aplicar los principios básicos de diseño visual para que un gráfico sea claro y honesto.
> - Identificar y evitar los errores más frecuentes en la presentación de datos.
> - Organizar un panel de resultados para un equipo de planta o una presentación para dirección.
> - Adaptar el nivel de detalle y el lenguaje al tipo de audiencia.
>
> Conceptos clave: **ratio datos/tinta, gráfico de barras, gráfico de líneas, gráfico de dispersión, panel de resultados, audiencia, mensaje principal**.

11.1. El análisis que nadie lee no existe

A lo largo de los capítulos anteriores hemos aprendido a calcular medias y desviaciones típicas, a construir histogramas y boxplots, a detectar correlaciones, a interpretar gráficos de control y a diseñar experimentos. Toda esa capacidad analítica tiene un solo propósito: **tomar mejores decisiones**.

Pero entre el análisis y la decisión hay un paso que con frecuencia se subestima: la comunicación. Un análisis excelente presentado de forma confusa, sobrecargada o inadecuada para la audiencia puede ser ignorado, malinterpretado o simplemente descartado. En cambio, un análisis moderado presentado con claridad y orientado a la acción puede generar cambios reales en el proceso.

Este capítulo no trata de hacer gráficos bonitos. Trata de hacer gráficos **efectivos**: que comuniquen exactamente lo que necesitan comunicar, a la audiencia correcta, en el tiempo disponible.

11.2. La audiencia determina el mensaje

Antes de elegir un gráfico o preparar una presentación, hay que responder una pregunta fundamental: **¿quién va a ver esto y para qué?**

En el entorno industrial hay básicamente tres tipos de audiencia, cada una con necesidades diferentes:

El equipo de planta — operarios, técnicos de turno, jefes de línea — necesita información inmediata y accionable. La pregunta que tienen es "¿qué tengo que hacer ahora mismo?". El gráfico de control en el panel de la línea de producción es para ellos: muestra si el proceso está bajo control o no, sin ambigüedades. No necesitan la distribución t de Student ni los índices de capacidad — necesitan saber si deben intervenir o no.

El equipo técnico — responsables de calidad, ingeniería de proceso, laboratorio — necesita entender el análisis en profundidad. La pregunta que tienen es "¿por qué está pasando esto y cómo lo mejoramos?". Para ellos sí son relevantes los gráficos de correlación, los diagramas de dispersión por trimestre, los gráficos de interacción del diseño de experimentos.

La dirección — gerencia, responsables de área — necesita el impacto en negocio. La pregunta que tienen es "¿cuánto cuesta este problema y cuánto ganamos si lo resolvemos?". Para ellos el análisis estadístico es secundario; lo que importa es la cifra económica y la recomendación clara.

> **i** Una presentación, un mensaje principal
>
> Un error frecuente es intentar mostrar todo el análisis a todas las audiencias. Una presentación eficaz tiene **un mensaje principal** claramente identificado antes de empezar a preparar ningún gráfico. Todos los elementos visuales deben apoyar ese mensaje. Lo que no apoya el mensaje no debería estar en la presentación — puede estar en un anexo para quien quiera profundizar.

11.3. Los principios de Tufte: menos es más

Edward Tufte es el referente más influyente en visualización de datos. En su obra *The Visual Display of Quantitative Information* (1983), formuló un principio que sigue siendo completamente vigente: el **ratio datos/tinta** (*data-ink ratio*).

La idea es sencilla: cada elemento visual de un gráfico — cada línea, cada color, cada símbolo — ocupa "tinta" (espacio visual). Si ese elemento transmite información real sobre los datos, justifica su presencia. Si no transmite información — si es decoración, relleno o ruido visual — debe eliminarse.

Tufte llamó "chartjunk" (basura de gráfico) a todos esos elementos decorativos que no aportan información: fondos de cuadrícula demasiado prominentes, sombras en las barras, efectos tridimensionales, degradados de color, iconos decorativos. No solo no añaden información: dificultan activamente la lectura del gráfico.

Aplicado a los gráficos que hemos construido a lo largo del libro, esto significa:

- Usar `theme_bw()` o `theme_minimal()` en ggplot2 en lugar del tema gris por defecto
- Eliminar las líneas de cuadrícula secundarias cuando no añaden información
- No usar colores si no transmiten información adicional (un gráfico de barras de una sola variable no necesita barras de colores diferentes)
- No usar efectos 3D nunca — distorsionan la percepción de las magnitudes

11.4. Los gráficos a evitar

11.4.1. El gráfico de tarta (pie chart)

El gráfico de tarta es uno de los más usados y uno de los menos efectivos. El ojo humano compara mal áreas y ángulos; comparamos mucho mejor longitudes. Si tenemos cinco categorías con proporciones similares, es prácticamente imposible saber cuál es mayor en un gráfico de tarta. Un gráfico de barras ordenado comunica exactamente la misma información de forma mucho más clara.

La única excepción razonable es cuando hay exactamente dos categorías (conforme / no conforme, por ejemplo) y la proporción es muy diferente (95 % / 5 %). En ese caso, el gráfico de tarta es intuitivo. Pero incluso ahí, una sola cifra ("5 % de no conformes") suele ser más efectiva que el gráfico.

11.4.2. Los gráficos 3D

Los gráficos 3D son el ejemplo más claro de chartjunk. La tercera dimensión no añade ninguna información — solo distorsión visual. Las barras del fondo parecen más pequeñas que las del frente aunque tengan el mismo valor. La perspectiva hace imposible leer los valores con precisión. Y el efecto es peor en pantalla que en papel, y peor aún proyectado en una sala de reuniones.

La regla es simple: **nunca usar gráficos 3D para datos cuantitativos**. Si los datos son en dos dimensiones, el gráfico debe ser en dos dimensiones.

11.4.3. El gráfico de doble eje Y

El gráfico con dos ejes Y distintos (uno a la izquierda y otro a la derecha, con escalas diferentes) es engañoso casi por definición. Al poder elegir las escalas libremente, se puede hacer que dos variables que no tienen ninguna relación parezcan perfectamente correlacionadas, o que dos variables muy relacionadas parezcan independientes. Es exactamente el truco visual que Tyler Vigen usa en sus correlaciones espurias que vimos en el capítulo de correlación.

Si necesitas mostrar dos variables en el mismo gráfico, usa dos gráficos separados con el mismo eje X — el lector puede compararlos visualmente sin que la escala le engañe.

11.5. ¿Qué gráfico usar? Recursos de referencia

Elegir el tipo de gráfico correcto no siempre es obvio. El **Visual Vocabulary** del Financial Times (ft-interactive.github.io/visual-vocabulary) es una de las mejores referencias disponibles: organiza los tipos de gráfico según el tipo de comparación que se quiere hacer — distribución, correlación, cambio temporal, desviación, parte de un todo — y para cada categoría muestra ejemplos visuales con una breve descripción de cuándo usarlos. Es un recurso de consulta rápida especialmente útil cuando no tenemos claro qué tipo de gráfico comunicará mejor un resultado concreto.

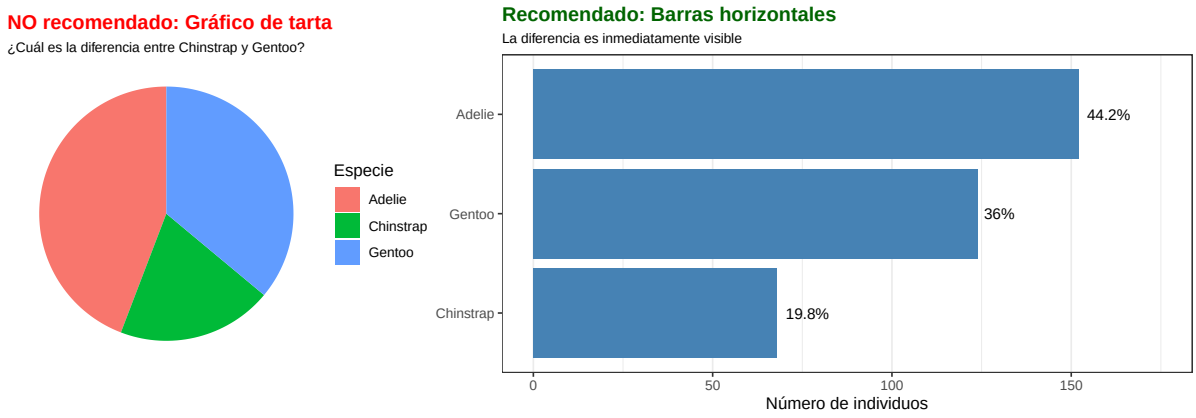
Una versión similar pero más orientada a la implementación en R es el R Graph Gallery, que muestra cientos de tipos de gráficos con el código R necesario para reproducirlos.

11.6. Ejemplos comparativos: el gráfico incorrecto y el gráfico correcto

La mejor forma de entender los principios de visualización es verlos en acción. Los ejemplos siguientes muestran, con datos que ya conocemos del libro, la diferencia entre un gráfico que dificulta la comunicación y uno que la facilita.

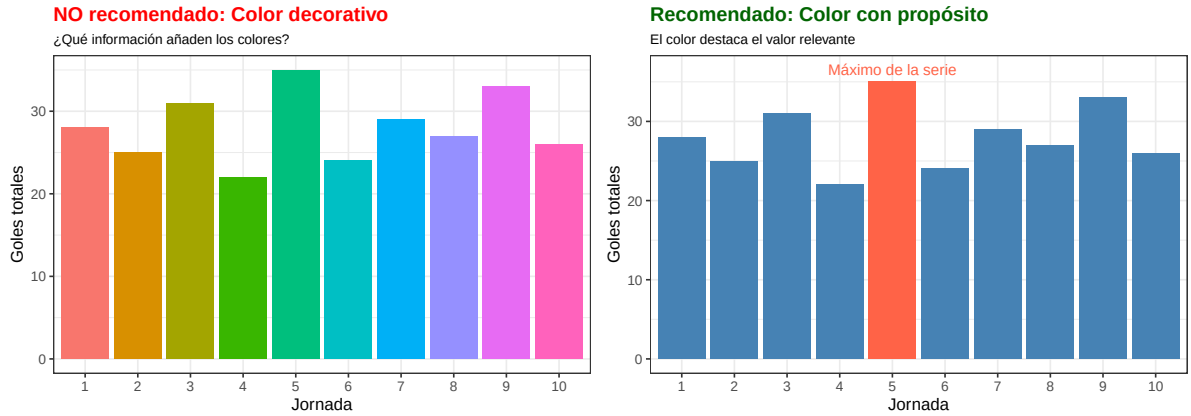
11.6.1. Ejemplo 1: composición por categorías — tarta vs. barras

El gráfico de tarta hace difícil comparar las proporciones de las tres especies de pingüinos. El gráfico de barras horizontales ordenado comunica exactamente lo mismo de forma mucho más clara:



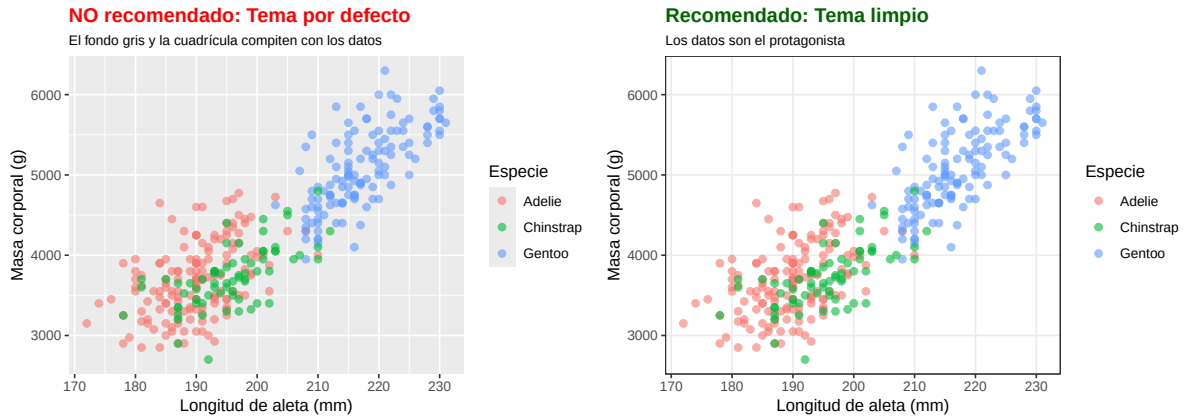
11.6.2. Ejemplo 2: color innecesario vs. color con propósito

Usar colores diferentes para cada barra cuando todas representan la misma variable sugiere falsamente que las categorías son distintas. Si queremos destacar algo específico — por ejemplo, el mes en que hubo una incidencia — el color tiene propósito:



11.6.3. Ejemplo 3: cuadrícula excesiva vs. gráfico limpio

El tema por defecto de ggplot2 tiene un fondo gris y una cuadrícula prominente que compite visualmente con los datos. El mismo gráfico con `theme_bw()` y sin cuadrícula secundaria es más limpio y más fácil de leer:



Los tres ejemplos ilustran el mismo principio de Tufte: eliminar todo elemento visual que no transmite información sobre los datos mejora la comunicación, no la empobrece.

La elección del tipo de gráfico depende del **tipo de comparación** que quieres hacer:

Comparación	Gráfico recomendado	Ejemplo del libro
Distribución de una variable	Histograma, boxplot, densidad	Flipper length de los pingüinos
Evolución temporal	Gráfico de líneas	Temperatura media de Oviedo
Comparación entre grupos	Boxplot, barras con error	Masa corporal por especie de pingüino
Relación entre dos variables	Dispersión	MG vs EST en el camembert
Seguimiento de proceso	Gráfico de control	Peso de yogures
Composición (pocas categorías muy distintas)	Barras horizontales	—

Una regla práctica: si te preguntas si deberías usar un gráfico de tarta, usa un gráfico de barras. Si te preguntas si deberías usar un gráfico 3D, usa un gráfico 2D. Si tienes dudas entre histograma y boxplot, usa el boxplot para comparar grupos y el histograma para explorar la forma de una distribución.

11.7. El color como información, no como decoración

El color es uno de los recursos visuales más potentes y más mal utilizados. En un gráfico bien diseñado, el color transmite información específica: diferentes series, diferentes grupos, una escala de intensidad. En un gráfico mal diseñado, el color es pura decoración — barras de

colores diferentes aunque todas representen la misma variable, gradientes sin significado, paletas llamativas que dificultan la lectura.

Algunas reglas prácticas:

Una variable, un color. Si tienes un gráfico de barras con los resultados mensuales de una sola variable, todas las barras deben ser del mismo color. Usar colores diferentes para cada mes sugiere que los meses son categorías distintas, lo que confunde al lector.

El color para destacar, no para decorar. Si quieres llamar la atención sobre un valor específico (el mes en que el proceso falló, el período fuera de control), usa un color diferente solo para ese elemento. El contraste entre el elemento destacado y el resto en color neutro comunica inmediatamente dónde debe mirar el lector.

Accesibilidad para daltónicos. Aproximadamente el 8 % de los hombres tiene algún grado de daltonismo. El rojo y el verde son los colores más problemáticos. Si necesitas distinguir dos grupos, usa azul y naranja, o azul y rojo, en lugar de rojo y verde. En ggplot2, la paleta `viridis` y las paletas de `RColorBrewer` están diseñadas para ser legibles por personas con daltonismo.

Pocas categorías, colores diferenciados. El ojo humano distingue bien hasta 6-8 colores en un gráfico. Con más categorías, el gráfico de colores se vuelve ilegible. Si tienes más de 8 grupos, considera otras formas de organizar la información (facetas, gráficos separados).

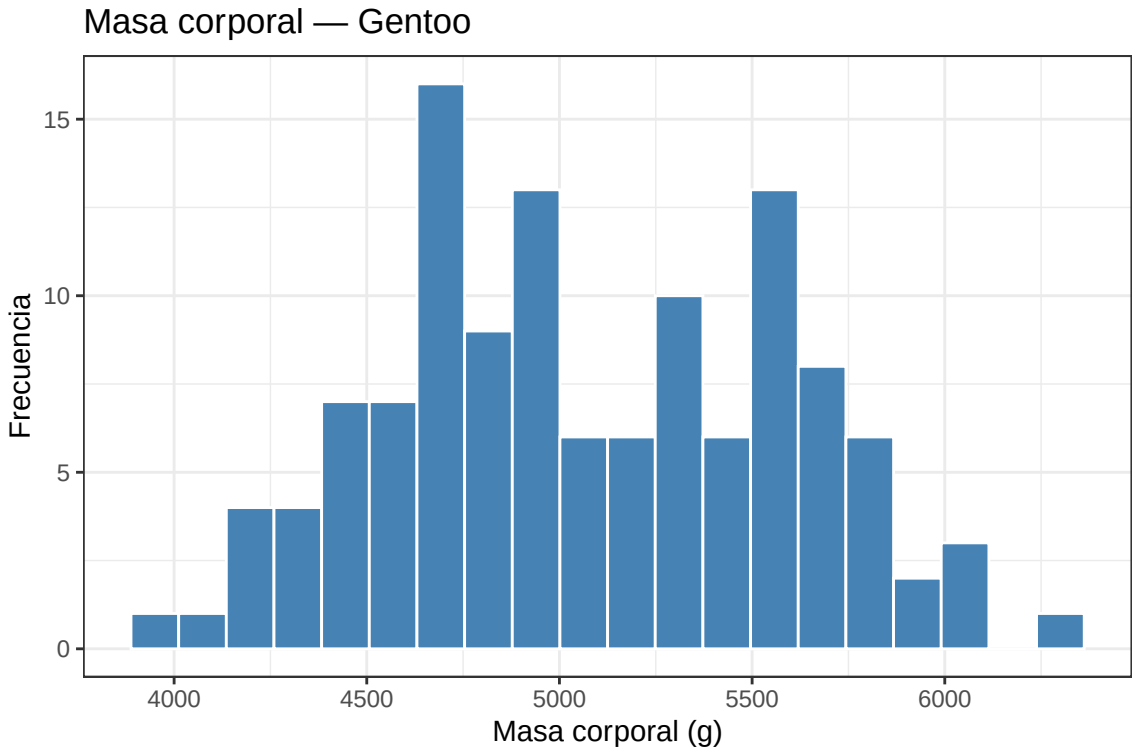
11.8. De los gráficos del libro a la comunicación real

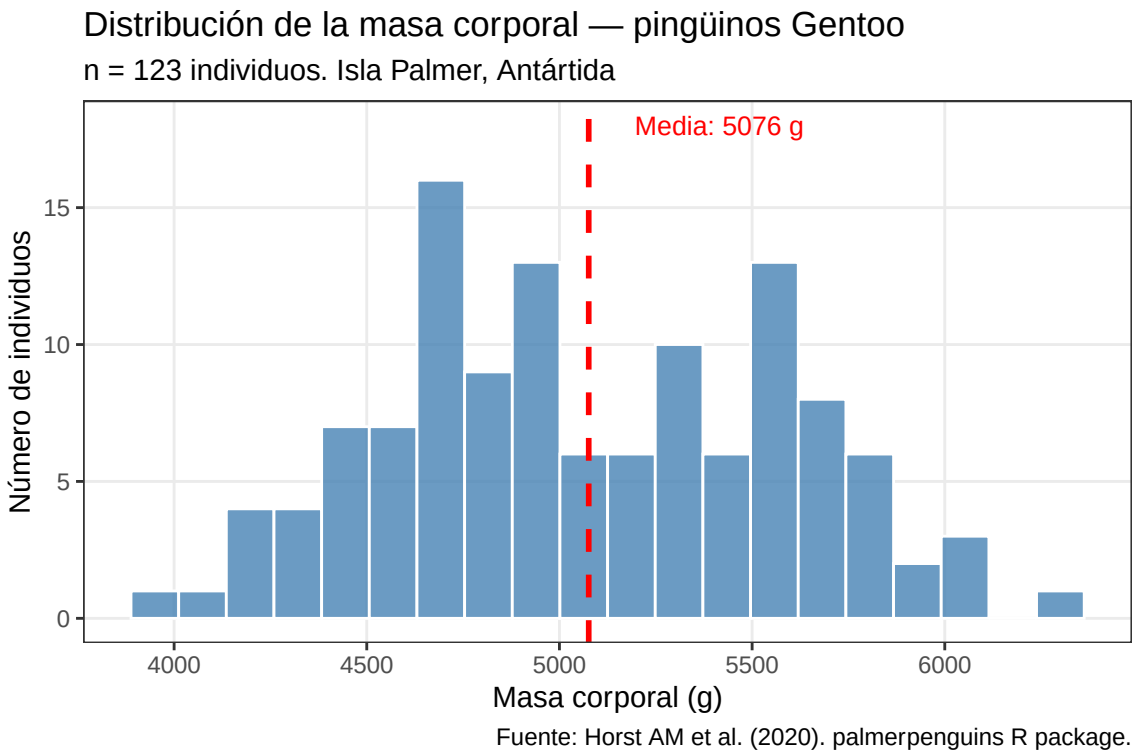
A lo largo del libro hemos construido muchos gráficos con propósito analítico — para explorar los datos, detectar patrones, verificar supuestos. Esos gráficos son para nosotros, no para la audiencia. Antes de presentarlos, necesitan una revisión editorial:

11.8.1. El histograma de exploración vs el histograma de comunicación

Cuando cargamos un dataset nuevo y hacemos un histograma para ver la distribución, el gráfico tiene ejes automáticos, título genérico y ninguna anotación. Es suficiente para explorar. Para comunicar, el mismo histograma necesita: un título que diga exactamente qué muestra, etiquetas de eje con unidades, y posiblemente una línea vertical indicando el objetivo o límite relevante.

Comparemos los dos enfoques con la distribución del peso de los pingüinos Gentoo, que usamos en el capítulo de distribuciones:



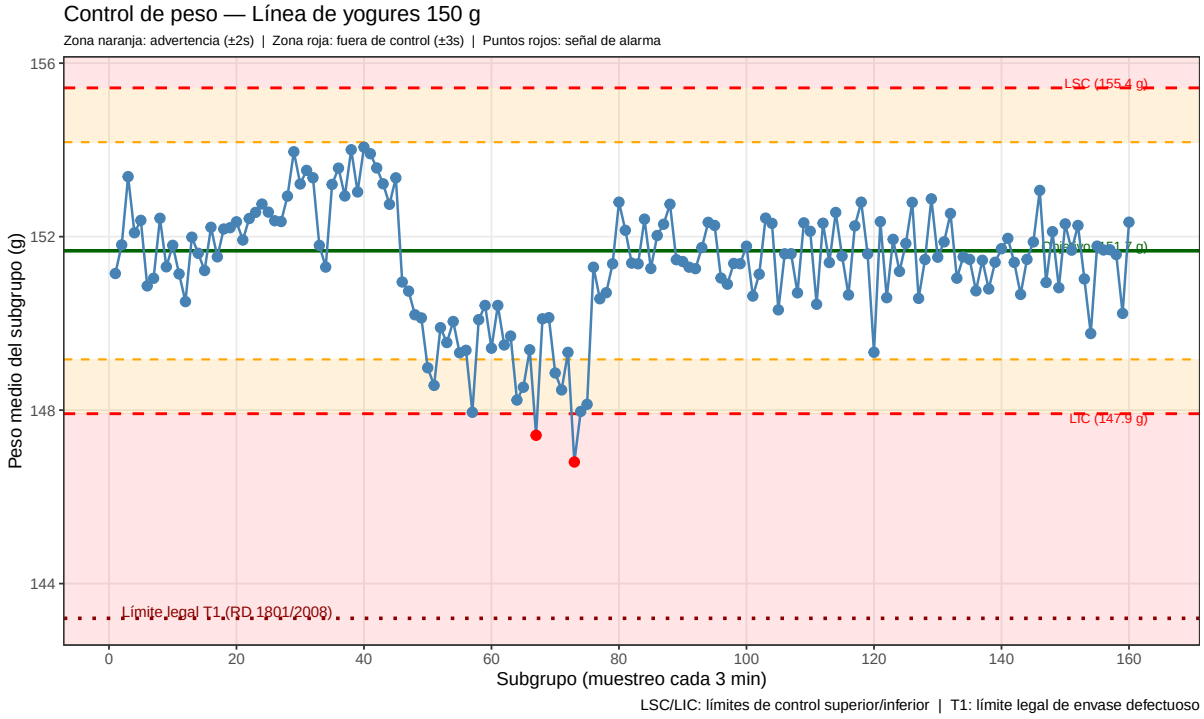


La diferencia no está en el tipo de gráfico — es el mismo histograma — sino en los elementos que orientan al lector: el título descriptivo, el subtítulo con contexto, la línea de la media anotada, las etiquetas de eje con unidades, y la fuente de los datos.

11.8.2. El gráfico de control para el panel de planta

El gráfico de control del proceso de llenado de yogures que construimos en el capítulo de SPC tenía todos los elementos necesarios para el análisis: límites de control, puntos fuera de límites marcados, título. Para un panel de planta, habría que añadir: el valor objetivo, la referencia al límite legal (T1 del RD 1801/2008), y una zona sombreada de advertencia entre los límites internos de proceso y el límite legal.

La diferencia clave entre un gráfico de análisis y un gráfico de panel de planta es que el panel de planta tiene que ser **autoexplicativo para alguien que no ha visto el análisis**. Tiene que responder por sí solo las preguntas: ¿qué se está midiendo?, ¿cuál es el objetivo?, ¿estamos dentro o fuera?, ¿qué hay que hacer si estamos fuera?



El gráfico añade tres elementos respecto al gráfico de análisis del capítulo SPC: las zonas coloreadas de advertencia (naranja) y fuera de control (rojo) que permiten leer el estado del proceso de un vistazo, el límite legal T1 como referencia externa, y las etiquetas con los valores numéricos de cada línea para que el operario sepa exactamente cuándo actuar.

11.9. Organizar una presentación de resultados

Tanto si es un panel en la pared de la planta como una presentación en PowerPoint para dirección, la estructura efectiva sigue el mismo principio: **mensaje antes que evidencia**.

El error más frecuente es organizar la presentación en el orden en que se hizo el análisis: primero los datos brutos, luego la exploración, luego el análisis, y al final la conclusión. Para el analista tiene sentido — así fue el proceso. Para la audiencia es agotador: tienen que esperar hasta el final para saber de qué va todo.

La estructura efectiva invierte ese orden:

1. **El mensaje principal** — una frase, en la primera diapositiva o en el encabezado del panel. "El proceso de llenado cumple el RD 1801/2008 en condiciones normales, pero no cuando hay derivas de más de 30 minutos."
2. **La evidencia clave** — uno o dos gráficos que demuestran el mensaje. No todos los gráficos del análisis, solo los que demuestran lo que se está afirmando.
3. **La recomendación** — qué hay que hacer. Concreta, asignable, con plazo si es posible.
4. **El detalle** — en un anexo, para quien quiera verificar el análisis completo.

> **La regla del titular de periódico**
>
> Un buen ejercicio antes de preparar cualquier presentación de datos es escribir el titular: una frase de menos de 15 palabras que resume el hallazgo principal. Si no puedes escribirlo, probablemente no tienes claro cuál es el mensaje principal. Si el titular es obvio y poco informativo ("Análisis de los datos de peso del mes de marzo"), el análisis no ha encontrado nada relevante o no se ha formulado la pregunta correcta.
> Ejemplos de titulares poco informativos: "Resultados del análisis de peso de enero". Ejemplos de titulares efectivos: "La variabilidad del peso aumenta un 40 % en el turno de noche" o "Reducir de 2,6 a 1,5 g ahorra 8.000 € anuales en sobredosificación".

11.10. Informes reproducibles: Quarto y el código abierto

En el capítulo dedicado a las herramientas de análisis vimos en detalle las limitaciones de la hoja de cálculo para el análisis reproducible: las fórmulas ocultas en las celdas dificultan la auditoría, los informes no se pueden regenerar automáticamente cuando los datos cambian, y el conocimiento queda atrapado en ficheros que nadie más entiende. Aquí retomamos ese argumento desde la perspectiva de la comunicación: no basta con hacer un buen análisis y presentarlo bien, hay que asegurarse de que ese análisis sea verificable y actualizable.

11.10.1. La alternativa: el informe reproducible

Un **informe reproducible** es un documento en el que el texto, los cálculos y los gráficos están escritos en el mismo fichero, en código visible. Cuando los datos cambian, basta con regenerar el documento — todo se recalcula y se redibuja automáticamente, sin intervención manual.

El libro que estás leyendo es un ejemplo: está escrito en **Quarto**, una herramienta de código abierto que combina texto en formato Markdown con código en R o Python. Cada gráfico del libro se genera a partir del código que aparece junto a él. Si los datos cambian, el gráfico cambia. Si hay un error en el cálculo, está visible en el código y cualquiera puede encontrarlo y corregirlo.

Quarto puede generar documentos en múltiples formatos a partir del mismo fichero fuente: HTML para publicar en web, PDF para imprimir, Word para compartir con quien no tiene acceso al sistema. Un mismo informe mensual puede entregarse en los tres formatos sin trabajo adicional.

11.10.2. Código abierto vs. herramientas propietarias

Existen herramientas comerciales para crear informes y dashboards de datos, como **Power BI** (Microsoft) o **Tableau**. Son potentes, tienen interfaces visuales atractivas y están muy extendidas

en grandes empresas. Pero tienen una limitación importante: **el conocimiento que adquieres es propiedad de la empresa que vende el software**.

El lenguaje visual de Power BI, sus fórmulas DAX, su forma de conectar datos — todo ese aprendizaje solo sirve dentro de Power BI. Si la empresa deja de pagar la licencia, o si cambias de trabajo a una empresa que usa otra herramienta, parte de tu inversión de aprendizaje se pierde. Es una inversión "cerrada".

En cambio, aprender a analizar y comunicar datos con Python o R — y a generar informes con Quarto o Jupyter Notebooks — es una inversión abierta. Python y R son gratuitos, funcionan en cualquier ordenador, y el conocimiento que adquieres es completamente transferible: de una empresa a otra, de un sector a otro, de un proyecto a otro. La comunidad que los desarrolla y los mejora es global y no depende de ninguna empresa concreta.

Esto no significa que las herramientas propietarias sean malas — en algunos contextos son la opción correcta. Pero para un técnico que está construyendo su perfil profesional, aprender herramientas de código abierto es una apuesta más sólida a largo plazo.

Jupyter Notebooks: el equivalente en Python

El equivalente de Quarto en el ecosistema Python son los **Jupyter Notebooks**: documentos que combinan código Python, texto y gráficos en un formato interactivo. Son el estándar en ciencia de datos y análisis en Python, y se pueden exportar a HTML o PDF igual que Quarto. Las prácticas en Google Colab de este libro están escritas en Jupyter Notebooks. Quarto, de hecho, puede incorporar notebooks de Jupyter directamente, lo que permite combinar Python y R en el mismo documento.

11.11. Recursos para seguir aprendiendo

Los principios de este capítulo se desarrollan con mucho más detalle en una serie de sitios de referencia que el alumno puede consultar libremente. Cada uno tiene un enfoque distinto y resulta útil en situaciones diferentes:

Para elegir el tipo de gráfico correcto:

- **Visual Vocabulary** — Financial Times: organiza los tipos de gráfico por el tipo de comparación que se quiere hacer (distribución, correlación, cambio temporal, parte de un todo…). Es la referencia más rápida para responder "¿qué gráfico uso aquí?".
- **From Data to Viz**: árbol de decisión interactivo que, a partir del tipo de datos que tienes (numérico, categórico, temporal, geográfico…), te guía hasta el tipo de gráfico recomendado. Incluye código R y Python para cada tipo, y advierte de los errores más frecuentes.

Para implementar gráficos en R y Python:

- **R Graph Gallery**: catálogo exhaustivo de tipos de gráficos en R con el código ggplot2 necesario para reproducirlos. Especialmente útil cuando sabes qué quieres hacer pero no cómo hacerlo en R.
- **Python Graph Gallery**: equivalente al anterior para Python, con ejemplos en matplotlib, seaborn y plotly. Mismo formato: gráfico + código listo para copiar y adaptar.

Para informes y comunicación con Quarto:

- **Quarto Gallery**: ejemplos de documentos, informes, dashboards y presentaciones generados con Quarto. Permite ver el resultado final y el código fuente de cada ejemplo. Es el mejor punto de partida para entender qué se puede hacer con Quarto más allá de lo que muestra este libro.

Para desarrollar el criterio visual:

- **Storytelling with Data — Chart Guide**: orientado a la comunicación más que a la implementación. Explica qué hace que un gráfico funcione o no funcione para transmitir un mensaje, con ejemplos de gráficos reales mejorados paso a paso. Complementa perfectamente los recursos técnicos anteriores.

11.12. Resumen del capítulo

Comunicar bien los resultados de un análisis es tan importante como hacer bien el análisis. Un gráfico efectivo tiene un propósito claro, está adaptado a su audiencia, elimina todo elemento visual que no transmite información, y orienta al lector hacia el mensaje principal.

Los principios de Tufte — maximizar el ratio datos/tinta, eliminar el chartjunk — son una guía práctica para evaluar cualquier gráfico: si un elemento no transmite información sobre los datos, debe eliminarse. Los gráficos 3D, las tartas con muchas categorías y los dobles ejes Y son los errores más frecuentes y los más fáciles de evitar.

La elección del tipo de gráfico depende del tipo de comparación que se quiere hacer. Para distribuciones, el histograma y el boxplot. Para evolución temporal, el gráfico de líneas. Para relaciones entre variables, el gráfico de dispersión. Para seguimiento de proceso, el gráfico de control.

Finalmente, una presentación efectiva pone el mensaje antes que la evidencia: primero el hallazgo principal, luego los gráficos que lo demuestran, luego la recomendación. El detalle del análisis va al final, para quien quiera verificarlo.

Parte II.

Aplicaciones en producción quesera

12. Análisis exploratorio de una fabricación de queso camembert.

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Aplicar el flujo de trabajo completo del análisis de datos (importar, limpiar, visualizar, comunicar) a un caso real de fabricación de queso camembert.
- Detectar e interpretar errores en los datos mediante la inspección visual y estadística de cada variable.
- Relacionar la forma de un histograma y un boxplot con las características del proceso que los genera, conectando lo aprendido en los capítulos 6 y 7.
- Identificar y analizar la estacionalidad y la tendencia en una serie temporal de datos de fabricación.
- Calcular y analizar una variable derivada (`hqd`) a partir de variables medidas, y relacionar su evolución temporal con las causas tecnológicas del proceso.
- Interpretar la distribución asimétrica positiva de recuentos microbiológicos y extraer conclusiones sobre la higiene del proceso.
- Formular hipótesis de trabajo a partir del análisis gráfico y contrastarlas con el conocimiento tecnológico y la experiencia del equipo.
- Comunicar los resultados del análisis mediante un informe estructurado y un plan de acción priorizado.

Conceptos clave: **análisis exploratorio, flujo de trabajo, dato atípico, error de entrada, estacionalidad, tendencia, variable derivada, humedad del queso desnatado (hqd), distribución asimétrica positiva, recuento microbiológico, hipótesis de trabajo, plan de acción**.

Versión interactiva en Google Colab

Este capítulo tiene una versión en formato cuaderno Jupyter con solo código Python que puedes abrir y ejecutar directamente en Google Colab, sin necesidad de instalar nada en tu ordenador:
Abrir versión sólo Python en Google Colab

En los capítulos anteriores hemos aprendido a describir datos mediante gráficos y estadísticos. Ahora vamos a aplicar todo lo aprendido a un caso real: el análisis exploratorio de una temporada completa de fabricación de queso camembert. Los datos corresponden a los análisis de control de calidad realizados durante el año 2020 en una quesería, con una o dos fabricaciones diarias a lo largo de los días laborables. El dataset contiene 211 observaciones y seis variables:

- `est`: extracto seco total (%)

- `mg`: materia grasa (%)
- `ph`: pH del queso
- `cloruros`: contenido en cloruros (%)
- `coliformes`: recuento de bacterias coliformes (ufc/g)
- `fabricacion`: número de fabricación del día (1 o 2)

Descargar los datos `camembert.csv`

12.1. Flujo de trabajo

Como vimos en el capítulo 2, es muy conveniente establecer un flujo de trabajo regular, de forma que cada etapa del análisis se apoye en las anteriores:

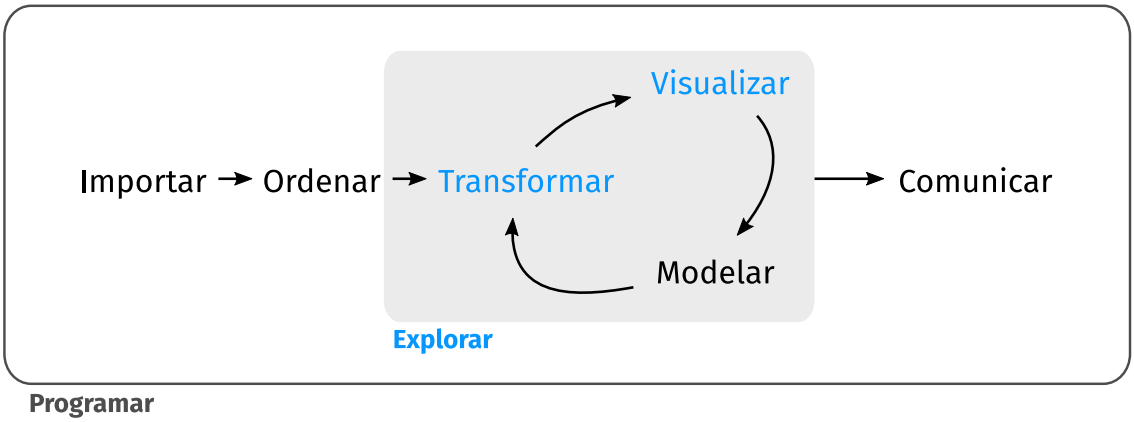


Figura 12.1.: Modelo de flujo de trabajo en la ciencia de datos, según Wickham

Vamos a ir desarrollando este flujo paso a paso.

12.2. Importar los datos

Cargamos el fichero desde GitHub. Si has descargado el fichero en tu ordenador, puedes adaptar la ruta de lectura según vimos en el capítulo anterior.

```
Dimensiones: 211 x 7
```

Inspeccionamos las primeras filas y la estructura del dataframe:

```
# A tibble: 6 x 7
  fecha      fabricacion   est    mg    ph cloruros coliformes
  <chr>            <dbl> <dbl> <dbl> <dbl>    <dbl>      <dbl>
1 11/01/2020           1  46.7  24    4.85     1.5          80
2 12/01/2020           1  48.1  25    4.67     1.61          0
```

```
3 13/01/2020           1  46.0  24    4.71     1.48       9200
4 14/01/2020           1  46.2  23.5  4.78     1.69         20
5 15/01/2020           1  45.8  23    4.77     1.56        150
6 18/01/2020           1  46    24    4.67     1.56         60

Rows: 211
Columns: 7
$ fecha       <chr> "11/01/2020", "12/01/2020", "13/01/2020", "14/01/2020", "1~
$ fabricacion <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 1, 2, 1, 2, 1, 2~
$ est         <dbl> 46.68, 48.09, 45.97, 46.24, 45.81, 46.00, 44.83, 45.82, 47~
$ mg          <dbl> 24.0, 25.0, 24.0, 23.5, 23.0, 24.0, 23.5, 25.0, 24.0, 24.0~
$ ph          <dbl> 4.85, 4.67, 4.71, 4.78, 4.77, 4.67, 4.73, 4.68, 4.75, 4.85~
$ cloruros    <dbl> 1.50, 1.61, 1.48, 1.69, 1.56, 1.56, 1.39, 1.60, 1.54, 1.62~
$ coliformes  <dbl> 80, 0, 9200, 20, 150, 60, 40, 40, 175, 340, 0, 0, 0, 0, 5,~
```

La columna `fecha` aparece como tipo texto. La convertimos a formato fecha:

```
Rows: 211
Columns: 7
$ fecha       <date> 2020-01-11, 2020-01-12, 2020-01-13, 2020-01-14, 2020-01-1~
$ fabricacion <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 1, 2, 1, 2, 1, 2~
$ est         <dbl> 46.68, 48.09, 45.97, 46.24, 45.81, 46.00, 44.83, 45.82, 47~
$ mg          <dbl> 24.0, 25.0, 24.0, 23.5, 23.0, 24.0, 23.5, 25.0, 24.0, 24.0~
$ ph          <dbl> 4.85, 4.67, 4.71, 4.78, 4.77, 4.67, 4.73, 4.68, 4.75, 4.85~
$ cloruros    <dbl> 1.50, 1.61, 1.48, 1.69, 1.56, 1.56, 1.39, 1.60, 1.54, 1.62~
$ coliformes  <dbl> 80, 0, 9200, 20, 150, 60, 40, 40, 175, 340, 0, 0, 0, 0, 5,~
```

12.3. Verificar los datos

Antes de analizar, verificamos que los valores son plausibles. Calculamos un resumen estadístico de todas las variables:

```
     fecha             fabricacion         est              mg
 Min.   :2020-01-11   Min.   :1.000   Min.   :42.92   Min.   :21.50
 1st Qu.:2020-03-21   1st Qu.:1.000   1st Qu.:45.62   1st Qu.:23.00
 Median :2020-07-04   Median :1.000   Median :46.60   Median :23.50
 Mean   :2020-06-30   Mean   :1.052   Mean   :46.64   Mean   :23.73
 3rd Qu.:2020-10-05   3rd Qu.:1.000   3rd Qu.:47.47   3rd Qu.:24.50
 Max.   :2020-12-29   Max.   :2.000   Max.   :52.61   Max.   :28.00

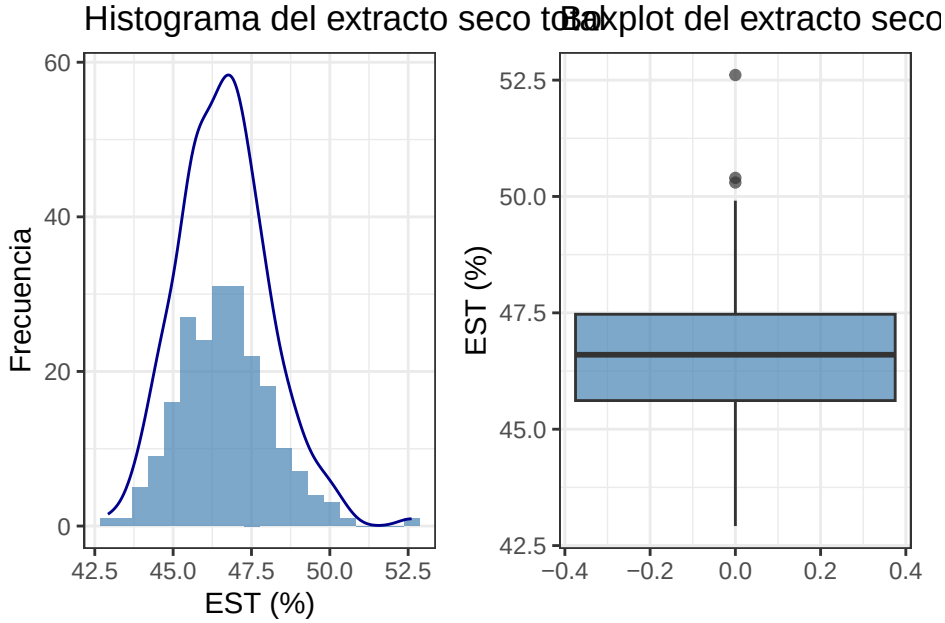
       ph           cloruros        coliformes
 Min.   :4.350   Min.   :-1.000   Min.   :    0.0
 1st Qu.:4.630   1st Qu.: 1.350   1st Qu.:    0.0
 Median :4.680   Median : 1.460   Median :   10.0
 Mean   :4.685   Mean   : 1.453   Mean   :  650.9
 3rd Qu.:4.735   3rd Qu.: 1.560   3rd Qu.:  190.0
 Max.   :4.990   Max.   : 1.890   Max.   :20200.0
                                  NA's   :1
```

Ya en este primer resumen aparecen varias señales que merecen atención: el mínimo de `cloruros` es -1, lo que es físicamente imposible; el máximo de `est` es 52,61, claramente alejado del resto; y el rango de `coliformes` va de 0 a 20.200, con una dispersión enorme. Analizaremos cada variable con detalle en la sección siguiente.

12.4. Análisis variable a variable

12.4.1. Extracto seco total (`est`)

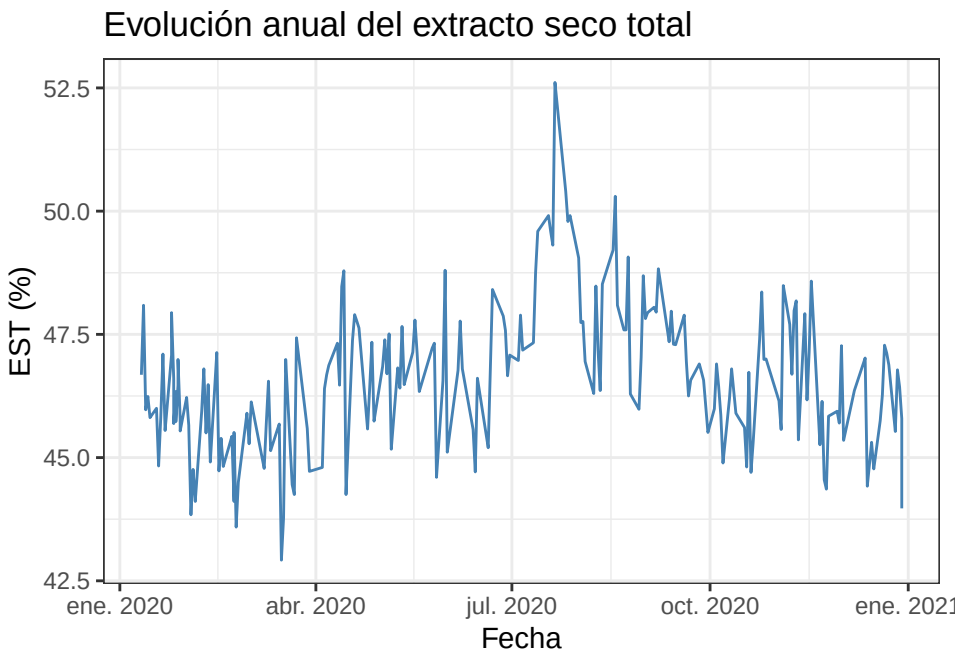
Comenzamos con la variable principal. En el capítulo 6 usamos el histograma y el boxplot para estudiar la forma de los datos; aquí los aplicamos directamente al caso real.



El histograma muestra una distribución aproximadamente simétrica en torno a 46-47 %, pero con una cola hacia la derecha y una barra aislada en torno a 52 %. La curva de densidad muestra una pequeña elevación en ese extremo que no debería estar ahí si la distribución fuese una campana de Gauss limpia. El boxplot confirma la presencia de varios valores atípicos por encima de 50 %.

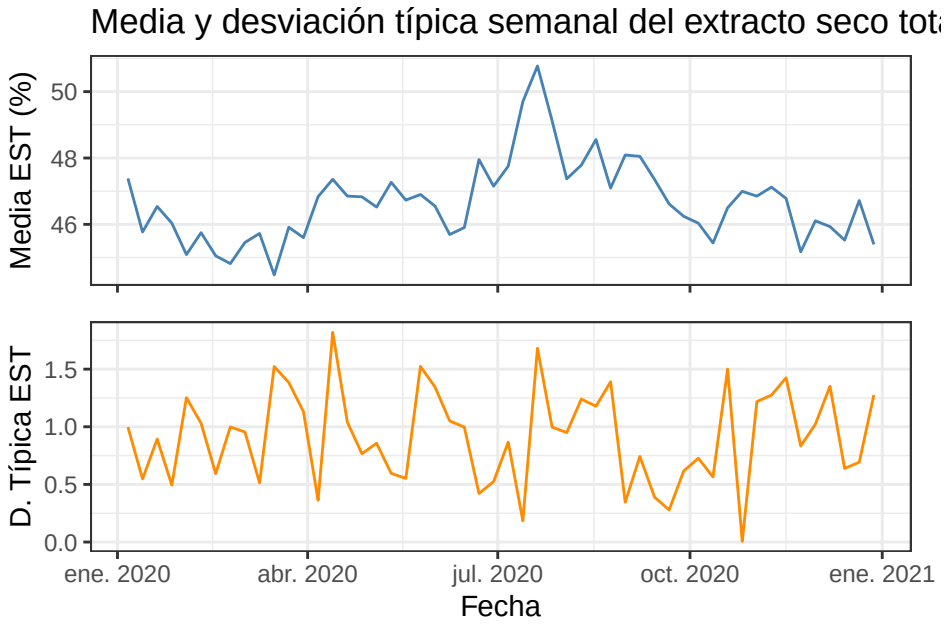
¿Son errores o valores reales? Para responderlo necesitamos contexto temporal.

12.4.2. Serie temporal del extracto seco



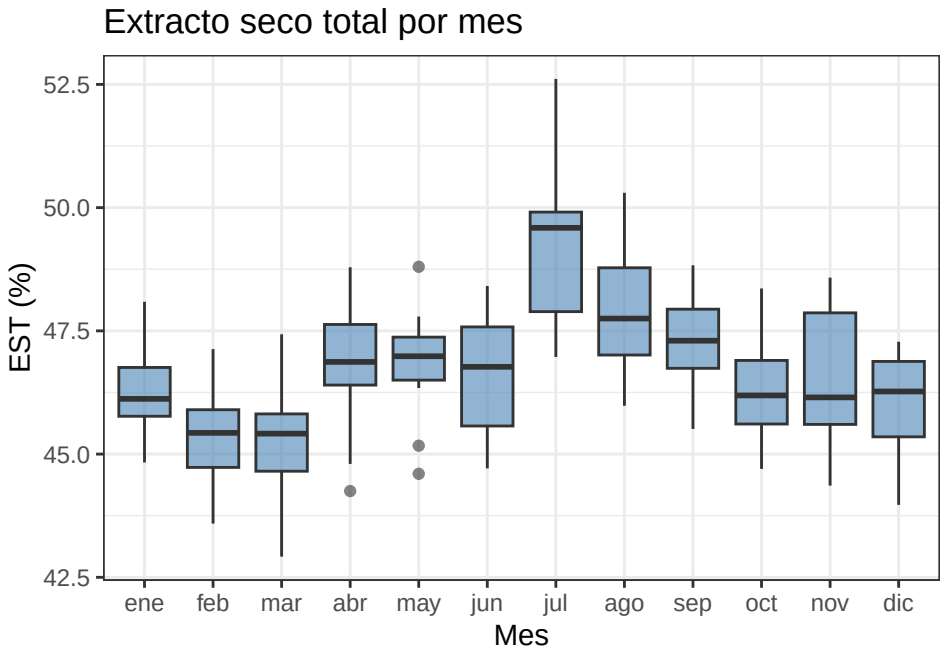
La serie temporal revela lo que el histograma no podía mostrar: los valores altos se concentran en los meses de verano, especialmente julio y agosto. El valor máximo de 52,61 % corresponde al 21 de julio. Esto cambia completamente la interpretación: los valores por encima de 50 % no son errores aislados sino parte de una desviación estacional sostenida durante varias semanas. La forma del histograma que parecía simplemente asimétrica era en realidad la mezcla de dos momentos del año con comportamientos distintos: exactamente el caso de distribución bimodal que estudiamos en el capítulo 6.

Visualizamos la media semanal y su dispersión para ver la evolución con más claridad:



12.4.3. Boxplot mensual del extracto seco

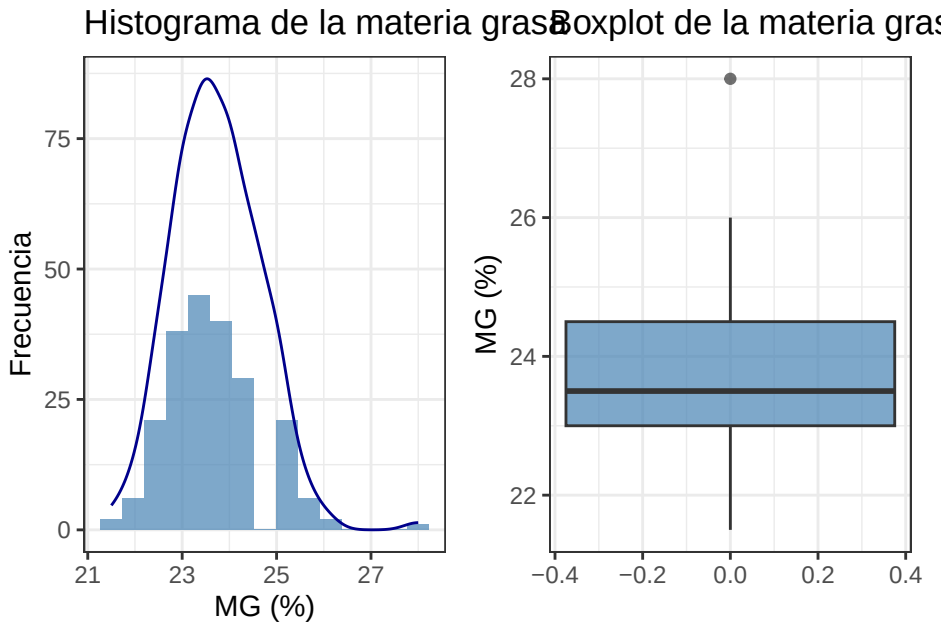
El boxplot por meses permite ver si los valores de julio son atípicos dentro de su propio contexto mensual:



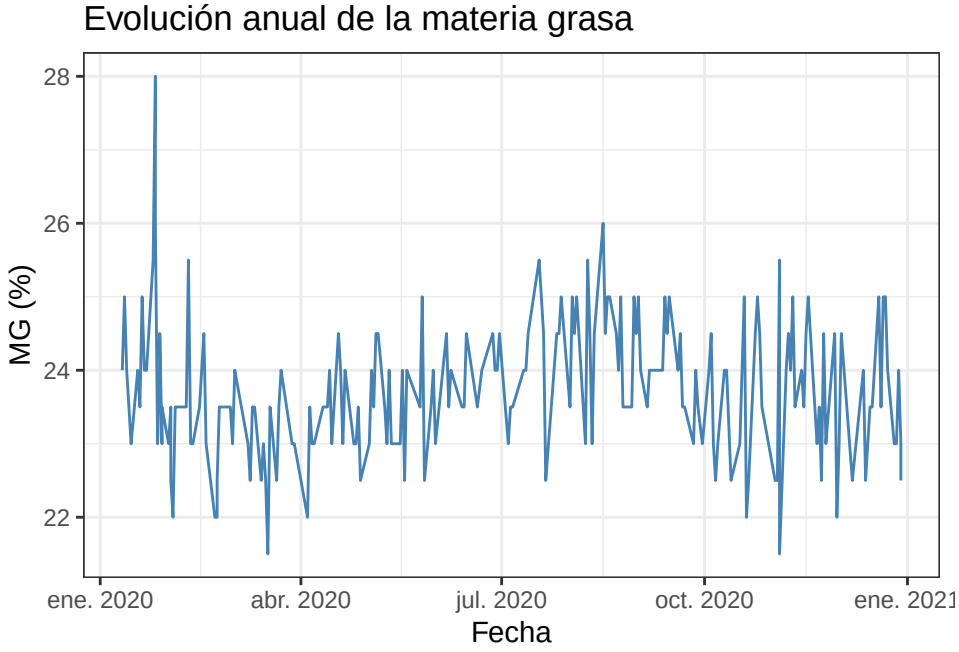
Ahora la imagen es completamente distinta. En julio prácticamente todos los valores son altos: la mediana mensual de julio es la más alta del año, y el valor de 52,61 % no es tan extremo dentro de ese mes. En cambio, en mayo aparece una dispersión muy baja seguida de un salto brusco en junio, que merece atención. Los meses de otoño e invierno muestran una distribución mucho más estable y centrada.

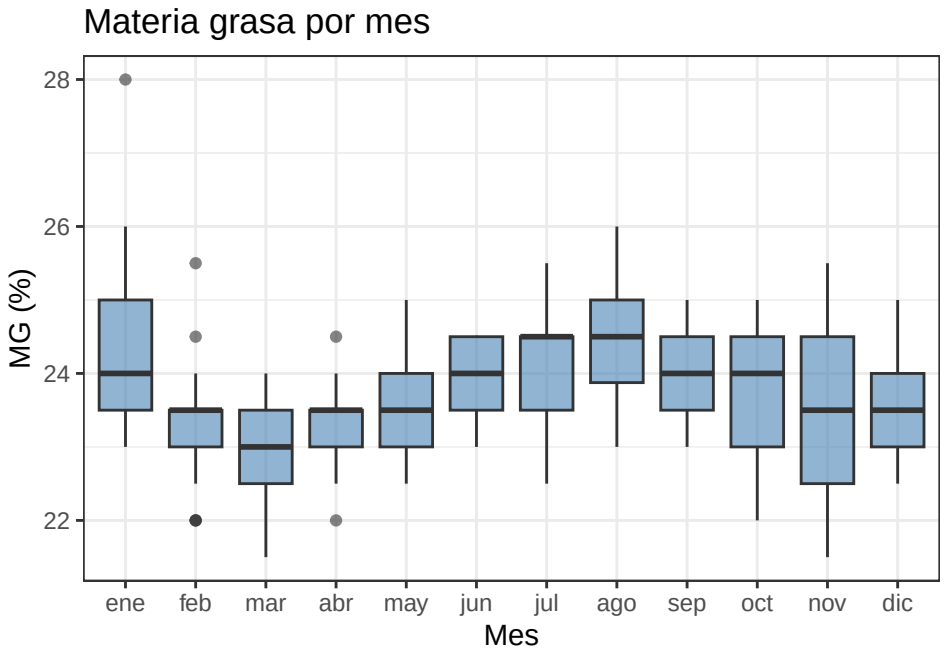
12.4.4. Materia grasa (`mg`)

Aplicamos el mismo análisis a la materia grasa:



El histograma de la materia grasa muestra una distribución aproximadamente simétrica centrada en torno a 23,5 %, pero el boxplot señala un valor atípico alto claramente separado del resto. Ese valor es 28 %, registrado el 26 de enero, y es el único por encima de 27 %. Puede ser un error de estandarización en el arranque del año, cuando la composición de la leche de invierno es más rica en grasa. Lo analizamos en la serie temporal:

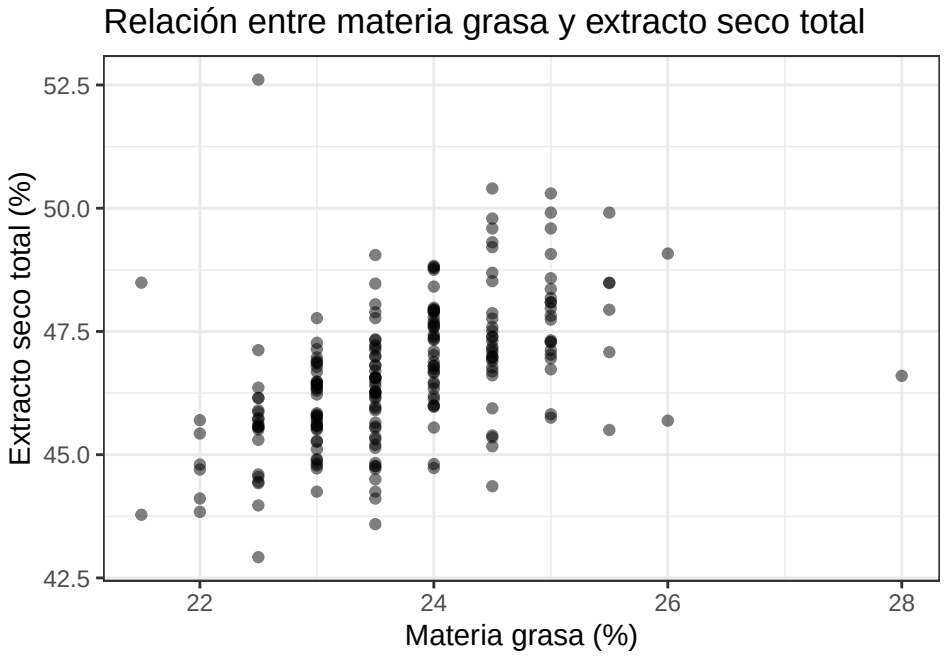




El boxplot mensual de la materia grasa no muestra la misma estacionalidad pronunciada que el extracto seco. El valor de 28 % de enero es claramente atípico respecto a su mes, pero el resto del año la materia grasa se mantiene en un rango bastante estable entre 22 y 26 %. A partir de febrero se observa una tendencia moderada al alza hasta el verano, que se corrige progresivamente en el segundo semestre.

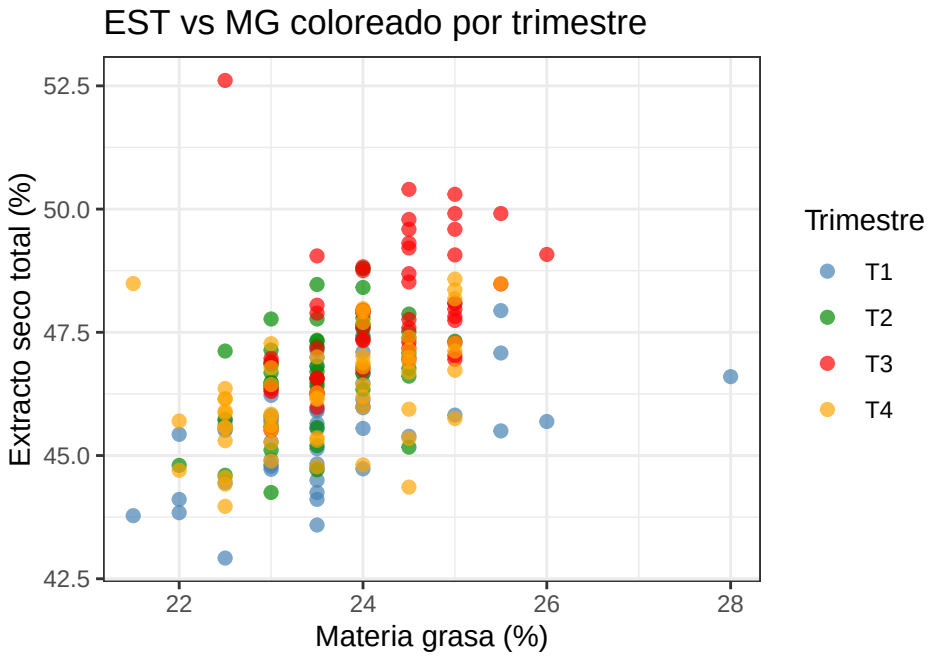
12.4.5. Análisis conjunto: gráfico de dispersión `est` vs `mg`

Hasta ahora hemos analizado cada variable por separado. El gráfico de dispersión nos permite ver si existe relación entre el extracto seco y la materia grasa:



La nube de puntos muestra una correlación positiva moderada: en general, cuando la materia grasa sube, el extracto seco también sube. Pero hay tres puntos que se separan claramente del conjunto: son los valores con `est` muy alto (en torno a 50-52 %) combinados con `mg` normal o incluso baja. Estos puntos corresponden al período de verano que ya identificamos. El punto aislado con `mg` = 28 % y `est` normal también destaca. Estos tres puntos anómalos son los que discutiremos con el equipo en la fase de conclusiones.

Coloreamos por trimestre para ver mejor la estructura estacional con una paleta legible:



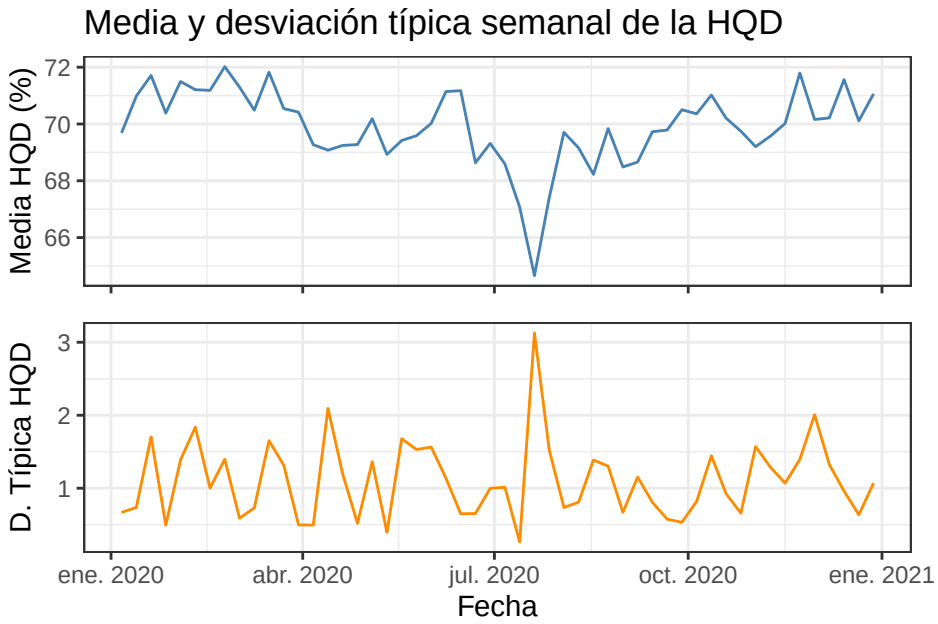
Los puntos del tercer trimestre (julio-septiembre) se sitúan claramente en la parte superior del gráfico, confirmando que la desviación de verano afecta a ambas variables simultáneamente, aunque con mayor intensidad en el extracto seco.

12.4.6. Variable derivada: humedad del queso desnatado (`hqd`)

Como tecnólogos queseros, sabemos que un factor crítico de la textura del queso, y en consecuencia de su calidad, es la humedad del extracto seco desnatado. Este parámetro se calcula a partir del extracto seco y la materia grasa:

$$\text{hqd} = \frac{(100 - \text{est}\,\%)}{(100 - \text{mg}\,\%)} \times 100$$

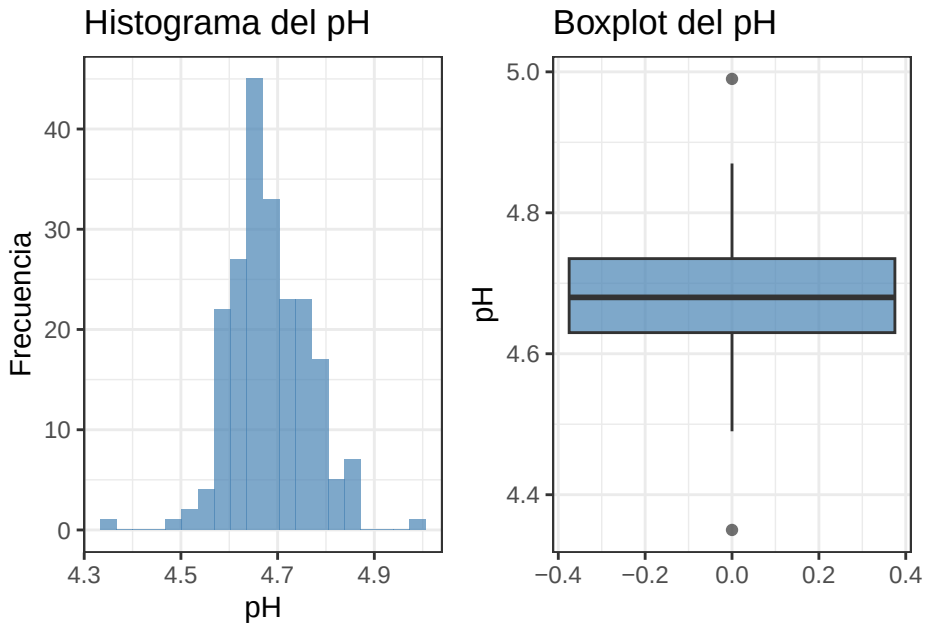
Creamos la nueva columna y analizamos su evolución:



La `hqd` muestra el patrón más revelador de todo el análisis. El fabricante mantiene la humedad razonablemente estable en torno al 70-71 % durante la primera mitad del año, con algunos ajustes menores. En julio se produce una caída brusca hasta valores de 61-63 %, la peor semana corresponde al 21 de julio con una `hqd` de 61,15 %. Esta desviación de casi 10 puntos es muy significativa para la textura del camembert y explica las reclamaciones de queso demasiado seco que se recibieron en ese período.

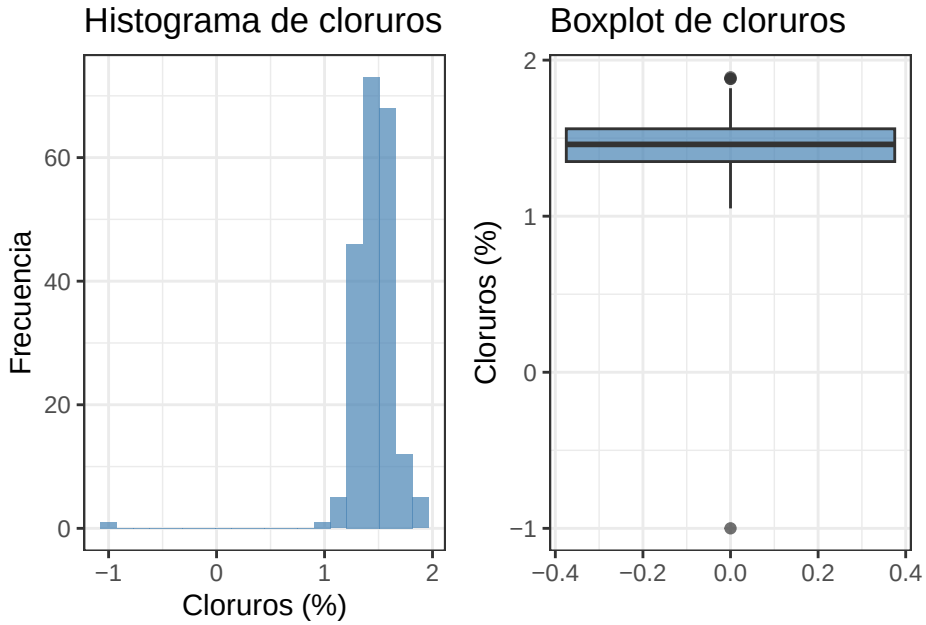
12.5. Análisis de otras variables

12.5.1. pH



El pH muestra una distribución aproximadamente simétrica centrada en 4,68, con un rango habitual entre 4,5 y 4,9. El boxplot señala dos valores atípicos: el mínimo de 4,35 (18 de abril) y el máximo de 4,99 (25 de enero). El valor de 4,35 merece atención porque se aleja bastante del rango habitual; puede indicar una acidificación excesiva en esa fabricación o un error analítico. El pH y los cloruros se proponen como ejercicio de análisis completo al final del capítulo.

12.5.2. Cloruros



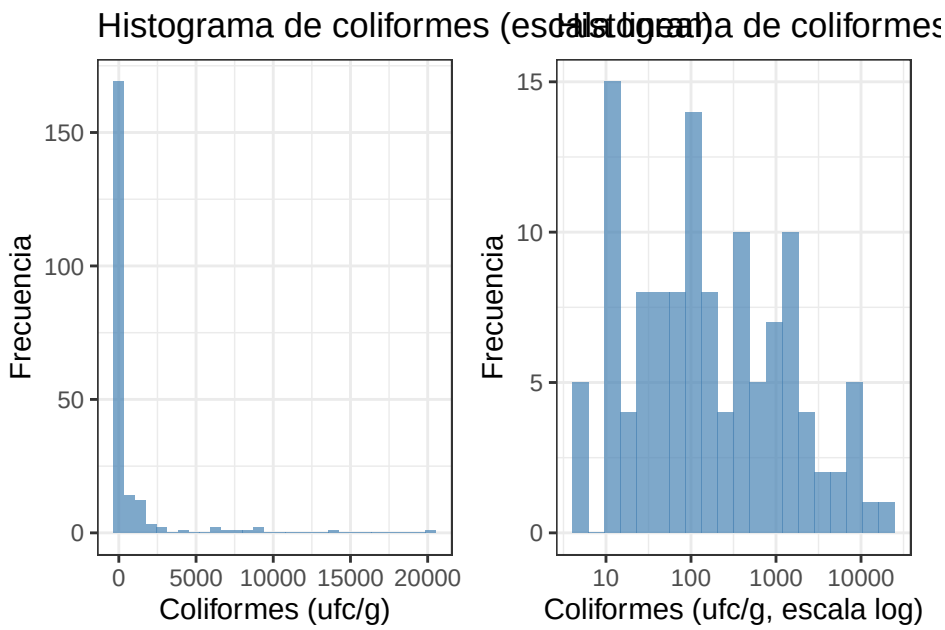
El histograma de cloruros muestra una distribución aproximadamente simétrica en torno a 1,45-1,50 %, con un rango habitual entre 1,1 y 1,9 %. El boxplot señala un único valor atípico muy llamativo: -1 %, registrado el 11 de febrero. Un contenido en cloruros negativo es físicamente imposible, por lo que se trata sin duda de un error de entrada de datos: probablemente se introdujo el valor con el signo menos por error. Este valor debe tratarse como un dato ausente (`NaN`) antes de cualquier análisis posterior.

12.5.3. Coliformes: un ejemplo de distribución asimétrica positiva

Los recuentos de bacterias coliformes merecen un análisis específico porque su distribución es radicalmente distinta a la del resto de variables. Antes de hacer el histograma, veamos los estadísticos básicos:

```
# A tibble: 1 x 9
      n media mediana    dt   min   max ceros mayor_1000 mayor_5000
  <int> <dbl>   <dbl> <dbl> <dbl> <dbl> <int>      <int>      <int>
1   210  651.      10 2194.     0 20200    89         28          9
```

La mediana es 10 ufc/g pero la media es 651 ufc/g, casi 65 veces mayor. El 42 % de los valores son exactamente cero, y hay 9 valores por encima de 5.000 ufc/g, con un máximo de 20.200 ufc/g el 12 de agosto. Esta diferencia enorme entre la mediana y la media es la señal característica de una distribución muy asimétrica positiva.

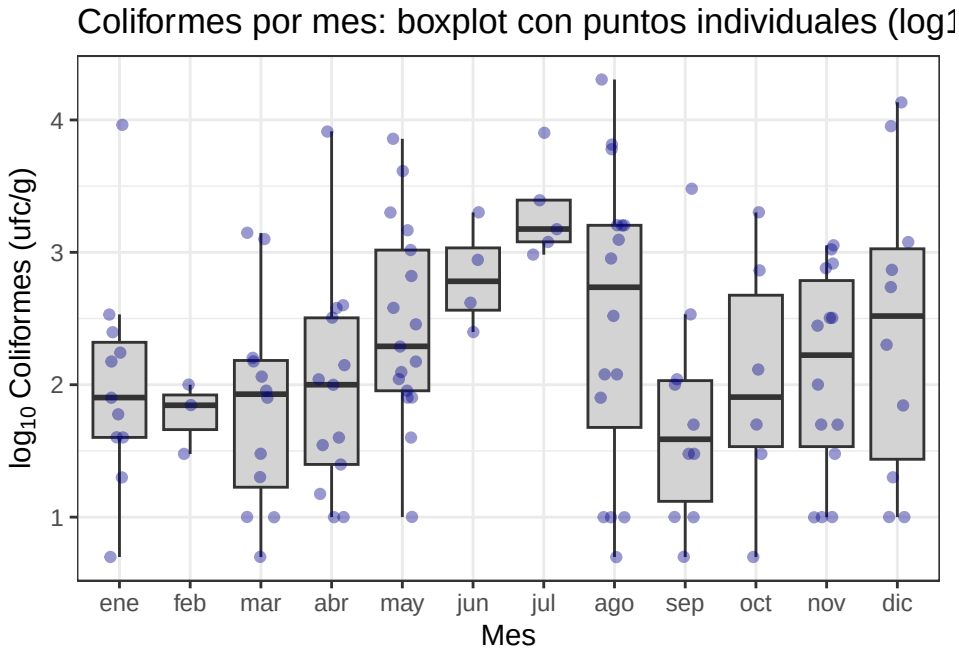


En escala lineal, el histograma muestra una barra altísima en los valores bajos y una larga cola hacia la derecha: es la asimetría positiva extrema que veíamos en el capítulo 6 con los goles por partido, pero mucho más pronunciada. En escala logarítmica la distribución se hace visible con más detalle: la mayoría de los recuentos positivos están entre 10 y 1.000 ufc/g, y los valores muy altos son escasos pero existen.

> **Nota**
>
> En microbiología alimentaria, los recuentos siempre siguen distribuciones asimétricas positivas: la mayoría de las muestras tienen recuentos bajos o nulos, pero ocasionalmente aparecen recuentos muy altos que reflejan episodios de contaminación. Por este motivo, en microbiología es habitual trabajar con la transformación logarítmica de los recuentos, que convierte la distribución asimétrica en una distribución más simétrica y más fácil de analizar. La media aritmética de los recuentos tiene muy poco sentido; es más informativo trabajar con la mediana o con la media geométrica (la media de los logaritmos).

Este efecto es el mismo que el de un peso situado lejos del fulcro de una balanza: aunque sea un solo valor extremo, su distancia al centro multiplica su influencia sobre la media de forma desproporcionada. Por eso en variables con distribución muy asimétrica la media no es un buen descriptor del conjunto.

Veamos la distribución mensual mediante un boxplot con los puntos individuales superpuestos. Como el logaritmo de cero no está definido, excluimos las muestras con recuento nulo: estas muestras no aportan información sobre la magnitud de la contaminación, y su inclusión aplastaría el gráfico hacia el cero haciendo ilegible el resto de la distribución. El alumno debe tener en cuenta que los meses con muchos ceros tendrán menos puntos representados, lo que también es información relevante sobre la higiene del proceso.



El gráfico muestra picos puntuales dispersos a lo largo del año, sin un patrón estacional claro y sostenido. La mediana de los valores se incrementa desde abril hasta julio, donde hay un máximo que parece significativo, ya que la caja del boxplot no se solapa con las anteriores. De manera coherente con la información agregada, los valores individuales se concentran en primavera y verano, coincidiendo con las temperaturas ambientales más altas y el período de sustituciones de personal en vacaciones. El valor máximo de 20.200 ufc/g del 12 de agosto es el más llamativo. En invierno los recuentos son en general más bajos y más homogéneos.

12.6. Conclusiones y plan de acción

12.6.1. Análisis de resultados

Una vez explorados los datos de todas las variables, podemos formular las hipótesis de trabajo:

1. A principio de año hay un valor anómalo de materia grasa (28 %, 26 de enero) que puede haberse debido a un error en la estandarización coincidiendo con una leche de invierno más rica en grasa. A pesar de esto, la `hqd` se mantuvo estable, lo que indica que el fabricante corrigió el extracto seco para compensar.
2. Hay un claro error de entrada en cloruros: el valor -1 % del 11 de febrero es físicamente imposible y debe tratarse como dato ausente.
3. El pH de 4,35 del 18 de abril se aleja significativamente del rango habitual y merece verificación con el laboratorio.
4. La desviación más importante del año es el aumento sostenido del extracto seco en julio, con un máximo de 52,61 % el 21 de julio, que produjo una caída de la `hqd` hasta 61,15 %. Esta bajada de casi 10 puntos respecto al objetivo habitual de 70-71 % es la causa directa de las reclamaciones por queso demasiado seco recibidas en ese período.

5. Los recuentos de coliformes no muestran una tendencia estacional clara, pero los valores más altos se concentran en verano, coincidiendo con el período de aumento de temperatura ambiente que incrementa el riesgo de crecimiento bacteriano. Hay que tener en cuenta también las sustituciones de personal en vacaciones, que pueden añadir más variabilidad a los resultados analíticos como consecuencia de la menor experiencia analítica de las personas temporales.
6. Hay tres puntos en el gráfico de dispersión `est` vs `mg` que se separan claramente del conjunto: son candidatos a revisión analítica antes de repetir el análisis definitivo.

12.6.2. Comunicar: discusión en equipo

Hemos presentado el análisis al equipo de fabricación, laboratorio y producción. Las conclusiones de la reunión son:

- El responsable de fabricación confirma que hace ajustes estacionales en la estandarización a lo largo del año para mantener la `hqd` constante. En verano, debido a las temperaturas más altas en las zonas de distribución, la práctica habitual es bajar moderadamente la `hqd` para evitar una proteólisis excesiva durante el ciclo de comercialización.
- Este año el quesero fue sustituido durante vacaciones por una persona con menos experiencia, que forzó el extracto seco más de lo debido. Las reclamaciones de los clientes por queso demasiado seco en agosto confirman esta hipótesis.
- El laboratorio confirma que los tres valores anómalos del gráfico de dispersión pueden corresponder a análisis incorrectos, y recomienda no tenerlos en cuenta en el análisis definitivo.
- El valor negativo de cloruros es claramente un error de entrada de datos.

12.6.3. Plan de acción

A la vista del análisis, el equipo propone las siguientes acciones:

1. Revisar diariamente la composición de la leche para evitar errores de estandarización, especialmente en los cambios de estación.
2. Mejorar la formación de las personas que cubren los puntos clave (quesero, analistas) en períodos de vacaciones o enfermedad, anticipando los ciclos de formación.
3. Revisar los métodos analíticos con el laboratorio y valorar un estudio de precisión, incluyendo la variabilidad entre analistas.
4. Establecer un sistema de seguimiento ágil de la `hqd` en tiempo real, para detectar desviaciones antes de que afecten al producto en el punto de venta.
5. Valorar si los problemas de proteólisis en verano son generales o se concentran en clientes específicos con peores condiciones de conservación, ajustando el objetivo de `hqd` de verano de forma más precisa.
6. Repetir el análisis eliminando los valores erróneos identificados, para verificar que las conclusiones se mantienen.

Dado que la capacidad del equipo es limitada, en sucesivas reuniones se priorizarán las acciones de mayor impacto y se establecerán indicadores que se publicarán semanalmente en paneles de planta.

12.7. Resumen del capítulo

En este capítulo hemos aplicado el flujo de trabajo completo del análisis de datos a una fabricación real de queso camembert. El análisis variable a variable ha permitido identificar errores de entrada (el valor negativo de cloruros), valores atípicos que requieren verificación (el pH de 4,35 en abril, el valor de materia grasa de 28 % en enero) y la desviación estacional más importante del año: el aumento sostenido del extracto seco en julio, que produjo una caída de la humedad del queso desnatado de casi 10 puntos y originó reclamaciones de los clientes.

La serie temporal ha sido la herramienta clave para interpretar correctamente lo que el histograma mostraba como una simple distribución asimétrica: lo que parecía un valor atípico aislado era en realidad parte de una desviación estacional sostenida durante varias semanas. El análisis de los coliformes ha ilustrado con datos reales el concepto de distribución asimétrica positiva extrema, característica de los recuentos microbiológicos, y la razón por la que la mediana es más informativa que la media en este tipo de variables.

El capítulo concluye con una fase de comunicación en equipo que transforma el análisis estadístico en hipótesis de trabajo contrastadas con el conocimiento tecnológico y en un plan de acción priorizado. En el capítulo siguiente nos enfrentaremos al análisis de las entradas de leche en una gran fábrica de queso.

12.8. Ejercicios propuestos

12.8.1. Ejercicio 1: análisis completo de pH y cloruros

Realiza el análisis exploratorio completo de las variables `ph` y `cloruros`, siguiendo la misma metodología aplicada a `est` y `mg` en este capítulo:

- Histograma y boxplot
- Serie temporal anual
- Boxplot mensual
- Interpretación de los valores atípicos detectados

Para los cloruros, filtra previamente el valor negativo convirtiéndolo en `NaN` antes de representar los gráficos.

12.8.2. Ejercicio 2: repetir el análisis sin los valores erróneos

El laboratorio ha confirmado que los tres puntos anómalos del gráfico de dispersión `est` vs `mg` son probablemente errores analíticos. Utiliza Python o R para filtrarlos y repite el análisis completo con el dataset corregido. ¿Cambian las conclusiones?

Como referencia, los criterios de filtrado son: valores de `mg` superiores a 27 %, valores de `est` superiores a 52 %, y valores con `mg` inferior a 22 % y `est` superior a 48 % de forma simultánea.

12.8.3. Ejercicio 3 (avanzado): transformación logarítmica de coliformes

Los recuentos microbiológicos se analizan habitualmente en escala logarítmica. Crea una nueva columna `log_coliformes` con el logaritmo en base 10 de los recuentos (excluyendo los ceros), y compara el histograma de la escala lineal con el de la escala logarítmica. ¿Cómo cambia la forma de la distribución? ¿Qué valores de la escala logarítmica corresponden a los límites microbiológicos habituales en queso camembert?

12.9. Práctica en Google Colab

En este enlace se proporciona acceso a los datos de este capítulo en un cuaderno de Google Colab, para practicar de forma interactiva el código Python desde ese entorno.

Abrir versión sólo Python de este cuaderno en Google Colab

13. Los costes de materia: el precio de la leche

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Explicar cómo funciona el sistema de pago de la leche por calidad en España y qué componentes lo determinan.
- Calcular el precio de la leche a partir de los valores analíticos de materia grasa y proteína.
- Obtener el coste unitario de la materia grasa y la proteína de la leche en €/kg.
- Utilizar el precio de la materia prima para valorar económicamente las pérdidas de proceso y las desviaciones de rendimiento.

Conceptos clave: **pago por calidad, precio de la leche, materia grasa, proteína, coste de materia prima, precio unitario de componentes**.

Antes de estudiar el balance de materia y los rendimientos queseros, vamos a ver cómo se construye el precio de la leche. Esto nos permitirá determinar no sólo el precio que pagamos al ganadero por la materia prima, sino también conocer el coste de materia a la entrada en fábrica, descompuesto en sus componentes principales, materia grasa y proteína. Conocer este coste nos permite conocer con precisión cuál es el coste real de nuestras perdidas de materia en fábrica, y también de las desviaciones de rendimientos, lo que, a su vez, nos permitirá priorizar las acciones de mejora hacia aquellos puntos con mayor repercusión en nuestros resultados económicos.

13.1. El pago de la leche por calidad en España

El pago por calidad de la leche de vaca en España se basa en parámetros físico-químicos y sanitarios como la materia grasa (MG), materia proteica (MP), células somáticas y bacterias. Estos factores determinan el precio final que recibe el ganadero por litro entregado.

13.2. Conceptos clave del pago por calidad

El sistema de pago por calidad busca incentivar la producción de leche con mejores características nutricionales e higiénicas. Los principales criterios son:

13.2.1. 1. Composición química

- **Materia Grasa (MG)**: Aporta valor energético. Cuanto mayor el porcentaje, mayor el precio.

- **Materia Proteica (MP)**: Indicador de calidad nutricional. Muy valorada por la industria quesera.
- **Urea**: Indicador del equilibrio nutricional de la dieta del ganado.

13.2.2. 2. Calidad higiénico-sanitaria

- **Recuento de células somáticas (RCS)**: Refleja la salud mamaria. Valores altos penalizan el precio.
- **Recuento de bacterias (RB)**: Mide la higiene en el ordeño y conservación. Penaliza si supera ciertos umbrales.
- **Inhibidores**: Presencia de antibióticos u otras sustancias. Si se detectan, la leche se rechaza.

13.2.3. 3. Otros factores

- **Punto crioscópico**: Detecta adulteraciones (agua añadida).
- **Letra Q**: Etiquetado voluntario que certifica calidad superior. Está controlado por la autoridades veterinarias de cada región.
- **Marcas de calidad**: DOP, IGP, ecológica, etc., pueden mejorar el precio.

13.3. Aplicación práctica: ejemplo de cálculo

Supongamos que un ganadero entrega 10.000 litros de leche con la siguiente composición:

- **MG**: 4,10 %
- **MP**: 3,45 %
- **RCS**: 180.000 células/ml
- **RB**: 20.000 ufc/ml

La industria tiene una tabla de precios base que puede variar regionalmente y por empresa, según los acuerdos firmados con cada ganadero o cooperativa. Hay un precio base al cual se van sumando bonificaciones en función de diversos criterios, negociados entre el ganadero (o la cooperativa) y la empresa. En el caso de Asturias, podemos suponer un precio base de 0,510 €/L, y estas bonificaciones:

Parámetro para pago por calidad	Resultado analítico	Límite prima	Prima	Calidad real	Bonificación (€/L)
Grasa (MG)	4,10 %	MG > 3,80 %	+0,0050 €/L	3 décimas (4,10 vs 3,80)	0,0150
Proteína (MP)	3,45 %	MP > 3,30 %	+0,0080 €/L	1,5 décimas (3,45 vs 3,30)	0,0120
Recuento de células somáticas (RCS)	180.000	RCS < 200.000	+0,0070 €/L		0,0070

Parámetro para pago por calidad	Resultado analítico	Límite prima	Prima	Calidad real	Bonificación (€/L)
Recuento de bacterias totales (RB)	20.000	RB < 50.000	+0,0080 €/L		0,0080
Bienestar animal	Sí		+0,0100 €/L	certificacion Welfair/AENOR	0,0100
Letra Q	Sí		+0,0050 €/L		0,0050

Resumiendo las primas por conceptos, podemos agruparlas así:

Concepto	Precio pagado
Precio base	0,5100
Primas Calidad (MG + MP)	0,0270
Higiene (RCS + RB)	0,0150
Sostenibilidad (BA + Letra Q)	0,0150
Precio neto final	0,5670

La liquidación mensual daría un **total a percibir** de:

$$10.000\ L \cdot 0,567\ euros/L = 5.670\ euros$$

De esta manera se establece un precio por litro, que se aplica mensualmente tras el análisis de las muestras representativas. En las diferentes regiones, este proceso es gestionado por los laboratorios interprofesionales lecheros mediante protocolos de muestreo y análisis estandarizados. El Ministerio de Agricultura también ofrece ayudas específicas por calidad bajo marcas reconocidas o la Letra Q.

Es importante recordar que cada industria puede tener su propia tabla de bonificaciones y penalizaciones, pues son acordadas por negociación entre ganaderos (o centrales lecheras) y la industria, y en la mayoría de los casos, forman parte de los contratos lecheros de aprovisionamiento. Hace algunos años, la bonificación por materia grasa era siempre superior a la bonificación por proteína; este tipo de bonificación, que aplicaba la industria lechera, no es recomendable en la industria quesera, que valora sobre todo la riqueza en proteina coagulable (caseína). Por esta razón, no siempre las características de la leche recogida por la industria lechera son idóneas para la fabricación de queso. Actualmente, las empresas queseras bonifican más las mejoras en proteína, y en algunos casos también las empresas lecheras, que están encontrando más usos de valor añadido para la proteína, obtenida por técnicas de filtración tangencial, que para la grasa comercializada como mantequilla.

13.3.1. La conversión del precio por litro en los costes totales de materia prima, grasa y proteína.

Una vez establecido el precio de la leche, a la industria quesera (y lechera) le interesa descomponer este precio en los ingredientes que van a ser objeto de transformación, la materia grasa y la proteína, para poder establecer con precisión los costes de materia en producción.

La transformación quesera está determinada por la eficiencia en la retención de estas materias primas en el queso, como veremos en el análisis de los rendimientos queseros. La materia prima más importante para el quesero es la proteína, que forma la matriz quesera; la materia grasa se necesita como elemento que confiere sabor y textura al queso.

Hasta hace unos años, el precio de la leche se determinaba por su riqueza en **materia seca útil (MSU)**, también llamada **extracto seco quesero (ESQ)**, que se calcula sumando el contenido de materia grasa más la proteína:

$$MSU = MG + MP$$

Este parámetro, vigente aún para la leche de oveja y de cabra, no es recomendable en la industria quesera. El motivo es que el productor puede aumentar la materia grasa de la leche mediante determinados tipos de alimentación animal, elevando el contenido en MG hasta un punto porcentual completo (por ejemplo, de 3,5 % a 4,5 %). Sin embargo, la proteína apenas puede incrementarse por la alimentación —solo 0,1–0,2 puntos porcentuales (por ejemplo, de 3,3 % a 3,5 %)— porque su nivel depende fundamentalmente de la genética del animal, que determina entre el 60 % y el 70 % de su contenido. Por esta razón, la leche de una vaca frisona nunca alcanzará el contenido proteico propio, por ejemplo, de una vaca Montbéliarde, con independencia de la alimentación que tenga disponible.

El efecto de un contenido en materia grasa demasiado elevado es una leche desequilibrada, con una cantidad de materia grasa que es posible qie no pueda ser utilizada en la producción de queso, porque se rebasaría el contenido en grasa del queso. Esto obliga al quesero a desnatar parte de la leche y vender la nata como excedente a bajo precio, lo que impacta negativamente en sus resultados.

La forma de controlar la cantidad de materia grasa necesaria en la leche de aprovisionamiento (compra) consiste en el control del factor MG/MP, que debe ser sólo ligeramente superior al del producto final (queso), para cubrir las necesidades del queso más las perdidas de producción.

Por esta razón, es muy frecuente que la industria quesera no valore de la misma manera la materia grasa y la proteína en la leche de compra, y establezca un criterio de valoración que bonifique la riqueza en proteína, por ejemplo, 40/60, como veremos a continuación.

13.4. Cálculo del precio de la leche mediante la hoja de cálculo.

Podemos construir una hoja de calculo para el precio de la leche, en el que recojamos los diferentes elementos del pago por calidad y el transporte; de esta manera podemos comparar nuestros objetivos con lo obtenido en el caso real. En primer lugar, establecemos las hipótesis de nuestro presupuesto, es decir, lo que esperamos para el promedio de las entradas del año

Parámetro para pago por calidad (valores presupuestados)	Resultado analítico	Límite prima	Prima (€/L)	Calidad real	Bonificación (€/L)
Grasa (MG)	4,10%	MG > 3,80%	+ 0,005	3 décimas (4,10 vs 3,80)	0,0150
Proteína (MP)	3,45%	MP > 3,30%	+ 0,008	1,5 décimas (3,45 vs 3,30)	0,0120
Recuento de células somáticas (RCS)	180.000	RCS < 200.000	+ 0,007		0,0070
Recuento de bacterias totales (RB)	20.000	RB < 50.000	+ 0,008		0,0080
Bienestar animal	Sí		+ 0,010	certificacion Welfair/AENOR	0,0100
Letra Q	Sí		+ 0,005		0,0050

Figura 13.1.: Tabla con primas previstas en el presupuesto

Podemos resumir los principales conceptos del pago por calidad, con el precio resultante de la aplicación de estas bonificaciones al precio base:

Concepto	Precio pagado
Precio base	0,5100
Primas Calidad (MG + MP)	0,0270
Higiene (RCS + RB)	0,0150
Sostenibilidad (BA + Letra Q)	0,0150
Precio neto final	**0,5670**

Figura 13.2.: Tabla resumen con precio presupuestado

Conociendo las hipótesis de modificación del precio, sólo tenemos que verificar cada concepto para estableer el precio de la leche en el periodo considerado, en este caso, un mes de abril, como ejemplo::

Parámetro para pago por calidad Mes de ABRIL	Resultado analítico	Límite prima	Prima	Calidad real (diferencia entre resultado y límite prima)	Bonificación (€/L)
Grasa (MG)	3,95%	3,80%	0,0050	1,5	0,0075
Proteína (MP)	3,40%	3,30%	0,0080	1	0,0080
Recuento de células somáticas (RCS)	195.000	200.000	0,0070	Aplica	0,0070
Recuento de bacterias totales (RB)	52.000	50.000	0,0080	No aplica	0,0000
Bienestar animal	Sí		0,0100		0,0100
Letra Q	Sí		0,0050		0,0050

Figura 13.3.: Tabla con resultado real de primas en un mes

Vemos que en este mes no se han cumplido los valores de grasay proteína presupuestados, aunque son superiores a los mínimos previstos para la aplicación de las primas de calidad, y recogen una bonificación ligeramente inferior a la presupuestada. Los recuentos de células somática han sido superiores a lo previsto, pero inferiores al límite que recoge la prima por calidad, por lo que se aplica la prima por este concepto. En cambio, se ha superado el recuento de bacterias totales (52.000 vs 50.000), por lo que no se obtiene la bonificación por este concepto. Se mantienen las primas de bienestar animal y letra Q.

En total, el precio neto final del litro de leche pagado en el mes es inferior a lo previsto en el presupuesto:

Concepto	Precio pagado
Precio base	0,5100
Primas Calidad (MG + MP)	0,0155
Higiene (RCS + RB)	0,0070
Sostenibilidad (BA + Letra Q)	0,0150
Precio neto final	**0,5475**

Figura 13.4.: Tabla resumen con el precio pagado real

13.5. Construcción del precio de la materia grasa y la proteína a partir del precio de la leche

Una vez determinado el precio de leche pagado, y conocido el precio previsto en nuestro presupuesto, podemos comparar el coste de materia, y para ello utilizamos estos datos y los de la composición de la leche para establecer el coste real de la materia grasa y la proteína. Vamos a analizar la siguiente tabla paso a paso.

Coste de la leche en fabrica	Presupuesto	Real
1. Precio base	0,5100	0,5100
2. Primas calidad (MG/MP)	0,0270	0,0155
3. Primas higiene	0,0150	0,0070
4. Prima sostenibilidad	0,0150	0,0150
5. Total precio al ganadero	0,5670	0,5475
6. Coste transporte + otros recogida	0,0210	0,0250
Total euros/L	**0,5880**	**0,5725**
7. Materia grasa	0,2352	0,2290
8. Proteína	0,3528	0,3435
Composición leche (% m/m)		
9. Materia grasa	4,10%	3,95%
10. Proteinas totales	3,45%	3,40%
Composición leche (g/L)		
11. Materia grasa	42,403	40,852
12. Proteinas totales	35,681	35,164
13. Lactosa	48,000	48,000
14. Sales minerales y otros	9,000	9,000
15. Agua	899,146	901,216
16. Densidad	1,034	1,034
°C medida	20	20
Valoración materia prima		
17. Valoración MG	40%	40%
18. Valoración MP	60%	60%
Precio resultante de la materia		
19. Precio MG (euros/kg)	**5,547**	**5,606**
20. Precio MP (euros/kg)	**9,888**	**9,769**

Figura 13.5.: Tabla Excel de construcción del precio de materia a la entrada en fábrica

En las líneas 1 a 4 tenemos los conceptos principales del pago por calidad, que, sumados, nos permiten obtener la cantidad neta pagada al ganadero, en la línea 5. Pero ants de obtener un coste de materia en fábrica, tenemos que sumar a esta cantidad los portes, gastos de transporte y otros gastos que se deriven de la recogida y transporte de la leche a la fábrica (que pueden incluir, por ejemplo, los gastos derivados de lavar las cisternas de leche, o de pesar la leche en una báscula externa). Agrupamos todos estos costes en una línea de gastos de transporte y recogida (línea 6), y la sumamos al precio pagado al ganadero para obtener el coste real de la leche puesta en fábrica.

En las líneas 9 a 12 obtenemos al composición real de la leche comprada, mediante las analíticas de la leche; y a continuación vamos a establecer el precio al que hemos comprado el kg de grasa y de proteína, necesario para valorar nuestro producto y nuestras pérdidas.

Vamos a repartir el precio del litro de leche comprada entre la materia grasa y la proteína. Supongamos que queremos que la materia grasa soporte la mitad del precio de la leche, y que la proteína soporte la otra mitad. Podemos calcular entonces el precio del kilo de materia grasa de la sigueinte forma:

- Dividimos el precio del litro de leche entre 2, destinando cada mitad a cada materia.
- Para hallar el precio de la materia grasa, dividimos una mitad por los gramos de grasa que tiene el litro de leche, lo que nos permite obtener el precio del gramo de grasa.
- Sólo tenemos que multiplicar por 1000 para obtener el precio del kilo

$$\begin{aligned}\text{Precio de la MG } \frac{\text{euros}}{\text{kg}} &= \frac{\frac{\text{Precio de la leche}}{2}\ \frac{\text{euros}}{\cancel{L}}}{\text{Cantidad de MG } \frac{\text{g}}{\cancel{L}}} \cdot 1000\ \frac{\cancel{\text{g}}}{\text{kg}} \\ &= \frac{0{,}294}{42{,}403} \cdot 1000\ \frac{\text{euros}}{\text{kg}} \\ &\approx 6{,}933\ \frac{\text{euros}}{\text{kg}}\end{aligned} \tag{1}$$

Podemos calcular el precio de la proteína de la misma manera, y de esta forma repartimos el precio de la leche entre las dos materias

$$\begin{aligned}\text{Precio de la MP } \frac{\text{euros}}{\text{kg}} &= \frac{\frac{\text{Precio de la leche}}{2}\ \frac{\text{euros}}{\cancel{L}}}{\text{Cantidad de MP } \frac{\text{g}}{\cancel{L}}} \cdot 1000\ \frac{\cancel{\text{g}}}{\text{kg}} \\ &= \frac{0{,}294}{35{,}681} \cdot 1000\ \frac{\text{euros}}{\text{kg}} \\ &\approx 8{,}240\ \frac{\text{euros}}{\text{kg}}\end{aligned} \tag{2}$$

Lo primero que llama la atención es que, a pesar de que hemos dividido el precio de la leche al 50 % entre la grasa y la proteína, los precios unitarios son diferentes: la razón es que al estar siempre la proteína en una concentración inferior a la grasa, repartimos el mismo coste (50 %) entre una cantidad de materia menor, por lo que el coste unitario es más alto.

Volvamos a nuestra hoja de cálculo. En realidad, las industrias queseras nunca reparten el precio de la leche al 50 % entre la grasa y la proteína; como la proteína es la materia más valiosa para la fabricación de queso, siempre se pondera un poco más su valor respecto a la materia grasa. Esto es lo que hacemos en las líneas 17 y 18: asignamos a la materia grasa un valor del 40 % del litro de leche, y a la proteína el 60 %. Este porcentaje no se varía a lo largo del año, es una decisión estratégica de la empresa que sólo se cambia por razones muy excepcionales.

Este cálculo (incluyendo el análisis dimensional) nos da los valores definitivos:

$$\begin{aligned}\text{Precio de la MG } \left[\frac{\text{euros}}{\text{kg}}\right] &= \frac{\text{Precio de la leche } \left[\frac{\text{euros}}{\cancel{L}}\right]}{\text{Cantidad de MG } \left[\frac{\text{g}}{\cancel{L}}\right]} \cdot 1000\ \left[\frac{\cancel{\text{g}}}{\text{kg}}\right] \cdot 0{,}40 \\ &= \frac{0{,}588}{42{,}403} \cdot 1000 \cdot 0{,}40 \left[\frac{\text{euros}}{\text{kg}}\right] \\ &\approx 5{,}547\ \left[\frac{\text{euros}}{\text{kg}}\right]\end{aligned} \tag{3}$$

y

$$\begin{aligned}\text{Precio de la MP } \left[\frac{\text{euros}}{\text{kg}}\right] &= \frac{\text{Precio de la leche } \left[\frac{\text{euros}}{\cancel{L}}\right]}{\text{Cantidad de MP } \left[\frac{\cancel{g}}{\cancel{L}}\right]} \cdot 1000 \left[\frac{\cancel{g}}{\text{kg}}\right] \cdot 0{,}60 \\ &= \frac{0{,}588}{35{,}681} \cdot 1000 \cdot 0{,}60 \left[\frac{\text{euros}}{\text{kg}}\right] \\ &\approx 9{,}888 \left[\frac{\text{euros}}{\text{kg}}\right]\end{aligned} \tag{4}$$

Llevaremos estos datos a los siguientes ejemplos para valorar económicamente las pérdidas de materia y los rendimientos queseros.

En la hoja de cálculo adjunta se pueden verificar las tablas que se han presentado arriba, y sus fórmulas de cálculo. También se incluye una entrada en una columna adicional para ver el coste de materia resultante de los datos simulados de la recogida de leche que hemos situado en el mes de abril. Esta diferencia en el precio de la leche nos servirá para calcular las diferencias de precio al analizar las desviaciones de rendimientos.

13.6. Resumen del capítulo

El precio de la leche en España se determina por un sistema de pago por calidad que pondera la composición química — fundamentalmente materia grasa y proteína — junto con la calidad higiénico-sanitaria. Conocer con precisión cómo se construye ese precio es el punto de partida para cualquier análisis económico del proceso quesero.

El paso más relevante para el análisis de rendimientos es la conversión del precio por litro en un coste unitario de la materia grasa y la proteína expresado en €/kg. Este coste unitario de los componentes es la herramienta que permite valorar económicamente las pérdidas de proceso: cada kilogramo de grasa o proteína que se pierde en el suero o en las roturas tiene un coste real que puede calcularse con precisión.

Los valores obtenidos en este capítulo — coste de la materia grasa y de la proteína en €/kg — se utilizarán directamente en los capítulos siguientes para cuantificar el impacto económico de las desviaciones de rendimiento y priorizar las acciones de mejora hacia los puntos del proceso con mayor repercusión en los resultados económicos de la empresa.

14. El balance de materia

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Explicar el concepto de balance de materia en la elaboración de queso y su importancia económica.
- Calcular la recuperación de materia grasa y proteína a partir de los datos analíticos de leche y queso.
- Identificar las principales etapas del proceso quesero donde se producen pérdidas de materia.
- Construir un balance de materia en Excel e interpretar los resultados.
- Analizar la evolución temporal de las pérdidas y detectar tendencias o anomalías.
- Proponer un plan de acción para la reducción de pérdidas a partir del análisis del balance.

Conceptos clave: **balance de materia, recuperación de materia grasa, recuperación de proteína, extracto seco magro (ESM), pérdidas en proceso, finos de queso, suero, eficiencia de transformación**.

14.1. El proceso de elaboración de queso.

La elaboración de queso tiene como objetivo principal **preservar y concentrar los componentes nutritivos de la leche**, transformándolos en un producto alimentario con **elevado valor sensorial, nutricional y comercial**. Este proceso da lugar a una amplia variedad de quesos, cada uno con características únicas que responden a factores como el tipo de leche, la tecnología aplicada y las condiciones de maduración.

El propósito de la tecnología quesera es **optimizar esta transformación**, guiando el proceso de forma que se obtenga el mejor producto posible, garantizando la calidad sanitaria, tecnológica y organoléptica, y todo ello de manera **eficiente y rentable**. Para lograrlo, los objetivos técnicos se centran en **minimizar las pérdidas de materia**, especialmente de **grasa y proteína**, que son los componentes clave del coste en la elaboración del queso.

En cualquier empresa quesera, independientemente de su tamaño, una de las tareas esenciales es analizar el balance global del proceso de elaboración. Para un período determinado, que, como primera aproximación, puede ser anual, resulta fundamental conocer el balance de grasa y proteína entre la leche adquirida y el queso producido. Toda la materia de la leche que no es incorporada al queso deja de ser vendible, de modo que las pérdidas durante el proceso incrementan el coste del producto final y reducen la competitividad. Además, conviene recordar que el suero prácticmente ya no genera ingresos por venta: en la actualidad, en la mayoría de

los casos, es retirado sin coste por las empresas encargadas de su secado, siendo el transporte el único elemento sujeto a negociación.

Con el fin de conocer las pérdidas de materia (grasa y proteína) en nuestro proceso de elaboración, en este capítulo veremos en qué consiste el **balance de materia**, explicando cómo construirlo y analizarlo.

14.2. Etapas en el proceso de fabricación de queso.

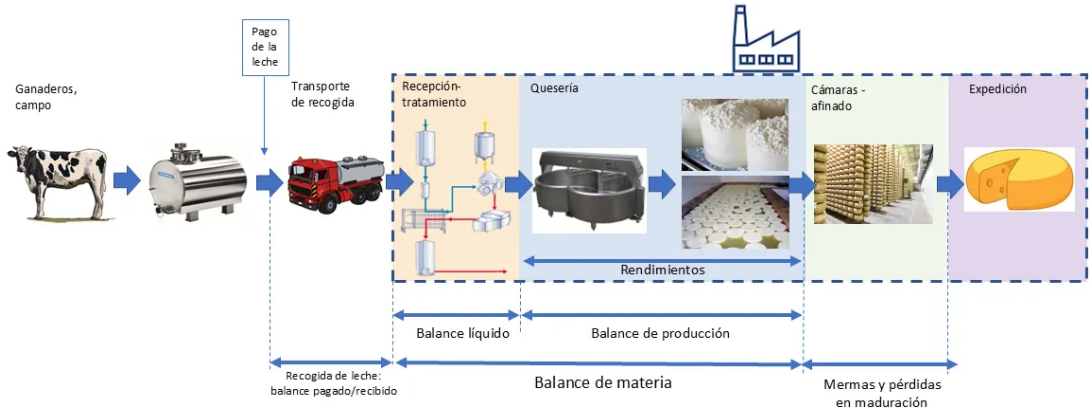


Figura 14.1.: Las diferentes unidades de una fábrica de queso y las medidas del balance de materia

El proceso de la leche para elaborar queso empieza con el ordeño, y el almacenamiento en frío. La leche almacenada es cargada en el camión de transporte, que la lleva a la fábrica. En el momento de la carga, se toma una muestra representativa, que será analizada por el laboratorio interprofesional lechero de la zona, y que tiene como objetivo el pago por calidad, y se registran los litros cargados en la cisterna. En otras ocasiones, es el propio personal del laboratorio interprofesional el que toma la muestra, para evitar posibles conflictos con la industria, y el resultado es enviado por el laboratorio tanto al ganadero como a la industria.

A su llegada a fábrica, se toma una muestra representativa de la leche, después de agitarla adecuadamente; esta muestra será analizada en el laboratorio de fábrica, y este análisis establece las cantidades de materia que se dan de entrada en la unidad de producción.

Debido a los procesos de muestreo, y a los posibles arrastres con agua de los depósitos y tuberías, casi siempre se presentan diferencias entre las analíticas realizadas por el laboratorio interprofesional y las realizadas en fábrica a la recepción. Estas diferencias, tanto de analíticas como de cantidad medida (litros o kg), forman parte de lo que en el sector se conoce como **diferencia pagado-recibido**. Habitualmente, forman parte de la negociación en el proceso de compra y pueden partirse a medias, siempre que el promedio acumulado esté muy próximo a cero, indicando que no hay sesgos, o repartirlas entre comprador y vendendor con otros criterios, siempre de forma negociada y acordada.

Hay que tener en cuenta que en la aparición de diferencias analíticas pueden influir incluso las diferencias en los métodos analíticos o sistemas automáticos utilizados; es fundamental realizar procesos de calibración inter-laboratorios y auditorías de proceso para asegurar que las analíticas de laboratorio interprofesional y de la fábrica proporcionan los mismos resultados para muestras

de calibración idénticas, y que los sistemas de medida de fábrica proporcionan medidas correctas y son fiables y repetitivos.

El balance de materia propiamente dicho comienza con los volúmenes y analíticas que la unidad de producción ha dado de entrada en fábrica, teniendo cuidado de que no se intente llevar a diferencias pagado-recibido lo que realmente son pérdidas dentro de la fábrica. Para el control del balance de materia de la fábrica, es fundamental que las diferencias pagado-recibido no se incluyan en el balance, ya que coresponden a eventos o situaciones fuera de su control, y su resolución no puede hacerse por otros medios que no sean la negociación del reparto de diferencias.

Una vez en fábrica, el proceso de la leche puede tener varias etapas antes de llegar a la cuba:

- **Termización**
- **Estandarización** en grasa y/o proteína, que puede implicar **desnatado** y posterior **reconstitución**
- En algunos casos, como la elaboración de queso azul, una **homogeneización** de parte de la materia grasa
- El **trasvase** y movimiento de la leche y otras materias dentro de la sección de **recepción-tratamiento** entre tanques, desnatadoras, homogeneizadores y resto de sistemas.

Como resultado de todos estos movimientos y procesos, se producen pérdidas de materia por diversas razones, entre las que hay que considerar la pérdida física por valvulas averiadas, malos cierres, juntas estropeadas, etc, y las pérdidas ficticias por errores de muestreo o analíticos. La consecuencia es que, casi siempre, el total de la materia enviada a las cubas es menor que la recibida en fábrica. Estas diferencias se analizan mediante el **balance líquido**, que con mayor o menor detalle va contabilizando las diferencias entre entradas y salidas de los diferentes procesos realizados sobre la materia líquida **hasta** su llegada a la cuba de fabricación.

Las cantidades analizadas en la cuba de fabricación constituyen el cierre (salida) del balance líquido y el inicio del **balance de producción**, que recoge la transformación quesera en sentido estricto, desde la leche en la cuba lista para fabricación, hasta el queso obtenido, antes o después de salado (opcional)

Como resultado de la manipulación de la cuajada en la cuba y los procesos de corte y agitación, se producen pequeñas pérdidas de finos de quesería, que consisten en grasa y proteína coagulada que no se ha podido retener en la cuajada enviada a moldear. En el proceso de moldeo se produce también una pérdida de materia que puede ser significativa, según el proceso y según el control que el equipo de quesería tenga sobre el proceso. Finalmente, en los intercambios osmóticos en el proceso de salado, se produce una pérdida de suero y una ganancia de extracto seco magro en forma de aporte de sal.

En el proceso de obtención del queso se produce una eliminación del suero de quesería, que recogerá la mayor cantidad de la lactosa de la leche, proteínas solubles, y algo de grasa y proteína. En la mayor parte de las ocasiones, el suero es desnatado para recuperar esta materia grasa, en forma de **nata de suero**. Si está producida y conservada en las condiciones adecuadas, la nata de suero puede adicionarse a la leche de fabricación de la siguiente fabricación de queso en la estandarización. Este reciclado de la materia grasa ayuda a reducir las pérdidas de grasa, y es realizable siempre que el producto lo admita y no haya problemas de calidad.

En resumen, todos los procesos que llevan a la elaboración de queso, constan a su vez de otros subprocesos, en los cuales se van a producir pérdidas de materia grasa y proteína en mayor o menor cantidad. Dado que en el pago por calidad de la leche, la grasa y la proteína son las materias que se valoran y son el objeto del pago, parece lógico que la optimización de la eficiencia

de la elaboración de queso se enfoque en la reducción de las perdidas de materia en todas las partes del proceso.

14.3. Las pérdidas de materia en quesería

Los procesos de preparación de leche y fabricación que tienen lugar en una fábrica de queso, pueden esquematizarse así:

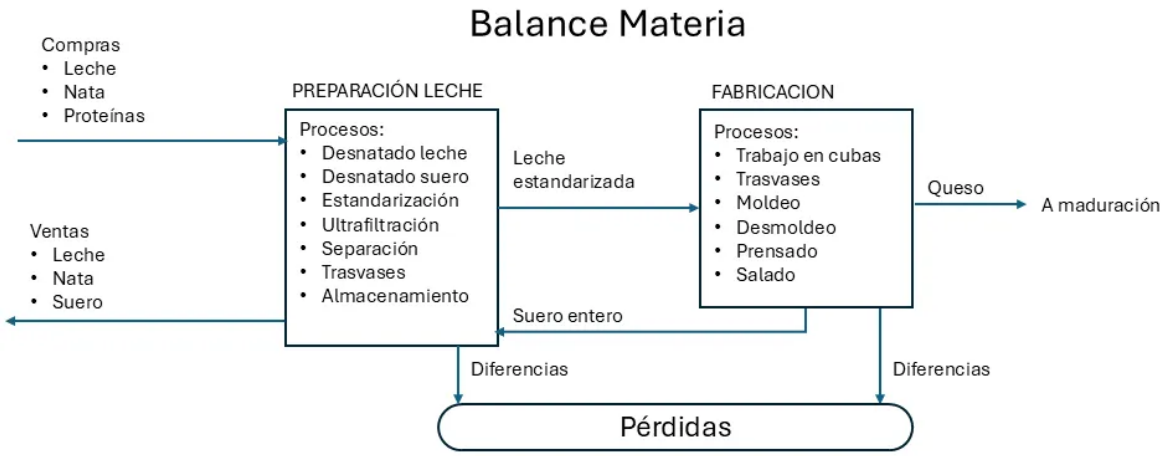


Figura 14.2.: Balance de materia

Hemos organizado la información de los procesos de fábrica en dos grandes grupos, la **preparación de leche** y la **fabricación**. En la terminología del balance de materia, llamaremos a estos grupos **balance de preparación** (o **balance líquido**) y **balance de fabricación**.

Los diferentes procesos de manipulación de la materia prima en quesería tienen como consecuencia que en cada etapa se vayan produciendo pérdidas de materia, lo que hace que la cantidad de materia real que tenemos para su transformación en queso es siempre menor que la que hemos pagado.

La fórmula general de cualquier balance, heredada de los balances contables, es siempre:

$$Existencia\ inicial + Entradas = Salidas + Existencia\ final \pm Prdidas$$

El término **Pérdidas** recoge las diferencias entre entradas y salidas, para que pueda producirse la identidad de los dos términos a cada lado del signo igual (=)

Aunque en este esquema indicamos de forma genérica las compras de leche, nata y otras materias primas, así como su envío a fabricación para obtener el queso, no debemos perder de vista que, en realidad, lo que pagamos al comprar la leche, y lo que transformamos en fábrica, es la **grasa** y la **proteína** de la leche. Por esta razón, resulta más conveniente representar en nuestros balances los movimientos de MG y MP:

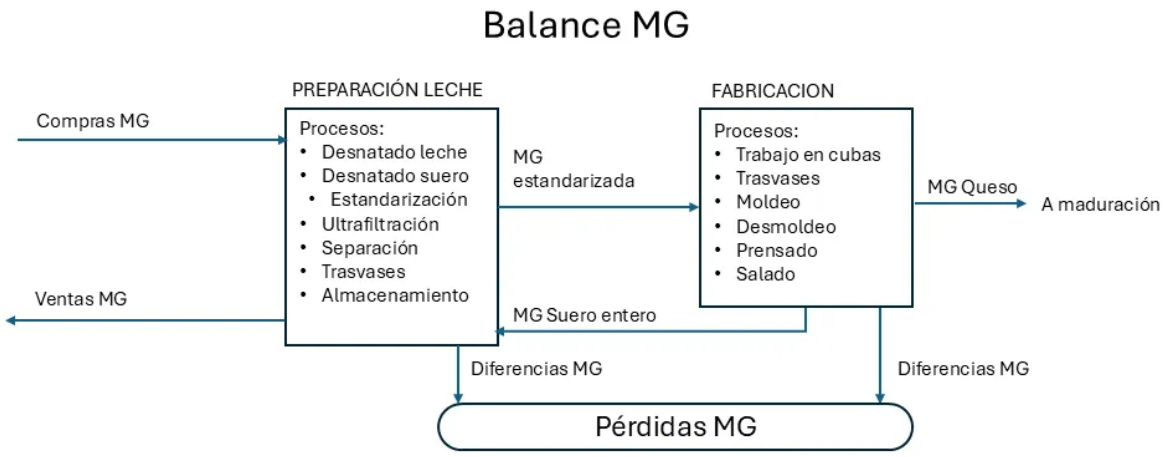


Figura 14.3.: Balance de MG

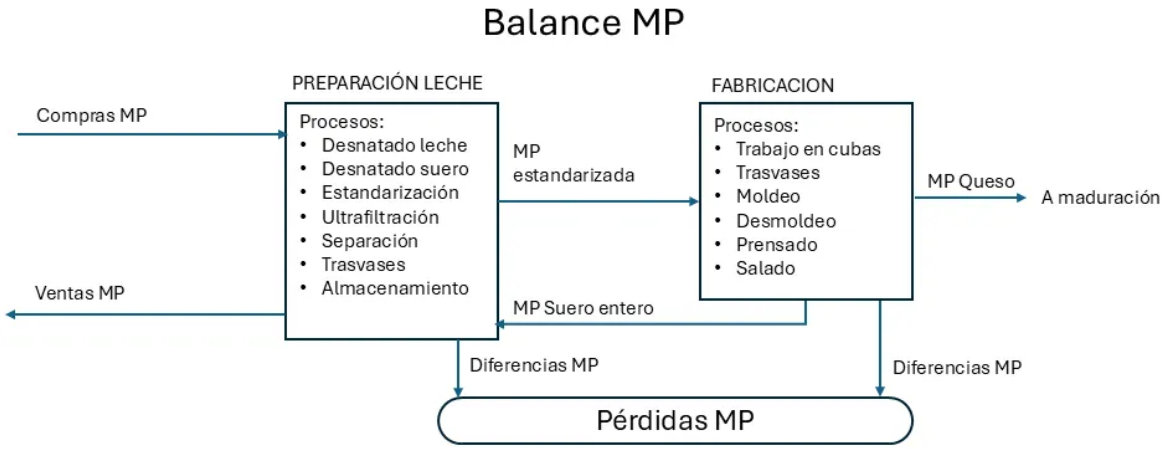


Figura 14.4.: Balance de MP

14.4. Análisis de un caso

Comenzaremos con un caso simple, en el que se utiliza un solo tipo de leche, que no se estandariza en MG ni en MP, y se envía a fabricación después de pasteurización. En nuestro ejemplo, los datos que vamos a utilizar están registrados en ficheros de datos en formato `CSV`, que incluyen las entradas de leche en fábrica y el envío a fabricación, con sus las analíticas correspondientes. Analizaremos el conjunto de datos con hoja de cálculo y con Python, siguiendo nuestra línea de trabajo.

14.4.1. Descripción del caso

En nuestra quesería de ejmplo se recibe leche de vaca de domingo a jueves, y se fabrica de lunes a viernes. De lunes a jueves se fabrican unos 5000 L de manera bastante regular, y los viernes se fabrica el resto de leche para que el stock quede a cero el fin de semana.

Los movimientos diarios de compra de leche y de envío a fabricación se recogen en un fichero csv organizado según los principios de *tidy data*.

La leche se recibe en una cisterna, se pesa en báscula, con lo que se dispone de los kilos de leche que se dan de entrada; se convierten a litros utilizando una densidad estándar de 1,030 g/ml. En el momento de la recepción de la leche, se hacen análisis de materia grasa y proteína, y los resultados analíticos se recogen en g/L.

La leche enviada a fabricación es analizada diariamente en grasa y proteína mediante una muestra recogida en la cuba; los resultados se expresan en g/L.

No se hace control diario de existencias; la leche se recibe sobre un tanque de recepción en el que puede quedar algún resto de leche de un día para otro, no tiene por qué enviarse a fabricación cada día el 100 % de la entrada. Pero la fabricación del viernes debe recoger el 100 % de la leche existente, de forma que las existencias queden a cero y el lunes se empiece sin stock.

Entre las entradas y el envío a fabricación hay pérdidas de materia y, simultáneamente, un incremento de volumen por arrastres de agua.

Debido a que las entradas para la fabricación semanal tienen lugar el domingo, se considera una semana de domingo a sábado (la semana ISO es lunes a domingo).

El fichero de datos que utilizaremos acumula las recepciones y fabricación de un año completo.

Descargar los datos de ejemplo utilizados en este cuaderno (archivo `02-fab_queso_sim.csv`)

Descargar la hoja de cálculo Excel con el balance de materia grasa de ejemplo (archivo `03-fab_queso_sim.xlsx`)

14.5. Balance de materia con la hoja de cálculo

El fichero CSV incluye el peso de báscula de la cisterna de entrada, la conversión en litros, el envío a fabricación, también en litros, y el queso fabricado, junto con las diversas analíticas. Por comodidad y para evitar errores de medida y de muestreo (desigual reparto de la MG), la fábrica utiliza la densidad estándar de 1,030 g/ml de leche para convertir los kilos de leche en litros, como hemos dicho. Tenemos una columna con el stock de leche diario, que no controlamos analíticamente, y que queda a cero semanalmente.

La existencia de un stock de leche diario sin analizar nos impide hacer un balance de materia diario, ya que tendríamos que tener en cuenta las diferencias de stock, y no tenemos los análisis correspondientes. Por otra parte, en una fase inicial, descubriremos que las variaciones analíticas y de medida pueden despistarnos introduciendo valores que no podemos explicar y que en realidad se deben a errores analíticos o de muestreo.

Por ello es más conveniente hacer el balance de materia semanalmente, asegurandonos de que los stocks de leche han quedado a cero. Al acumular los resultados, minimizamos los errores de medida.

Haremos entonces el balance de la primera semana de forma manual, para formalizar los conceptos, y luego intentaremos una mínima automatización mediante el uso de las tablas dinámicas de Excel; gracias al campo de fecha, podemos obtener mediante funciones `python` o fórmulas Excel tanto la semana del año como el día de la semana. Haremos uso de esta funcionalidad para agrupar el balance por semanas.

En Excel vamos a desarrollar sólo el balance de la materia grasa, el balance de la proteína queda como ejercicio complementario.

14.5.1. El balance de la materia grasa paso a paso

Una vez leído el fichero CSV en Excel, lo primero que haremos será convertir el formato en una tabla, lo que nos permitirá definir las fórmulas en la primera fila con facilidad.

	A	B	C	D	E	F	G	H	I	J	K	L
1	fecha	entrada_kg	entrada_litrc	entrada_gras	entrada_prot	cuba_fab_liti	cuba_fab_gr	cuba_fab_pr	stock_cierre_	queso_kg	queso_est_p	queso_mg_pct
2	31/12/2023	4895	4752	45,13	36,68				4752			
3	01/01/2024	5516	5355	40,98	34,63	5025	41,07	33,95	5107	637,56	49,95	25,46
4	02/01/2024	4938	4794	40,88	35,16	5029	39,99	33,61	4901	630,34	51,68	26,12
5	03/01/2024	5704	5538	43,38	35,32	5032	40,55	33,85	5439	628,81	51,29	26,16
6	04/01/2024	5170	5019	41,47	35,93	5035	39,9	33,78	5458	656,69	49,81	25,28
7	05/01/2024					5472	40,42	33,92		705,3	52,73	26,31
8	06/01/2024											

Figura 14.5.: Fichero de datos en formato CSV leído en Excel

Para ello, con el cursor dentro del área de datos, utilizamos la opción **`Menú > Insertar > Tabla`**. Aceptamos la opción por defecto y convertimos el formato del rango completo.

A1 | fx | fecha

	A	B	C	D	E	F	G	H	I	J	K	L
1	fecha	entrada_kg	entrada_litros	entrada_grasa_g_l	entrada_prot_g_l	cuba_fab_litros	cuba_fab_grasa_g_l	cuba_fab_prot_g_l	stock_cierre_litros	queso_kg	queso_est_pct	queso_mg_pct
2	31/12/2023	4895	4752	45,13	36,68				4752			
3	01/01/2024	5516	5355	40,98	34,63	5025	41,07	33,95	5107	637,56	49,95	25,46
4	02/01/2024	4938	4794	40,88	35,16	5029	39,99	33,61	4901	630,34	51,68	26,12
5	03/01/2024	5704	5538	43,38	35,32	5032	40,55	33,85	5439	628,81	51,29	26,16
6	04/01/2024	5170	5019	41,47	35,93	5035	39,9	33,78	5458	656,69	49,81	25,28
7	05/01/2024					5472	40,42	33,92		705,3	52,73	26,31

Figura 14.6.: Hoja de datos en formato tabla

La tabla de datos nos muestra las entradas de datos en domingo, sin fabricación en cuba, y las fabricaciones en viernes, a partir del stock del jueves, sin que haya entradas en el día. Como hemos dicho, simplificaremos el balance haciendo un análisis semanal, para lo cual totalizamos los kilos de materia grasa y de proteína en cada etapa, mediante los análisis de los que disponemos. Añadimos estos totales como columnas nuevas a la derecha de la tabla, columna a columna. El formato **`tabla`** tiene muchas ventajas para el análisis de datos, una de ellas es la definición de las fórmulas de cálculo que afectan a la tabla en la primera fila; una vez definidas las fórmulas, la tabla replica el cálculo en el resto de la tabla, de manera semejante a cómo se calculan las columnas en un dataframe de Python.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	fecha	entrada_kg	entrada_litros	entrada_grasa_g_l	entrada_prot_g_l	cuba_fab_litros	cuba_fab_grasa_g_l	cuba_fab_prot_g_l	stock_cierre_litros	queso_kg	queso_est_pct	queso_mg_pct	entrada_grasa_kg	entrada_prot_kg
2	31/12/2023	4895	4752	45,13	36,68				4752				=[@[entrada_litros]]*[@[entrada_grasa_g_l]]/1000	
3	01/01/2024	5516	5355	40,98	34,63	5025	41,07	33,95	5107	637,56	49,95	25,46	219,4479	185,44365
4	02/01/2024	4938	4794	40,88	35,16	5029	39,99	33,61	4901	630,34	51,68	26,12	195,97872	168,55704
5	03/01/2024	5704	5538	43,38	35,32	5032	40,55	33,85	5439	628,81	51,29	26,16	240,23844	195,60216
6	04/01/2024	5170	5019	41,47	35,93	5035	39,9	33,78	5458	656,69	49,81	25,28	208,13793	180,33267

Figura 14.7.: Añadiendo las columnas de materia grasa y proteína

M	N	O	P
entrada_grasa_kg	entrada_prot_kg	cuba_fab_grasa_kg	cuba_fab_prot_kg
214,45776	174,30336	0	0
219,4479	185,44365	206,37675	170,59875
195,97872	168,55704	201,10971	169,02469
240,23844	195,60216	204,0476	170,3332
208,13793	180,33267	200,8965	170,0823
0	0	221,17824	185,61024

Figura 14.8.: Añadiendo nuevas columnas a la tabla

Hemos añadido cuatro nuevas columnas:

- **`entrada_grasa_kg`**, calculada como

$$entrada_grasa_kg = (entrada_litros) * (entrada_grasa_g_l)/1000$$

- **`entrada_prot_kg`**, calculada como

$$entrada_prot_kg = (entrada_litros) * (entrada_prot_g_l)/1000$$

- **`cuba_fab_grasa_kg`**, calculada como

$$cuba_fab_grasa_kg = (cuba_fab_litros) * (cuba_fab_grasa_g_l)/1000$$

- **`cuba_fab_prot_kg`**, calculada como

$$cuba_fab_prot_kg = (cuba_fab_litros) * (cuba_fab_prot_g_l)/1000$$

No tenemos más que totalizar las cantidades de materia en la leche de entrada y en cuba para estimar el balance de pérdidas. Como el formato de la tabla no nos permite hacer los totales con facilidad sin insertar líneas, y sabemos que no debemos modificar nuestra tabla de datos, copiamos y pegamos en una nueva pestaña para construir la tabla de balance.

Entradas de leche	Litros	MG (kg)	MP (kg)
31/12/2023	4.752	214,5	174,3
01/01/2024	5.355	219,4	185,4
02/01/2024	4.794	196,0	168,6
03/01/2024	5.538	240,2	195,6
04/01/2024	5.019	208,1	180,3
05/01/2024		0,0	0,0
Total	**25.458**	**1.078,3**	**904,2**
Envío a fabricación	**Litros**	**MG (kg)**	**MP (kg)**
31/12/2023		0,0	0,0
01/01/2024	5.025	206,4	170,6
02/01/2024	5.029	201,1	169,0
03/01/2024	5.032	204,0	170,3
04/01/2024	5.035	200,9	170,1
05/01/2024	5.472	221,2	185,6
Total	**25.593**	**1.033,6**	**865,6**
Balance	135	-45	-39
Desviación (%)	0,5%	-4,1%	-4,3%

Figura 14.9.: Balance de materia semanal sencillo

El balance de materia entre las entradas de leche y la leche en cubas nos dice que en esta semana hemos perdido en esta parte del proceso 45 kg de grasa (-4,1 %) y 39 kg de proteína (-4,3 %) en la semana, y que hemos ganado 135 litros de leche (+0,5 %), seguramente por los arrastres de agua añadida.

14.5.2. Automatizando el análisis en Excel

En el análisis que hacabamos de hacer, hemos hecho los cálculos y diseñado la tabla de forma manual para la primera semana del año. Esto quiere decir que, si utilizamos este método para las semanas sucesivas, deberemos repetir 52 veces el mismo copia y pega, formato, etc, lo que resulta bastante engorroso y sujeto a errores. Sería más adecuado que nuestro sistema de análisis pudiese leer la tabla de datos y actualizar la información a medida que vamos añadiendo días de fabricación, sin tener que intervenir manualmente.

Afortunadamente, las **tablas dinámicas** de Excel nos permiten un cierto grado de automatización; aunque no es todo lo flexible que sería de desear, si poedmos hacer el recálculo sin necesidad de modificar la tabla, una vez que se ha diseñado.

Para construir la tabla dinámica, con el cursor dentro del rango de nuestra tabla de datos, simplemente insertamos la tabla desde el `Menú > Insertar > Tabla dinámica`.

Una vez creada la tabla en una nueva pestaña de Excel, vamos a colocar el nombre del campo `fecha` en filas, lo que creará los nuevos campos de fecha `Años(fecha)`. `Trimestres (fecha)`, `Meses(fecha)` y `fecha`, éste último será el que guarde los valores originales de la columna. Retiramos de las filas los `Trimestres` y la `fecha` para quedarnos sólo con el `Año` y los `Meses`. Podríamos hacer una agrupacion semanal incluyendo una columna en nuestra tabla que nos

indique la semana; eso se puede hacer mediante la fórmula de Excel `=NUM.DE.SEMANA()` aplicada a la fecha.

Ahora arrastramos al área de `Valores` los campos de kg totales que hemos calculado: `entrada_grasa_kg`, `cuba_fab_grasa_kg` y `queso_mg_kg`. Vamos a construir el balance de materia grasa entre estas tres etapas.

Una vez insertados los tres campos, formateamos los valores para que sólo muestren un decimal, en la opción de **`Configuración de campo de valor`**, que aparece al hacer click con el botón derecho dentro de la tabla, con el cursor sobre el campo que queremos formatear.

A continuación, necesitamos crear cuatro campos calculados, dos para las diferencias de materia en kilos y otros dos para las diferencias en porcentaje. Las fórmulas a utilizar en los campos calculados son:

$$Dif\ de\ balance\ cubas = cuba_fab_grasa_kg - entrada_grasa_kg$$

$$Dif\ de\ balance\ fab = queso_mg_kg - cuba_fab_grasa_kg$$

$$Desviacin\ MG\ cubas\ (\%) = \frac{(cuba_fab_grasa_kg - entrada_grasa_kg)}{entrada_grasa_kg}$$

$$Desviacin\ MG\ queso\ (\%) = \frac{(queso_mg_kg - cuba_fab_grasa_kg)}{cuba_fab_grasa_kg}$$

A estos campos añadimos dos más con los totales:

$$Dif\ de\ balance\ total = queso_mg_kg - entrada_grasa_kg$$

$$Desviacin\ total\ (\%) = \frac{(queso_mg_kg - entrada_grasa_kg)}{entrada_grasa_kg}$$

Una vez creados los campos, damos formato a los valores numéricos y formateamos el encabezado para obtener la tabla:

Mes	Entrada en fábrica (kg MG)	Leche en cubas (kg MG)	Queso (Kg MG)	Dif de balance cubas (kg MG)	Dif de balance queso (kg MG)	Dif de balance total (kg MG)	Desviación cubas (%)	Desviación queso (%)	Desviación total (%)
2023	**214,5**	**0,0**	**0,0**	**-214,5**	**0,0**	**-214,5**	**-100,0%**		**-100,0%**
dic	214,5	0,0	0,0	-214,5	0,0	-214,5	-100,0%		-100,0%
2024	**54.774,7**	**52.772,1**	**44.205,8**	**-2.002,6**	**-8.566,4**	**-10.569,0**	**-3,7%**	**-16,2%**	**-19,3%**
ene	4.783,5	4.614,7	3.909,8	-168,8	-704,9	-873,7	-3,5%	-15,3%	-18,3%
feb	4.544,6	4.315,9	3.592,6	-228,7	-723,2	-951,9	-5,0%	-16,8%	-20,9%
mar	4.545,7	4.366,5	3.680,8	-179,2	-685,8	-864,9	-3,9%	-15,7%	-19,0%
abr	4.569,8	4.399,2	3.649,1	-170,6	-750,0	-920,6	-3,7%	-17,0%	-20,1%
may	4.735,6	4.758,2	3.929,7	22,6	-828,5	-805,9	0,5%	-17,4%	-17,0%
jun	4.411,1	4.039,8	3.347,0	-371,4	-692,7	-1.064,1	-8,4%	-17,1%	-24,1%
jul	4.719,3	4.591,0	3.840,1	-128,3	-750,9	-879,2	-2,7%	-16,4%	-18,6%
ago	4.507,5	4.459,4	3.724,9	-48,1	-734,4	-782,6	-1,1%	-16,5%	-17,4%
sep	4.668,5	4.286,1	3.616,5	-382,4	-669,6	-1.052,0	-8,2%	-15,6%	-22,5%
oct	4.848,4	4.691,3	3.936,7	-157,0	-754,6	-911,7	-3,2%	-16,1%	-18,8%
nov	4.202,2	4.187,4	3.540,1	-14,7	-647,4	-662,1	-0,4%	-15,5%	-15,8%
dic	4.238,6	4.062,7	3.438,5	-175,9	-624,2	-800,1	-4,2%	-15,4%	-18,9%
Total general	**54.989,2**	**52.772,1**	**44.205,8**	**-2.217,1**	**-8.566,4**	**-10.783,4**	**-4,0%**	**-16,2%**	**-19,6%**

Figura 14.10.: Tabla dinámica con el balance de materia grasa

14.5.3. Análisis de la tabla de balance de materia grasa

El balance de materia grasa nos muestra que en el año hemos perdido 10.783,4 kilos de materia grasa (19.6 % de lo comprado), que se reparten entre el balance líquido (2.217,1 kg) y la elaboración propiamente dicha (8.566,4 kg). Las pérdidas del balance líquido suponen un 4 % de lo comprado, mientras que las perdidas en la elaboración suponen el 15,6 % de lo comprado (y el 16,2 % de la MG en cuba)

Estas pérdidas suponen 59.815 euros, a nuestro precio calculado de 5,547 euros/kg de MG.

Hay que tener en cuenta que en el balance de queso deberíamos tener en cuenta el análisis del suero. Las pérdidas en fabricación se corresponden en su mayoría con las pérdidas en el suero; es necesario diferenciar las pérdidas que son inherentes a nuestro proceso, de las pérdidas extraordinarias por desviaciones en la tecnología o cualquier otro problema. Como no analizamos el suero, no podremos dar respuesta hasta el análisis detallado de los rendimientos, que veremos en el próximo capítulo.

14.5.4. El balance de materia de la proteína

Para hacer el balance de materia de la proteína, no tenemos más que repetir los pasos que hemos dado en el análisis de la materia grasa, sustituyendo los campos correspondientes en la tabla dinámica.

En el caso del ejemplo, tenemos el inconveniente de que no disponemos de análisis de la proteína del queso, porque la empresa no lo hace. Sólo podemos hacer entonces el balance de materia de la fase líquida, desde la recepción hasta la cuba. Veremos la desviación del consumo de proteína en el capítulo siguiente, mediante el análisis de los rendimientos queseros. Si dispusiéramos de análisis de proteína del queso, sólo tendríamos que incorporar el campo(columna) con sus valores a la tabla dinámica para disponer del análisis completo.

14.6. Diseñar un plan de acción para la reducción de pérdidas

Mediante nuestro balance de materia, hemos detectado el nivel de pérdidas que tenemos en nuestro proceso. Este conocimiento no es algo que hagamos porque sí, sino con el objetivo de establecer acciones para reducirlas y mejorar los resultados de la empresa.

14.6.1. El "problema" de los finos de queso en el suero y de las roturas diversas en el proceso

Hay que tener en cuenta que consideramos **pérdidas de balance** sólo aquellas que son diferencias entre entradas y salidas. Por ejemplo, pérdidas de finos (restos de queso en el proceso de moldeo, o en el suero) que han sido bien medidas en el suero pueden no ser una pérdida de balance si están bien contabilizadas como ***finos*** en las salidas de producción, es decir, la cantidad de materia en los finos está bien pesada y analizada, y no hay diferencias entre entradas y salidas. Sin embargo, son pérdidas de rendimiento porque esos finos no se recuperan en el queso, y tendremos que establecer acciones tecnológicas para reducirlos.

Para incorporarlos al balance de materia, tendríamos que incluir en nuestra hoja de datos una columna `finos` en la que fuésemos anotando las cantidades producidas diariamente en la

fabricación y sus análisis, y entonces podríamos incluirlos en la hoja de balance. Este control es un tanto complicado de hacer en rutina en la mayoría de los casos, debido tanto a la imprecisión en la recogida y control analítico de los restos de queso que se generan en la quesería, como a la necesidad de obtener los finos del suero mediante filtración o centrifugado, que no siempre es posible, y su análisis de forma fiable.

Por ello, a pesar de que el concepto de **pérdida de balance** es el que hemos explicado, casi siempre resulta más práctico considerar roturas, restos y finos como pérdidas, puesto que no hemos sido capaces de recuperar esa materia en el queso.

Lo importante es que las acciones que tomemos para reducir estos restos redundarán en una mejora del resultado del balance, al mejorar la retención de materia en el queso.

14.6.2. Causas de pérdidas en el balance líquido

Entre las diversas causas de pérdidas en el **balance líquido**, podemos considerar:

- Mala calibración de la báscula de entrada o de los contadores de medida en la descarga
- Pérdidas en válvulas que cierran mal y no tienen un buen programa de mantenimiento preventivo de cierres y juntas
- Operaciones mal descritas y que dejan demasiado espacio a las decisiones individuales que pueden ser improvisadas
- Falta de auditorías de procesos que permitan evaluar la calidad de las operaciones y detectar los puntos críticos de mala operación
- Procedimientos de arrastres (fin de línea, depósitos) mal temporizados, lo que hace que sean demasiado cortos (pérdidas de materia) o demasiado largos (dilución excesiva)
- Mal estado de los útiles de corte en la cuba, lo que aumenta las pérdidas de finos en la cuba
- Información insuficiente (pocas muestras) para evaluar bien el balance y conocer los puntos de pérdida
- Desconocimiento del error de medida (muestreo, variabilidad de analistas, repetibilidad de los análisis), lo que lleva a correcciones que pueden no corresponder a valores de pérdida real sino a errores analíticos.
- Errores en el control de los stocks a final de día o de la semana
- Insuficiente formación en la toma de muestras, que se realiza de manera incorrecta
- Uso de bombas centrífugas para el transporte de cuajada, lo que hace que aumente la cantidade de finos que se pierden en el suero (estrictamente, puede no ser una pérdida de balance sino de rendimiento quesero)

El trabajo del tecnólogo quesero consistirá en identificar las causas específicas de las pérdidas en su caso concreto, y proponer y aplicar planes de acción para reducirlas. Los objetivos a lograr con estos planes de acción se ejecutan inmediatamente cuado es posible, o se incorporan al presupuesto del año siguiente, de tal manera que las mejoras previstas se puedan aplicar al coste presupuestado del producto, y así mejorar la competitividad del precio.

Los planes de acción de reducción de pérdidas deben actualizarse permanentemente, de forma que el proceso de mejora sea un trabajo que esté siempre en marcha.

Descargar los datos de balance de materia semanal para análisis en hoja de cálculo (archivo `04-balance_materia_semanal.csv`)

14.7. Otros casos más complejos: mezclas de leche, estandarizaciones diferentes, ventas de materia y otras situaciones

El caso que hemos visto es relativamente sencillo, para entender lo que es un balance de materia. Pero en realidad, pocas fábricas son tan sencillas. En la mayoría, a la leche de fabricación se le añade nata de suero, o se preparan leches estandarizadas en materia grasa y proteína, o bien se preparan leches de fabricación utilizando varios tipos de leche (vaca, cabra, oveja) en proporciones fijas o variables.

Lo que complica el análisis del balance es el diseño del sistema de información: en la medida en que tenemos más materias primas (nata de leche, nata de suero, retentado fresco, diferentes tipos de leche, diferentes preparaciones de leche para fabricación, etc), nos vemos obligados a llevar un control analítico sobre estas materias, además de un control de stocks. El sistema de información debe diseñarse para poder llevar este control que puede llegar a ser enormemente complejo y costoso, ya que los controles analiticos se multiplican. Pero, en todo caso, la filosofía del procedimiento es que si no queremos tener pérdidas desconocidas que no sepamos cómo atacar, nos vemos obligados a mantener un control analítico detallado de nuestras materias primas y nuestros stocks.

El uso de herramientas informáticas se hace imprescindible a medida que el diseño se hace más complejo. En estos casos, no es aconsejable diseñar un sistema sobre hojas de cálculo, sino de herramientas como `python` o `R` que permiten separar la lógica del análisis del modelo de datos, que se soporta en el sistema de información de la empresa. En estos casos, el diseño del sistema de análisis ligado al sistema de información debe ser realizado por técnicos especialistas, que diseñen un sistema que responda a las necesidades del técnico quesero para el análisis de su fabricación.

14.8. Resumen del capítulo

El balance de materia es la herramienta fundamental para controlar la eficiencia del proceso de transformación quesera. Comparando la materia grasa y la proteína que entran con la leche con las que salen en el queso producido, podemos cuantificar exactamente cuánta materia se pierde en cada período y en qué magnitud económica se traduce esa pérdida.

En este capítulo hemos visto cómo construir el balance de materia grasa y de proteína paso a paso en Excel. El uso del extracto seco magro como base de cálculo para la recuperación de proteína es una decisión técnica importante que garantiza que los resultados sean comparables entre fabricaciones con diferente humedad de queso.

El análisis del balance nos indica el nivel global de pérdidas, pero no nos explica por qué se producen. La mayor parte de las pérdidas ocurre durante la elaboración — en el suero, en los finos y en las roturas de proceso — y cada origen tiene sus propias causas y sus propias soluciones. Identificar y cuantificar esas causas es el objetivo del análisis de rendimientos queseros, que desarrollamos en el capítulo siguiente.

La reducción de pérdidas en el balance de materia es uno de los proyectos de mejora con mayor retorno económico en cualquier quesería, ya que cada punto porcentual de mejora en la recuperación de grasa o proteína se traduce directamente en producto adicional vendible sin incremento de coste de materia prima.

15. El rendimiento quesero

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Explicar el concepto de rendimiento quesero y distinguirlo del balance de materia.
- Calcular el rendimiento real de una fabricación a partir de los datos analíticos de leche y queso.
- Construir un estándar técnico de fabricación y usarlo como referencia para el análisis de desviaciones.
- Identificar y cuantificar las causas de las desviaciones de rendimiento: efecto del extracto seco, efecto de la recuperación de materia y efecto del precio de la leche.
- Calcular el coste económico de las desviaciones tecnológicas en una fabricación y extrapolar el impacto anual.
- Explicar por qué la estandarización de la leche es una herramienta clave para reducir la variabilidad del rendimiento.

Conceptos clave: **rendimiento quesero, estándar técnico de fabricación, desviación de rendimiento, recuperación de materia, extracto seco, estandarización de la leche, coste de las desviaciones, efecto precio, efecto consumo**.

En el capítulo anterior hemos visto el balance de materia y cómo nos ayuda a conocer las pérdidas en las diferentes etapas del proceso de elaboración. En el balance de materia grasa que hemos hecho como ejemplo, hemos visto que las pérdidas más importantes se producen en la fase de elaboración; esto es debido sobre todo a la pérdida de materia grasa en el suero, pero también a las pérdidas extraordinarias de materia por desviaciones en la tecnología. También hemos encontrado una dificultad para hacer un balance correcto de la materia proteica cuando no se hace un análisis de proteína del queso.

En este capítulo abordaremos el análisis de la eficiencia de la transformación quesera, mediante los indicadores del rendimiento quesero, que calcularemos a partir de los valores analíticos de la leche de fabricación y del queso recién elaborado, utilizando para la proteína el coeficiente de recuperación calculado con el extracto seco magro (ESM) del queso. Extraeremos diversas conclusiones:

- Estableceremos los parámetros de referencia de nuestro propio proceso, que nos servirán de punto de comparación para las fabricaciones que vayamos realizando.
- Evaluaremos las causas posibles de las desviaciones, y veremos cómo proponer planes de acción para la reducción o eliminación de estas desviaciones.

Descargar los datos de ejemplo utilizados en este cuaderno (archivo `02-fab_queso_sim.csv`)

15.1. Un ejemplo de cálculo de rendimientos

Imaginemos una empresa que ha fabricado durante un año unos **5.000 L diarios**, sólo en días laborables. Esto supone la cantidad aproximada de **1.300.000 litros de leche de vaca**, algo más de 100.000 L al mes. Esta empresa ha elaborado un solo tipo de queso, y sus ventas han sido de unas **130 toneladas de queso**. El responsable de la empresa nos dice que el rendimiento quesero de esta fábrica que él está estimando es de **10 litros por kilo de queso**; para calcularlo, ha dividido los litros de leche comprados entre los kilos de queso vendido.

> ⚠ ATENCION: Sobre la medida del rendimiento quesero
>
> La relación *litros de leche por kilo de queso*, que usamos en este ejemplo, puede resultar útil como aproximación rápida, pero **no es una medida fiable del rendimiento** cuando la composición del queso varía, y puede llevar a conclusiones erróneas. Esta medida **sólo es válida si el queso tiene la composición correcta en extracto seco y materia grasa**. Si estos parámetros cambian, el valor de litros/kilo deja de reflejar el rendimiento real.
> En este capítulo veremos que, para evaluar el rendimiento de forma rigurosa, debemos utilizar **el consumo de materia grasa y de proteína por kilo de queso producido**, una medida que refleja con precisión el aprovechamiento real de los componentes lácteos.

A la vista de estos datos, esta empresa,

- ¿ha fabricado bien o ha fabricado mal?
- ¿Cómo puede organizar su información y analizarla para saber qué mejoras puede poner en marcha y mejorar sus resultados?
- ¿Cómo puede compararse con otras empresas competidoras y saber si está trabajando mejor o peor que la competencia?

De una forma práctica, a los efectos de la gestión contable, la información proporcionada es real y correcta, y delimita bien los límites del proceso industrial, desde la compra de leche hasta la venta del queso. Sin embargo, no nos ayuda a entender la calidad del trabajo ni dónde deberíamos actuar para plantear mejoras.

Pérdidas en recepción y tratamiento de leche: pérdidas de materia

Con los datos que nos han facilitado no tenemos suficiente información para profundizar más, por lo que estudiamos sus documentos de fabricación. Revisamos sus registros de quesería (en nuestro ejemplo, los datos en el CSV) y comprobamos que, con unas entradas de leche contabilizadas de 1.301.407 litros, la cantidad de leche realmente controlada como fabricada, mediante el contador en la cuba, ha sido algo superior; el quesero ha contabilizado en cuba 1.308.012 litros, sumando todas las cubas fabricadas. Es decir, entre la leche que la empresa ha comprado y la que ha enviado a quesería para fabricación, ha ganado una cantidad mínima de volumen (0,5 %).

Analizando estos datos con el quesero y las personas de fábrica, descubrimos que en los depósitos de leche y línea de pasteurización, hay válvulas que no cierran bien y en ocasiones la leche se derrama por el suelo, y también que ha habido algún accidente debido a mangueras que no se habían conectado bien y han producido también algunos derrames, aparte de otras incidencias diversas. Esto nos lleva a pensar que el pequeño incremento de volumen puede deberse a arrastres de agua, pero que puede haber pérdidas reales de leche. ¿Cómo saberlo? La respuesta es: verificando la composición en nuestros registros documentales (datos en el CSV).

La leche comprada tenía un contenido de 54.989 kg de materia grasa y 46.482 kg de proteína. La leche enviada a fabricación tenía 52.772 kg de materia grasa y 44.617 kg de proteína. Las cantidades de materia en cuba son netamente inferiores a lo comprado, aunque los litros utilizados son prácticamente los mismos. Suponemos que los litros se han mantenido por los arrastres de agua, pero si la materia en cuba es inferior a lo comprado, parece claro que hemos perdido leche en los procesos de descarga y trasvases, como nos dice el conjunto de problemas que hemos constatado.

Como en el pago de la leche utilizamos la composición en grasa y proteína para el pago por calidad, está claro que hemos pagado más materia de la que ha entrado realmente en la cuba de fabricación. Si utilizamos para el cálculo de rendimiento los litros, que prácticamente se han mantenido, no tendremos en cuenta esta pérdida de materia, que es real, y que ya hemos constatado en nuestro balance de materia.

Pérdidas en maduración: mermas por pérdida de humedad

El responsable nos da algo más de información del proceso: después de la elaboración, el queso tiene un período de maduración en cámara de 15 días, en donde el queso se seca y afina, y en consecuencia, pierde peso (pierde humedad, aunque no materia láctea). El quesero considera que esa pérdida de peso no debería contabilizarse en sus rendimientos queseros, porque el afinado del queso no está en su responsabilidad y es un proceso posterior a la fabricación. Como parece un comentario razonable, volvemos a verificar la información de nuestro fichero de datos.

En realidad, en las cámaras se han introducido unos 163.795 kilos de queso, según las hojas de control (registradas en el CSV), que se han puesto a madurar en cámaras y se ha envasado a los 15 días. Se han vendido 130.009 kg. En el tiempo de maduración en cámara, el queso ha perdido (163.795 - 130.009) = 33.786 kilos, debido a la pérdida de humedad. Esto corresponde a una merma de maduración de un 21 %, aproximadamente.

Integrando los datos y precisando las conclusiones

Con esta nueva información, concluimos que el verdadero rendimiento de la quesería, medido en litros/kilo ha sido de

$$\frac{\text{1.308.012 litros de leche en cuba}}{\text{163.795 kilos de queso al final del salado}} = 7.99 \text{ L/kg}$$

Este resultado es bastante mejor que la estimación inicial de 10 litros/kg, pero es incompleto porque no diferencia las pérdidas de materia que se han producido en los procesos antes de la cuba. Hay otras pérdidas de peso por merma de humedad en maduración que no tienen que ver con el rendimiento quesero. Además, sabemos que este rendimiento está reflejando el hecho de que la composición de la leche que hemos fabricado no es la de la leche comprada, porque hemos perdido materia e incorporado agua. Podemos utilizar los litros comprados para el cálculo del rendimiento, pero debido a que, a pesar de las pérdidasd de materia, el volumen se ha mantenido por los arrastres de agua, el resultado es prácticamente idéntico.

Gracias al balance de materia hemos conseguido saber que esta quesería ha perdido un 4 % de la materia grasa y de la proteína de la leche comprada en los procesos de descarga y movimientos de leche y trasvases entre depositos hasta la cuba. Ha tenido también unas mermas de maduración

en cámara de un 21 % en un periodo de 15 días. El detalle de estos valores permite establecer tres áreas de trabajo para la mejora bien diferenciadas:

- Las pérdidas en los trasvases de leche (actualmente, un 4 % de la materia comprada)
- El rendimiento quesero y las pérdidas en la cuba (actualmente, 7,99 litros/kilo)
- Las mermas de humedad en maduración (actualmente, un 21 % de pérdida de peso en 15 días)

Sin embargo, la información del rendimiento que nos proprciona el índice de litros/kilo no es suficientemente preciso, por dos razones principales:

1. Dado que el valor que hemos asignado a la materia grasa y a la proteína es diferente, si el extracto seco de nuestro queso es correcto pero por alguna razón su composición es más alta en proteína de la esperada, el coste por kg del extracto seco será mayor de lo previsto, aunque los litros utilizados para fabricar hayan sido los correctos.
2. Igualmente, si los litros/kilo son los previstos, pero el queso tiene más humedad de lo buscado, esto quiere decir que en el peso del queso hemos sustituido extracto seco por agua y hemos perdido materia que ha ido a pérdidas. En este caso, aunque el rendimiento en litros/kilo es correcto, nuestras pérdidas totales han sido mayores.

Puesto que el rendimiento en litros/kilo puede verse influído por el extracto seco, debemos calcular el rendimiento mediante parámetros que no se vean afectados por la humedad del queso, sino que reflejen con precisión la calidad del trabajo quesero. La mejor forma de hacerlo es calcular el porcentaje de materia quesera que hemos sido capaces de retener en el queso. Dado que los elementos de valor de la leche, que se utilizan en el pago por calidad, son la materia grasa y la proteína, calcularemos la recuperación de materia grasa, de materia proteica y de extracto seco magro.

Estos valores son propios de cada tecnología quesera, y cada uno sirve de referencia para comprender cuáles son los diferentes problemas en fabricación, por ejemplo,

- Una mala retención de materia grasa
- Una mala retención de proteína
- Una mala retención de extracto seco magro

15.2. El estándar técnico de fabricación

Para determinar si nuestro rendimiento ha sido correcto o no, hemos hablado en el punto anterior de comparar nuestro resultado con **el resultado previsto**, que es el que esperamos obtener si todo va bien en la fabricación. Por lo tanto, necesitamos construir una referencia que nos permita comparar los valores reales con los que deberíamos haber tenido. A estos valores de referencia los conocemos como **estándar técnico de fabricación**, y deben reflejar exclusivamente **lo que somos capaces de conseguir** con nuestra tecnología, es decir, cuántos litros necesitamos para fabricar un kilo de queso, y cuántos gramos de materia grasa y de proteína necesitamos poner en juego en nuestra cuba de fabricación para obtener un queso con la composición deseada.

Es importante insistir en que **un estándar técnico de fabricación debe reflejar lo que realmente somos capaces de hacer, y no lo que nos gustaría conseguir, o lo que los libros o manuales dicen que deberíamos conseguir**. No es buena práctica establecer objetivos inalcanzables o que no sabemos cómo conseguir. En cambio, el análisis de las desviaciones

respecto a lo que somos capaces de hacer (y ya hemos hecho), nos ayudará a entender dónde están las causas de estas desviaciones, de manera que podamos plantear los planes de mejora y reducción de la dispersión.

15.3. Construcción de un estándar técnico de fabricación

15.3.1. Cálculo de la cantidad de leche necesaria para fabricar 1 kg de queso

Sabemos que nuestro proceso de fabricación quesera consiste en la coagulación de la caseína y expulsión de suero, y que la materia grasa queda retenida en la red de caseína.

Este concepto es la base fundamental de la comprensión de la tecnología quesera: el rendimiento en la recuperación de la proteína es el que nos va a definir todo el proceso; la materia grasa "acompañará" de forma estática (aunque tendrá influencia en el desuerado)

Por esta razón, **el principal elemento del rendimiento es el porcentaje de recuperación de proteína en el extracto seco magro**. Vamos a utilizar los datos reales de nuestras fabricaciones a lo largo de un año, recogidas en el archivo CSV `fab_queso_sim.CSV` que hemos estado utilizando en el análisis del balance de materia.

Para calcular nuestro **estándar técnico de fabricación** inicial, vamos a utilizar los datos de la fabricación real de un año, recogidos en nuestro CSV, que es lo que realmente hemos sido capaces de hacer en el año.

En primer lugar, calculamos el **coeficiente de recuperación ESM/MP**, que establece la relación entre la proteína puesta en cuba y el ESM del queso.

Como el ESM real del queso puede ser superior al valor de la MP en cuba, el coeficiente puede ser mayor de 100 %. El valor real de los coeficientes refleja que hay pérdidas de MG y MP, bien en el suero, bien en los finos de moldeo o en cuajada que se ha caído, etc, en resumen, que no ha ido a parar al queso moldeado. Podemos argumentar, correctamente, que la parte de los finos recoge también la eficiencia de la coagulación, pero al final lo que nos interesa es recoger la conversión real en queso de nuestra materia prima, excluyendo todo lo que constituyen las **pérdidas de proceso**. Si nuestro proceso es estable, estos coeficientes deben ser siempre más o menos constantes: en un proceso estable, en el que las condiciones del proceso se han mantenido, las pérdidas deben ser muy semejantes de un día a otro. Por lo tanto, lo que nos interesa es este valor medio del coeficiente en nuestra fabricación.

Podemos hacer el cálculo mediante la tabla dinámica de balance de materia que habíamos dejado como ejercicio en el capitulo anterior, y que calculamos de manera semejante a la de la materia grasa.

Mes	Entrada en fábrica (kg MP)	Leche en cubas (kg MP)	Queso (kg ESM)	Dif balance cubas (kg MP)	Dif balance queso (kg ESM)	Desviación cubas	Desviación queso	Coef recup MP/ESM
2023	**174**	**0**	**0**	**-174**	**0**	**-100,0%**		
dic	174	0	0	-174	0	-100,0%		
2024	**46.307**	**44.617**	**41.043**	**-1.690**	**-3.574**	**-3,6%**	**-8,0%**	**92,0%**
ene	4.044	3.901	3.645	-144	-255	-3,6%	-6,5%	93,5%
feb	3.825	3.635	3.344	-190	-292	-5,0%	-8,0%	92,0%
mar	3.838	3.680	3.372	-159	-308	-4,1%	-8,4%	91,6%
abr	3.867	3.731	3.429	-136	-301	-3,5%	-8,1%	91,9%
may	3.956	3.973	3.615	17	-358	0,4%	-9,0%	91,0%
jun	3.725	3.413	3.127	-312	-286	-8,4%	-8,4%	91,6%
jul	4.056	3.942	3.564	-113	-378	-2,8%	-9,6%	90,4%
ago	3.799	3.758	3.452	-41	-307	-1,1%	-8,2%	91,8%
sep	3.931	3.604	3.346	-327	-258	-8,3%	-7,2%	92,8%
oct	4.083	3.954	3.647	-129	-308	-3,2%	-7,8%	92,2%
nov	3.599	3.589	3.330	-10	-259	-0,3%	-7,2%	92,8%
dic	3.583	3.437	3.173	-146	-264	-4,1%	-7,7%	92,3%
Total general	**46.482**	**44.617**	**41.043**	**-1.865**	**-3.574**	**-4,0%**	**-8,0%**	**92,0%**

Figura 15.1.: Balance de materia de la MP y el ESM

En el capítulo anterior sobre el balance de materia se proporcionó un enlace para descargar la hoja Excel con las tablas dinámicas del balance de materia, que se incluye de nuevo aquí; la tabla con el balance de proteína está en la pestaña `BM TD MP`

Descargar hoja de cálculo Excel con el balance de materia y el coeficiente de recuperacion de proteína (archivo `03-fab_queso_sim.xlsx`)

> **!** ¡Atención!
>
> Es muy recomendable dedicar un rato a analizar la construcción de la tabla y de los campos calculados utilizados.

En la tabla podemos ver que las pérdidas de MP entre recepción y cubas son un -4 %, mientras que las pérdidas de MP frente al ESM recuperado son un -8 % (usamos signos negativos para indicar **pérdidas**). Esto nos permite calcular una recuperación en el queso de la MP en cubas de un 92 %; sumando el -4 % que tenemos en el balance líquido obtenemos un 88 % de recuperación.

Utilizando el coeficiente de recuperación de la MP (ESM/MP), calculamos el resto de los valores necesarios para nuestro estándar técnico.

Como hemos fabricado 1.308.012 L de leche (litros totales en cubas), la cantidad media de proteína en g/L que tenemos en esa leche es de

$$\frac{44.617\ \cancel{kg_{MP\ en\ cubas}}}{1.308.012\ L\ leche} \cdot 1000 \frac{g}{\cancel{kg}} \approx 34,11\ g/L\ leche$$

Teniendo en cuenta el coeficiente de recuperación de la MP (ESM/MP), podemos calcular la cantidad de ESM que obtendremos en el queso por cada litro de leche en cubas:

$$\frac{34{,}11\ \cancel{g\ proteína}}{1\ L\ leche} \cdot \frac{0{,}92\ g\ ESM}{1\ \cancel{g\ proteína}} = 31{,}38\ g\ ESM\ en\ el\ queso\ por\ litro\ de\ leche$$

Esta es la conversión clave de nuestra tecnología, y es conocida como ***coeficiente G*** en honor a su autor, Antoine M Guérault, que lo introdujo formalmente por primera vez por en su libro *La fromagerie devant les techniques nouvelles,* en 1966; desde entonces sigue utilizándose con plena validez. Originalmente, el coeficiente indica el porcentaje de ESM que hemos recuperado en el queso, dividiendo el ESM del queso entre el ESM de la leche puesta en fabricación, aunque es más habitual usar el coeficiente de recuperación de proteína en vez del de ESM, como hemos hecho arriba.

Como comentamos más atrás, para una tecnología concreta, normalmente la cantidad de sal incluida en el salado y las pérdidas de ESM en el proceso de fabricación deberían mantenerse en una horquilla más o menos estrecha, de acuerdo con la variabilidad de nuestro proceso y nuestra precisión analítica. Si el valor del coeficiente se mantiene en estos límites, nos indicará que la transformación se ha realizado dentro de los valores normales de la tecnología; en caso contrario, si hemos tenido valores anormalmente altos o bajos, será indicador de incidencias tecnológicas que intentaremos explicar para poner en marcha acciones correctivas.

Hemos definido nuestro queso con el 52 % de EST y 27 % de MG (porcentajes masa/masa), lo que supone un 25 % de ESM.

Como sabemos la cantidad de ESM que vamos a obtener de 1 L de leche, podemos calcular los litros de leche que necesitamos para obtener 1 kg de queso con esta composición estándar, mediante una conversión simple. A este valor lo llamaremos *litraje unitario.*

$$\text{Litraje unitario} = \frac{25{,}00\,\cancel{g\ ESM}}{100\,\cancel{g\ queso}} \cdot \frac{1000\,\cancel{g\ queso}}{1\,kg\ queso} \cdot \frac{1\,L\ leche}{31{,}38\,\cancel{g\ ESM}} = 7{,}967\ \text{L leche para hacer 1 kg de queso}$$

La composición media de la leche puesta en cubas, calculada antes, fue de 34,11 g/L. Podemos calcular ahora el consumo de MP por kilo de queso, que es el que resulta de calcular

$$\frac{7{,}967\ \cancel{L\ leche}}{1\ kg\ queso} \cdot \frac{34{,}11\ g\ MP}{1\ \cancel{L\ leche}} = 271{,}75\ g\ MP\ en\ cubas\ por\ kilo\ de\ queso$$

Es necesario insistir en que estos cálculos teóricos sólo son válidos en nuestras condiciones de trabajo precisas:

- con la composición en ESM de nuestro queso
- con la composición de proteína de nuestra leche
- con la tasa de recuperación de la proteína de la leche en el ESM del queso de nuestro específico proceso de fabricación.

Son valores teóricos que utilizamos como valor objetivo, y que pueden variar a medida que adaptemos o variemos nuestra tecnología. Para cualquier otro producto, otra composición de leche y/u otro proceso de fabricación, deberemos recalcular nuestro litraje por kilo y nuestro consumo de materia.

Sabemos que, en nuestras condiciones medias, que hemos aceptado como nuestro estándar, 7,967 L de leche deben darnos 1 kg de queso. Si obtenemos más o menos queso querrá decir que nuestras hipótesis de partida no se han cumplido, y analizando los tres elementos básicos, sabremos la razón de la desviación:

- Nuestra leche tiene una composición diferente
- Nuestro queso tiene una composición diferente
- Nuestra recuperación de proteína ha sido diferente.

Si disponemos de la analítica correspondiente, podremos tomar las decisiones correctas; no es lo mismo actuar ante un problema de composición de leche que ante un problema de composición de queso o un problema de tecnología quesera. Otros factores pueden influir directamente en el coeficiente de recuperación de proteína, por ejemplo, la cantidad de proteína coagulable (caseína) frente a la proteína total analizada puede variar a lo largo del año, y el análisis de proteína total no nos da una indicación de esta ratio. Más adelante construiremos un modelo para el análisis de estas desviaciones.

15.3.2. La materia grasa

En nuestro análisis de rendimiento hemos calculado también un % de recuperación de MG. Sin embargo, no utilizaremos este % para calcular el litraje, lo haremos tal como hemos visto, con la transformación de la proteína en ESM. La razón es que *la tecnología quesera nos permite actuar sobre el ESM del queso, pero la MG depende principalmente de la estandarización*, como veremos a continuación.

Como el cálculo que hemos realizado con el coeficiente de recuperación de la MP (ESM/MP) nos da los litros de leche que necesitamos para hacer 1 kg de queso, y tenemos una composición de nuestra leche, podemos saber la cantidad de MG que vamos a tener en esos litros. Sabemos la MG que hemos obtenido realmente en nuestro queso, mediante los diferentes análisis de nuestro producto.

Hemos calculado nuestro litraje unitario: necesitamos 7,967 L leche para hacer 1 kg de queso.

Según nuestros datos, nuestra leche en cubas tiene $52.772,13/1.308.012 = 40,35\ g/L$ de MG, luego los $7,967\ L$ de leche teóricos tendrán

$$7,967 \cancel{L\ leche} \cdot \frac{40,35\ g\ MG}{1\ \cancel{L\ leche}} = 321,43\ g\ MG$$

Es decir, para fabricar 1 kg de queso necesitamos 7,967 L leche, que según su composición tienen $321,43\ g\ MG$

Sin embargo, el estándar de nuestro queso nos dice que en 1 kg de queso tenemos un 27 % de MG, es decir, 270 g MG por kilo de queso.

¿A qué se debe esta diferencia? La respuesta es: *a las pérdidas de MG en el proceso*, es decir, *a nuestro porcentaje de recuperación de MG.* Podemos calcular este porcentaje mediante la fracción

$$\frac{MG\ terica\ en\ el\ queso}{MG\ en\ la\ leche\ en\ cubas} = \frac{270{,}00\ g\ MG/kg\ en\ el\ queso}{321{,}43\ g\ MG/kg\ leche\ en\ cubas} \approx 0,8399 = 83{,}99\,\%$$

Es decir, con nuestra tecnología, recuperamos un 83,99 % de la materia grasa puesta en la cuba.

El mismo cálculo resulta utilizando la composición en g/L de la leche en cubas. La composición teórica en cubas debería ser la necesaria para permitirnos obtener la composición del 27 % de MG con el litraje unitario que hemos calculado, es decir, los 7,967 L/kg:

$$\frac{27\ g\ MG}{100\ \cancel{g\ queso}} \cdot \frac{1000\ \cancel{g\ queso}}{1\ \cancel{kg\ queso}} \cdot \frac{1\ \cancel{kg\ queso}}{7,967\ L\ leche} = \frac{27 \cdot 1000}{7,967} \frac{g\ MG}{L\ leche} = 33,89 \frac{g\ MG}{L\ leche}$$

Nuestra leche en cubas debería tener teóricamente 33,89 g/L de MG para obtener la MG que hemos analizado en el queso. A esta MG en cuba, calculada a partir de la composición del queso, la llamaremos **materia grasa teórica en cuba**, ya que proviene de un cálculo y no de un análisis real.

Sin embargo, nuestros datos analíticos de la leche en cuba dicen que tenemos 40,35 g/L de MG, según el cálculo anterior. Comparando los dos valores, obtenemos el mismo valor de coeficiente de recuperación de MG:

$$\frac{33,89}{40,35} = 83,99\,\%$$

Esta es la *recuperación estándar* que resulta de hacer los cálculos según nuestros datos de composición de leche, composición del queso y recuperación de proteína en el promedio de nuestra fabricación anual; cada fabricación individual real tendrá valores que podrán no coincidir con el valor estándar.

De la misma forma que en el caso de la recuperación de proteína, si nuestra recuperación de MG es diferente de la calculada teóricamente, debemos encontrar la explicación en los mismos factores:

- Composición real de la leche
- Composición real del queso
- Variaciones en la tecnología

Estas variaciones pueden implicar una mayor pérdida de MG, en el suero de quesería o en los finos de queso (o en ambos); una parte de estas pérdidas puede recuperarse mediante un desnatado del suero y la incorporación de la nata de suero obtenida a la leche en cubas.

15.4. El estándar técnico de fabricación en la hoja de cálculo

El razonamiento y cálculos que hemos ido realizando, se suelen recoger en un documento o una hoja de cálculo, que recoge los valores estándar de nuestra tecnología dada una composición media de nuestro queso obtenido y una composición de leche de partida.

A continuación se proporciona un enlace para descargar una hoja Excel con un estándar de fabricación con los datos utilizados en el ejemplo.

Descargar hoja de cálculo Excel con el estándar de fabricación (archivo `05-ejemplo-std-tecnico.xlsx`)

15.5. La importancia de la estandarización de la leche

La tecnología quesera se diseña para optimizar el **coeficiente de recuperación de ESM/MP**, que llamaremos **rendimiento quesero**. Aunque la retención de materia grasa (MG) también depende de factores tecnológicos como el corte, el calentamiento y el pH, no está directamente controlada por la tecnología, aunque sí influenciada por ella.

En una tecnología concreta, con parámetros de trabajo fijados, cuando la cantidad de MG en la leche es superior a la definida en el proceso, se producen dos efectos:

- Una parte del exceso de MG queda retenida en la matriz proteica, lo que incrementa la cantidad de grasa en el queso y, por tanto, modifica su composición.
- Otra parte de la MG se pierde en el suero, ya que las condiciones del proceso determinan una relación fija con la cantidad total de MG de partida. Es decir, al aumentar la MG inicial, también aumentan las pérdidas relativas en el suero.

Desgraciadamente, no es posible calcular teóricamente cuánta MG se retendrá en el queso y cuánta se perderá en el suero, ya que estas cantidades no responden a una función conocida. Lo que sí sabemos es que:

- Aumentarán las pérdidas.
- Se modificará la composición del queso, lo que puede alterar su textura y el valor nutricional declarado.
- Se alterará la expulsión de suero de la matriz proteica, lo que afectará la cantidad de lactosa retenida en la cuajada y, en consecuencia, las curvas de acidificación, el extracto seco, etc.

Cuando la MG es *inferior* a la definida, estos efectos se producen en sentido inverso, afectando tanto la composición del queso como su comportamiento tecnológico.

Para minimizar estas variaciones y mantener una composición constante del producto, es necesario:

- Trabajar con leche que tenga un contenido estable de materia grasa (MG) y materia proteica (MP). Dado que la composición de la leche varía estacionalmente, esto implica estandarizarla en MG y MP, **manteniendo constante la relación MG/MP**.
- Adaptar la tecnología de forma estacional, ya que la variación estacional no solo afecta la relación MG/MP, sino también la proporción de caseína coagulable dentro del total de proteínas.

Es fundamental recordar lo señalado al definir el estándar técnico: *la tecnología permite modificar el extracto seco magro (ESM) del queso, pero la MG depende principalmente de la cantidad presente en la leche de fabricación.* **No es posible modificar la cantidad de grasa en el queso mediante la tecnología quesera en la cuba**; es necesario preparar la leche con la cantidad de grasa adecuada para cubrir tanto la retención esperada como las pérdidas previstas.

En la medida en que no se puedan realizar estas adaptaciones, se deberá aceptar una mayor variabilidad en el producto, con dos consecuencias:

- Irregularidad en el producto final, que afecta la aceptación por parte del consumidor.
- Variación en el coste del producto, que puede dar lugar a pérdidas económicas no previstas.

Por estas razones, es imprescindible realizar un seguimiento detallado de las desviaciones tecnológicas, para comprender mejor el comportamiento del proceso y actuar eficazmente sobre sus causas. Las desviaciones observadas deben analizarse siempre apoyándose en el conocimiento tecnológico, para que los planes correctivos sean eficaces.

Conociendo el coste de la MG y de la MP pagada, es posible calcular el valor económico de cada desviación, lo que permite priorizar las acciones correctivas según su impacto financiero. A continuación veremos el análisis de las desviaciones.

15.6. El análisis de las desviaciones de rendimiento

Una vez construido nuestro estándar técnico de fabricación, vamos a usarlo de referencia para analizar las desviaciones producidas en una fabricación (haríamos le mismo razonamiento para un conjunto de ellas).

En este análisis vamos a tener en cuenta varias informaciones:

- El precio de la materia prima (coste de la MG y MP puesta en fábrica), calculada como hemos visto en el capìtulo anterior, con los valores de presupuesto y un período concreto para el que hacemos el análisis.
- EL estándar técnico que hemos preparado
- Los datos reales de las fabricaciones, que están registradas en el CSV `fab_queso_sim.csv`

El objetivo del análisis de las desviaciones de rendimiento es explicar esas desviaciones utilizando dos componentes principales: - La desviación del extracto seco total - La desviación de su composición (materia grasa y extracto seco magro)

Además, veremos una explicación adicional del desajuste que se produce al utilizar la proteína de la leche en cubas y el extracto seco magro del queso para explicar la recuperación de la proteína.

La desviación del extracto seco

El extracto seco de un queso se obtiene mediante la eliminación del suero, como sabemos. En esta eliminación intervienen diversos factores tecnológicos, como la acidificación, el corte del grano, la temperatura y el tiempo. La importancia relativa de estos factores varía según la tecnología utilizada y el producto que queramos obtener([14]).

Las pérdidas de finos en el suero, o la degradación de la calidad de las caseínas por causas diversas (por ejemplo, proteolisis temprana en la leche producida por bacterias psicrotrofas) pueden ser también causas de la pérdida de extracto seco en el producto final. El balance de materia nos indicará si nuestras pérdidas en el suero han sido mayores de lo esperado, y el análisis de los parámetros tecnológicos, sobre todo en la cuba de fabricación, nos permitirá explicar si ha habido modificaciones que justifiquen un aumento o disminución del extracto seco final.

El efecto de aumentar el extracto seco es un mayor consumo de materia por kilo de queso, que afecta a todos los componentes del queso. La reducción del extracto seco, al contrario, implica un menor consumo de materia, ya que se sustituye por agua. En ambos casos, el producto obtenido se aparta del estándar objetivo, y este hecho suele tener un impacto negativo en el consumidor.

La evaluación de la respuesta del consumidor a la reducción del extracto seco en el producto es de suma importancia, ya que nos permitirá detectar el límite aceptable en el que nos debemos situar para maximizar la rentabilidad del producto, atendiendo también a los cambios de vida útil que se pueden derivar de una mayor actividad de agua en el producto (se puede verificar de forma indirecta mediante el valor de HQD)

Tanto los aumentos como las reducciones del extracto seco respecto al estándar tienen un impacto directo en el coste del producto, que nuestro análisis debe poner en evidencia.

Las variaciones en la composición del extracto seco

Dado que, como hemos visto repetidas veces, el valor de la materia grasa y el de la proteína no son iguales, cualquier variación en la proporción de materia grasa respecto al extracto seco magro del queso implica una diferencia de coste del producto.

Un aumento del extracto seco magro implica un aumento porcentual del coste por mayor consumo de proteína (suponiendo que no hay diferencias sustanciales en el porcentaje de sal), mientras que una reducción porcentual del extracto seco magro en el extracto seco total implica un aumento de la materia grasa, y por lo tanto una reducción del coste del producto.

Sin embargo estas variaciones de composición no son neutras para el producto:

- Un aumento porcentual de la materia grasa respecto al extracto seco magro implica un aumento de la HQD (humedad del queso desnatado o magro), lo que a su vez indica una mayor actividad del agua, y por lo tanto, un aumento de la proteolisis y una reducción de la vida útil del queso.
- Una disminución porcentual de la materia grasa respecto al extracto seco magro implica una reducción de la HQD, que se traduce en una percepción del producto por el consumidor como más seco, con una textura más firme.

En este caso, el interés del quesero será mantener la proporción de materia grasa más alta posible que permita tener

- una buena apreciación de la textura por el consumidor
- un comportamiento correcto del producto en el punto de venta y en el hogar del consumidor desde el punto de vista de su vida útil.

En nuestro caso, suponemos que el estándar de producto está ajustado a la optimización tanto del extracto seco total como de su composición, y por lo tanto, explicaremos las desviaciones y su coste como objetivos de mejora, que es necesario corregir tanto para ajustar el coste del producto como su calidad.

15.7. Análisis de una fabricación

15.7.1. Precio de la materia

Utilizaremos la tabla de precios que hemos construido en el capítulo dedicado al precio de la leche:

Coste de la leche en fabrica	Presupuesto	Real
Precio resultante de la materia		
19. Precio MG (euros/kg)	**5,547**	**5,606**
20. Precio MP (euros/kg)	**9,888**	**9,769**

Figura 15.2.: Tabla de precios de materia

15.7.2. Estándar técnico de producto

Vamos a utilizar el estándar técnico calculado en este capítulo, que tenemos disponible para descarga en el enlace que hemos proporcionado en el apartado anterior:

Estándar de producto	Vaca
Fabricación, KG	1,000
1. Características del queso	
EST salida salado	52,00%
MG salida salado	27,00%
ESM	25,00%
HFD	65,75%
G/ES	51,92%
2. Composición de la leche de fabricación	
Leche en cuba MG (g/L)	40,35
Leche en cuba MP (g/L)	34,11
3. Datos tecnológicos	
Recup MP (dato real de la fabricación)	92,00%
4. Cálculos	
ESM queso obtenido a partir de MP leche (g/L)	31,38
Litraje unitario	7,967
MG teórica en la cuba (g/L)	33,89
Recup MG	83,99%
MG pérdida bruta en suero (g/L)	-6,46
MG pérdida bruta en suero %	-16,01%
Consumo MG/kg queso	321,45
Consumo MP/kg queso	271,74

Figura 15.3.: Estándar técnico.png

15.7.3. Datos de fabricación real

Utilizaremos los datos correspondientes a la primera fabricación que tenemos en nuestro CSV, con fecha 01/01/2024. Por comodidad, reformateamos estos datos en una hoja de Excel, que después vincularemos con la hoja de cálculo de diferencias:

Fabricación	
Datos de la fabricación real	01/01/2024
Fabricación, KG	637,56
EST a salida de sal (%)	49,95%
MG a salida de sal (%)	25,46%
Litros leche puestos en fab (cuba)	5.025
Composición leche MG (g/L)	41,070
Composición leche MP (g/L)	33,950
KMG puestos en fabricacion (cuba)	206,377
KMP puestos en fabricacion (cuba)	170,599
Utilización de nata de suero	
KMG Nata suero recuperada puesta en fab	0,000
MG (% m/m)	40%
MG (g/L)	394,00
MP (g/L)	5,91
Densidad nata a 20 °C (kg/L)	0,985

Figura 15.4.: Datos de la fabricación real

La tabla tiene un apartado para la posible inclusión de nata de suero recuperada. Dado que en nuestra fabricación no hemos reutilizado la nata de suero, ya que no desnatamos el suero, la cantidad está a cero.

15.7.4. Análisis de las desviaciones

Nuestra hoja de análisis de desviaciones tiene dos columnas, una para los valores estándar y otra para los reales.

Análisis de los valores estándar

En los valores estándar, utilizamos los coeficientes del estándar de fabricación para estimar las cantidades de materia que deberíamos haber consumido en la fabricación de 637,56 kilos de queso si su composición se hubiese ajustado al estándar.

Las primeras líneas hacen los cálculos ordinarios de composición; a partir de los datos de extracto seco total y materia grasa, obtenemos el extracto seco magro (ESM), la humedad del queso desnatado o magro (HFD o HQD) y la grasa del extracto seco (G/ES), datos de importancia en la caracterización denuestro producto, que utilizremos para comparar conel producto real fabricado. A continuación, introducimos el valor del factor MG/MP del queso, que será de utilidad en el análisis (en el mundo anglosajón se suele utilizar la relación inversa, MP/MG).

A partir de estos datos, tenemos un bloque en el que calculamos los datos teóricos de la cuba de fabricación, si los parámetros fuesen los del estándar. Utilizamos la composición de la leche definida en el estándar, que es la composición media con la que hemos construido el coste de la materia prima que esperamos comprar, por lo tanto, el coste con el que hemos construido nuestro precio de venta. El cálculo nos proporciona el litraje unitario teórico, que hemos calculado en el capitulo anterior del estándar de fabricación. Calculamos también el factor MG/MP de la leche

en cubas, que nos permite anticipar la pérdida prevista de materia grasa. Si el factor MG/MP en la leche era de 1,183 y en el queso resulta ser de 1,080, esto nos indica una pérdida relativa de grasa, que esperamos que sea la que estamos definiendo en este estándar.

Mediante los cálculos anteriores, obtenemos los coeficientes de recuperación de MG y MP (recordemos que la recuperación de la MP está medida mediante el valor del ESM del queso), y finalmente, nuestras pérdidas brutas de MG. Como no recuperamos MG del suero, el valor está a cero.

Análisis de los valores reales

En el caso de los valores reales, las fórmulas de cálculo son distintas, ya que hay cantidades que no son calculadas sino resultado de nuestra medida, y que hemos visto más arriba en la hoja que recoge los datos de fabricación.

Los datos que necesitamos para desglosar los detalles de la fabricación son los kilos de queso fabricados y su composición en EST y MG, y los litros de leche utilizados (leche en cubas), con su composición en EST y MG. No utilizamos los datos de leche comprada, por razones que ya hemos visto en el balance de materia, y que puede ser oportuno recordar: las pérdidas anteriores a la cuba de fabricación se deben a causas diferentes de la tecnología quesera, y nos interes separarlas para entender, buscar y explicar sus causas, aplicando planes de reducción de pérdidas adecuados. Introducir estas pérdidas en el análisis de rendimientos nos dificultaría entender estas pérdidas sólo por las modificaciones de la tecnología en cuba.

Análisis de desviaciones	Estándar	Real
Fabricación, KG		637,560
EST	52,00%	49,95%
MG	27,00%	25,46%
ESM	25,00%	24,49%
HFD	65,75%	67,15%
G/ES	51,92%	50,97%
gr MG queso/kg queso	270,000	254,600
g ESM queso/kg queso	250,000	244,900
factor MG/MP queso	1,080	1,040
Litros leche puestos en fab (cuba)	5.079	5.025
Composición leche en cuba MG (g/L)	40,35	41,07
Composición leche en cuba MP (g/L)	34,11	33,95
KMG puestos en fabricacion (cuba)	204,94	206,38
KMP puestos en fabricacion (cuba)	173,25	170,60
KMG Nata suero recuperada puesta en fab	0,00	0,00
factor MG/MP leche cubas	1,183	1,210
g MG/L leche en cuba	40,350	41,070
g MP/L leche en cuba	34,110	33,950
MG teórica en cuba g/L	33,892	32,303
Litraje unitario (L/Kg)	7,967	7,882
Recup MG	83,99%	78,65%
Recup MP	92,00%	91,52%
MG pérdida bruta (g/L)	6,458	8,767
MG pérdida bruta %	16,01%	21,35%
MG suero recuperada puesta en fab g/L	0,000	0,000
MG pérdida neta g/L	6,458	8,767
MG pérdida neta %	16,01%	21,35%

Figura 15.5.: Análisis de desviaciones

Primer análisis comparado de resultados

Si comparamos el factor MG/MP de la leche en cubas con el del queso, vemos que en cubas el factor MG/MP real es de 1,210 frente a 1,183 en nuestro estándar. Esto quiere decir que la leche utilizada ha sido más grasa de lo esperado. Sin embargo, el factor real en el queso es de 1,040 frente a 1,080 en el estándar, lo que nos indica ya una mayor pérdida de MG en el proceso.

La composición del queso es diferente del estándar: tenemos menos extracto seco y menos grasa; la proporción de MG en el EST menor, como vemos en el indicador G/ES (50,97 % vs 51,92 %), pero, debido al incremento de humedad, nuestro valor de HQD ha aumentado (67,15 % vs 65,75 %). Los quesos serán más blandos y su proteólisis será más rápida.

Debido a la composición de la leche, hemos puesto en cuba más MG por litro (41,070 g/L vs 40,350 g/L std) y menos proteína (33,950 g/L vs 34,110 g/L). Los litros de leche utilizados han sido menores que en el estándar, lo que es lógico teniendo en cuenta que nuestro queso tiene algo más de dos puntos porcentuales menos de extracto seco: hemos obtenido los kilos con menos

litros porque hemos incorporado más agua al peso del queso. Por esta razón, el litraje unitario es más bajo (7,882 L vs 7,967 L)

Con estos datos, obtenemos los coeficientes clave del rendimiento: los porcentajes de recuperación. En ambos casos, nuestra recuperación ha sido peor que el estándar (MG: 78,65 % vs 83,99 %; MP: 91,52 % vs 92 %). La menor recuperación de la MG se comprueba por el porcentaje de pérdidas en el suero, que ha sido sensiblemente mayor (21,35 % vs 16,01 %)

Resumen del análisis inicial

En la fabricación analizada, hemos obtenido un queso con menor extracto seco que el estándar y una HFD más elevada. Aunque nuestro rendimiento en L/kg ha sido mejor que el estándar (hemos utilizado menos litros para obtener 1 kg de queso), en realidad nuestra recuperación de materia ha sido peor: hemos perdido tanto MG como MP.

A continuación vamos a analizar el coste que hemos tenido frente al coste estándar previsto en nuestro presupuesto.

15.7.5. Análisis del coste de las desviaciones

Desviaciones por consumo y precio

Tal como hemos hecho en el cálculo del estándar, calculamos los consumos de materia puesta en cubas frente a los kilos de queso obtenidos, y lo expresamos en gramos de materia por kilo de queso. Al multiplicar este consumo por los kilos totales fabricados obtenemos las desviaciones de materia totales, que al coste de materia que hemos calculado, nos permite obtener el coste de las desviaciones.

Hacemos los cálculos en dos partes:

- Calculamos las diferencias de consumos a coste estándar, de manera que las diferencias de coste calculadas se deban sólo al consumo de materia, sin que nos influyan las diferencias de precio
- Calculamos el impacto del precio por separado, porque, de nuevo, estas diferencias están fuera de la responsabilidad de la tecnología quesera, y deben tratarse por otras vías.

No obstante, es necesario hacer ver que cuando por razones diversas, como la evolución del mercado de la leche, la meteorología o cualquier otra razón, se produce una diferencia de precio, siempre será necesario poner en marcha planes de contingencia con medidas tecnológicas que puedan compensar en lo posible estas diferencias, ya que la empresa no siempre tiene la capacidad de modificar de manera rápida y flexible ni las condiciones de compra de materia prima ni los precios de venta del queso. Aquí la tecnología puede ser de ayuda para equilibrar los resultados económicos de la empresa.

Consumos y desviaciones por consumo y precio	Std	Real	Desv kg	Desv total €	Desv € /kg
Consumo g MG/kg queso	321,45	323,70	-1,433	-7,948	-0,012
Consumo g MP/kg queso	271,74	267,58	2,651	26,216	0,041
Total desviaciones por consumo				18,268	0,029
Coste MG (euros/kg)	5,547	5,606		-37,616	-0,059
Coste MP (euros/kg)	9,888	9,769		75,870	0,119
Total desviaciones por precio				38,254	0,060

Figura 15.6.: Desviaciones por consumo y precio

En el análisis global de desviaciones, vemos el reflejo de lo analizado antes para el total de la fabricación:

- un mayor consumo de MG frente al estándar, que se traduce en una desviación negativa de 7,948 euros
- un menor consumo de MP, que se traduce en una ganancia de 26,216 euros
- en total, una desviación positiva de 18,268 euros.

Respecto al precio,

- el incremento en la MG nos produce una desviación negativa de -12,176 euros,
- en la MP, una desviación positiva de 20,301 euros,
- en total, una desviación total positiva de 8,125 euros.

Con todos estos análisis, podemos hacer una primera valoración: el resultado económico total ha sido positivo, debido a una desviación favorable en el consumo de materia, y también en el coste de la materia. Las causas del resultado positivo han sido dos:

- la evolución favorable del precio de la proteína, y
- el extracto seco del producto que ha estado dos puntos por debajo del estándar (aunque esto tiene una lectura negativa en el aspecto de la calidad del producto)

Si descomponemos los costes de MG y MP en función de la cantidad de materia puesta en cuba, vemos estas diferencias: un mayor consumo de MG y un menor consumo de MP:

Desviaciones por componente de materia prima	Std	Real	Dif	Desv total €	Desv € /kg
MG leche cuba (kg)	204,944	206,377	-1,433	-7,948	-0,012
MP leche cuba (kg)	173,250	170,599	2,651	26,216	0,041
				18,268	0,029

Figura 15.7.: Desviaciones de coste de materia según la materia puesta en cubas

Detalle de las desviaciones por composición y rendimiento y cálculo de la interacción

Como hemos visto, en la fabricación de queso, las desviaciones de coste de producto debidas a la tecnología quesera (precio de materia aparte) ocurren fundamentalmente por dos causas:

- Nuestra recuperación de materia en el queso ha sido diferente de la prevista en el estándar (**efecto rendimiento**)

- El producto obtenido tiene una composición diferente del estándar en extracto seco total (**efecto EST o composición**). La composición de este EST importa, porque, dado que la MG y la MP tienen un valor diferente, un mismo EST con diferentes valores de MG y MP no tendrán el mismo impacto en el coste final.

El análisis de desviaciones se puede abordar con la pregunta clásica "qué pasaría si...". Las fórmulas utilizadas a continuación son equivalentes a las utilizadas en contabilidad de costes para calcular los efectos tasa, precio y mix.

Disponemos de dos datos básicos, nuestro estándar y nuestra situación real. En ambos casos, tenemos un valor de rendimiento (ESM/MP) y de EST. Para descomponer las causas de la variación, calcularemos dos datos adicionales:

- qué valor de rendimiento hubiésemos tenido si la composición hubiese sido la del estándar
- qué valor de composición hubiésemos tenido si el rendimiento hubiese sido el del estándar

Para calcular estos rendimientos, necesitamos calcular las cantidades de materia teóricas puestas en cuba en estos supuestos.

Para la MG, las fórmulas que utilizamos son:

$$MGcuba_{compo_std} = \frac{compo_std_{MG}}{recup_real_{MG}} * kg_queso$$

para la MG a composición estándar, y

$$MGcuba_{recup_std} = \frac{compo_real_{MG}}{recup_std_{MG}} * kg_queso$$

para la MG a recuperación (rendimiento) estándar.

Aplicando las fórmulas,

$$MGcuba_{compo_std} = \frac{27,00\,\%}{78,65\,\%} * 637,560 = 218,860 \text{ kg MG en cuba a composicion std}$$

y

$$MGcuba_{recup_std} = \frac{25,46\,\%}{83,99\,\%} * 637,560 = 193,255 \text{kg MG en cuba a recup std}$$

Con estos cálculos, podemos construir una tabla de dos entradas,

MG puesta en cuba (kg)	Recuperación de MG estándar	Recuperación de MG real
Composición estándar del queso	204,944	218,860
Composición real del queso	193,255	206,377

Esta tabla nos permite calcular el efecto de cada factor por separado:

- el efecto de la recuperación (rendimiento) ha sido de 204,944 - 218,860 = -13,916 kg
- el efecto de la composición ha sido de 204,944 - 193,255 = 11,689 kg

La desviación total en MG, como hemos visto arriba, es de -1,433 kg (pérdida). Ahora sabemos que este resultado está escondiendo que nuestro rendimiento ha sido bastante peor, ya que hemos perdido -13,916 kg de MG. Esta pérdida se ha visto compensada al hacer el queso más blando, ya que hemos ganado 11,689 kg por haber tenido menor EST.

Nos queda por calcular una última cantidad, que es la que se conoce como *interacción* entre la composición y el rendimiento. Para entender este concepto, tenemos que darnos cuenta de que en el análisis del rendimiento, hemos calculado la diferencia de rendimiento a composición estándar. Sin embargo esta no ha sido la realidad, ya que hemos tenido un extracto seco algo más bajo del estándar. En consecuencia, hay una pequeña parte de la pérdida de rendimiento calculada que no ha tenido lugar. Para obtener esta cantidad real, calculamos la diferencia de rendimiento a composición real, y obtenemos la interacción por diferencia:

- efecto rendimiento real a composición real: 193,255 - 206,377 = -13,122 kg

La diferencia entre esta cantidad y el efecto rendimiento a composición estándar nos da la interacción buscada:

-13,122 - (-13,916) = +0,794

Esta cantidad se corresponde, como decíamos más arriba, con la pequeña parte de pérdida de rendimiento que realmente no ha tenido lugar, ya que el extracto seco que hemos obtenido ha sido menor que el estándar. Por esta razón es una desviación positiva.

Si colocamos todos estos valores en una sola tabla, tenemos a la vista todos los factores de desviación en el componente analizado, con su valor a precio estándar.

Grasa (MG del queso / MG en cuba)		
MG puesta en cuba (kg)	**Recuperación de MG estándar**	**Recuperación de MG real**
Composición estándar del queso	204,944	218,860
Composición real del queso	193,255	206,377
Efecto	**kg**	**€ (precio estándar)**
EST (composición del queso)	11,689	64,84 €
Rendimiento (recuperación de MG), sobre composición estándar	-13,916	-77,19 €
Rendimiento (recuperación de MG), sobre composición real (referencia, no se suma)	-13,122	-72,79 €
Interacción EST × rendimiento	0,794	4,40 €
Total (de la casilla estándar a la real)	**-1,433**	**-7,95 €**
Comprobación: total – (EST + rendimiento + interacción) = 0	0,000	0,00 €

En la última línea incluimos un término de comprobación: la desviación total menos la suma de los componentes calculados debe ser cero.

Procedemos de la misma forma para el cálculo de las desviaciones e interacción de la MP:

Proteína (ESM del queso / MP en cuba)		
MP puesta en cuba (kg)	**Coeficiente ESM/MP estándar**	**Coeficiente ESM/MP real**
Composición estándar del queso	173,250	174,151
Composición real del queso	169,716	170,599

Efecto	**kg**	**€ (precio estándar)**
EST (composición del queso)	3,534	34,95 €
Rendimiento (coeficiente ESM/MP), sobre composición estándar	-0,901	-8,91 €
Rendimiento (coeficiente ESM/MP), sobre composición real (referencia, no se suma)	-0,883	-8,73 €
Interacción EST × rendimiento	0,018	0,18 €
Total (de la casilla estándar a la real)	**2,651**	**26,22 €**
Comprobación: total – (EST + rendimiento + interacción) = 0	0,000	0,00 €

La suma de las desviaciones (MG+MP) nos permite calcular la desviación total:

Total grasa + proteína		
Concepto	**kg**	**€ (precio estándar)**
Desviación total por composición	—	**99,79 €**
Desviación total por rendimiento (recuperación materia)	—	**-81,52 €**
Desviación total por consumo	—	**18,27 €**
Comprobación con «Desviaciones» E33 = 0	—	0,00 €

El análisis detallado nos ha permitido verificar cómo los efectos del bajo extracto seco del producto fabricado producen un resultado positivo (+99,79 euros). mientras que los efectos tecnológicos (recuperación de materia), incluyendo la interacción composición-rendimiento, han sido negativos (-81,52 euros). El resultado total, de 18,27 euros positivos podría hacernos pensar que hemos tenido un buen resultado, mejor que lo presupuestado, pero el análisis detallado de las desviaciones nos permite mayor detalle en la interpretación:

- Hemos tenido una fuerte desviación negativa en el rendimiento, que deberemos corregir. Si las pérdidas debidas a la tecnología han sido de -81,52 euros en una fabricación, y hemos previsto unas 260 fabricaciones anuales, la falta de corrección de nuestra tecnología nos puede llevar a unas pérdidas anuales de algo más de 20.000 euros.
- Hemos compensado este error en la conducción de la tecnología bajando el extracto seco. Esto no es una buena decisión, ya que la modificación de la composición puede tener un impacto desfavorable en el consumidor, y en consecuencia, un efecto negativo a largo plazo sobre la aceptación de nuestro producto.

En el enlace a continuación se puede descargar una hoja Excel con el detalle de cada tabla presentada en este documento, y repasar la construcción de la fórmulas utilizadas.

Descargar la hoja de cálculo Excel con el análisis de desviaciones de rendimientos de ejemplo (archivo `06-analisis-desviaciones-rendimientos_2x2.xlsx`)

15.8. Resumen del capítulo

El análisis de rendimientos queseros es la herramienta más potente para identificar y cuantificar las ineficiencias del proceso de transformación. A diferencia del balance de materia, que nos dice

cuánta materia se pierde en global, el análisis de rendimientos nos permite desglosar las causas de las desviaciones y asignarles un coste económico concreto.

El **estándar técnico de fabricación** es el punto de referencia fundamental: define qué rendimiento debería obtener el proceso con la leche disponible, calculado a partir de los valores medios anuales, o mensuales, en caso de disponer de un estándar mensual. La diferencia entre el rendimiento estándar y el rendimiento real se descompone en tres efectos independientes: el efecto del extracto seco del queso (¿hemos obtenido el grado de concentración previsto?), el efecto de la recuperación de materia prima (¿hemos retenido en el queso la proporción de grasa y proteína esperada?) y el efecto del precio de la leche (¿hemos pagado por la materia prima lo que teníamos previsto en el presupuesto, y su composición real se ajusta a lo presupuestado?).

Esta descomposición es esencial para priorizar las acciones de mejora: un problema de recuperación de materia apunta a causas tecnológicas (temperatura de cuajado, tiempo de desuerado, manejo de la cuajada, curva de acidificación), mientras que un problema de extracto seco pede apuntar además a causas de proceso adicionales (tiempo de prensado, salado, condiciones de maduración).

La estandarización de la leche antes de la fabricación reduce la variabilidad del rendimiento al eliminar el efecto de las fluctuaciones estacionales de la composición. Es una inversión con retorno directo y cuantificable: a mayor variabilidad del rendimiento, mayor dificultad para detectar problemas tecnológicos reales entre el ruido de las variaciones de materia prima.

Como hemos visto en el ejemplo de análisis, incluso una sola fabricación con desviaciones tecnológicas moderadas puede representar un coste de decenas de euros; extrapolado a cientos de fabricaciones anuales, el impacto económico justifica ampliamente el esfuerzo de análisis sistemático.

Parte III.

Otras aplicaciones

16. El análisis del sistema de medición

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Identificar las principales fuentes de error en un análisis de laboratorio y clasificarlas según su origen.
- Distinguir entre veracidad y precisión según la norma ISO 5725-1:2023, y reconocer cada tipo de error en datos reales.
- Visualizar y comparar el comportamiento analítico de diferentes analistas mediante boxplot y dotplot.
- Calcular el sesgo y la desviación típica de repetibilidad para cada analista a partir de un dataset de resultados.
- Interpretar los resultados de un estudio de repetibilidad y proponer acciones correctoras adecuadas al tipo de error detectado.

Conceptos clave: **medida, fuente de variación, veracidad, precisión, exactitud, sesgo, repetibilidad, reproducibilidad, ISO 5725-1:2023**.

16.1. ¿Qué es una medida?

Una medida es el resultado de la acción de *medir*: comparar lo que queremos cuantificar con un patrón de referencia, siguiendo un procedimiento definido, con un instrumento adecuado, y por parte de uno o varios analistas.

En apariencia, el proceso parece sencillo. Sin embargo, si lo analizamos con atención, veremos que hay múltiples elementos que pueden hacer que el resultado no sea tan fiable como esperamos. Pensemos en algo tan cotidiano como medir la altura de una persona con una cinta métrica:



Figura 16.1.: Medición de la altura de un niño

¿Está el niño descalzo? ¿Tiene las rodillas rectas? ¿Está apoyado en un plano vertical? ¿La posición de los ojos del analista es perpendicular a la escala? ¿La cinta métrica está homologada? Cada uno de estos elementos puede introducir un error diferente en el resultado.

La **descripción detallada del procedimiento**, junto con la especificación del instrumento y sus requisitos de calibración, constituye lo que se conoce como *método analítico*. Un buen método analítico reduce al mínimo la influencia del analista y del instrumento en el resultado, garantizando que diferentes personas obtengan resultados comparables en diferentes momentos y lugares.

La Organización Mundial de la Salud, por ejemplo, define procedimientos muy precisos para la medición de peso y talla en niños, porque pequeños errores sistemáticos en esas medidas tienen consecuencias directas en el diagnóstico nutricional a escala global.

16.2. Las fuentes de variación en el laboratorio

En un laboratorio de quesería, las fuentes de variación más habituales son:

El analista. La técnica personal, la experiencia, la fatiga o simplemente un hábito incorrecto en la lectura del instrumento pueden introducir diferencias entre personas. Dos analistas que siguen el mismo método pueden obtener resultados distintos de forma sistemática.

El instrumento. Un butirómero descalibrado, una centrífuga con velocidad irregular, un baño maría con temperatura inestable: todos ellos introducen variación en el resultado con independencia de la habilidad del analista.

El método. La temperatura de la muestra en el momento del análisis, el tiempo de reposo antes de la lectura, la forma de homogeneizar la muestra: son condiciones que el procedimiento debe especificar con precisión para que no sean una fuente de variación adicional.

La muestra. Una muestra heterogénea o que ha sufrido degradación desde su recogida hasta el análisis introduce una variación que no es del sistema de medición sino del objeto medido.

En la práctica, lo que observamos en los resultados analíticos es la suma de todas estas fuentes. El objetivo del análisis del sistema de medición es separar y cuantificar cada una de ellas.

16.3. Veracidad y precisión: la norma ISO 5725-1:2023

La norma internacional **ISO 5725-1:2023** (*Accuracy of measurement methods and results*) establece la terminología y los conceptos para evaluar la calidad de un método analítico. Distingue tres conceptos que en el uso cotidiano se confunden con frecuencia:

Exactitud (*accuracy*): término general que describe la proximidad entre un resultado de medida y el valor verdadero. Engloba dos componentes independientes.

Veracidad (*trueness*): proximidad entre la media de un gran número de resultados y el valor verdadero o de referencia. Cuando un método no es verídico, produce un **sesgo** sistemático: los resultados están desplazados de forma consistente hacia arriba o hacia abajo.

Precisión (*precision*): proximidad entre resultados independientes obtenidos en condiciones definidas. Un método preciso produce resultados muy parecidos entre sí, aunque no necesariamente cercanos al valor verdadero.

> **i** Una aclaración terminológica
>
> En el uso coloquial, "exacto" y "preciso" se usan como sinónimos. En metrología, son conceptos distintos: un método puede ser muy preciso (resultados muy reproducibles) pero poco verídico (con sesgo), o verídico en promedio pero poco preciso (con mucha dispersión). La norma ISO 5725-1:2023 reserva el término *exactitud* para cuando ambas condiciones se cumplen simultáneamente.

La imagen de las dianas ilustra las cuatro combinaciones posibles:

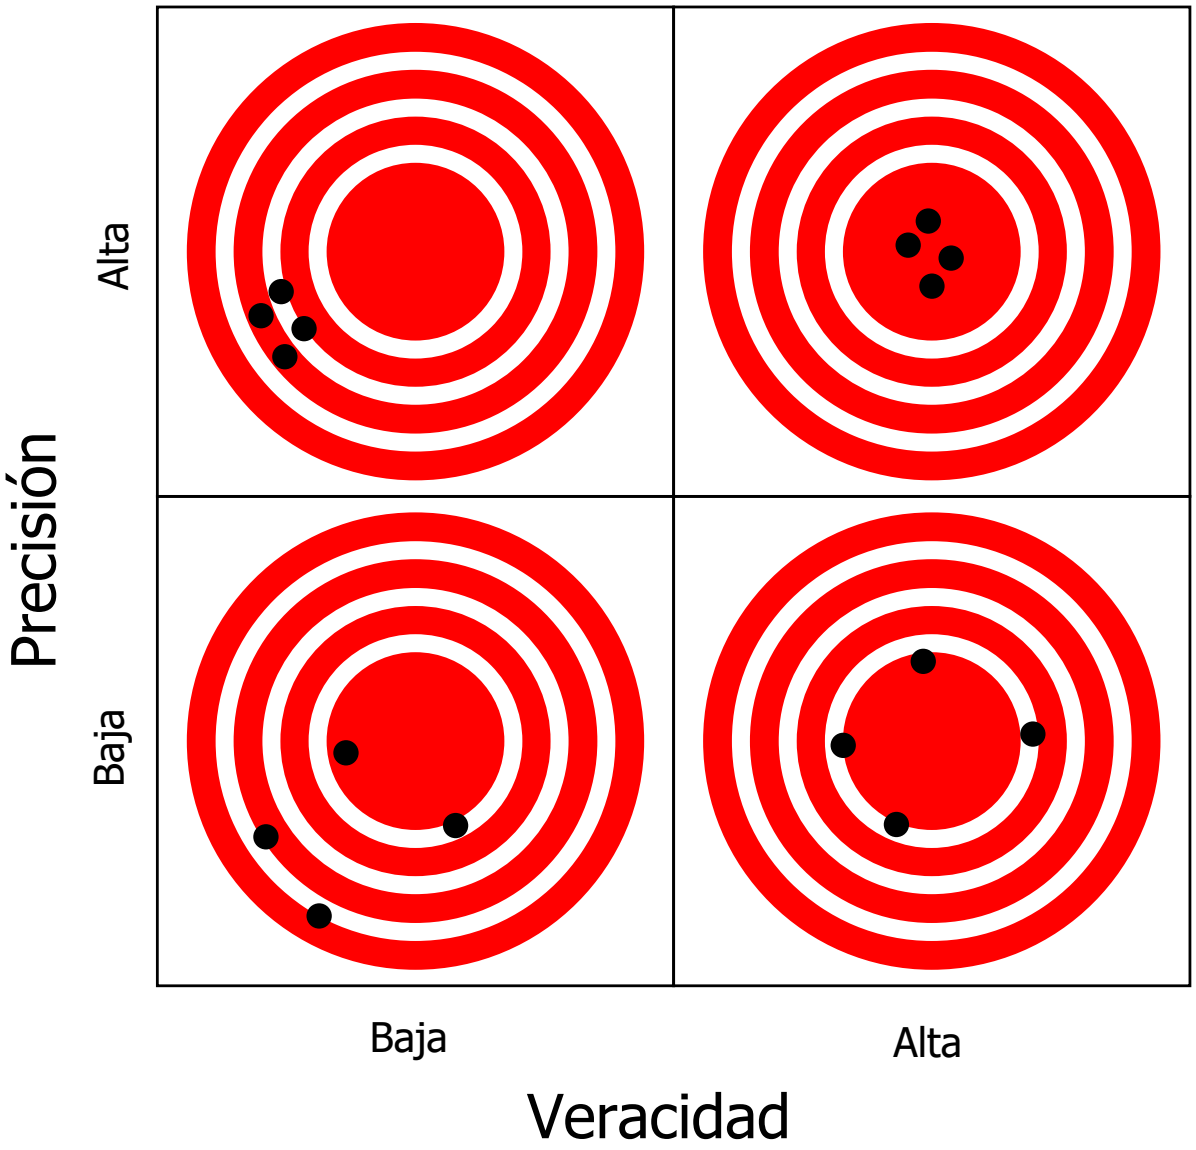


Figura 16.2.: Veracidad y precisión: las cuatro combinaciones posibles

- **Alta veracidad, alta precisión:** los impactos están agrupados y centrados. Es el objetivo.
- **Alta veracidad, baja precisión:** los impactos están dispersos pero centrados en promedio. Hay variabilidad pero no sesgo.
- **Baja veracidad, alta precisión:** los impactos están agrupados pero desplazados del centro. Hay sesgo sistemático pero buena repetibilidad.
- **Baja veracidad, baja precisión:** los impactos están dispersos y desplazados. El peor caso.

En el laboratorio de quesería, cada uno de estos cuadros tiene una causa distinta y una solución distinta. Un analista con baja veracidad (sesgo) necesita revisar su técnica o recalibrar su instrumento. Un analista con baja precisión necesita trabajar la consistencia de su procedimiento.

16.4. Repetibilidad y reproducibilidad

Dentro del concepto de precisión, la norma ISO 5725 distingue dos niveles:

Repetibilidad: variación obtenida cuando el mismo analista analiza la misma muestra varias veces en las mismas condiciones (mismo día, mismo instrumento, mismo procedimiento). Mide la consistencia interna de un analista.

Reproducibilidad: variación obtenida cuando diferentes analistas, en diferentes momentos o laboratorios, analizan la misma muestra. Mide la comparabilidad entre analistas o entre laboratorios.

La desviación típica de repetibilidad (s_r) y la desviación típica de reproducibilidad (s_R) son las medidas numéricas de cada uno de estos conceptos. Por definición, $s_R \geq s_r$: la variación entre analistas siempre es mayor o igual que la variación dentro de un mismo analista.

16.5. Caso práctico: evaluación de analistas en el método Gerber

El método Gerber es uno de los métodos de referencia para la determinación de grasa en leche. Es un método volumétrico que los alumnos de tecnología láctea aprenden y practican en el laboratorio. Su resultado depende de varios factores de técnica personal: la temperatura del baño maría, el tiempo y la velocidad de centrifugación, y sobre todo la lectura correcta del menisco en el butirómetro.

Vamos a analizar los resultados de un estudio de repetibilidad en el que cinco analistas han determinado el contenido en grasa de tres muestras de leche con diferente contenido graso, realizando tres repeticiones cada uno.

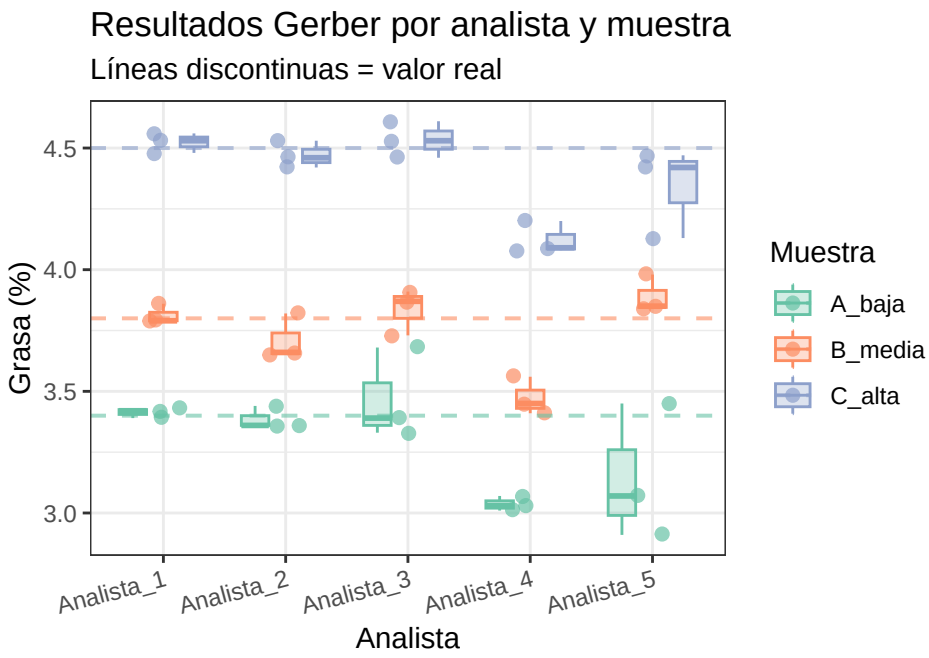
Cargamos el dataset:

```
Dimensiones: 45 x 5
```

```
# A tibble: 10 x 5
   analista   muestra valor_referencia repeticion resultado
   <chr>      <chr>              <dbl>      <dbl>     <dbl>
 1 Analista_1 A_baja               3.4          1      3.42
 2 Analista_1 A_baja               3.4          2      3.39
 3 Analista_1 A_baja               3.4          3      3.43
 4 Analista_1 B_media              3.8          1      3.86
 5 Analista_1 B_media              3.8          2      3.79
 6 Analista_1 B_media              3.8          3      3.79
 7 Analista_1 C_alta               4.5          1      4.56
 8 Analista_1 C_alta               4.5          2      4.53
 9 Analista_1 C_alta               4.5          3      4.48
10 Analista_2 A_baja               3.4          1      3.44
```

16.5.1. Visualización de los resultados por analista

El primer paso es visualizar todos los resultados. Usamos un boxplot por analista con los puntos individuales superpuestos, separando las tres muestras por color:



El gráfico permite identificar visualmente los dos problemas distintos. ¿Puedes detectarlos antes de continuar con el análisis numérico?

16.5.2. Cálculo del sesgo y la desviación típica de repetibilidad

Calculamos para cada analista y muestra la media, la desviación típica de repetibilidad y el sesgo respecto al valor real:

```
# A tibble: 15 x 6
   analista   muestra valor_referencia media dt_repetibilidad  sesgo
   <chr>      <chr>              <dbl> <dbl>            <dbl>  <dbl>
 1 Analista_1 A_baja               3.4  3.41            0.021  0.013
 2 Analista_1 B_media              3.8  3.81            0.04   0.013
 3 Analista_1 C_alta               4.5  4.52            0.04   0.023
 4 Analista_2 A_baja               3.4  3.39            0.046 -0.013
 5 Analista_2 B_media              3.8  3.71            0.095 -0.09
 6 Analista_2 C_alta               4.5  4.47            0.056 -0.03
 7 Analista_3 A_baja               3.4  3.47            0.187  0.067
 8 Analista_3 B_media              3.8  3.84            0.095  0.037
 9 Analista_3 C_alta               4.5  4.53            0.075  0.033
10 Analista_4 A_baja               3.4  3.04            0.031 -0.363
11 Analista_4 B_media              3.8  3.47            0.078 -0.327
12 Analista_4 C_alta               4.5  4.12            0.067 -0.377
13 Analista_5 A_baja               3.4  3.14            0.277 -0.257
```

```
14 Analista_5 B_media              3.8  3.89            0.078  0.09
15 Analista_5 C_alta               4.5  4.34            0.184 -0.16
```

16.5.3. Resumen por analista

Agregamos los resultados por analista para tener una visión global del comportamiento de cada uno:

```
# A tibble: 5 x 3
  analista   sesgo_medio dt_repetibilidad_media
  <chr>            <dbl>                  <dbl>
1 Analista_1       0.016                  0.034
2 Analista_2      -0.044                  0.066
3 Analista_3       0.046                  0.119
4 Analista_4      -0.356                  0.059
5 Analista_5      -0.109                  0.18
```

16.5.4. Interpretación

La tabla y el gráfico permiten clasificar claramente a los cinco analistas:

Analistas 1 y 2 muestran un sesgo prácticamente nulo y una desviación típica de repetibilidad baja. Son analistas con buena veracidad y buena precisión.

Analista 3 presenta un sesgo leve pero consistente hacia valores altos, con una dispersión algo mayor que los anteriores. Probablemente redondea sistemáticamente al alza en la lectura de la columna de grasa del butirómetro. La solución pasa por revisar la técnica de lectura.

Analista 4 destaca por tener una dispersión muy baja (alta repetibilidad) pero un sesgo negativo importante: sus resultados son sistemáticamente bajos en las tres muestras. Es el caso típico de un error de posición del ojo al leer el menisco del butirómetro: alta precisión, baja veracidad. Este analista necesita corrección en la técnica de lectura, no en la consistencia de su procedimiento.

Analista 5 presenta la situación opuesta: sesgo nulo en promedio, pero una dispersión muy alta. Sus resultados son impredecibles: a veces acertados, a veces muy alejados del valor real. El origen más probable es una técnica irregular: temperatura del baño maría inestable, tiempo de centrifugación variable, o dificultad para homogeneizar la muestra antes del análisis.

> **Dos tipos de error, dos soluciones distintas**
>
> El analista 4 y el analista 5 tienen errores de magnitud comparable, pero de naturaleza completamente diferente. El analista 4 necesita corregir un hábito concreto y repetible; el analista 5 necesita trabajar la consistencia de todo su procedimiento. Confundir los dos tipos de error llevaría a acciones incorrectas: no sirve de nada dar más formación teórica al analista 4 si el problema es una postura incorrecta; ni tampoco sirve corregir la postura del analista 5 si su problema es la variabilidad de las condiciones del análisis.

16.6. Seguimiento temporal del sistema de medición

El estudio GRR que hemos realizado es una fotografía del sistema de medición en un momento concreto. Pero los sistemas de medición no son estáticos: los electrodos de los pHmetros se colmatan progresivamente, los analistas desarrollan hábitos que pueden derivar con el tiempo, los instrumentos pierden calibración. Un laboratorio que solo evalúa su sistema de medición una vez al año puede estar trabajando meses con un sistema degradado sin saberlo.

La solución es el **seguimiento temporal**: repetir el estudio GRR de forma periódica — mensualmente en el caso del método Gerber — y representar la evolución de los indicadores clave a lo largo del tiempo. Esto convierte el análisis puntual en un sistema de vigilancia continua.

Usamos el dataset `grr_gerber_temporal.csv` que contiene los resultados de 12 meses de control, con 5 analistas, 3 muestras de referencia y 3 repeticiones por combinación (540 observaciones en total). El dataset incluye dos intervenciones: en el mes 4 se corrigió el hábito de lectura del menisco del analista A4, y en el mes 6 se formó al analista A5 en la técnica de agitación.

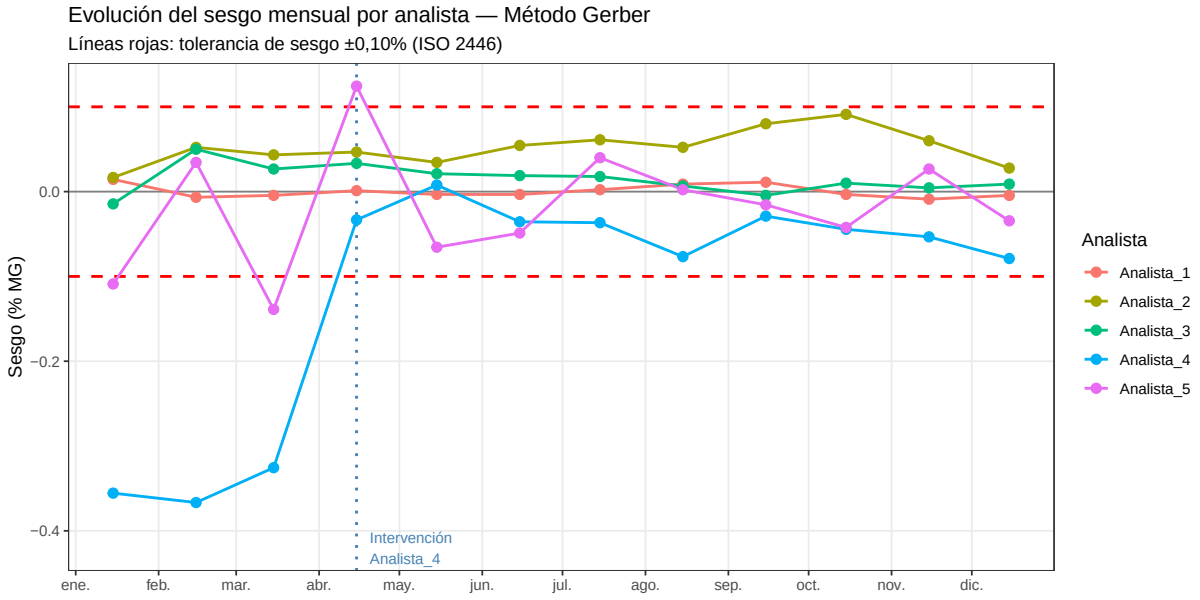
```
Dimensiones: 540 x 7
```

```
Período: ene. 2024 → dic. 2024
```

```
Analistas: Analista_1, Analista_2, Analista_3, Analista_4, Analista_5
```

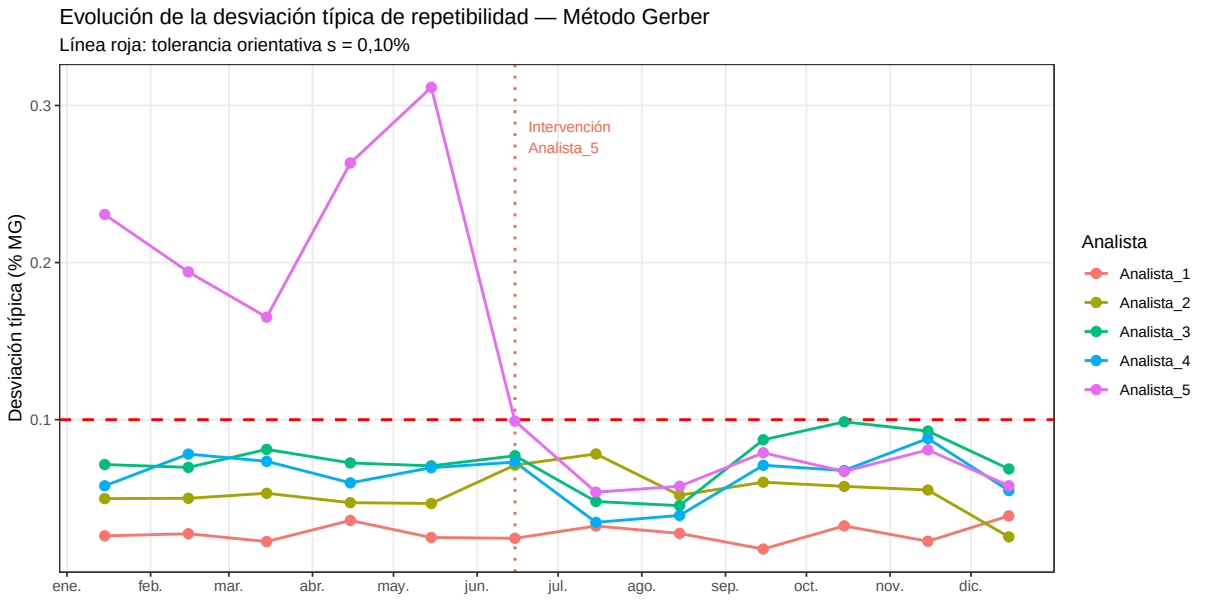
Calculamos el sesgo y la desviación típica mensual por analista:

16.6.1. Evolución del sesgo por analista



El gráfico muestra claramente el sesgo persistente de Analista_4 durante los tres primeros meses (alrededor de −0,35 %), bien fuera de la tolerancia ISO. Tras la intervención en abril, el sesgo se corrige y se mantiene dentro de los límites durante el resto del año.

16.6.2. Evolución de la desviación típica de repetibilidad



La sigma elevada de A5 durante los cinco primeros meses (entre 0,20 % y 0,28 %) indica una técnica de análisis irregular. Tras la formación específica en el mes 6, su repetibilidad mejora notablemente y se mantiene por debajo de la tolerancia.

> **Seguimiento temporal e intervenciones documentadas**
>
> El valor del seguimiento temporal no es solo detectar problemas, sino también **verificar que las intervenciones han sido eficaces** y que la mejora se mantiene en el tiempo. Un laboratorio que solo detecta el problema pero no verifica la corrección puede estar repitiendo el mismo ciclo de degradación y corrección indefinidamente sin saberlo. Los dos gráficos anteriores son exactamente el tipo de evidencia que se presenta en una auditoría de laboratorio para demostrar que el sistema de gestión de la calidad analítica funciona.

En muchas queserías tradicionales, la evaluación de la calidad se basa en la experiencia acumulada del quesero: el tacto para reconocer el punto de la cuajada, la vista para evaluar el color del suero, el olfato para detectar una contaminación incipiente. Este conocimiento tácito tiene un valor real e indudable.

Sin embargo, tiene una limitación importante: **no se puede transferir, no se puede auditar, y se pierde cuando el experto deja la empresa.**

El análisis del sistema de medición no pretende sustituir ese conocimiento, sino complementarlo. Cuando cuantificamos el error analítico, convertimos una percepción subjetiva (“este analista es menos fiable”) en un dato objetivable (“este analista tiene un sesgo de −0,35 % en el método Gerber”). Eso permite actuar con precisión: formarle en la lectura correcta del butirómetro, no en todo el método.

La combinación del conocimiento experto con la cuantificación sistemática del error es lo que caracteriza a un laboratorio de producción maduro.

16.7. Resumen del capítulo

Este capítulo ha introducido los conceptos fundamentales del análisis del sistema de medición aplicados al laboratorio de quesería. La norma ISO 5725-1:2023 distingue entre veracidad (ausencia de sesgo) y precisión (consistencia de los resultados), dos componentes independientes de la exactitud que requieren diagnóstico y solución distintos.

El caso práctico con el método Gerber ha mostrado cómo un estudio sencillo de repetibilidad —cinco analistas, tres muestras, tres repeticiones— permite identificar con claridad dos tipos de problema: el analista con sesgo sistemático pero alta repetibilidad, y el analista sin sesgo pero con alta variabilidad. La visualización con boxplot y puntos individuales superpuestos, combinada con el cálculo del sesgo y la desviación típica de repetibilidad, proporciona las herramientas suficientes para este diagnóstico en un laboratorio de producción.

Parte IV.

La metodología para la mejora continua

17. La variabilidad industrial

Síntesis: qué es, cómo se mide, cómo se reduce y cómo se gestiona

> **Objetivos de aprendizaje**
>
> Al finalizar este capítulo, el alumno será capaz de:
>
> - Definir la variabilidad industrial y explicar sus fuentes principales.
> - Identificar las consecuencias económicas y de calidad de no medir ni gestionar la variabilidad.
> - Relacionar las herramientas del libro con los distintos aspectos de la medición y gestión de la variabilidad.
> - Proponer un enfoque estructurado para reducir la variabilidad en un proceso concreto.
> - Explicar por qué la variabilidad es una oportunidad de mejora, no solo un problema a evitar.
>
> Conceptos clave: **variabilidad natural, causas comunes, causas especiales, coste de la variabilidad, capacidad de proceso, mejora continua**.

17.1. Qué es la variabilidad industrial

Ningún proceso industrial produce resultados idénticos. Dos yogures fabricados consecutivamente en la misma línea no pesan exactamente lo mismo. Dos análisis del mismo queso realizados por el mismo analista no dan exactamente el mismo valor de extracto seco. Dos fabricaciones de camembert con la misma leche y el mismo protocolo no producen exactamente el mismo rendimiento.

Esta variación inevitable es la **variabilidad industrial**: la dispersión de los resultados de un proceso alrededor de su valor medio, causada por la suma de múltiples factores que actúan simultáneamente y que nunca se pueden controlar de forma perfecta.

La variabilidad tiene tres características fundamentales que hay que entender antes de intentar gestionarla:

Es inevitable. Todo proceso real tiene variabilidad. El objetivo nunca es eliminarla completamente — eso es imposible — sino reducirla hasta niveles que sean compatibles con los requisitos de calidad y con el coste que estamos dispuestos a asumir.

No es aleatoria en su totalidad. Como vimos en el capítulo de control estadístico de procesos, hay una parte de la variabilidad que es aleatoria e inherente al sistema (causas comunes) y otra parte que responde a causas concretas identificables (causas especiales). Confundir las dos lleva

a tomar decisiones incorrectas: intervenir cuando no hace falta, o no intervenir cuando sí hace falta.

Tiene estructura. La variabilidad no aparece de forma uniforme. Hay variabilidad entre fabricaciones del mismo turno, entre turnos del mismo día, entre días de la misma semana, entre semanas del mismo mes, y entre meses del mismo año. Cada nivel tiene sus propias causas y requiere herramientas diferentes para analizarla.

17.1.1. Las fuentes de variabilidad

En un proceso quesero — y en cualquier proceso industrial de transformación biológica — las fuentes de variabilidad son múltiples y se agrupan en cinco categorías clásicas, conocidas como las **5M**:

- **Materia prima:** la composición de la leche varía con la raza, la alimentación, la etapa de lactación y la estación del año. Es una fuente de variabilidad que el fabricante no controla pero sí puede medir y compensar.
- **Método:** el protocolo de fabricación puede estar bien o mal documentado, bien o mal seguido. La variabilidad de método es una de las más frecuentes y de las más evitables.
- **Maquinaria:** los equipos envejecen, se desajustan, se ensucian. Un pHmetro con el electrodo colmatado, una dosificadora con la válvula desgastada, un intercambiador de calor con depósitos: todos son fuentes de variabilidad creciente a lo largo del tiempo.
- **Mano de obra:** la formación, la experiencia y la atención del operario influyen en el resultado. La variabilidad de mano de obra se reduce con formación, procedimientos claros e instrucciones de trabajo en el puesto.
- **Medio ambiente:** la temperatura y la humedad de la sala de maduración, la carga microbiana ambiental, las variaciones estacionales. Son fuentes de variabilidad difíciles de eliminar pero posibles de monitorizar y controlar parcialmente.

> **La variabilidad no es mala gestión**
>
> Es importante no confundir variabilidad con incompetencia. Un proceso con variabilidad alta puede estar gestionado por un equipo muy competente que, sencillamente, trabaja con una tecnología antigua, una materia prima muy variable o unos recursos insuficientes. La variabilidad es una propiedad del sistema, no del operario. Reducirla requiere actuar sobre el sistema — y eso es responsabilidad de la dirección, no solo del equipo de planta.

17.2. Consecuencias económicas y de calidad: el coste de no medir

La variabilidad tiene un coste real, aunque con frecuencia no aparezca en ninguna partida del presupuesto. Es un coste invisible que se manifiesta de formas distintas:

Coste de la sobredosificación. Como vimos en el capítulo del RD 1801/2008, un proceso con alta variabilidad de peso obliga a llenar los envases con más producto del nominal para garantizar el cumplimiento legal. Con 50.000 envases diarios, la diferencia entre un proceso con = 1,0 g y uno con = 3,0 g puede suponer decenas de miles de euros anuales en producto entregado gratuitamente.

Coste de la no conformidad. Un proceso con alta variabilidad produce más unidades fuera de especificación: quesos con humedad incorrecta, yogures con pH fuera de rango, lotes con recuentos microbiológicos elevados. Cada unidad no conforme es producto que no se puede vender, o que se vende a precio reducido, o que genera reclamaciones y devoluciones.

Coste del retrabajo y el desperdicio. En muchos procesos, la variabilidad alta genera la necesidad de operaciones correctoras: reprocesar lotes, alargar la maduración, ajustar la estandarización. Estas operaciones tienen un coste directo en tiempo, energía y mano de obra.

Coste de la pérdida de confianza. Un proveedor que entrega producto con alta variabilidad — aunque siempre dentro de especificación — genera desconfianza en el comprador. A igualdad de precio, los compradores prefieren proveedores predecibles. La variabilidad alta es un obstáculo para acceder a clientes exigentes y a mercados de mayor valor añadido.

El coste de no medir. Quizás el más importante de todos: si no medimos la variabilidad, no sabemos cuánto cuesta. Un proceso puede estar perdiendo miles de euros al mes en sobredosificación o en no conformidades sin que nadie lo sepa, porque nadie ha hecho el cálculo. Medir es la condición previa para mejorar.

17.3. Cómo hemos medido la variabilidad a lo largo del libro: un recorrido

A lo largo de los capítulos anteriores hemos utilizado diferentes herramientas para medir y describir la variabilidad. Cada una captura un aspecto distinto:

La desviación típica y la varianza (capítulo de estadísticos básicos) son las medidas fundamentales de dispersión. La desviación típica cuantifica en las mismas unidades que la variable cuánto se alejan los valores de la media. Es el punto de partida de cualquier análisis de variabilidad.

El histograma y el boxplot (capítulo de exploración gráfica) permiten ver la forma de la distribución: si es simétrica o asimétrica, si tiene valores atípicos, si hay varios grupos mezclados. Un proceso con distribución bimodal está diciendo que hay dos poblaciones distintas — dos turnos, dos operarios, dos proveedores — que hay que separar antes de analizar.

El QQ-plot (capítulo de distribuciones) permite verificar si la variabilidad sigue una distribución normal, lo que es necesario para usar la mayor parte de las herramientas estadísticas de forma válida.

El coeficiente de correlación y la regresión (capítulo de correlación) permiten identificar qué variables están relacionadas con la variabilidad de la respuesta: si la variabilidad del rendimiento quesero está correlacionada con la variabilidad de la materia grasa de la leche, tenemos una pista sobre dónde buscar la causa.

El análisis del sistema de medición (capítulo 16) mide la variabilidad del propio sistema de análisis: cuánta parte de la variación observada se debe al proceso y cuánta al instrumento o al analista. Es inútil intentar reducir la variabilidad del proceso si la variabilidad de la medida es comparable a la del proceso.

El gráfico de control y los índices de capacidad (capítulo de SPC) son las herramientas específicas para la gestión en tiempo real de la variabilidad. El gráfico distingue entre variabilidad normal (causas comunes) y señales de alarma (causas especiales). Los índices C_p y C_{pk} cuantifican si la variabilidad natural del proceso es compatible con las especificaciones.

El diseño de experimentos (capítulo de DoE) es la herramienta para identificar qué factores causan la variabilidad y en qué medida. Cuando queremos reducir la variabilidad de forma sistemática, el diseño de experimentos nos dice dónde actuar con el mayor efecto.

17.4. Cómo reducir la variabilidad: herramientas, prioridades y objetivos realistas

Reducir la variabilidad es un proceso sistemático, no un conjunto de acciones aisladas. Requiere seguir una secuencia lógica:

Primero, medir. No se puede reducir lo que no se mide. El primer paso es siempre cuantificar la variabilidad actual: desviación típica, índice de capacidad, porcentaje de no conformidades. Sin esta línea base no hay forma de saber si las acciones de mejora están funcionando.

Segundo, identificar las causas especiales y eliminarlas. Antes de intentar reducir la variabilidad de fondo (causas comunes), hay que asegurarse de que no hay causas especiales activas. Un proceso con causas especiales no está bajo control estadístico, y intentar reducir su variabilidad sin eliminarlas primero es trabajar sobre un sistema inestable. El gráfico de control es la herramienta para detectarlas.

Tercero, priorizar. En un proceso real hay docenas de fuentes potenciales de variabilidad. No es posible actuar sobre todas a la vez. La herramienta clásica para priorizar es el **diagrama de Pareto**: el principio de que el 80 % de la variabilidad suele estar causado por el 20 % de las causas. Identificar y actuar sobre ese 20 % es mucho más eficiente que distribuir el esfuerzo uniformemente.

Cuarto, actuar sobre las causas comunes. Reducir la variabilidad de fondo requiere cambiar el sistema: mejorar la precisión de los equipos, estandarizar los procedimientos, estabilizar la materia prima, mejorar la formación del equipo. Son acciones más costosas y de mayor plazo que la eliminación de causas especiales, pero son las que producen mejoras sostenibles.

Quinto, verificar y mantener. Una vez conseguida la mejora, hay que verificar que se ha mantenido — midiendo de nuevo la desviación típica o el índice de capacidad — y establecer un sistema de seguimiento para detectar cualquier deriva futura. Sin seguimiento, los procesos tienden a volver a su variabilidad anterior.

> **i** Objetivos realistas
>
> Un error frecuente es fijar objetivos de reducción de variabilidad sin conocer la capacidad actual del proceso. “Reducir los defectos a cero” o “eliminar toda la variabilidad” son objetivos que ignoran las leyes físicas. Un objetivo realista parte de la variabilidad actual, evalúa qué es posible con los recursos disponibles, y fija un objetivo concreto y alcanzable: por ejemplo, “reducir la desviación típica del peso de 2,6 g a 1,5 g en 6 meses”. Ese objetivo es verificable, tiene un plazo, y su impacto económico se puede calcular de antemano.

17.5. Cómo hacer el seguimiento: indicadores, revisiones y tendencias

Reducir la variabilidad sin hacer seguimiento es como adelgazar sin pesarse: puede que funcione, pero no lo sabrás hasta que sea demasiado tarde para corregir.

El seguimiento de la variabilidad requiere tres elementos:

Indicadores definidos. Cada proceso crítico debe tener uno o dos indicadores de variabilidad bien definidos: la desviación típica del peso de llenado, el índice C_{pk} del proceso de acidificación, el porcentaje de lotes no conformes del mes. Los indicadores deben ser pocos, específicos y calculados de forma consistente.

Revisiones periódicas. Los indicadores deben revisarse con una frecuencia adecuada al ritmo del proceso. Un gráfico de control diario es adecuado para seguir la variabilidad turno a turno. Un análisis mensual de la desviación típica por categoría de producto es adecuado para detectar derivas de largo plazo. Una revisión trimestral de los índices de capacidad es adecuada para evaluar el progreso de los planes de mejora.

Tendencias, no solo niveles. Un indicador que hoy está dentro del objetivo pero lleva tres meses subiendo es una alarma tan importante como uno que ya ha superado el límite. El seguimiento efectivo mira la tendencia, no solo el valor puntual. Los gráficos de control a largo plazo — construidos con datos de semanas o meses, no de horas — son la herramienta para detectar estas tendencias antes de que se conviertan en problemas.

17.6. La variabilidad como oportunidad

A lo largo del libro hemos presentado la variabilidad principalmente como un problema: algo que produce no conformidades, que obliga a sobredosificar, que genera costes ocultos. Esa perspectiva es correcta pero incompleta.

La variabilidad también es **información**. Un proceso con alta variabilidad está diciendo algo sobre sí mismo: que hay factores que no están bajo control, que hay causas que no se han identificado, que hay margen de mejora. Un proceso perfectamente estable y predecible no tiene nada que contar — ya está optimizado.

Cada episodio de variabilidad anómala — cada punto fuera de los límites de control, cada lote rechazado, cada deriva detectada — es una oportunidad de aprendizaje. La pregunta correcta no es "¿quién ha cometido el error?" sino "¿qué nos está diciendo el proceso sobre sí mismo?". La respuesta a esa pregunta, sistemáticamente buscada y respondida, es lo que permite mejorar de forma continua.

Esta es la perspectiva con la que cerramos este capítulo y con la que abrimos el siguiente, dedicado a la mejora continua: la variabilidad no es el enemigo. Es el punto de partida. Medirla, entenderla y reducirla progresivamente es exactamente el trabajo que hacen los equipos de mejora continua en la industria, y es el hilo conductor que conecta todas las herramientas que hemos aprendido en este libro.

17.7. Resumen del capítulo

La variabilidad industrial es inevitable: ningún proceso produce resultados idénticos. Sus fuentes son múltiples — materia prima, método, maquinaria, mano de obra, medio ambiente — y su gestión requiere distinguir entre la variabilidad de fondo inherente al sistema (causas comunes) y las señales de cambio que requieren investigación (causas especiales).

El coste de no medir la variabilidad es real aunque invisible: sobredosificación, no conformidades, retrabajo, pérdida de confianza de los clientes. Medir es la condición previa para mejorar.

A lo largo del libro hemos visto las herramientas para medir la variabilidad en sus distintos aspectos: la desviación típica para cuantificarla, el histograma y el boxplot para ver su forma, el gráfico de control para seguirla en tiempo real, los índices de capacidad para evaluar si es compatible con las especificaciones, el diseño de experimentos para identificar sus causas.

Reducir la variabilidad es un proceso sistemático: medir, eliminar causas especiales, priorizar, actuar sobre las causas comunes, verificar y mantener. El seguimiento mediante indicadores y revisiones periódicas es lo que garantiza que las mejoras se mantienen en el tiempo.

Finalmente, la variabilidad no es solo un problema: es información sobre el proceso. Cada episodio de variabilidad anómala es una oportunidad de aprendizaje. La mejora continua, que veremos en el capítulo siguiente, es precisamente la metodología para convertir esa información en acción sistemática.

18. La mejora continua y el análisis de datos

Del número a la acción: integración de las herramientas del libro en un marco de mejora

Objetivos de aprendizaje

Al finalizar este capítulo, el alumno será capaz de:

- Explicar qué es la mejora continua y por qué el análisis de datos es su herramienta fundamental.
- Formular correctamente la definición de un problema de proceso.
- Situar las herramientas del libro dentro del ciclo DMAIC.
- Relacionar los conceptos de Lean Manufacturing y Six Sigma con la reducción de la variabilidad.
- Analizar un caso de proceso quesero e identificar qué herramientas aplicaría y en qué orden.

Conceptos clave: **mejora continua, DMAIC, Lean Manufacturing, Six Sigma, definición del problema, costes de no calidad**.

18.1. Qué es la mejora continua y por qué importa en la industria quesera

La **mejora continua** es la filosofía de gestión que plantea que ningún proceso es perfecto y que siempre existe margen para mejorar — en calidad, en eficiencia, en reducción de variabilidad, en coste. No es un proyecto puntual que se hace y se acaba: es una forma sistemática y permanente de trabajar.

En la industria alimentaria en general, y en la quesería en particular, la mejora continua es especialmente relevante por varias razones. Los procesos son biológicos y por tanto inherentemente variables: la composición de la leche cambia con la estación, el cultivo iniciador evoluciona, las condiciones ambientales de maduración fluctúan. Esta variabilidad es la materia prima del trabajo de mejora: cada fuente de variación identificada y reducida es una ganancia real en calidad y en rentabilidad.

La mejora continua no es una tarea exclusiva de los técnicos de calidad o de los ingenieros de proceso. Es una responsabilidad de toda la organización, desde el operario que detecta una anomalía en su turno hasta la dirección que decide invertir en un nuevo equipo de dosificación. Lo que diferencia a una organización que mejora de una que no mejora no es la ausencia de problemas

— todos los procesos tienen problemas — sino la capacidad de identificarlos, cuantificarlos y resolverlos de forma sistemática.

18.2. Definir el problema: el paso más importante

Antes de buscar soluciones hay que tener claro cuál es exactamente el problema. Este paso, que parece obvio, es con frecuencia el más descuidado. Un problema mal definido lleva a análisis incorrectos, soluciones inadecuadas y recursos malgastados.

Una buena definición de problema tiene estas características:

Es breve. Si no cabe en dos o tres frases, probablemente no está bien definido. La brevedad obliga a identificar lo esencial y a descartar lo accesorio.

Usa lenguaje sencillo. Debe ser comprensible para cualquier persona de la organización, no solo para los técnicos. Si necesitas términos técnicos para explicarlo, inclúyelos pero explícalos. Un problema que solo entienden los expertos no genera el compromiso de la organización.

Cuantifica. Un problema sin cifras no está definido, está descrito. "El rendimiento es bajo" no es una definición. "El rendimiento medio del turno de noche es un 1,2 % inferior al del turno de día, lo que representa 180 kg de queso por semana" sí lo es.

Incluye el coste. La cuantificación económica del problema justifica el esfuerzo de resolverlo y permite priorizar entre varios problemas. Los **costes de no calidad** — el coste del retrabajo, de las no conformidades, de las devoluciones, de la sobredosificación — son a menudo mayores de lo que la dirección percibe.

Define el ámbito. ¿En qué línea? ¿En qué turno? ¿En qué producto? ¿Desde cuándo? Un problema bien acotado es un problema medio resuelto.

Es SMART. Específico, Medible, Alcanzable, Relevante y acotado en el Tiempo. Un objetivo de mejora que no cumpla estos cinco criterios es un deseo, no un objetivo.

Ejemplo de definición correcta vs incorrecta

Incorrecta: "Tenemos problemas con el rendimiento quesero."
Correcta: "El rendimiento del queso semicurado de vaca en la línea 2 ha disminuido de 9,8 % a 9,1 % entre enero y marzo, lo que representa una pérdida estimada de 12.000 € en el trimestre. El problema afecta principalmente al turno de noche (lunes a viernes). Objetivo: recuperar el rendimiento a 9,6 % antes del 30 de junio."

18.3. Estrategia de resolución de problemas

Ante un problema de proceso, la tentación es actuar de inmediato: cambiar algo, ajustar un parámetro, dar instrucciones al operario. Esta reacción intuitiva raramente resuelve el problema de forma duradera porque no identifica la causa raíz — la causa que, si se elimina, hace que el problema no vuelva a aparecer.

Una estrategia efectiva de resolución de problemas sigue esta secuencia:

1. **Definir el problema** con precisión y cuantificarlo (como vimos en la sección anterior).

2. **Recoger datos** sobre el proceso en el período del problema: no solo la variable afectada sino todas las variables que podrían estar relacionadas.
3. **Explorar los datos** gráficamente para identificar patrones, tendencias, correlaciones o anomalías que apunten a posibles causas.
4. **Formular hipótesis** sobre las causas más probables, basadas en el conocimiento del proceso y en los patrones observados en los datos.
5. **Verificar las hipótesis** — idealmente con un experimento diseñado — para confirmar cuál es la causa raíz.
6. **Implementar la solución** sobre la causa raíz identificada.
7. **Verificar la eficacia** de la solución midiendo de nuevo el indicador afectado.
8. **Estandarizar** el cambio en los procedimientos y formar al equipo.

Esta secuencia no es lineal en la práctica: con frecuencia los datos de la etapa 3 llevan a reformular el problema, o la verificación de hipótesis de la etapa 5 revela que la causa raíz no era la esperada. Lo importante es no saltarse pasos — especialmente el de verificación — y no implementar soluciones sin haber identificado la causa raíz.

18.4. El ciclo DMAIC: el marco de Six Sigma

El **ciclo DMAIC** — Define, Measure, Analyze, Improve, Control — es el marco metodológico de los proyectos Six Sigma para la resolución de problemas y la mejora de procesos. Es esencialmente la misma secuencia que describimos en la sección anterior, organizada en cinco fases con criterios de salida bien definidos para cada una.

Define (Definir): se define el problema con precisión, se identifican los clientes afectados y sus requisitos, se delimita el alcance del proyecto y se estima el impacto económico. La herramienta principal es el *Project Charter* o acta de proyecto.

Measure (Medir): se recogen datos del proceso actual para cuantificar la magnitud del problema y establecer una línea base. En esta fase se verifica también la fiabilidad del sistema de medición — no tiene sentido analizar datos si el sistema que los genera no es fiable. El análisis del sistema de medición que vimos en el capítulo 16 pertenece a esta fase.

Analyze (Analizar): se analizan los datos para identificar las causas raíz del problema. Aquí entran en juego la mayor parte de las herramientas estadísticas del libro: gráficos de control, análisis de correlación, análisis de varianza, diseño de experimentos.

Improve (Mejorar): se diseña e implementa la solución. Si la fase de análisis ha identificado correctamente las causas raíz, la solución es consecuencia directa del análisis. El diseño de experimentos es especialmente útil en esta fase para optimizar los parámetros del proceso.

Control (Controlar): se implanta un sistema de seguimiento para garantizar que la mejora se mantiene en el tiempo. Los gráficos de control, los procedimientos actualizados y la formación del equipo son los instrumentos de esta fase.

18.4.1. Las herramientas del libro en el contexto DMAIC

La tabla siguiente muestra cómo las herramientas que hemos aprendido encajan en las distintas fases del ciclo DMAIC:

Fase	Herramientas del libro
Define	Cuantificación del problema, costes de no calidad
Measure	Estadísticos básicos, histograma, boxplot, análisis del sistema de medición
Analyze	Gráfico de control, correlación, regresión, diseño de experimentos
Improve	Diseño de experimentos, simulación con `rnorm()`
Control	Gráfico de control (seguimiento), índices de capacidad C_p y C_{pk}

Ninguna de estas herramientas pertenece exclusivamente a una fase — el gráfico de control se usa en la fase Measure para entender el proceso actual y en la fase Control para verificar que la mejora se mantiene — pero la tabla ilustra cómo el ciclo DMAIC integra el conjunto de herramientas en una secuencia coherente.

18.5. Las 7 herramientas clásicas de la calidad

Las **7 herramientas clásicas de la calidad**, sistematizadas por Kaoru Ishikawa en los años 1960, son un conjunto de herramientas gráficas sencillas para el análisis y la resolución de problemas de calidad. Son el fundamento del trabajo de los equipos de mejora en planta y no requieren conocimientos estadísticos avanzados.

Herramienta	Propósito	Equivalente en el libro
Hoja de recogida de datos	Registrar observaciones de forma estructurada	Organización de datos, tidy data
Diagrama de Pareto	Priorizar causas por frecuencia o impacto	Gráfico de barras ordenado
Diagrama causa-efecto (Ishikawa)	Identificar causas potenciales de un problema	Las 5M
Histograma	Ver la distribución de una variable	Capítulo de exploración
Diagrama de dispersión	Ver la relación entre dos variables	Capítulo de correlación
Gráfico de control	Seguir el proceso en el tiempo	Capítulo de SPC
Diagrama de flujo	Documentar el proceso	Flujo de trabajo, cap. 4

La mayoría de estas herramientas las hemos utilizado a lo largo del libro, aunque sin llamarlas por este nombre. El diagrama de Pareto es un gráfico de barras ordenado de mayor a menor; el diagrama causa-efecto es una forma estructurada de listar las 5M; el histograma y el diagrama de dispersión son exactamente los que hemos construido en R y Python.

18.6. Lean Manufacturing: eliminar el desperdicio

Lean Manufacturing es una filosofía de gestión originada en el Sistema de Producción de Toyota que busca eliminar todo aquello que no añade valor al producto desde la perspectiva del cliente. En Lean, el **desperdicio** (*muda* en japonés) es cualquier actividad que consume recursos sin generar valor: sobreproducción, esperas, transporte innecesario, sobreprocesado, inventario excesivo, movimientos innecesarios y defectos.

La conexión con la variabilidad es directa: la variabilidad alta es una de las principales causas de desperdicio. Un proceso de llenado con alta variabilidad produce sobredosificación (desperdicio de producto), lotes rechazados (desperdicio de trabajo y materiales) y ajustes frecuentes (desperdicio de tiempo del operario). Reducir la variabilidad es, en términos Lean, eliminar una fuente de desperdicio.

Lean pone especial énfasis en la **estandarización**: los procedimientos deben estar documentados, actualizados y seguidos de forma consistente. Un proceso sin procedimiento estándar es un proceso que cada operario realiza a su manera, lo que genera variabilidad de método — una de las fuentes más frecuentes y más evitables de variabilidad en la industria.

18.7. Six Sigma: reducir la variabilidad con rigor estadístico

Six Sigma es una metodología de mejora que combina el ciclo DMAIC con herramientas estadísticas rigurosas para reducir la variabilidad de los procesos hasta niveles muy bajos. El nombre hace referencia al objetivo estadístico: un proceso Six Sigma tiene una variabilidad tan pequeña que los límites de especificación están a 6 desviaciones típicas de la media, lo que equivale a no más de 3,4 defectos por millón de oportunidades.

Alcanzar ese nivel de perfección no es el objetivo habitual en la industria alimentaria — la variabilidad biológica de las materias primas lo hace prácticamente imposible en la mayor parte de los casos. Pero la metodología Six Sigma, y en particular su marco DMAIC y sus herramientas estadísticas, es completamente aplicable para reducir la variabilidad desde niveles actuales hasta niveles significativamente mejores, con un retorno económico cuantificable.

18.7.1. El papel de los métodos estadísticos en Six Sigma

La característica que diferencia Six Sigma de otras metodologías de mejora es la exigencia de basar todas las decisiones en datos y en análisis estadístico riguroso. No se acepta "creemos que la causa es X" — se exige "los datos muestran que X explica el Y % de la variación de la respuesta". Esta exigencia es exactamente para lo que sirven las herramientas que hemos aprendido en este libro.

Un profesional que domina el análisis de datos con R o Python, que sabe interpretar un gráfico de control, que entiende qué es la capacidad de proceso y que puede diseñar y analizar un experimento factorial tiene las herramientas estadísticas fundamentales para participar activamente en proyectos Six Sigma — independientemente de si tiene o no una certificación formal en la metodología.

18.8. El gráfico como herramienta de decisión

A lo largo del libro hemos insistido en que los gráficos no son un ejercicio estético — son herramientas de comunicación y de decisión. En el contexto de la mejora continua, esta idea adquiere su significado más pleno.

Un gráfico de control en el panel de la línea de producción no está ahí para que quede bien. Está ahí para que el operario sepa, en cada momento, si el proceso está bajo control o no, y qué debe hacer en cada caso. Un gráfico de dispersión en la reunión mensual de calidad no está ahí para impresionar. Está ahí para que el equipo vea si hay correlación entre la variabilidad del rendimiento y la variabilidad de la grasa de la leche, y decida si investigar esa relación.

La diferencia entre un gráfico bien hecho y uno mal hecho no es estética: es la diferencia entre una decisión bien fundamentada y una decisión tomada a ciegas. En el capítulo de comunicación de resultados vimos los principios para hacer gráficos efectivos. Aquí añadimos la perspectiva de la mejora continua: **el gráfico debe estar diseñado para responder una pregunta concreta de proceso, no para mostrar todos los datos disponibles**.

18.9. Casos de discusión en equipo

Los casos siguientes presentan situaciones reales de proceso quesero para analizar en grupo. No tienen una solución única: el objetivo es discutir qué herramientas se aplicarían, en qué orden, qué datos se necesitarían y qué conclusiones preliminares se pueden extraer de la información disponible.

18.9.1. Caso 1: El rendimiento que bajó sin razón aparente

Una quesería artesanal produce queso de oveja curado con un rendimiento histórico estable de 18,5 % (kg de queso / 100 kg de leche). En octubre, el responsable de producción nota que el rendimiento ha bajado a 17,2 % y que lleva así tres semanas. No ha habido cambios conocidos en el proceso: mismo protocolo, mismos operarios, mismo proveedor de leche.

El responsable atribuye la bajada a "la leche de otoño" y decide esperar a que mejore sola. El técnico de calidad no está de acuerdo y propone hacer un análisis antes de decidir.

Preguntas para el debate:

1. ¿Cómo definirías el problema siguiendo los criterios de la sección anterior? ¿Qué información falta para completar la definición?
2. ¿Qué datos recogerías en las primeras 48 horas para entender qué está pasando? ¿Qué variables analizarías?
3. ¿Es suficiente la hipótesis "es la leche de otoño" para tomar una decisión? ¿Qué análisis harías para verificarla o descartarla?
4. El responsable dice "esperemos a que mejore sola". ¿Cuándo estaría justificado esperar y cuándo no? ¿Qué herramienta usarías para decidir si intervenir o no?
5. Si la causa fuera efectivamente la composición de la leche de otoño, ¿qué acciones correctoras serían posibles? ¿Y si la causa fuera otra?

18.9.2. Caso 2: La línea de yogures que cumple… a veces

Una empresa láctea produce yogures de 125 g en dos líneas idénticas. El análisis mensual de pesos muestra que la línea 1 cumple consistentemente el RD 1801/2008 (desviación típica 1,2 g, media 126,5 g). La línea 2, en cambio, tiene meses en que cumple y meses en que no (oscila entre 1,5 g y 3,8 g, media entre 126,0 g y 128,5 g).

El responsable de mantenimiento dice que las dos líneas son idénticas y que "si una cumple, la otra también debería". El técnico de proceso sospecha que el problema está en la forma en que se hacen los cambios de formato — la línea 2 tiene más cambios de formato por semana que la línea 1.

Preguntas para el debate:

1. ¿Qué tipo de variabilidad describe mejor el comportamiento de la línea 2: causas comunes, causas especiales, o ambas? ¿En qué se basa tu respuesta?
2. ¿Qué gráfico construirías para investigar la hipótesis del técnico de proceso sobre los cambios de formato? ¿Qué esperarías ver si la hipótesis es correcta?
3. ¿Cómo cuantificarías el coste de la variabilidad de la línea 2 respecto a la línea 1? ¿Qué datos necesitarías?
4. El responsable de mantenimiento propone revisar ambas líneas en la próxima parada. ¿Es una buena idea? ¿Qué buscarías específicamente en la revisión de la línea 2?
5. Si después de la revisión de mantenimiento la línea 2 mejora durante dos semanas pero luego vuelve a empeorar, ¿qué conclusión extraerías y qué harías a continuación?

Respuesta sugerida — Caso 1: El rendimiento que bajó sin razón aparente

1. Definición del problema: La información disponible ya permite una definición bastante completa: "El rendimiento del queso de oveja curado ha bajado de 18,5 % a 17,2 % en las últimas tres semanas, lo que representa aproximadamente 1,3 puntos porcentuales de pérdida. Con una producción de X kg de leche semanales, esto equivale a Y kg de queso no producido por semana, con un coste estimado de Z €. El problema se detectó a principios de octubre. Objetivo: identificar la causa y recuperar el rendimiento a 18,0 % o superior antes de fin de mes." Lo que falta es la producción semanal para calcular el impacto económico real.
2. Datos a recoger: En las primeras 48 horas conviene recoger: composición de la leche (grasa, proteína, extracto seco) de los últimos lotes afectados comparada con el período anterior, registros de temperatura y pH en cada etapa del proceso, tiempos de cuajado y desuerado, y pesos de entrada (leche) y salida (queso) de cada fabricación. Si hay registro histórico, conviene hacer un gráfico de evolución del rendimiento en el tiempo para ver exactamente cuándo empezó la bajada.
3. La hipótesis "es la leche de otoño": No es suficiente para tomar una decisión, pero tampoco es descartable. La composición de la leche de oveja cambia significativamente con

la estación y puede afectar al rendimiento. Para verificarla hay que comparar los análisis de leche actuales con los del mismo período del año anterior. Si la grasa y la proteína son similares a otros otoños en que el rendimiento fue normal, la hipótesis queda descartada. Si son diferentes, puede ser la causa — pero aun así habría que verificar si la diferencia es suficiente para explicar toda la bajada.

4. ¿Esperar o intervenir? La herramienta para decidir es el gráfico de control: si el rendimiento actual está fuera de los límites de control calculados sobre el histórico, es una señal de causa especial y hay que investigar. Si está dentro de los límites — aunque bajo — podría ser variabilidad normal. En este caso, una bajada de 1,3 puntos mantenida durante tres semanas es casi con certeza una señal de causa especial, no variabilidad aleatoria. Esperar sin investigar no está justificado.

5. Acciones correctoras: Si la causa es la composición de la leche de otoño: estandarizar la leche (ajustar la grasa o la proteína antes de cuajar) o ajustar el protocolo de cuajado en función de la composición. Si la causa es otra (por ejemplo, un cambio en el tiempo de desuerado o en la temperatura), la acción depende de la causa identificada. En ningún caso es correcto ajustar el proceso sin haber verificado la causa.

Respuesta sugerida — Caso 2: La línea de yogures que cumple… a veces

1. Tipo de variabilidad: La línea 2 tiene ambos tipos. La que oscila entre 1,5 g y 3,8 g según el mes indica claramente causas especiales activas: algo cambia de un mes a otro que hace que la variabilidad sea a veces normal y a veces muy alta. La media que oscila entre 126,0 g y 128,5 g también apunta a causas especiales que afectan al nivel del proceso. Dentro de cada mes, probablemente hay también causas comunes que generan la variabilidad de fondo. El hecho de que la línea 1 sea consistente descarta que el problema sea inherente al producto o al proceso en general.

2. Gráfico para investigar la hipótesis de los cambios de formato: Un gráfico de dispersión o boxplot con el eje X = número de cambios de formato por semana y el eje Y = desviación típica del peso en esa semana. Si la hipótesis es correcta, se verá una correlación positiva: las semanas con más cambios de formato tendrán mayor variabilidad. También sería útil un gráfico de control con los cambios de formato marcados como eventos para ver si la variabilidad aumenta justo después de cada cambio.

3. Cuantificación del coste: El coste tiene dos componentes. Primero, la sobredosificación: en los meses con alta (3,8 g), la media debe ser más alta para cumplir el RD, lo que implica más gramos por envase. Con el número de envases diarios y el coste por kg se puede calcular el sobrecoste mensual. Segundo, el riesgo de incumplimiento: en los meses fuera de norma puede haber envases bajo T1 que impliquen lotes rechazados o sanciones. Comparando los costes de la línea 2 con los de la línea 1 se obtiene el coste real de la variabilidad adicional.

4. Revisión de mantenimiento: Es una buena idea pero hay que saber qué buscar. En la línea 2, específicamente: el estado de las válvulas dosificadoras (desgaste que produce variabilidad creciente), el sistema de ajuste rápido del formato (si está desgastado o mal diseñado, cada cambio de formato introduce un error diferente), y la comparación directa entre los componentes de ambas líneas para identificar diferencias que puedan explicar el comportamiento distinto.

5. Si mejora dos semanas y luego vuelve a empeorar: Esta pauta — mejora transitoria seguida de recaída — indica que el mantenimiento corrigió los síntomas pero no la causa raíz.

Si el problema está en el procedimiento de cambio de formato (el operario no tiene una guía clara de ajuste, o la guía no es lo suficientemente precisa), la revisión de los componentes mecánicos lo mejorará temporalmente pero no resolverá el problema de fondo. El siguiente paso sería estudiar el proceso de cambio de formato en detalle: filmarlo, comparar cómo lo hacen los operarios de la línea 1 y de la línea 2, y estandarizarlo con un procedimiento claro y verificable.

18.10. Resumen del capítulo y cierre del libro

La mejora continua no es una metodología más: es la razón de ser de todo el análisis de datos que hemos aprendido a lo largo de este libro. Medir la variabilidad, explorar los datos, construir gráficos de control, diseñar experimentos, analizar el sistema de medición — todas estas herramientas tienen un propósito final: entender los procesos lo suficientemente bien como para mejorarlos de forma sistemática y sostenible.

El ciclo DMAIC organiza ese trabajo en cinco fases coherentes. Lean Manufacturing aporta la perspectiva del desperdicio y la estandarización. Six Sigma aporta el rigor estadístico y la exigencia de basar las decisiones en datos. Las tres perspectivas son complementarias y se refuerzan mutuamente.

Pero más allá de las metodologías y las herramientas, lo que hace que una organización mejore de verdad es algo más sencillo y más difícil a la vez: la cultura de hacer preguntas, de medir antes de opinar, de buscar causas raíz en lugar de culpables, y de ver en cada problema una oportunidad de aprendizaje. Esa cultura es lo que este libro ha intentado transmitir, a través de los datos de los pingüinos de Palmer, de los partidos de La Liga, de los quesos camembert, de los yogures de 150 g y de todos los demás ejemplos que hemos analizado juntos.

Los datos no mienten. Pero tampoco hablan solos. Necesitan alguien que sepa escucharlos.

A. Glosario de términos

Relación alfabética de los conceptos clave introducidos a lo largo del libro, con una definición breve de cada uno.

Aleatorización En diseño de experimentos, el orden en que se realizan los experimentos debe ser aleatorio para evitar que factores externos que cambian con el tiempo (temperatura ambiental, fatiga del operario) queden confundidos con los efectos de los factores estudiados.

Análisis de datos Proceso sistemático de inspección, limpieza, transformación e interpretación de datos con el objetivo de descubrir información útil, apoyar conclusiones y orientar la toma de decisiones.

Asimetría Propiedad de una distribución de datos que no es simétrica respecto a su media. Una distribución asimétrica positiva tiene una cola larga hacia la derecha (valores extremos altos); una distribución asimétrica negativa tiene la cola larga hacia la izquierda.

Balance de materia Análisis que compara la cantidad de materia grasa y proteína que entra en el proceso con la leche con la que sale en el queso producido, para cuantificar las pérdidas en cada etapa del proceso de transformación.

Beeswarm Variante del diagrama de puntos en la que los puntos se desplazan lateralmente para evitar solapamientos, mostrando la distribución individual de los datos. Útil como alternativa al boxplot cuando el número de observaciones es pequeño.

C_p (índice de capacidad) Índice que mide la relación entre la variabilidad natural del proceso (± 3) y la amplitud de los límites de especificación. Un C_p 1 indica que el proceso cabe dentro de los límites; no tiene en cuenta si la media está centrada.

C_pk (índice de capacidad centrado) Variante del C_p que tiene en cuenta la posición de la media respecto a los límites de especificación. Si el proceso está descentrado, C_pk $<$ C_p. Es el indicador más completo de la capacidad real del proceso.

Calidad de los datos Conjunto de propiedades que determinan la aptitud de los datos para el análisis: exactitud, completitud, consistencia, trazabilidad y ausencia de errores. Un análisis solo es tan bueno como los datos en que se basa.

Campana de Gauss Nombre coloquial de la distribución normal, por la forma característica de su función de densidad. Véase *distribución normal*.

Capacidad de proceso Medida de la aptitud de un proceso para producir resultados dentro de los límites de especificación, teniendo en cuenta su variabilidad natural. Se cuantifica mediante los índices C_p y C_pk.

Caso (observación) En un conjunto de datos, cada una de las unidades de análisis sobre las que se recogen valores de las variables. En una tabla de datos, cada caso corresponde a una fila.

Causas comunes Fuentes de variación inherentes al sistema que están siempre presentes y producen la variabilidad de fondo del proceso. Su eliminación requiere cambiar el diseño del sistema, no intervenir en el proceso. Véase también *causas especiales*.

Causas especiales Fuentes de variación discretas e identificables que producen variación adicional sobre la variabilidad de fondo. Su aparición es señal de que algo ha cambiado en el proceso y requiere investigación. Véase también *causas comunes*.

Chartjunk Término acuñado por Edward Tufte para referirse a los elementos visuales de un gráfico que no transmiten información sobre los datos: fondos decorativos, efectos 3D, gradientes, sombras. Reducen la claridad sin añadir valor.

Ciclo PDCA Marco de mejora continua compuesto por cuatro fases: Plan (planificar), Do (hacer), Check (verificar) y Act (actuar). Es la base de la filosofía de mejora continua y precursor del ciclo DMAIC de Six Sigma.

Código abierto Software cuyo código fuente es accesible, modificable y redistribuible libremente. Python y R son herramientas de código abierto; el conocimiento adquirido con ellas es completamente transferible entre empresas y sectores.

Coeficiente de determinación (R^2) Cuadrado del coeficiente de correlación de Pearson. Mide la proporción de la variación de una variable que queda explicada por la otra. Un $R^2 = 0{,}76$ significa que el 76 % de la variación de y queda explicada por x.

Coeficiente de Pearson (r) Medida de la intensidad y la dirección de la relación lineal entre dos variables. Toma valores entre -1 y +1: valores cercanos a ± 1 indican relación fuerte; valores cercanos a 0 indican ausencia de relación lineal.

Control estadístico de procesos (SPC) Metodología para la monitorización y control de procesos industriales mediante herramientas estadísticas, especialmente el gráfico de control. Permite distinguir entre variabilidad normal (causas comunes) y señales de alarma (causas especiales).

Correlación Relación estadística entre dos variables: cuando una varía, la otra tiende a variar también. No implica causalidad. Véase *coeficiente de Pearson*.

Correlación espuria Correlación estadística fuerte entre dos variables que no tienen ninguna relación causal. Ocurre frecuentemente cuando dos variables siguen tendencias temporales similares por razones independientes.

Coste de materia prima En tecnología quesera, el coste unitario de la materia grasa y la proteína de la leche expresado en €/kg de componente. Se obtiene a partir del precio pagado por litro de leche y su composición analítica.

CSV (Comma-Separated Values) Formato de fichero de texto plano para almacenar datos tabulares, en el que los valores están separados por un delimitador (coma, punto y coma). Es el formato más universal para el intercambio de datos entre aplicaciones.

Cuartil Cada uno de los tres valores que dividen un conjunto de datos ordenados en cuatro partes iguales. Q1 (percentil 25), Q2 (mediana, percentil 50) y Q3 (percentil 75).

Dataframe Estructura de datos tabular con filas y columnas, equivalente a una tabla de base de datos o una hoja de cálculo. Es la estructura fundamental de trabajo en pandas (Python) y en R.

Dato Representación simbólica de una característica de un objeto o fenómeno. Los datos son la materia prima del análisis; su calidad determina la calidad de las conclusiones.

Datos estructurados y no estructurados Los datos estructurados están organizados en filas y columnas con un formato definido (tablas, CSV). Los datos no estructurados no tienen un formato predefinido (textos libres, imágenes, registros de audio). El análisis industrial trabaja principalmente con datos estructurados.

Datos ordenados (tidy data) Estructura de datos en la que cada variable ocupa una columna, cada observación ocupa una fila y cada valor ocupa una celda. Es el formato estándar para el análisis con R y Python.

Datos rectangulares Estructura de datos organizada en filas y columnas donde todas las filas tienen el mismo número de columnas. Es el formato estándar para el análisis estadístico. Sinónimo de datos tabulares o datos estructurados.

Desviación de rendimiento Diferencia entre el rendimiento real obtenido en una fabricación y el rendimiento estándar calculado a partir de la composición de la leche. Se descompone en efecto del extracto seco, efecto de la recuperación de materia y efecto del precio.

Desviación típica Medida de dispersión que cuantifica, en las mismas unidades que la variable, cuánto se alejan los valores de la media. Es la raíz cuadrada de la varianza. Símbolo: (población) o s (muestra).

Diagrama de barras Gráfico que representa frecuencias o magnitudes de categorías mediante barras de longitud proporcional al valor. Más efectivo que el gráfico de tarta para comparar categorías.

Diagrama de caja (boxplot) Gráfico que representa la distribución de una variable mediante cinco estadísticos: mínimo, Q1, mediana, Q3 y máximo. Permite comparar distribuciones entre grupos y detectar valores atípicos.

Diagrama de dispersión Gráfico que representa pares de valores (x, y) como puntos en un plano cartesiano. Es la herramienta visual fundamental para explorar la relación entre dos variables cuantitativas.

Diseño de experimentos (DoE) Metodología para estudiar el efecto de varios factores sobre una variable respuesta de forma simultánea y eficiente, permitiendo detectar interacciones entre factores que el enfoque OFAT no puede revelar.

Diseño factorial Tipo de diseño de experimentos en el que se estudian todas las combinaciones posibles de los niveles de los factores. Un diseño 2^2 estudia 2 factores con 2 niveles cada uno, resultando en 4 combinaciones.

Distribución bimodal Distribución de datos con dos modas (dos picos) claramente diferenciados. Suele indicar la mezcla de dos poblaciones distintas en los datos (dos turnos, dos proveedores, dos grupos de analistas).

Distribución continua Distribución de probabilidad de una variable que puede tomar cualquier valor dentro de un intervalo. La distribución normal es el ejemplo más importante en el análisis industrial.

Distribución de frecuencias Tabla o gráfico que muestra cuántas veces aparece cada valor o intervalo de valores en un conjunto de datos. Base del histograma.

Distribución discreta Distribución de probabilidad de una variable que solo puede tomar valores enteros o un conjunto finito de valores. Ejemplo: número de defectos por lote.

Distribución normal Distribución de probabilidad simétrica en forma de campana, definida por su media ( ) y su desviación típica ( ). El 68,3 % de los valores cae dentro de $\pm$; el 95,4 % dentro de ± 2 ; el 99,7 % dentro de ± 3 .

Distribución simétrica Distribución de datos en la que los valores se distribuyen de forma equilibrada a ambos lados de la media. La distribución normal es el caso más importante.

DMAIC Ciclo de mejora de Six Sigma: Define (definir el problema), Measure (medir el proceso actual), Analyze (analizar las causas), Improve (mejorar) y Control (controlar que la mejora se mantiene).

Efecto principal En diseño de experimentos, el efecto medio de un factor sobre la variable respuesta, promediando sobre todos los niveles del otro factor. Se visualiza en el gráfico de efectos principales.

EMDT (error máximo por defecto tolerado) En el RD 1801/2008, la diferencia máxima admisible entre el contenido real de un envase y el peso nominal declarado. Su valor depende del peso nominal según una tabla establecida en la norma.

Envase defectuoso Según el RD 1801/2008, envase cuyo contenido es inferior al peso nominal menos el EMDT (límite T1). La norma permite un máximo del 2,5 % de envases defectuosos en un lote.

Envase no conforme Según el RD 1801/2008, envase cuyo contenido es inferior al peso nominal menos el doble del EMDT (límite T2). Ningún envase no conforme está permitido en un lote.

ggplot2 Librería de R para la creación de gráficos estadísticos basada en la gramática de gráficos. Es la herramienta de visualización principal del ecosistema tidyverse.

Estacionalidad Patrón de variación que se repite con una periodicidad regular (mensual, estacional, anual) en una serie temporal. En quesería, la composición de la leche tiene una marcada estacionalidad.

Estadístico Valor numérico calculado a partir de una muestra que describe alguna característica de la misma. La media muestral y la desviación típica muestral son estadísticos. Distinto de parámetro, que describe la población.

Estadístico no paramétrico Estadístico que no asume que los datos siguen una distribución normal. La mediana y el rango intercuartil son estadísticos no paramétricos; son más robustos frente a valores atípicos que la media y la desviación típica.

Estadístico paramétrico Estadístico cuyo cálculo asume que los datos siguen una distribución conocida, generalmente la normal. La media y la desviación típica son estadísticos paramétricos.

Estándar técnico de fabricación Documento que define los parámetros de referencia del proceso quesero: qué rendimiento debería obtener el proceso con una leche de composición dada. Sirve de base para el análisis de desviaciones.

Estandarización de la leche Ajuste de la composición de la leche (relación grasa/proteína) antes de la fabricación para reducir la variabilidad del rendimiento quesero y optimizar el proceso.

Estudio observacional Tipo de estudio en el que el analista recoge datos del proceso sin intervenir en él. Permite detectar correlaciones pero no establecer causalidad, ya que no se controlan los factores externos.

Estudio retrospectivo Tipo de estudio basado en datos ya recogidos en el pasado. Es rápido y económico, pero está limitado por la calidad y disponibilidad de los registros históricos.

Experimento diseñado Tipo de estudio en el que el analista interviene deliberadamente en el proceso modificando factores de forma controlada para estudiar su efecto sobre la respuesta. Permite establecer relaciones causales. Véase también *diseño de experimentos*.

Extracto seco magro (ESM) Fracción sólida del queso sin contar la materia grasa. Se usa como base de cálculo para la recuperación de proteína en el análisis de rendimientos queseros, porque permite comparar fabricaciones con diferente humedad.

Factor En diseño de experimentos, variable que se controla deliberadamente durante el experimento para estudiar su efecto sobre la respuesta.

Fichero plano Fichero de texto sin formato especial en el que los datos están separados por un delimitador (espacio, tabulador, punto y coma). El fichero CSV es el tipo más común de fichero plano usado en análisis de datos.

Flujo de trabajo Secuencia ordenada de pasos para realizar un análisis de datos: importar, verificar, limpiar, explorar, analizar, comunicar. Un flujo de trabajo estructurado garantiza la reproducibilidad y la trazabilidad del análisis.

Flujo de trabajo reproducible Secuencia de pasos de análisis documentada en código que puede ejecutarse de nuevo obteniendo los mismos resultados. Garantiza la trazabilidad y la verificabilidad del análisis.

Forma de los datos Descripción cualitativa de la distribución de una variable: simétrica, asimétrica positiva, asimétrica negativa, bimodal. Se evalúa visualmente mediante el histograma o el gráfico de densidad.

Frecuencia absoluta Número de veces que aparece un valor o intervalo de valores en un conjunto de datos.

Frecuencia acumulada Suma de las frecuencias absolutas (o relativas) de todos los valores hasta un determinado punto. Permite calcular qué proporción de datos está por debajo de un valor dado.

Frecuencia relativa Proporción de veces que aparece un valor o intervalo respecto al total de datos. Equivale a la probabilidad empírica de ese valor.

Gráfico de control Representación temporal de los resultados de un proceso con tres líneas horizontales: la línea central (media), el límite de control superior (media + 3) y el límite de control inferior (media − 3). Permite distinguir variabilidad normal de señales de alarma.

Gráfico de densidad Estimación suavizada de la distribución de una variable continua. Alternativa al histograma que no depende de la elección del tamaño de intervalo.

Histograma Gráfico de barras contiguas que representa la distribución de frecuencias de una variable continua dividida en intervalos (bins). La altura de cada barra es proporcional al número de datos en ese intervalo.

Hoja de cálculo Aplicación informática que organiza datos en una cuadrícula de filas y columnas con celdas que pueden contener valores o fórmulas. Es útil para el análisis básico, pero sus fórmulas ocultas dificultan la auditoría y la reproducibilidad del análisis.

Informe reproducible Documento en el que el texto, los cálculos y los gráficos están escritos en el mismo fichero en código visible. Cuando los datos cambian, basta con regenerar el documento para que todo se actualice automáticamente.

Interacción En diseño de experimentos, situación en la que el efecto de un factor sobre la respuesta depende del nivel del otro factor. Se detecta visualmente por líneas no paralelas en el gráfico de interacciones. Es la información más valiosa del diseño factorial y la que el enfoque OFAT no puede revelar.

Intervalo (bin) En un histograma, cada uno de los rangos de valores en que se divide la variable para agrupar las observaciones.

Lean Manufacturing Filosofía de gestión orientada a eliminar el desperdicio en los procesos productivos. En el contexto del análisis de datos, pone especial énfasis en la estandarización de procedimientos como base para la reducción de la variabilidad.

matplotlib Librería de Python para la creación de gráficos estáticos, animados e interactivos. Es la base sobre la que se construye seaborn.

Lenguaje de programación Sistema formal de instrucciones que permite comunicarse con un ordenador para realizar cálculos, transformaciones y visualizaciones de datos. Python y R son los lenguajes de programación principales de este libro.

Límites de control En un gráfico de control, las líneas que delimitan la zona de variabilidad esperada del proceso (media $\pm$ 3). Un punto fuera de estos límites es señal de una causa especial.

Línea de tendencia Véase *regresión lineal*.

Materia grasa Componente graso de la leche y del queso. Es el principal determinante del precio de la leche en el sistema de pago por calidad y uno de los factores clave del rendimiento quesero.

Media aritmética Suma de todos los valores dividida por el número de valores. Es el estadístico de centralidad más utilizado, pero sensible a los valores atípicos. Equivale al centro de gravedad de los datos.

Media móvil Media calculada sobre una ventana de n valores consecutivos de una serie temporal, que se desplaza a lo largo del tiempo. Suaviza las fluctuaciones y hace visible la tendencia subyacente.

Mediana Valor que divide un conjunto de datos ordenados en dos mitades iguales. Es más robusta que la media frente a valores atípicos.

Mejora continua Filosofía de gestión que plantea que todo proceso puede mejorarse de forma permanente y sistemática en calidad, eficiencia y reducción de variabilidad.

Método científico Proceso sistemático de observación, formulación de hipótesis, experimentación y verificación que fundamenta el conocimiento científico. El análisis de datos industrial aplica los principios del método científico a los problemas de proceso.

Muestra Subconjunto de la población seleccionado para el análisis. Los estadísticos calculados sobre la muestra (media, desviación típica) son estimaciones de los parámetros de la población.

Nivel En diseño de experimentos, cada uno de los valores que toma un factor durante el experimento. Un diseño de dos niveles usa un valor bajo y un valor alto para cada factor.

pandas Librería de Python para la manipulación y análisis de datos tabulares. Proporciona la estructura dataframe y operaciones de agrupación, filtrado y transformación.

OFAT (One Factor At a Time) Enfoque experimental que estudia un factor a la vez manteniendo los demás fijos. No puede detectar interacciones entre factores y es menos eficiente que el diseño factorial.

Outlier (valor atípico) Valor que se aleja notablemente del resto de los datos de un conjunto. Puede deberse a un error de medida, a un evento inusual o a la existencia de una subpoblación distinta en los datos.

Pago por calidad Sistema de retribución de la leche en el que el precio pagado al ganadero depende de la composición química (grasa, proteína) y la calidad higiénico-sanitaria de la leche entregada.

Parámetro Valor numérico que caracteriza una distribución de probabilidad teórica. La distribución normal tiene dos parámetros: la media ( ) y la desviación típica ( ).

Pensamiento estadístico Filosofía de trabajo que reconoce que toda actividad ocurre en un sistema de procesos interconectados, que en todos los procesos existe variabilidad, y que la comprensión y reducción de esa variabilidad es la clave para la mejora continua.

Pérdidas en proceso En quesería, la materia grasa y proteína de la leche que no queda retenida en el queso, sino que se pierde en el suero, en los finos o por roturas durante la elaboración.

Población Conjunto completo de elementos sobre los que se quiere obtener información. En la industria, raramente se puede medir toda la población, por lo que se trabaja con muestras.

Precio unitario de componentes Coste de la materia grasa o la proteína de la leche expresado en €/kg de componente. Se obtiene dividiendo el coste total de la leche entre la cantidad de grasa o proteína que contiene.

Proteína Componente nutritivo de la leche que, junto con la materia grasa, determina el precio de la leche y el rendimiento quesero. Su recuperación en el queso se calcula a partir del extracto seco magro.

Puntuación Z (Z-score) Valor tipificado que indica cuántas desviaciones típicas se aleja un valor de la media de su distribución. Se calcula como Z = (x −) / . Permite comparar valores de distribuciones con diferente escala.

Python Lenguaje de programación de código abierto, de propósito general, ampliamente usado en análisis de datos y ciencia de datos. En este libro se usa con las librerías pandas, matplotlib, seaborn y scipy.

QQ-plot (gráfico cuantil-cuantil) Gráfico que compara los cuantiles de los datos observados con los cuantiles teóricos de una distribución normal. Si los puntos se alinean sobre la diagonal, los datos siguen aproximadamente una distribución normal.

Quarto Herramienta de código abierto para la creación de informes reproducibles que combina texto, código R o Python y gráficos en un único documento. Este libro está escrito en Quarto.

R Lenguaje de programación y entorno estadístico de código abierto, especialmente potente para el análisis estadístico y la visualización de datos. En este libro se usa principalmente con el ecosistema tidyverse y ggplot2.

Rango intercuartil (IQR) Diferencia entre el tercer cuartil (Q3) y el primero (Q1). Mide la dispersión del 50 % central de los datos. Es una medida robusta de dispersión, no afectada por los valores atípicos.

Ratio datos/tinta Principio de visualización de Edward Tufte: la proporción de la tinta de un gráfico que transmite información real sobre los datos respecto a la tinta total. Un buen gráfico maximiza este ratio eliminando todos los elementos decorativos.

seaborn Librería de Python para la visualización estadística de datos, construida sobre matplotlib. Facilita la creación de gráficos estadísticos complejos con menos código.

Recuperación de materia En tecnología quesera, proporción de la materia grasa o proteína de la leche que queda retenida en el queso. Es el indicador fundamental de la eficiencia tecnológica del proceso.

Reglas de Western Electric Conjunto de cuatro reglas para detectar causas especiales en un gráfico de control, basadas en patrones no aleatorios en la secuencia de puntos: puntos fuera de límites, tendencias, ciclos y desplazamientos sostenidos.

Regresión lineal Método estadístico que ajusta una línea recta a la relación entre dos variables, minimizando la suma de los cuadrados de las distancias verticales entre los puntos y la línea. La línea permite hacer predicciones de una variable a partir de la otra.

Remuestreo Técnica de análisis de series temporales que consiste en calcular estadísticos (media, mediana) sobre ventanas de tiempo para suavizar la variabilidad y detectar tendencias.

Rendimiento quesero Indicador de la eficiencia de la transformación quesera que relaciona la cantidad de queso obtenido con la cantidad de leche utilizada. Existen múltiples formas de calcularlo; en este libro se usa el porcentaje de retención de materia prima en el extracto seco magro del queso.

Repetibilidad Capacidad de un instrumento o analista de obtener resultados consistentes al repetir la misma medición en las mismas condiciones. Medida por la desviación típica de las repeticiones.

Réplica En diseño de experimentos, repetición completa de una combinación de tratamiento. Las réplicas permiten estimar la variabilidad experimental y distinguirla del efecto real de los factores.

Reproducibilidad Capacidad de obtener los mismos resultados al replicar un análisis utilizando los mismos datos y la misma metodología. Un análisis reproducible tiene el código visible y documentado, de modo que cualquier persona puede verificarlo y repetirlo.

Reproducibilidad En el análisis del sistema de medición: variación entre analistas al medir la misma muestra. En el sentido más amplio: capacidad de obtener los mismos resultados al replicar un análisis con los mismos datos y metodología.

Respuesta En diseño de experimentos, la variable que se mide para evaluar el efecto de los factores estudiados.

Script Fichero de texto que contiene una secuencia de instrucciones de código que se ejecutan en orden. A diferencia de una hoja de cálculo, el script hace el análisis completamente visible y verificable.

Serie temporal Secuencia de valores de una variable medidos a lo largo del tiempo en intervalos regulares. Su análisis permite detectar tendencias, estacionalidad y cambios en el proceso.

Sesgo Diferencia sistemática entre el valor medido y el valor de referencia verdadero. Un sesgo constante indica un error sistemático del instrumento o del analista. Distinto de la dispersión, que es aleatoria.

Signo de estimación (℮) Símbolo que el fabricante puede imprimir en los envases cuando realiza control estadístico de peso conforme al RD 1801/2008. Certifica que la media del lote es igual o superior al peso nominal y que el porcentaje de envases defectuosos está dentro de los límites legales.

Six Sigma Metodología de mejora que combina el ciclo DMAIC con herramientas estadísticas rigurosas para reducir la variabilidad de los procesos. El nombre hace referencia al objetivo estadístico de tener los límites de especificación a 6 desviaciones típicas de la media.

Sobredosificación En envasado de productos de peso fijo, cantidad de producto entregada por encima del peso nominal para garantizar el cumplimiento legal cuando el proceso tiene variabilidad. A mayor variabilidad, mayor sobredosificación necesaria.

Stemplot (diagrama de tallo y hojas) Representación gráfica que muestra la distribución de un conjunto de datos usando los propios valores numéricos. Permite ver la forma de la distribución conservando los datos originales.

Tendencia En una serie temporal, variación sistemática y progresiva (creciente o decreciente) del nivel de la variable a lo largo del tiempo.

Tipificación Transformación de una variable que resta la media y divide por la desviación típica, obteniendo la puntuación Z. Permite comparar valores de distribuciones con diferente escala y calcular probabilidades usando la distribución normal estándar.

Valor central Estadístico que resume el nivel típico de un conjunto de datos. Los más usados son la media aritmética y la mediana.

Variabilidad a corto plazo Variabilidad que se manifiesta dentro de un turno o entre turnos consecutivos. Sus causas suelen ser visibles y trazables.

Variabilidad a largo plazo Variabilidad que solo se hace visible al analizar datos de semanas o meses. Sus causas son más difíciles de identificar porque su efecto es gradual: deriva de la composición de materias primas, desgaste de equipos, deriva de procedimientos.

Variabilidad natural Variabilidad inherente a un proceso bajo control estadístico, producida por causas comunes. Define el límite de lo que el proceso puede producir sin cambiar el sistema.

Variable Característica de un caso que puede tomar diferentes valores. Las variables pueden ser cuantitativas (numéricas) o cualitativas (categóricas). En una tabla de datos, cada variable ocupa una columna.

Variable cualitativa (categórica) Variable cuyos valores son categorías o etiquetas sin orden numérico intrínseco. Ejemplos: especie de pingüino, turno de producción, tipo de queso.

Variable cuantitativa Variable cuyos valores son números con significado aritmético. Puede ser continua (cualquier valor en un intervalo) o discreta (solo valores enteros o contables).

Varianza Media de los cuadrados de las desviaciones de cada valor respecto a la media. Es la desviación típica elevada al cuadrado. Se usa menos en la práctica porque está expresada en unidades al cuadrado.

Veracidad Grado de concordancia entre el valor medio de un conjunto de mediciones y el valor de referencia verdadero. Es el componente del sesgo en la norma ISO 5725-1. Distinta de la precisión, que describe la dispersión.

Violin plot Gráfico que combina el boxplot con una estimación de la densidad de la distribución, mostrando la forma completa de los datos a ambos lados. Especialmente útil para comparar distribuciones entre grupos.

X-barra (gráfico) Gráfico de control que representa la media de subgrupos de datos a lo largo del tiempo. Detecta cambios en el nivel medio del proceso. —

Este glosario recoge los términos marcados como conceptos clave en los callouts de objetivos de aprendizaje de cada capítulo. Para una definición más detallada y ejemplos de aplicación, consultar el capítulo correspondiente.

B. Configuración del entorno de trabajo

Este apéndice describe cómo preparar el entorno de trabajo para ejecutar el código Python y R que aparece a lo largo del libro. Se presentan dos escenarios: uno sin instalación, recomendado para centros con restricciones de administrador, y otro con instalación local, para quien disponga de libertad para instalar software en su equipo.

B.1. Escenario 1: Sin instalación (recomendado)

Esta es la opción más sencilla y funciona en cualquier ordenador con conexión a internet, incluso sin permisos de administrador. Solo se necesita una cuenta de Google.

B.1.1. Python: Google Colaboratory

Google Colaboratory (Colab) es un entorno de cuadernos Jupyter alojado en la nube de Google. Permite escribir y ejecutar código Python directamente en el navegador, sin instalar nada.

Para empezar:

1. Accede a colab.research.google.com con tu cuenta de Google.
2. Crea un cuaderno nuevo con `Archivo > Nuevo cuaderno`.
3. Los cuadernos se guardan automáticamente en tu Google Drive.

Todos los cuadernos de práctica de este libro tienen un enlace directo para abrirlos en Colab. Al abrirlos por primera vez, guarda una copia en tu Drive con `Archivo > Guardar una copia en Drive` para poder modificarlos y conservar tu trabajo.

> **Librerías en Colab**
>
> Colab incluye preinstaladas las librerías más habituales (`pandas`, `matplotlib`, `seaborn`, `numpy`). Si algún cuaderno requiere una librería adicional, lo indicará con una celda de instalación al principio del tipo `!pip install nombre_libreria`.

B.1.2. R: Posit Cloud

Posit Cloud es el equivalente de Colab para R. Ofrece un entorno RStudio completo en el navegador, sin instalación.

Para empezar:

1. Crea una cuenta gratuita en posit.cloud.
2. Crea un nuevo proyecto con `New Project > New RStudio Project`.

3. El plan gratuito incluye 25 horas de cómputo al mes, suficiente para seguir el libro.

Para instalar las librerías necesarias, ejecuta en la consola de R:

```
install.packages(c("tidyverse", "palmerpenguins",
                   "ggbeeswarm", "patchwork", "lubridate"))
```

B.2. Escenario 2: Instalación en local

Si tienes permisos para instalar software en tu equipo, esta opción ofrece más velocidad y comodidad para un uso continuo.

B.2.1. Python: Miniconda

Miniconda es una distribución mínima de Python que incluye el gestor de paquetes `conda`. A diferencia de la instalación estándar de Python, Miniconda puede instalarse **sin permisos de administrador** seleccionando la opción "Install just for me" durante el proceso de instalación en Windows.

Pasos:

1. Descarga el instalador desde docs.conda.io/en/latest/miniconda.html. Selecciona la versión para Windows de 64 bits.
2. Ejecuta el instalador y selecciona **"Just Me"** cuando pregunte para quién se instala.
3. Una vez instalado, abre el terminal **Anaconda Prompt** (aparecerá en el menú de inicio) e instala las librerías necesarias:

```
pip install pandas matplotlib seaborn palmerpenguins
```

B.2.2. R: instalación base

La instalación de R en Windows **requiere permisos de administrador** en la mayoría de configuraciones de centro. Si no dispones de ellos, utiliza Posit Cloud (Escenario 1).

Si puedes instalar:

1. Descarga R desde cran.r-project.org y ejecuta el instalador.
2. Descarga **Positron** desde positron.posit.co como IDE. Es el entorno recomendado para este libro por su soporte simultáneo de Python y R. Alternativamente, puedes usar **RStudio** desde posit.co/download/rstudio-desktop.
3. Abre Positron o RStudio e instala las librerías necesarias desde la consola de R:

```
install.packages(c("tidyverse", "palmerpenguins",
                   "ggbeeswarm", "patchwork", "lubridate"))
```

B.3. Recursos para aprender Python y R

Si necesitas una base más sólida antes de abordar el código del libro, estos recursos gratuitos están entre los mejor valorados:

Python

- Python for Everybody — Curso introductorio completo del Dr. Chuck Severance. Sin conocimientos previos. Disponible en español.
- Kaggle Learn — Python — Lecciones breves e interactivas directamente en el navegador. Enfocado en análisis de datos.
- Kaggle Learn — Pandas — Introducción práctica a pandas, la librería central del libro.

R

- R for Data Science (2ª ed.) — El manual de referencia para análisis de datos con tidyverse. Gratuito en línea.
- Posit Primers — Ejercicios interactivos de R en el navegador, sin instalación. Cubre desde los fundamentos hasta visualización y transformación de datos.
- Maxima Formación ha agrupado varios buenos enlaces de sitios para aprendizaje de R y *data science* con R. Esta web está dirigida por Rosana Ferrero, que publica regularmente en LinkedIn contenido formativo en ciencia de datos y es una de las *top voices* en esta plataforma.

B.4. Cómo usar la inteligencia artificial para entender el código

A lo largo del libro encontrarás bloques de código Python y R que pueden resultar densos a primera vista. No es necesario entender cada línea antes de ejecutarlos: el objetivo es comprender qué hace el código y cómo interpretar su resultado.

Una forma eficaz de avanzar es copiar cualquier bloque de código en un asistente de IA como Gemini, ChatGPT o Claude y preguntar directamente:

> *"Explícame este código línea a línea, en un lenguaje sencillo, como si no supiera programar"*

o bien:

> *"¿Qué hace este código? ¿Qué representa el gráfico que genera?"*

o también, para un detalle mayor,

> *"Actúa como un tutor de programación. Explica este código instrucción a instrucción de forma detallada y sencilla, indicando qué hace cada línea y por qué es necesaria. Usa analogías con Excel o tareas manuales para que sea más fácil de entender"*

Este enfoque es especialmente útil con las partes de formato y presentación gráfica (títulos, ejes, colores), que son secundarias para el análisis pero pueden distraer cuando se está aprendiendo.

C. La media aritmética como centro de gravedad de un grupo de datos

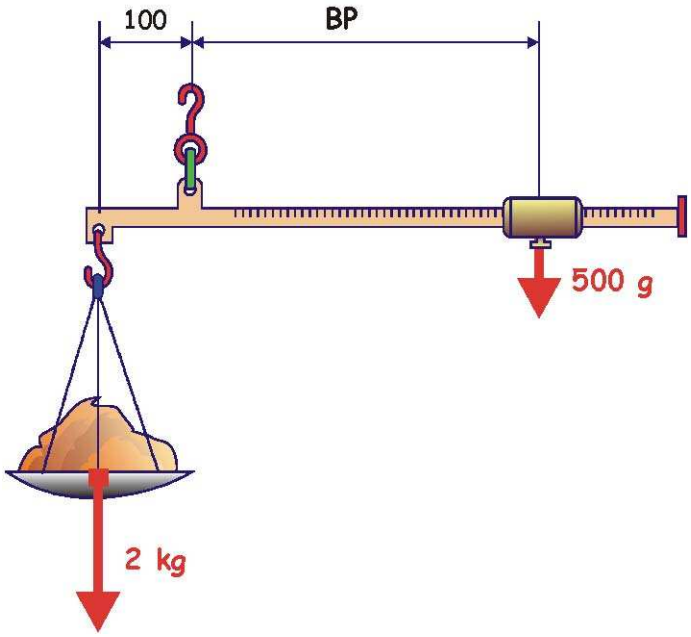


Figura C.1.: Roldana tradicional romana

Para ver cómo la media aritmética equivale al punto de equilibrio o centro de gravedad de un grupo de datos, imaginaremos que tenemos un conjunto de datos cuyos valores se distribuyen en un eje longitudinal X. Podemos hacer equivalentes estos valores a un conjunto de pesos que se distribuyen a lo largo de una barra, y vamos a suponer que existe un punto a una distancia d_i del origen de la barra en el cual dicha barra está en equilibrio. Para encontrar ese valor, empezaremos considerando el principio o ley de la palanca.

El **Principio de la Palanca** o la **Ley de la Palanca** fue formulada por el científico y matemático griego Arquímedes. Este principio dice que, en equilibrio, el producto de la fuerza aplicada (potencia) por su distancia al punto de apoyo (brazo de la potencia) es igual al producto de la resistencia por su distancia al punto de apoyo (brazo de la resistencia). Matemáticamente, se expresa como:

$$P \cdot d_p = R \cdot d_r$$

Donde:

- P es la potencia o fuerza aplicada.
- d_p es la distancia desde el punto de apoyo hasta el punto donde se aplica la potencia (BP: brazo de la potencia).

- R es la resistencia o carga.
- d_r es la distancia desde el punto de apoyo hasta el punto donde se aplica la resistencia (BR: brazo de la resistencia).

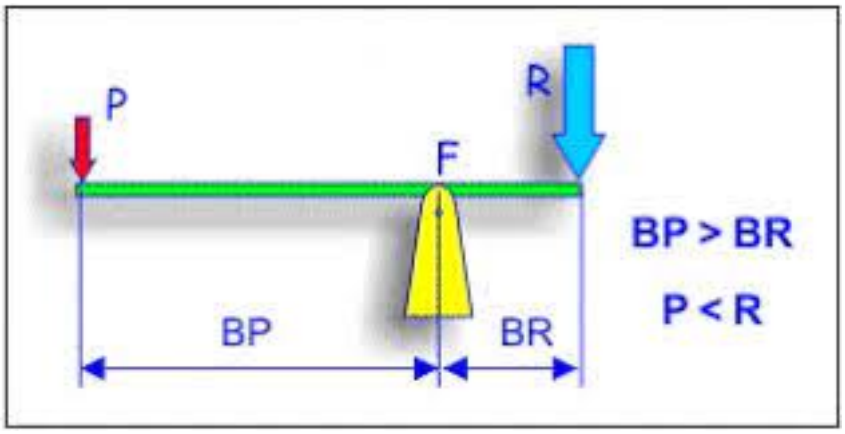


Figura C.2.: Palanca de primer grado con el fulcro como punto de equilibrio

C.1. Ejemplo

Si tienes una palanca con una longitud de 5 metros y aplicas una fuerza de 10 Newtons a 1 metro del punto de apoyo, para mantener el equilibrio, la fuerza de resistencia en el otro extremo a 4 metros del punto de apoyo debería ser:

$$P \cdot d_p = R \cdot d_r$$

$$10\,\mathrm{N} \cdot 1\,\mathrm{m} = R \cdot 4\,\mathrm{m}$$

$$R = \frac{10 \cdot 1}{4} = 2,5\mathrm{N}$$

Ahora vamos a considerar el punto de equilibrio de una barra de la que se cuelgan diferentes pesos a diferente distancias de su origen. Calcular el punto de equilibrio de una barra de la que se cuelgan diferentes pesos a diferentes distancias de su origen es un problema clásico de física que se puede resolver usando el principio de momentos.

C.2. Paso a paso

1. **Identificar las fuerzas**: Supongamos que tienes varios pesos $W_1, W_2, W_3, \ldots, W_n$ colgados a distancias $d_1, d_2, d_3, \ldots, d_n$ del origen (punto de apoyo).
2. **Calcular los momentos**: El momento (M) de un peso alrededor del punto de apoyo se calcula como el producto de la fuerza (peso) y la distancia al punto de apoyo:

$$M_i = W_i \times d_i$$

3. **Sumar los momentos**: Calcula la suma de todos los momentos:

$$M_{\text{total}} = W_1 \times d_1 + W_2 \times d_2 + W_3 \times d_3 + ... + W_n \times d_n$$

4. **Calcular el peso total**: Suma todos los pesos:

$$W_{\text{total}} = W_1 + W_2 + W_3 + ... + W_n$$

5. **Determinar el punto de equilibrio (x)**: El punto de equilibrio se encuentra dividiendo la suma de los momentos por el peso total:

$$x = \frac{\sum(W_i \times d_i)}{\sum W_i}$$

C.3. Ejemplo práctico

Supongamos que tenemos tres pesos de 4, 9 y 1 kg, situados, respectivamente, a 2, 1 y 3 m respectivamente del origen de la barra.

- $W_1 = 4\,\text{kg}$ a $d_1 = 2\,\text{m}$
- $W_2 = 9\,\text{kg}$ a $d_2 = 1\,\text{m}$
- $W_3 = 1\,\text{kg}$ a $d_3 = 3\,\text{m}$

1. **Calcular los momentos**:

$$M_1 = 4 \times 2 = 8\,\text{kg} \cdot \text{m}$$
$$M_2 = 9 \times 1 = 9\,\text{kg} \cdot \text{m}$$
$$M_3 = 1 \times 3 = 3\,\text{kg} \cdot \text{m}$$

2. **Sumar los momentos**:

$$M_{\text{total}} = 8 + 9 + 3 = 20\,\text{kg} \cdot \text{m}$$

3. **Calcular el peso total**:

$$W_{\text{total}} = 4 + 9 + 1 = 14\,\text{kg}$$

4. **Determinar el punto de equilibrio**:

$$x = \frac{20}{14} \approx 1{,}43\,\text{m}$$

El punto de equilibrio se encuentra a aproximadamente 1,43 metros del origen.

C.4. Media ponderada

En muchas situaciones, el centro de gravedad de un sistema de masas puede interpretarse como una **media ponderada** de las posiciones de las masas.

C.4.1. Media aritmética

Para un conjunto de números $x_1, x_2, \ldots, x_n$, la media aritmética es:

$$\text{Media} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

C.4.2. Media ponderada

Para un conjunto de valores $x_1, x_2, \ldots, x_n$ con pesos asociados $w_1, w_2, \ldots, w_n$, la media ponderada es:

$$\text{Media ponderada} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_n x_n}{w_1 + w_2 + \cdots + w_n}$$

C.5. Centro de gravedad como media ponderada

Cuando calculamos el centro de gravedad (x_{cg}) de un sistema de masas, estamos esencialmente calculando una media ponderada de las posiciones (x_i) de esas masas (m_i):

$$x_{\text{cg}} = \frac{\sum(m_i \cdot x_i)}{\sum m_i}$$

Aquí, las posiciones x_i son ponderadas por las masas m_i.

C.5.1. Ejemplo numérico

En nuestro ejemplo anterior,

- Masa 1: $m_1 = 4\,\text{kg}$ en posición $x_1 = 2\,\text{m}$
- Masa 2: $m_2 = 9\,\text{kg}$ en posición $x_2 = 1\,\text{m}$
- Masa 3: $m_3 = 1\,\text{kg}$ en posición $x_3 = 3\,\text{m}$

La media aritmética de las posiciones sería:

$$\text{Media} = \frac{2 + 1 + 3}{3} = 2\,\text{m}$$

El punto de equilibrio de la barra, o centro de gravedad, calculado como media ponderada, sería:

$$x_{\text{cg}} = \frac{(4 \cdot 2) + (9 \cdot 1) + (1 \cdot 3)}{4 + 9 + 1} = \frac{8 + 9 + 3}{14} = \frac{20}{14} \approx 1{,}43\,\text{m}$$

que es el mismo resultado que obteníamos formulando el cálculo de los momentos; la fórmula resulta ser idéntica. Nótese que la media aritmética de las posiciones ($\frac{2+1+3}{3} = 2\,\text{m}$) difiere del centro de gravedad ($1{,}43\,\text{m}$) precisamente porque las masas no son iguales: el peso de 9 kg situado a solo 1 m del origen arrastra el punto de equilibrio hacia ese extremo.

C.6. Media aritmética y centro de gravedad con masas idénticas

En los ejemplos anteriores, calculábamos el punto de equilibrio para diferentes pesos colocados a lo largo de una barra. Si en vez de eso suponemos que la distancia al origen de la barra equivale a nuestro eje X, que recoge los valores de los que queremos calcular nuestra media aritmética, podemos eliminar el efecto de la masa suponiendo que todas las masas son iguales.

Si las masas de los diferentes objetos son idénticas, podemos decir que la media aritmética de las posiciones coincide con el centro de gravedad. Esto se debe a que, en este caso, cada masa tiene el mismo peso o influencia en el cálculo del centro de gravedad. Esta es la explicación detallada:

Suposición: Cada objeto tiene la misma masa m.

C.6.1. Media aritmética

Para un conjunto de posiciones $x_1, x_2, \dots, x_n$, la media aritmética es:

$$\text{Media} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

C.6.2. Centro de gravedad

El centro de gravedad (x_{cg}) para un conjunto de masas idénticas en posiciones $x_1, x_2, \dots, x_n$ es:

$$x_{\text{cg}} = \frac{\sum(m \cdot x_i)}{\sum m}$$

Dado que las masas m son idénticas, el numerador se convierte en:

$$\sum(m \cdot x_i) = m \cdot (x_1 + x_2 + \cdots + x_n)$$

Y el denominador se convierte en:

$$\sum m = n \cdot m$$

Al sustituir estos en la fórmula del centro de gravedad, obtenemos:

$$x_{\text{cg}} = \frac{m \cdot (x_1 + x_2 + \cdots + x_n)}{n \cdot m}$$

Al simplificar, los términos m se cancelan, y nos queda:

$$x_{\text{cg}} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

que es exactamente la fórmula de la media aritmética.

Si repetimos nuestro ejemplo anterior, suponiendo en este caso masas idénticas

- Masa 1: $m_1 = 1\,\text{kg}$ en posición $x_1 = 2\,\text{m}$
- Masa 2: $m_2 = 1\,\text{kg}$ en posición $x_2 = 1\,\text{m}$
- Masa 3: $m_3 = 1\,\text{kg}$ en posición $x_3 = 3\,\text{m}$

La media aritmética de las posiciones sería:

$$\text{Media} = \frac{2+1+3}{3} = 2\,\text{m}$$

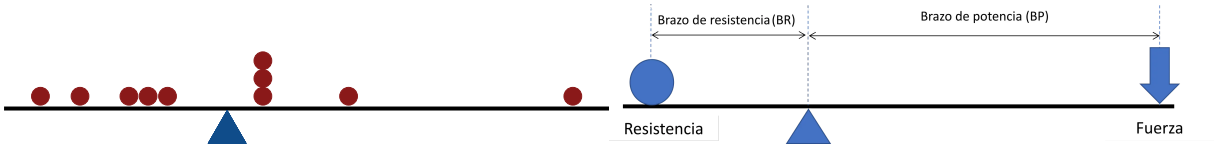
El punto de equilibrio de la barra, o centro de gravedad, calculado como media ponderada, sería:

$$x_{\text{cg}} = \frac{(1\cdot 2)+(1\cdot 1)+(1\cdot 3)}{1+1+1} = \frac{2+1+3}{3} = \frac{6}{3} = 2\,\text{m}$$

que es el mismo resultado que obteníamos con la fórmula de la media aritmética de las distancias.

C.7. Conclusión

Cuando las masas son idénticas, la media aritmética de las posiciones coincide con el centro de gravedad. Esto nos permite afirmar que en el caso de una dimensión (por ejemplo, el peso) la media aritmética de un conjunto de valores coincide con el centro de gravedad o punto de equilibrio de ese conjunto de valores. Este es un resultado interesante que muestra la conexión entre conceptos estadísticos y físicos.



(a) La media como punto de equilibrio (b) Palanca de primer grado

Figura C.3.: Comparación gráfica del significado de la media en un diagrama de puntos (*dotplot*) con una palanca de primer grado, con el fulcro como punto de equilibrio.

C.8. Importancia del concepto de la media como centro de gravedad, y su comparación con la mediana.

Entender la media como punto de equilibrio tiene una consecuencia práctica directa: permite visualizar de forma intuitiva el efecto de los valores extremos u *outliers*.

Cuando un conjunto de datos contiene un valor muy alejado del resto, ese valor actúa como un peso situado lejos del fulcro. Por la ley de la palanca, su momento —el producto de su magnitud por su distancia al centro— es desproporcionadamente grande respecto a los valores moderados. El punto de equilibrio, es decir, la media, se desplaza hacia ese extremo mucho más de lo que cabría esperar por un único dato.

Este desplazamiento tiene dos efectos simultáneos: la media deja de representar bien al grupo mayoritario de valores, y la varianza —que mide la suma de las distancias al cuadrado— se incrementa de forma acusada porque el valor extremo contribuye con una distancia muy grande elevada al cuadrado.

La mediana, en cambio, no se ve afectada de la misma manera: al ser el valor central por orden de magnitud, un único dato extremo no puede desplazarla más allá de una posición. Por eso, ante distribuciones con valores atípicos, la mediana y el rango intercuartil son estadísticos más robustos y más fiables para describir el conjunto de datos.

Referencias

[1] R. Panko, «What We Know About Spreadsheet Errors», *Journal of End User Computing*, vol. 10, feb. 2005, doi: 10.4018/joeuc.1998040102.

[2] S. G. Powell, K. R. Baker, y B. Lawson, «Impact of errors in operational spreadsheets», *Decision Support Systems*, vol. 47, n.º 2, pp. 126-132, 2009, doi: https://doi.org/10.1016/j.dss.2009.02.002.

[3] P. Posit Software, *RStudio*. (2024). Disponible en: https://posit.co

[4] P. Posit Software, *Positron*. (2024). Disponible en: https://posit.co/positron

[5] Quarto Development Team, *Quarto*. Posit Software, PBC, 2024. Disponible en: https://quarto.org

[6] Anthropic, *Claude Sonnet 4.6*. (2025). Anthropic. Disponible en: https://www.anthropic.com

[7] K. Ryssdal, «The Excel mistake heard round the world». Accedido: 17 de abril de 2013. [En línea]. Disponible en: https://www.marketplace.org/2013/04/17/economy/excel-mistake-heard-round-world/

[8] P. Krugman, «La depresión del Excel». Accedido: 19 de abril de 2013. [En línea]. Disponible en: https://elpais.com/economia/2013/04/19/actualidad/1366398440_370422.html

[9] L. Garicano, «El error de Reinhart y Rogoff». Accedido: 14 de abril de 2013. [En línea]. Disponible en: https://nadaesgratis.es/garicano/el-error-de-reinhardt-y-rogoff

[10] R. Ferrero, «Los errores de Reinhart & Rogoff: R y la reproducibilidad». Accedido: 1 de febrero de 2018. [En línea]. Disponible en: https://www.maximaformacion.es/blog-dat/los-errores-de-reinhart-rogo/

[11] G. G. Hadley Wickham Mine Çetinkaya-Rundel, *R for Data Science, 2nd ed.* 1005 Gravenstein Highway North, Sebastopol, CA95472: O'Reilly Media Inc., 2023. Disponible en: https://r4ds.hadley.nz/

[12] G. G. Hadley Wickham, «R Para Ciencia de Datos». [En línea]. Disponible en: https://es.r4ds.hadley.nz/

[13] K. B. Gorman, T. D. Williams, y W. R. Fraser, «Ecological Sexual Dimorphism and Environmental Variability within a Community of Antarctic Penguins (Genus *Pygoscelis*)», *PLOS ONE*, vol. 9, n.º 3, p. e90081, 2014, doi: 10.1371/journal.pone.0090081.

[14] M. Almena-Aliste y B. Mietton, «Cheese Classification, Characterization, and Categorization: A Global Perspective», *Microbiology Spectrum*, vol. 2, n.º 1, pp. 10.1128/microbiolspec.cm-0003-2012, 2014, doi: 10.1128/microbiolspec.cm-0003-2012.

Bibliografía recomendada

Alexander, Rohan. 2023. “Telling Stories with Data.” 2023. https://tellingstorieswithdata.com/.

Allaire, JJ, Yihui Xie, Jonathan McPherson, Javier Luraschi, Kevin Ushey, Aron Atkins, Hadley Wickham, Joe Cheng, Winston Chang, and Richard Iannone. 2022. *Rmarkdown: Dynamic Documents for r*. https://CRAN.R-project.org/package=rmarkdown.

Almena-Aliste, Montserrat, and Bernard Mietton. 2014. “Cheese Classification, Characterization, and Categorization: A Global Perspective.” *Microbiology Spectrum* 2 (1): 10.1128/microbiolspec.cm-0003-2012. https://doi.org/10.1128/microbiolspec.cm-0003-2012.

Broman, Karl W., and Kara H. Woo. 2018. “Data Organization in Spreadsheets.” *The American Statistician* 72 (1): 2–10. https://doi.org/10.1080/00031305.2017.1375989.

Buck, Stuart. 2015. “Solving Reproducibility.” *Science* 348 (6242): 1403. https://www.science.org/doi/full/10.1126/science.aac8041.

Douglas C Montgomery, Norma Faris Hubele, George C Runger. 2011. *Engineering Statistics*. 111 River Street, Hoboken, NJ 07030-5774: John Wiley & Sons, Inc.

Dwyer, Christopher P. 2017. *Critical Thinking*. Cambridge University Press. https://doi.org/10.1017/9781316537411.016.

Emilio L Cano, Andrés Redchuk, Javier M Moguerza. 2012. *Six Sigma with r: Statistical Engineering for Process Improvement*. Springer.

Ethan P. White, Zachary T. Brym, Elita Baldridge, and Sarah R. Supp. 2013. “Nine Simple Ways to Make It Easier to (Re)use Your Data.” *Ideas in Ecology and Evolution* 6 (2): 1–10. https://doi.org/10.4033/iee.2013.6b.6.f.

Fernández, Javier A. 2021. “Cómo Aplicar El Pensamiento Crítico En Tu Trabajo.” 2021. https://elpais.com/economia/estar-donde-estes/2021-03-24/como-aplicar-el-pensamiento-critico-en-tu-trabajo.html.

Ferrero, Rosana. 2018. “Los Errores de Reinhart & Rogoff: R y La Reproducibilidad.” 2018. https://www.maximaformacion.es/blog-dat/los-errores-de-reinhart-rogo/.

Few, Stephen. 2012. *Show Me the Numbers: Designing Tables and Graphs to Enlighten*. Burlingame, CA 94011: Analytic Press.

Garicano, Luis. 2013. “El Error de Reinhart y Rogoff.” 2013. https://nadaesgratis.es/garicano/el-error-de-reinhardt-y-rogoff.

Hadley Wickham, Garret Grolemund. 2023. “R Para Ciencia de Datos.” 2023. https://es.r4ds.hadley.nz/.

Hadley Wickham, Garret Grolemund, Mine Çetinkaya-Rundel. 2023. *R for Data Science, 2nd Ed.* 1005 Gravenstein Highway North, Sebastopol, CA95472: O’Reilly Media Inc. https://r4ds.hadley.nz/.

Harrell, Frank E. 2022a. “Biostatistics for Biomedical Research.” 2022. https://hbiostat.org/bbr/.

———. 2022c. “R Workflow.” 2022. https://hbiostat.org/rflow/.

———. 2022b. “R Workflow.” 2022. https://www.fharrell.com/post/rflow/.

———. 2024. “Reproducible Research.” 2024. https://hbiostat.org/rr/.

Hoerl, Roger, and Ron Snee. 2012. *Statistical Thinking: Improving Business Performance*. JOhn Wiley; Sons.

Holtz, Yan. n.d. “The r Graph Gallery.” http://r-graph-gallery.com/index.html.

Kluyver, Thomas, Benjamin Ragan-Kelley, Fernando Pérez, Brian Granger, Matthias Bussonnier, Jonathan Frederic, Kyle Kelley, et al. 2016. “Jupyter Notebooks - a Publishing Format for Reproducible Computational Workflows.” In *Positioning and Power in Academic Publishing: Players, Agents and Agendas*, 87–90. IOS Press.

Krugman, Paul. 2013. “La Depresión Del Excel.” 2013. https://elpais.com/economia/2013/04/19/actualidad/1366398440_370422.html.

Mary G Leitnaker, Cheryl Hild, Richard D Sanders. 1996. *The Power of Statistical Thinking: IMproving Industrial Processes*. Addison-Wesley Publishing Company Inc.

Project Jupyter. 2026. “Jupyter Project Website.” https://jupyter.org/.

Python Software Foundation. 2026. “Python Programming Language.” https://www.python.org/.

R Core Team. 2023. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. https://www.R-project.org/.

Ryssdal, Karl. 2013. “The Excel Mistake Heard Round the World.” 2013. https://www.marketplace.org/2013/04/17/economy/excel-mistake-heard-round-world/.

Sadler, Jesse. 2017. “Excel Vs r: A Brief Introduction to r.” 2017. https://www.jessesadler.com/post/excel-vs-r/.

Sweigart, Al. 2021a. “The Big Book of Small Python Projects.” 2021. https://inventwithpython.com/bigbookpython/.

———. 2021b. *The Big Book of Small Python Projects*. No Starch Press, Inc. https://inventwithpython.com/bigbookpython/.

Tufte, Edward R. 1986. *The Visual Display of Quantitative Information*. Cheshire, Connecticut 06410: Graphic Press.

———. 1990. *Envisioning Information*. Cheshire, Connecticut 06410: Graphic Press.

Wheeler, Donald J. 2000. *Understanding Variation: The Key to Managing Chaos*. Knoxville, Tennessee 37919: SPC Press.

Wickham, Hadley. 2014. “Tidy Data.” *Journal Od Statistical Software* 59 (10): 1–23. https://doi.org/10.18637/jss.v059.i10.

World Economic Forum. 2025. “Future of Jobs Report, 2025.” 91-93 route de la Capite,CH-1223 Cologny/Geneva, Switzerland: World Economic Forum. https://www.weforum.org/publications/the-future-of-jobs-report-2025/.

Xie, Yihui, J. J. Allaire, and Garrett Grolemund. 2018. *R Markdown: The Definitive Guide*. Boca Raton, Florida: Chapman; Hall/CRC. https://bookdown.org/yihui/rmarkdown.

Xie, Yihui, Christophe Dervieux, and Emily Riederer. 2020. *R Markdown Cookbook*. Boca Raton, Florida: Chapman; Hall/CRC. https://bookdown.org/yihui/rmarkdown-cookbook.